

Family Macroeconomics

Kazuharu Yanagimoto
Kobe University
yanagimoto@econ.kobe-u.ac.jp

2026-10-01

目次

はじめに	vi
講義の概要	vi
成績評価と課題	vi
GitHub による提出	vi
第 I 部 数値計算	
1 非線形最適化	3
1.1 求根法	3
1.1.1 一変数の非線形方程式	3
1.1.2 多変数の非線形方程式	13
1.2 一変数の非線形最適化	14
1.2.1 準ニュートン法	15
1.2.2 黄金分割法	16
1.3 多変数の非線形最適化	17
1.3.1 単純なケース	17
1.3.2 複雑なケース	18
1.4 制約付き非線形最適化	20
1.5 Mathematical Programming	21
2 関数近似	25
2.1 補間	25
2.1.1 グリッドサーチ	25
2.1.2 区分線形補間と 3 次スプライン補間	26
2.2 数値微分	27
2.2.1 有限差分	27
2.2.2 複素ステップ微分	28
2.2.3 自動微分	29
2.3 数値積分	29
2.3.1 台形則 (Trapezoidal Rule)	30
2.3.2 モンテカルロ法	31
2.3.3 ガウス求積 (Gaussian Quadrature)	32
2.4 AR(1) 過程の離散化	34
2.4.1 Tauchen 法	34
2.4.2 Rouwenhorst 法	35
3 動的計画法	39
3.1 ベルマン方程式の数値解法	39
3.1.1 Value Function Iteration	40

3.1.2	Policy Function Iteration	42
3.1.3	Endogenous Grid Method	47
3.2	確率的なモデル	48
3.2.1	Value Function Iteration	49
3.2.2	Policy Function Iteration	50
3.2.3	Endogenous Grid Method	51
3.3	Aiyagari モデル	52
3.3.1	モデル	52
3.3.2	家計の動的計画問題	53
3.3.3	企業と価格	54
3.3.4	定常均衡	54
3.3.5	数値解法	55
3.3.6	結果	57
4	GMM	61
4.1	一階条件による GMM	61
4.1.1	推定量の性質	61
4.1.2	モデル	63
4.1.3	推定	66
4.1.4	識別	68
4.2	最小距離推定と SMM	73
4.2.1	モデル	74
4.2.2	推定	78
4.2.3	標準誤差	78
4.2.4	識別	81
第 II 部 結婚の経済学		
	結婚の経済学的な意義	86
	規模の経済	86
	公共財の供給	86
	リスクシェアリング	86
	愛	86
	結婚モデルの 2 つの流派	87
5	Search & Matching	89
5.1	McCall モデル	89
5.2	Greenwood と Guner (2009 年)	91
5.2.1	モデル	92
5.2.2	定性的な含意	94
5.2.3	推定	94
5.2.4	結果	96
5.3	Greenwood ほか (2016 年)	97
5.3.1	事実: 同類婚と格差	97

5.3.2	モデル	100
5.3.3	推定	102
5.3.4	反実仮想	105
5.3.5	まとめ	105
5.4	Goussé ほか (2017 年)	106
5.4.1	Motivation	106
5.4.2	モデル	107
5.4.3	推定	112
5.4.4	結果	115
6	Marriage and Fertility	125
6.1	Doepke ほか (2023 年)	125
6.1.1	Old Facts	125
6.1.2	Quantity-Quality Tradeoff	127
6.1.3	女性の機会費用	129
6.1.4	関係の逆転 と原因	130
6.2	Greenwood ほか (2023 年)	134
6.2.1	6 つの Kuznets facts	135
6.2.2	Model	139
6.2.3	Calibration	141
6.2.4	Great Transition	144
A	証明	149
A.1	黄金分割法における黄金比	149
A.2	3 次スプライン補間の最小曲率性	150
A.3	縮小写像と動的計画法	151
A.3.1	縮小写像	151
A.3.2	ベルマン方程式への適用	153
A.4	留保賃金方程式のオプション価値項	154
A.5	平均保存的な広がり と凸順序	156
A.6	標本統計量の影響関数	156
A.7	Goussé, Jacquemet, Robin (2017) の式の導出	158
A.7.1	コミットメントのない結婚の価値	158
A.7.2	余剰の方程式	158
A.7.3	家事時間の効率性条件	159
A.7.4	独身の価値	160
A.7.5	Sharing rule	160
A.7.6	推定の手順	161
A.8	出生モデルの証明	167
A.8.1	閉形式解と賃金の効果	167
A.8.2	女性の賃金と出生	167
B	連続時間モデル	169

B.1 確率過程	169
B.1.1 ブラウン運動	169
B.1.2 伊藤積分	170
B.1.3 Orstein-Uhlenbeck 過程	171
B.2 最大値原理	173
B.2.1 HJB 方程式 (Deterministic)	173
B.2.2 伊藤の補題	174
B.2.3 HJB 方程式 (Stochastic)	174
B.3 連続時間の Aiyagari モデル	175
B.3.1 設定	175
B.4 有限差分法	178
B.4.1 Upwind スキーム	178
B.4.2 生産性方向の離散化	179
B.4.3 遷移行列 A	179
B.4.4 陰的スキーム	180
B.4.5 KF 方程式はタダで解ける	180
B.4.6 均衡	181
B.5 Julia 実装	181
B.5.1 政策関数	182
B.5.2 定常分布	183
B.5.3 離散時間モデルとの比較	183
B.6 まとめと拡張	185
References	187

はじめに

本書は、神戸大学大学院の講義 Family Macroeconomics の講義ノートです。結婚、離婚、出生、家計内の資源配分といった家族の意思決定を、マクロ経済学の定量的な手法（動的計画法、構造推定、均衡モデル）で分析します。

講義の概要

この講義は次の2つの部分から構成されます。

数値計算では、家族のマクロモデルを解き、推定するための道具を Julia で実装しながら学びます。求根法と非線形最適化、関数近似（補間・数値微分・数値積分・離散化）という基礎の上に、動的計画法を3段階（決定論的 → 確率的 → 異質エージェント）で積み上げ、最後に構造推定のための GMM（識別、標準誤差、最小距離推定）を扱います。

結婚と出生が本書の本体です。サーチモデル（Greenwood と Guner 2009 年; Greenwood ほか 2016 年）、摩擦のない結婚市場（Galichon ほか 2019 年; Ciscato 2025 年; Reynoso 2024 年）、そして出生の古典理論とその変化（Doepke ほか 2023 年）、140 年の構造変化の定量分析（Greenwood ほか 2023 年）を読みます。各章の冒頭では、その章の論文を読むために必要な理論（最適停止と留保値、確率効用モデルとロジット）を証明付きで準備します。

数値計算はすべて Julia で書かれており、リポジトリの `Project.toml` から実行環境を再現できます。前提知識としては、大学院初年級のミクロ経済学・マクロ経済学と、基礎的な確率論を想定しています。

成績評価と課題

この講義は、60% の課題と 40% の期末レポートで評価されます。課題の提出は全て、[Quarto](#) と Julia を用いたレポートとします。Julia と Quarto の使い方は TA セッションにて解説予定です。

内容は、講義で扱った内容の手計算の部分と数値計算の部分の両方を含みます。

GitHub による提出

課題は GitHub を通じて提出します。TA セッションで解説がありますが、次の手順に従ってください。

0. 教員（柳本）と学生（個人）専用のプライベートリポジトリを作成する。講義を通じて一つのレポジトリを使う
1. 課題の提出期限までに、レポジトリに解答の `qmd` ファイルを `push` する
2. GitHub Actions が起動し、自動的に解答の `qmd` ファイルのコードを実行して PDF を生成する
3. 成績評価は PDF の内容をもとに行われる

第 I 部
数值計算

第 1 章

非線形最適化

Nonlinear Optimization

```
using Roots
using NonlinearSolve
using Optim
using Optimization
import OptimizationNLopt
import NLopt
using JuMP
using Ipopt
using Plots
using LaTeXStrings
```

経済モデルを数値的に解く作業は、多くの場合「非線形方程式 $f(\mathbf{x}) = \mathbf{0}$ を解く」か「非線形関数を最大化・最小化する」のどちらかに帰着します。両者は表裏一体です。最大化問題は一階条件を導出すれば方程式として解けますし、最適化アルゴリズムの多くは方程式の解法の analogy として理解できます。本章では、前半で非線形方程式の解法である**求根法** (root finding) を、後半で目的関数を直接扱う**非線形最適化** (nonlinear optimization) を解説します。

1.1 求根法

モデルを解く際に、 $f(\mathbf{x}) = \mathbf{0}$ となるような $\mathbf{x}$ を求める必要があることが多いです。例えば、家計の最大化問題を解く際の一階条件は、一般に非線形方程式の形をとります。ごく特殊なケースを除いて、解析的に解くことができないため、数値的に解を求める必要があります。このような非線形方程式の数値解法は、一変数の場合と多変数の場合に分けられます。以下では、それぞれの方法について解説します。

1.1.1 一変数の非線形方程式

ここでは例として、次のような CRRA 効用関数を用いた家計の最大化問題を考えてみましょう。

$$\max_{c,l} \frac{c^{1-\gamma_c}}{1-\gamma_c} + \alpha_l \frac{l^{1-\gamma_l}}{1-\gamma_l} \quad \text{s.t.} \quad c = w(1-l) \quad (1.1)$$

この問題は以下の一階条件の解を求めることで解くことができます。

$$w^{1-\gamma_c}(1-l)^{-\gamma_c} - \alpha_l l^{-\gamma_l} = 0.$$

```
foc(l; w=1.0, γ_c=1.5, α_l=1.2, γ_l=1.5) =  
    w^(1 - γ_c) * (1 - l)^(-γ_c) - α_l * l^(-γ_l)
```

これを図で表すと 図 1.1 のようになります. 求めたいのは, この関数と $y = 0$ の交点の値です.

```
plot(0.1:0.01:0.9, foc, label=false, lw=2)  
hline!([0.0], ls=:dash, lw=2, label=false, color=:black)
```




図 1.1: FOC for CRRA utility. $f(l) = w^{1-\gamma_c}(1-l)^{-\gamma_c} - \alpha_l l^{-\gamma_l}$.

この様な一変数の非線形方程式 $f(x) = 0$ の解法として, 以下の 2 つの選択肢があります.

1. **Non-bracketing method:** 初期値 x_0 からスタートして, $f(x_n)$ が十分 0 に近づくまで反復的に計算. (ニュートン法など)
2. **Bracketing method:** 区間 $[a, b]$ を選び, 区間を狭めていくことで解を求める. (二分法など)

一般に, Non-bracketing method は収束が速い代わりにその収束は保証されません. 一方で, Bracketing method は収束がわずかに遅い代わりに, 解が存在する区間を保証することができます. 以下では, その理由とそれぞれの適した利用場面を解説します.

1.1.1.1 Non-bracketing method

Non-bracketing method は基本的には一階微分を利用し, 初期値 x_0 からスタートして反復的に解を求めます. ここでは, 最も古典的で簡単なニュートン法を紹介します.

💡 ニュートン法

1. 初期値 x_0 を選ぶ. また停止条件として十分小さい $\epsilon > 0$ を選ぶ.
2. $x_{n+1} = x_n - \frac{f(x_n)}{f'(x_n)}$ を計算する.
3. $|f(x_{n+1})| < \epsilon$ ならば停止し, x_{n+1} を解として返す. そうでなければ, $n \leftarrow n + 1$ として2に戻る.




図 1.2: Visualization of Newton Method

```
dfoc(l; w=1.0, γ_c=1.5, α_l=1.2, γ_l=1.5) =
    w^(1 - γ_c) * γ_c * (1 - l)^(-γ_c - 1) + α_l * γ_l * l^(-γ_l - 1)

find_zero((foc, dfoc), 0.5, Roots.Newton())
```

```
0.530349570343484
```

実際に `foc` の上でニュートン法が収束していく様子を見てみましょう. 初期値を $x_0 = 0.15$ とし, スライダー (Iteration N) を動かすと, 各反復での接線 (赤) が引かれ, その x 切片が次の点 x_{N+1} になります. 接線が急な最初の一步で大きく動き, 数回の反復で根 (灰色の破線) に急速に近づく様子が確認できます.

```
//| label: ojs-newton-load
//| echo: false
newton_iters = FileAttachment("static/data/newton_iterations.csv")
    .csv({typed: true})
newton_curve = FileAttachment("static/data/newton_curve.csv").csv({typed: true})
n_newton = d3.max(newton_iters, d => d.iter)
sub = (n) => n.toString().split("").map(c => "0123456789"[+c]).join("")
```

```

///| label: ojs-newton-slider
///| echo: false
viewof nstep = {
  const input = Inputs.range([0, n_newton],
    {step: 1, value: 0, label: "Iteration N", width: 420});
  input.style.fontSize = "17px";
  return input;
}

```

```

///| label: ojs-newton-fig
///| echo: false
{
  const cur = newton_iters.find(d => d.iter === nstep);
  const root = newton_iters[newton_iters.length - 1].xnext;
  const [xL, xR] = [0.12, 0.60];
  const ydom = [d3.min(newton_iters, d => d.f) * 1.06, 2.5];
  // tangent line  $y = f(x_N) + f'(x_N)(x - x_N)$ , across the whole range
  const tangent = [{x: xL, y: cur.f + cur.d * (xL - cur.x)},
    {x: xR, y: cur.f + cur.d * (xR - cur.x)}];
  return Plot.plot({
    width: 620,
    height: 420,
    marginLeft: 55,
    marginBottom: 48,
    style: {fontSize: "16px"},
    x: {label: "Leisure l", domain: [xL, xR]},
    y: {label: "f(l)", domain: ydom},
    marks: [
      Plot.ruleY([0], {stroke: "#999999", strokeDasharray: "3 3"}),
      Plot.ruleX([root], {stroke: "#cccccc", strokeDasharray: "4 3"}),
      Plot.line(newton_curve,
        {x: "x", y: "f", stroke: "#5c363a", strokeWidth: 2}),
      Plot.line(tangent, {x: "x", y: "y", stroke: "#c2676d", strokeWidth: 2.5}),
      // dotted drop from x_N on the axis up to the point (x_N, f(x_N))
      Plot.line([
        {x: cur.x, y: 0}, {x: cur.x, y: cur.f}],
        {x: "x", y: "y", stroke: "#0f6a81",
          strokeDasharray: "3 3", strokeWidth: 1.5}),
      Plot.dot([cur], {x: "x", y: "f", r: 5, fill: "#0f6a81"}),
      Plot.dot([cur], {x: "x", y: 0, r: 5, fill: "#0f6a81"}),
    ],
  });
}

```

```

Plot.dot([cur], {x: "xnext", y: 0, r: 5, fill: "#c2676d"}),
Plot.text([cur], {x: "x", y: 0, text: () => `x${sub(nstep)}`,
    fill: "#0f6a81", dx: -14, dy: 16, fontSize: 16}),
Plot.text([cur], {x: "xnext", y: 0, text: () => `x${sub(nstep + 1)}`,
    fill: "#c2676d", dx: 8, dy: 16, fontSize: 16}),
Plot.text(['N = ${nstep}'],
    {frameAnchor: "top-left", dx: 10, dy: 10,
    fontSize: 20, fontWeight: 600})
]
})
}

```

ニュートン法は解の近くでは反復ごとに有効数字が倍増する 2 次収束を示し、わずかな回数で高精度の解に達します。一方で、導関数 f' がゼロに近い点や初期値が悪い場合には反復が定義域の外に飛び出して発散することもあり、収束は保証されません。

Hybrid method

Julia の `Roots.jl` のデフォルトの Non-bracketing method (`Order0()`)は、厳密には Bracketing method も一部利用します。また一階微分も必要としないため、より汎用的に利用することができます。ただし、収束が速く収束が保証されない性質は Non-bracketing method と同じです。

```
l = find_zero(foc, 0.5)
```

```
0.530349570343484
```

定義域の変換

Non-bracketing method では、 x_{n+1} の値を更新する際に、必ずしも x_{n+1} が定義域内にあることが保証されません。例えば、今回の例では 余暇時間ですので、 $l \in (0, 1)$ ですが、初期値や関数形によっては、 $l < 0$ や $l > 1$ となる可能性があります。

この場合、端点解が存在するかどうかを確認する必要があります。端点解が想定される場合は、次節で説明するように Bracketing method を利用することが適しています。今回の例では、端点解が存在しないため ($l = 0, 1$ のどちらにおいても効用が負の無限大に発散するため)、Non-bracketing method で解の収束が保証されています。以下の様な定義域の変換を用いることで、解の収束を保証することができます。

i 定義域の変換

x が区間 (a, b) で定義されるとき、以下の変換を用いて定義域を $(-\infty, \infty)$ にすることができる。

$$x = \frac{a + b \exp y}{1 + \exp y}$$

明らかに、 $y \rightarrow -\infty$ のとき $x \rightarrow a$ 、 $y \rightarrow \infty$ のとき $x \rightarrow b$ となる。

今回の例では, $l = \frac{1}{1 + \exp(-y)}$ (つまりシグモイド関数) という変換を用いることができます.

```
y = find_zero(y → foc(1 / (1 + exp(-y))), 0.0)
l = 1 / (1 + exp(-y))
```

```
0.530349570343484
```

1.1.1.2 Bracketing method

Bracketing method は, 解が存在する区間 $[a, b]$ を選び, その区間を狭めていくことで解を求めます. ここでは最も基本的な二分法を用いることで解を求めることができます.

🔍 二分法

1. 区間 $[a, b]$ を選ぶ. また停止条件として十分小さい $\epsilon > 0$ を選ぶ.
2. $f(a) \cdot f(b) < 0$ ならば, $c = \frac{a+b}{2}$ を計算する.
3. $|f(c)| < \epsilon$ ならば, c を解として返す. そうでなければ, $f(a) \cdot f(c) < 0$ ならば, $b \leftarrow c$ として 2 に戻る. そうでなければ, $a \leftarrow c$ として 2 に戻る.




図 1.3: Visualization of Bisection Method

例えば, 今回の例では $l \in (0, 1)$ ですので, $l = 0$ と $l = 1$ で効用が発散することから, 解が存在する区間は $(0, 1)$ です. なお, 端点で FOC が定義されていない場合も多いので, 端点より微小に内側の区間を選ぶことが多いです.

```
ε = 1e-9
l = find_zero(foc, (ε, 1 - ε))
```

```
0.530349570343484
```

二分法が区間を狭めていく様子も見てみましょう. 開始区間を $[a_0, b_0] = [0.4, 0.8]$ とし, スライダー (Iteration N) を動かすと, 中点 c_N での符号に応じて区間 (水色の帯) が半分ずつに狭まっていきま

す。ニュートン法と違い解は常に区間内に保証されますが、区間幅は毎回半分になるだけなので、同じ精度に達するにはより多くの反復が必要です。

```

///| label: ojs-bisection-load
///| echo: false
bisection_iters = FileAttachment("static/data/bisection_iterations.csv")
  .csv({typed: true})
bisection_curve = FileAttachment("static/data/bisection_curve.csv")
  .csv({typed: true})
n_bisection = d3.max(bisection_iters, d => d.iter)

```

```

///| label: ojs-bisection-slider
///| echo: false
viewof mstep = {
  const input = Inputs.range([0, n_bisection],
    {step: 1, value: 0, label: "Iteration N", width: 420});
  input.style.fontSize = "17px";
  return input;
}

```

```

///| label: ojs-bisection-fig
///| echo: false
{
  const cur = bisection_iters.find(d => d.iter === mstep);
  const root = bisection_iters[bisection_iters.length - 1].c;
  const [xL, xR] = [0.37, 0.82];
  const ydom = [-4, 6];
  const band = [{x1: cur.a, x2: cur.b, y1: ydom[0], y2: ydom[1]}];
  return Plot.plot({
    width: 620,
    height: 420,
    marginLeft: 55,
    marginBottom: 48,
    style: {fontSize: "16px"},
    x: {label: "Leisure l", domain: [xL, xR]},
    y: {label: "f(l)", domain: ydom},
    marks: [
      Plot.rect(band, {x1: "x1", x2: "x2", y1: "y1", y2: "y2",
        fill: "#45939c", fillOpacity: 0.12}),
      Plot.ruleY([0], {stroke: "#999999", strokeDasharray: "3 3"}),
    ]
  )
}

```

```

Plot.ruleX([root], {stroke: "cccccc", strokeDasharray: "4 3"}),
Plot.line(bisect_curve,
  {x: "x", y: "f", stroke: "#5c363a", strokeWidth: 2}),
Plot.ruleX([cur], {x: "a", stroke: "#45939c", strokeWidth: 1.5}),
Plot.ruleX([cur], {x: "b", stroke: "#45939c", strokeWidth: 1.5}),
// midpoint c_N: evaluated on the curve, with a dotted drop to the axis
Plot.line([x: cur.c, y: 0], [x: cur.c, y: cur.fc]),
  {x: "x", y: "y", stroke: "#c2676d",
    strokeDasharray: "3 3", strokeWidth: 1.5}),
Plot.dot([cur], {x: "c", y: "fc", r: 5, fill: "#c2676d"}),
Plot.dot([cur], {x: "c", y: 0, r: 5, fill: "#c2676d"}),
Plot.text([cur], {x: "a", y: 0, text: () => `a${sub(mstep)}`,
  fill: "#45939c", dx: -12, dy: 16, fontSize: 16}),
Plot.text([cur], {x: "b", y: 0, text: () => `b${sub(mstep)}`,
  fill: "#45939c", dx: 12, dy: 16, fontSize: 16}),
Plot.text([cur], {x: "c", y: 0, text: () => `c${sub(mstep)}`,
  fill: "#c2676d", dx: 0, dy: cur.fc > 0 ? 18 : -16, fontSize: 16}),
Plot.text(['N = ${mstep}'],
  {frameAnchor: "top-left", dx: 10, dy: 10,
    fontSize: 20, fontWeight: 600})
]
})
}

```

二分法は各反復で区間幅がちょうど半分になる線形収束です。収束は遅いものの、初期区間の両端が異符号でありさえすれば必ず解に収束する頑健さが利点です。

端点解の存在

以下の様なカップルの意思決定問題を考えてみましょう。

$$\max_{c_m, c_f, l_m, l_f} u(c_m, l_m) + u(c_f, l_f) \quad (1.2)$$

subject to

$$c_m + c_f = w_m(1 - l_m) + w_f(1 - l_f).$$

一階条件から以下の関係が導けます:

$$\frac{l_m}{l_f} = \left(\frac{w_f}{w_m} \right)^{\frac{1}{\gamma_l}}.$$

この関係から一方の相対賃金が十分に大きい場合、例えば $w_m \gg w_f$ の場合、 $l_f > 1$ となる可能性があります (l_m は余暇時間のため、0 よりある程度大きい値をとることが想像できます。) 内点解が存在する場合の l_f に関する一階条件は以下のようになります。

$$w_m \left(1 - \left(\frac{w_f}{w_m} \right)^{\frac{1}{\gamma_l}} l_f \right) + w_f (1 - l_f) - 2 \left(\frac{w_f}{\alpha_l} \right)^{\frac{1}{\gamma_c}} l_f^{\frac{\gamma_l}{\gamma_c}} = 0.$$

```
function foc_bargaining(l_f; w_m=1.0, w_f=0.5, γ_c=1.5, α_l=1.2, γ_l=1.5)
    return w_m * (1 - (w_f / w_m)^(1 / γ_l) * l_f) + w_f * (1 - l_f) -
        2 * (w_f / α_l)^(1 / γ_c) * l_f^(γ_l / γ_c)
end

lf_grid = 0.01:0.01:0.99
cols = [mypalette[6], mypalette[2], mypalette[4]]
p = plot(xlabel=L"l_f", legend=false, xlims=(0.0, 1.13))
for (i, wf) in enumerate([1.0, 0.5, 0.1])
    ys = foc_bargaining.(lf_grid; w_f=wf)
    plot!(p, lf_grid, ys, lw=2, color=cols[i])
    # direct label at the right end of each line
    annotate!(p, 1.0, ys[end], text(L"w_f = %$wf", 9, :black, :left))
end
hline!(p, [0.0], ls=:dash, lw=2, label=false, color=:black)
p
```




図 1.4: FOC for bargaining problem. $w_m = 1.0$, $\alpha_l = 1.2$, $\gamma_c = \gamma_l = 1.5$.

また、 $l_f = 1$ における一階条件は以下のようになります。

$$w_m(1 - l_m) - 2 \left(\frac{w_m}{\alpha_l} \right)^{\frac{1}{\gamma_c}} l_m^{\frac{\gamma_l}{\gamma_c}} = 0.$$

このような場合, Bracketing method の考えが有効です.

1. 端点 $l_f = 0, 1$ (実用上は $\epsilon, 1 - \epsilon$) において, 一階条件の値を計算.
2. 一階条件の値が異符号であれば, 二分法を用いて解を求める.
3. 一階条件の値が同符号であれば, 端点解 (この場合, $l_f = 1$) 上の解を求める.

```
function solve_bargaining(; w_m=1.0, w_f=0.5, γ_c=1.5, α_l=1.2, γ_l=1.5)

    ε = 1e-9

    left = w_m * (1 - (w_f / w_m)^(1 / γ_l) * ε) + w_f * (1 - ε) -
           2 * (w_f / α_l)^(1 / γ_c) * ε^(γ_l / γ_c)
    right = w_m * (1 - (w_f / w_m)^(1 / γ_l) * (1 - ε)) + w_f * ε -
           2 * (w_f / α_l)^(1 / γ_c) * (1 - ε)^(γ_l / γ_c)

    if left * right < 0
        l_f = find_zero(
            l_f → w_m * (1 - (w_f / w_m)^(1 / γ_l) * l_f) + w_f * (1 - l_f) -
                  2 * (w_f / α_l)^(1 / γ_c) * l_f^(γ_l / γ_c),
            (ε, 1 - ε))
        l_m = (w_f / w_m)^(1 / γ_l) * l_f
    else
        l_f = 1.0
        x = find_zero(
            x → w_m * (1 - 1 / (1 + exp(x))) -
                2 * (w_m / α_l)^(1 / γ_c) * (1 / (1 + exp(x)))^(γ_l / γ_c),
            0.0)
        l_m = 1 / (1 + exp(x))
    end

    c = w_m * (1 - l_m) + w_f * (1 - l_f)
    c_m = 0.5 * c
    c_f = 0.5 * c
    U = (c_m^(1 - γ_c) / (1 - γ_c)) + α_l * (l_m^(1 - γ_l) / (1 - γ_l)) +
        (c_f^(1 - γ_c) / (1 - γ_c)) + α_l * (l_f^(1 - γ_l) / (1 - γ_l))
    return (c_m=c_m, c_f=c_f, l_m=l_m, l_f=l_f, U=U)
end
```

```

wf_grid = 0.1:0.01:0.9
lm = [solve_bargaining(w_f=w).l_m for w in wf_grid]
lf = [solve_bargaining(w_f=w).l_f for w in wf_grid]
p = plot(xlabel=L"w_f", legend=false, xlims=(0.1, 1.0))
plot!(p, wf_grid, lm, lw=2, color=mypalette[6])
plot!(p, wf_grid, lf, lw=2, color=mypalette[2])
# direct labels at the right end (nudged apart since the lines converge there)
annotate!(p, 0.915, lm[end] - 0.02, text(L"l_m", 9, :black, :left))
annotate!(p, 0.915, lf[end] + 0.02, text(L"l_f", 9, :black, :left))
p

```




図 1.5: **Solution of bargaining problem.** $w_m = 1.0, \alpha_l = 1.2, \gamma_c = \gamma_l = 1.5$.

1.1.2 多変数の非線形方程式

多変数の非線形方程式では Bracketing method は使えず、ニュートン法のような Non-bracketing method を用いる必要があります。そのため内点解と微分可能な関数を仮定しており、端点解やスムーズでない関数が想定される場合は使えません。そのような場合は、原始的なグリッドサーチを用いるか、後述するように非線形最適化問題として解く必要があります。

なお、多くの標準的な効用関数 (CRRA, CES など) の場合、一階条件は一変数の非線形方程式に帰着できます。基本的には、一変数の非線形方程式の方が収束が速く、端点解の存在を確認しやすいので、可能な場合は一変数の非線形方程式に帰着させることが望ましいです。今回は学習のために、式 (1.1) を 3 変数 (c, l, λ) の非線形方程式 (1.3) として解いてみましょう。NonlinearSolve.jl を用いると便利です。

$$\begin{aligned}
 c^{-\gamma_c} &= \lambda \\
 \alpha_l l^{-\gamma_l} &= \lambda w \\
 c &= w(1 - l)
 \end{aligned}
 \tag{1.3}$$

```

function solve_nonlinear_system(; w=1.0, γ_c=1.5, α_l=1.2, γ_l=1.5)
    f((c, l, λ), par) = [
        λ * c^γ_c - 1,
        α_l - λ * w * l^γ_l,
        c - w * (1 - l)
    ]
    prob = NonlinearProblem(f, [0.5, 0.5, 0.35], 0.)
    sol = solve(prob, NewtonRaphson())

    return (c=sol.u[1], l=sol.u[2], λ=sol.u[3])
end

solve_nonlinear_system()

```

```
(c = 0.469650429656516, l = 0.530349570343484, λ = 3.1069761107915044)
```

工夫として負の指数を避けるように式変形しています。これは最適化の際に、負の数の負の数乗によってエラーが起きることを避けるためです。

1.2 一変数の非線形最適化

ここからは、非線形最適化の方法について解説します。基本的には、次の非線形関数 $f(\cdot)$ の最小化問題を考えます。

$$\min_{\mathbf{x} \in \mathcal{X}} f(\mathbf{x}).$$

制約条件として、 $g(\mathbf{x}) = \mathbf{0}$ や $h(\mathbf{x}) \leq \mathbf{0}$ を課すこともできますが、まずは制約なしの最適化問題を考えます。制約付きの最適化問題については 1.4 節 で解説します。

一変数の非線形最適化は、1.1 節 で解説した、ニュートン法と二分法の analogy である、**準ニュートン法** (Quasi-Newton method) と **黄金分割法** (Golden-section search) で解くことができます。これらの方法は、それぞれニュートン法と二分法のように、収束の速さと保証のトレードオフがあります。準ニュートン法は、収束が速い代わりに、解が存在する保証がありません。一方で、黄金分割法は、収束が遅い代わりに、解が存在する区間を保証することができます。

1.2.1 準ニュートン法

求根法のニュートン法では, $f(x) = 0$ を解くために $x_{n+1} = x_n - f(x_n)/f'(x_n)$ という更新式を用いました. 最適化問題 $\min_x f(x)$ では, 一階条件 $f'(x) = 0$ を解くことが目標ですので, ニュートン法を $f'(x) = 0$ に適用すると, 以下のアルゴリズムが得られます.

💡 ニュートン法 (1 変数)

1. 初期値 x_0 を選ぶ. 停止条件として十分小さい $\epsilon > 0$ を選ぶ.
2. $x_{n+1} = x_n - \frac{f'(x_n)}{f''(x_n)}$ を計算する.
3. $|f'(x_{n+1})| < \epsilon$ ならば停止し, x_{n+1} を解として返す. そうでなければ, $n \leftarrow n + 1$ として 2 に戻る.

二階微分 $f''(x_n)$ の計算が困難な場合, これを近似する方法が**準ニュートン法** (Quasi-Newton method) です. 代表的な方法として **BFGS 法** があり, 一階微分の情報のみを用いて二階微分 (ヘッセ行列) を逐次的に近似します.

1.1 節 で用いた CRRA 効用関数の最大化問題 (式 (1.1)) を例にとりましょう. 制約を代入すると, 以下の一変数最大化問題になります.

$$\max_l v(l) = \frac{(w(1-l))^{1-\gamma_c}}{1-\gamma_c} + \alpha_l \frac{l^{1-\gamma_l}}{1-\gamma_l}.$$

```
v(l; w=1.0, γ_c=1.5, α_l=1.2, γ_l=1.5) =
  (w * (1 - l))^(1 - γ_c) / (1 - γ_c) + α_l * l^(1 - γ_l) / (1 - γ_l)
```

Optim.jl の BFGS() を用いて解くことができます. BFGS() は多変数関数に対応する手法であるため, 一変数であってもベクトルの形で表現する必要があります. また, Optim.jl は最小化を行うため, 目的関数の符号を反転させます. なお, $l \in (0, 1)$ の制約を考慮するために Fminbox を使います.¹

```
ε = 1e-9
result = optimize(l → -v(l[1]), [ε], [1.0 - ε], [0.5], Fminbox(BFGS()))
result.minimizer[1]
```

```
0.530349570336863
```

求根法のニュートン法と同様に, 初期値の選び方によっては収束しない場合があります, 大域的な最適解への収束は保証されません.

数値微分

ニュートン法系のアルゴリズムは, 一階微分や二階微分を必要とします. 解析的に導関数が分かっている場合は, それを勾配として optimize() に渡すことでより高速に解くことができます. 解析的に分からない場合は導関数を数値的に求めますが, その方法 (有限差分・複素ステップ・自動微分) は 2.2 節 で扱います. Optim.jl は勾配を指定しなければ自動微分などで勾配を計算します.

デフォルトの設定

¹1.1.1.1 節 で説明したように, 定義域の変換で対処することも可能です.

`Optim.optimize()` では、メソッドを指定せず区間も指定しない場合は、デフォルトでは [Nelder-Mead 法](#) が用いられます (`NelderMead()`). これは導関数を必要としない最適化アルゴリズムです. また、勾配を指定した場合でも、BFGS 法のメモリ使用量を改善した [L-BFGS 法](#) (`LBFGS()`) が用いられます.

1.2.2 黄金分割法

二分法が区間 $[a, b]$ において $f(a) \cdot f(b) < 0$ (中間値の定理) を利用して区間を半分に分けていくのに対し、黄金分割法は関数が区間で**単峰** (unimodal) であること、すなわち極値が一つだけ存在することを仮定し、黄金比を用いて区間を縮小していきます.

💡 黄金分割法

最小化問題 $\min_{x \in [a, b]} f(x)$ を解く. 黄金比を $\varphi = \frac{\sqrt{5}-1}{2} \approx 0.618$ とする.

1. 区間 $[a, b]$ を選ぶ. 停止条件として十分小さい $\epsilon > 0$ を選ぶ.
2. 内分点 $x_1 = a + (1 - \varphi)(b - a)$, $x_2 = a + \varphi(b - a)$ を計算する.
3. $f(x_1) \leq f(x_2)$ ならば $b \leftarrow x_2$ とし、そうでなければ $a \leftarrow x_1$ とする.
4. $|b - a| < \epsilon$ ならば停止し、 $\frac{a+b}{2}$ を解として返す. そうでなければ、2 に戻る.




図 1.6: Visualization of Golden Section Search

図 1.6 は単峰関数 f に対する黄金分割法の一ステップを表しています. 内分点 x_1, x_2 で関数値を比較し、 $f(x_1) > f(x_2)$ であるため極小値は x_1 より右側にあると判断でき、区間の左端を $a \leftarrow x_1$ (赤い破線) に更新して探索区間を縮小します.

各ステップで区間が $\varphi \approx 0.618$ 倍に縮小されるため、単峰関数であれば収束が保証されます. なぜ内分比に黄金比を取るのかについては、[A.1 節](#) で証明します. ただし、準ニュートン法と比較すると収束速度は遅くなります (線形収束). `Optim.jl` の `GoldenSection()` を用いて解くことができます (`NonlinearSolve.jl` も同名の関数をエクスポートしているため、`Optim.GoldenSection()` と修飾して呼びます).

```

ε = 1e-9
result = optimize(l → -v(l), ε, 1 - ε, Optim.GoldenSection())
result.minimizer

```

```
0.5303495600624788
```

二分法と同様に、適切な区間を指定すれば収束が保証されるため、準ニュートン法よりも堅牢な方法です。

デフォルトの設定

`Optim.optimize()` では、メソッドを指定せずに区間を指定した場合は、デフォルトでは黄金分割法を改良した **Brent 法** が用いられます (`Brent()`)。

1.3 多変数の非線形最適化

1.3.1 単純なケース

一変数の場合と同様に、多変数関数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ の最小化も、一階条件 $\nabla f(\mathbf{x}) = \mathbf{0}$ を解く問題として捉えられます。これは 1.1 節 の多変数求根法を最適化に応用したものです。ニュートン法は、ヤコビアン¹の代わりにヘッセ行列 $\nabla^2 f$ を用いて更新します。

💡 ニュートン法 (多変数)

1. 初期値 $\mathbf{x}_0$ を選ぶ。停止条件として十分小さい $\epsilon > 0$ を選ぶ。
2. $\mathbf{x}_{n+1} = \mathbf{x}_n - [\nabla^2 f(\mathbf{x}_n)]^{-1} \nabla f(\mathbf{x}_n)$ を計算する。
3. $\|\nabla f(\mathbf{x}_{n+1})\| < \epsilon$ ならば停止する。そうでなければ $n \leftarrow n + 1$ として 2 に戻る。

目的関数が滑らかで局所最適点が1つしかない場合は、初期値の近傍を下っていく**局所的手法** (local method) だけで大域的最適点に到達できます。一変数の場合と同様、ヘッセ行列とその逆行列の計算は高コストなため、実際には**準ニュートン法** (BFGS) が広く使われます。BFGS はヘッセ行列 (今度 $n \times n$ 行列) を一階微分の履歴から逐次的に近似します。勾配すら利用できない場合は、導関数を必要としない **Nelder-Mead 法** (単体法) が使えます。

例として、資本 k と労働 l を投入する企業の利潤最大化を考えます。

$$\max_{k,l} \pi(k,l) = k^\alpha l^\nu - rk - wl, \quad \alpha + \nu < 1.$$

一階条件は「限界生産物 = 要素価格」, すなわち $\alpha k^{\alpha-1} l^\nu = r$ と $\nu k^\alpha l^{\nu-1} = w$ です。

```
profit(k, l; α=0.3, ν=0.5, r=0.1, w=1.0) = k^α * l^ν - r * k - w * l
```

$k, l > 0$ の正值制約を満たすため、対数をとった変数 ($\log k, \log l$) について最適化します。² `Optim.jl` の `BFGS()` と、導関数を使わない `NelderMead()` の両方で解いてみましょう。

²1.1.1.1 節 で述べた定義域の変換です。指数関数を通すことで、任意の実数が正の k, l に対応します。

```
obj(a) = -profit(exp(a[1]), exp(a[2]))
res_bfgs = optimize(obj, [0.0, 0.0], BFGS())
res_nm = optimize(obj, [0.0, 0.0], NelderMead())
println("BFGS:      ", round.(exp.(Optim.minimizer(res_bfgs)), digits=4))
println("Nelder-Mead: ", round.(exp.(Optim.minimizer(res_nm)), digits=4))
```

```
BFGS:      [2.7557, 0.4593]
Nelder-Mead: [2.7553, 0.4592]
```

どちらも同じ最適点 $(k, l) \approx (2.76, 0.46)$ に収束します。

1.3.2 複雑なケース

単純なケースでは、どの初期値から出発しても同じ最適点に収束しました。これは目的関数が (対数変換の後に) 凸で、局所最適点がただ1つだったからです。しかし、構造推定の目的関数 (SMM や GMM の目的関数など) をはじめ、多くの経済モデルの目的関数は多峰性 (multimodal, 非凸) をもつ可能性があります。局所最適点が複数存在する場合があります。このとき最適化法は2種類に大別されます。

- **局所的手法** (local method): 初期値の近くの谷を下っていく。BFGS や Nelder-Mead はこれにあたり、収束は速いが、たどり着く最適点は初期値に依存する。悪い初期値では、大域的最適点でない局所最適点に捕まる。
- **大域的手法** (global method): 定義域全体を系統的 (あるいは確率的) に探索し、大域的最適点を探す。探索範囲 (box 制約) を指定する必要がある、一般に局所的手法より多くの関数評価を要する。

大域的手法を数多く備えた代表的なライブラリが **NLopt** です。Julia では **Optimization.jl** が³, **NLopt** を含む多くのソルバーを共通のインターフェースで扱えます。問題を **OptimizationProblem** として組み立て、ソルバー (例えば **NLopt** の **NLopt.GN_DIRECT_L()**) を指定して **solve** するだけです。以下ではこの **Optimization.jl** 経由で **NLopt** を呼びます。³

多峰性の例として、多数の局所最適点をもつ Rastrigin 関数を最小化します。

$$f(\mathbf{x}) = 10n + \sum_{i=1}^n [x_i^2 - 10 \cos(2\pi x_i)], \quad \mathbf{x} \in [-5.12, 5.12]^n.$$

放物線 $\sum_i x_i^2$ に余弦波の細かい起伏を重ねた関数で、定義域の至る所に局所最適点を持ちます。大域的最適点は原点 $\mathbf{x} = \mathbf{0}$ で、そこで $f = 0$ です。以下では $n = 2$ とします。

```
rastrigin(x) = 10 * length(x) + sum(x.^2 .- 10 .* cos.(2π .* x))
```

図 1.7 にこの関数の形状を示します。放物線状のなだらかな碗の上に細かい起伏が重なり、至る所に局所最適点 (谷) があるのが分かります。

³NLopt も **optimize** を輸出し **Optim.jl** と衝突するため、**OptimizationNLopt** と **NLopt** は **using** ではなく **import** で読み込んでいます。

```
xs = range(-5.12, 5.12, length=150)
Z = [rastrigin([x, y]) for y in xs, x in xs]
surface(xs, xs, Z, c=:inferno, xlabel=L"x_1", ylabel=L"x_2",
        zlabel=L"f(\mathbf{x})", colorbar=false, camera=(35, 40), size=(560, 440))
```




図 1.7: **Rastrigin function ($n = 2$)**. Local minima appear throughout the domain.

まず, 単純なケースでも使った局所的手法 (Nelder-Mead) を, 原点から離れた初期値 $[3, 3]$ から走らせます.

```
res_local = optimize(rastrigin, [3.0, 3.0], NelderMead())
(x=round.(Optim.minimizer(res_local), digits=3),
 f=round(Optim.minimum(res_local), digits=3))
```

```
(x = [2.985, 2.985], f = 17.909)
```

局所最適点 $(2.98, 2.98)$ に捕まり, $f \approx 17.9$ と大域的最適値 0 から大きく外れています. 初期値を原点の近くにとれば $f = 0$ に収束しますが, どの谷に落ちるかは初期値次第です.

次に, NLOpt の大域的手法 DIRECT-L で探索範囲 $[-5.12, 5.12]^2$ 全体を探索します. Optimization.jl では目的関数を $f(u, p)$ の形 (u が変数, p がパラメータ) で与え, 探索範囲を lb / ub で指定します.

```

optf = OptimizationFunction((u, p) → rastrigin(u))
prob = OptimizationProblem(optf, [3.0, 3.0]; lb=[-5.12, -5.12], ub=[5.12, 5.12])
sol = solve(prob, NLOpt.GN_DIRECT_L(), maxiters=5000)
(x=round.(sol.u, digits=3), f=round(sol.objective, digits=3))

```

```
(x = [0.0, 0.0], f = 0.0)
```

初期値によらず大域的最適点 $\mathbf{x} = \mathbf{0}$ ($f = 0$) にたどり着きます。DIRECT (DIviding RECTangles) は探索範囲を系統的に分割していく決定論的な手法で、初期値の値には依存しません。

実務では、大域的手法で有望な領域を絞り込んでから局所的手法で精密化する、という組み合わせがよく使われます。NLOpt の **MLSL** (Multi-Level Single-Linkage, :G_MLSL_LDS) は、定義域全体から多数の初期値をサンプルして局所的手法を繰り返し適用する **multistart** 法で、この考えを体系化したものです。

1.4 制約付き非線形最適化

経済モデルでは、予算制約などの制約付き最適化が中心的です。一般に、等式制約 $g(\mathbf{x}) = \mathbf{0}$ と不等式制約 $h(\mathbf{x}) \leq \mathbf{0}$ のもとで $f(\mathbf{x})$ を最小化する問題を考えます。ラグランジュ関数

$$\mathcal{L}(\mathbf{x}, \lambda, \mu) = f(\mathbf{x}) - \lambda^\top g(\mathbf{x}) - \mu^\top h(\mathbf{x})$$

の停留点を KKT 条件のもとで求める、というのが基本的な考え方です。数値的には主に 3 つのアプローチがあります。

変数消去。 等式制約を代入して未知数を減らし、制約なし問題に帰着させる方法です。一変数の例で予算制約 $c = w(1 - l)$ を代入したのがこれにあたります。2 財の消費者問題を例にとりましょう。

$$\max_{c_1, c_2} c_1^a c_2^b \quad \text{s.t.} \quad p_1 c_1 + p_2 c_2 = m.$$

予算制約から $c_2 = (m - p_1 c_1) / p_2$ を代入すれば、 c_1 のみの一変数問題になります。

```

p1, p2, m = 1.0, 2.0, 10.0
u2(c1; a=0.4, b=0.6) = c1^a * ((m - p1 * c1) / p2)^b
res = optimize(c1 → -u2(c1), 1e-6, m / p1 - 1e-6, Optim.GoldenSection())
c1 = Optim.minimizer(res)
(c1=c1, c2=(m - p1 * c1) / p2)

```

```
(c1 = 3.9999999973978277, c2 = 3.00000000013010863)
```

コブ・ダグラス型の需要 $c_1 = am/p_1 = 4$, $c_2 = bm/p_2 = 3$ と一致します。

箱制約。 $0 \leq c \leq \bar{c}$ のような単純な上下限 (box constraint) は、ソルバーに下限 **lb** と上限 **ub** を渡すだけで直接扱えます。変数消去した消費者問題を、導関数を使わない NLOpt の BOBYQA 法で解いてみましょう。

```

negu(c1, p) = -(c1[1]^0.4 * ((m - p1 * c1[1]) / p2)^0.6)
prob = OptimizationProblem(OptimizationFunction(negu), [2.0];
    lb=[1e-6], ub=[m / p1 - 1e-6])
sol = solve(prob, NLOpt.LN_BOBYQA(), maxiters=10_000)
(c1=sol.u[1], c2=(m - p1 * sol.u[1]) / p2)

```

```
(c1 = 4.00000000167979515, c2 = 2.9999999916010243)
```

変数消去と同じ解 $(c_1, c_2) = (4, 3)$ が得られます.

一般の制約. 変数消去が難しい一般の等式・不等式制約は, 制約関数を直接ソルバーに渡して扱います. 制約 $g(\mathbf{x})$ を `cons` で, その下限・上限を `lcons` / `ucons` で与えます (等式制約は下限 = 上限). 予算制約 $p_1 c_1 + p_2 c_2 = m$ を消去せずに, 制約を扱える NLOpt の COBYLA 法で解いてみましょう.

```

negu2(c, p) = -(c[1]^0.4 * c[2]^0.6)
budget(res, c, p) = (res[1] = p1 * c[1] + p2 * c[2] - m)
optf = OptimizationFunction(negu2; cons=budget)
prob = OptimizationProblem(optf, [2.0, 4.0]; lcons=[0.0], ucons=[0.0],
    lb=[0.0, 0.0], ub=[50.0, 50.0])
sol = solve(prob, NLOpt.LN_COBYLA(), maxiters=10_000)
sol.u

```

```

2-element Vector{Float64}:
 4.00000000528577555
 2.99999999735711227

```

予算制約 $p_1 c_1 + p_2 c_2 - m$ の下限・上限をとともに 0 とすることで等式を表しています. 同じ解 $(c_1, c_2) = (4, 3)$ が得られます. NLOpt には勾配を使う SLSQP など制約付き問題向けの手法も揃っており, 真の内点法が必要であれば次節の Ipopt を使います.

より複雑な制約付き問題では, 次に述べるように, 問題を宣言的に記述してソルバーに渡す方法が便利です.

1.5 Mathematical Programming

より強力な方法として, 解きたい最適化問題を直接ソルバーにかける方法があります. Julia の場合は JuMP.jl が有名です. ここでは, 式 (1.2) を JuMP を用いて解いてみましょう.

```

function solve_jump(; w_m=1.0, w_f=0.5, y_c=1.5, α_l=1.2, γ_l=1.5)

    model = Model(Ipopt.Optimizer)
    set_silent(model)
    set_attribute(model, "print_level", 0)

```

```

set_attribute(model, "sb", "yes") # suppress the Ipopt banner
@variables(model, begin
    0 <= c_m
    0 <= c_f
    0 <= l_m <= 1
    0 <= l_f <= 1
end)

@objective(
    model,
    Max,
    (c_m^(1 - γ_c) / (1 - γ_c)) + α_l * (l_m^(1 - γ_l) / (1 - γ_l)) +
    (c_f^(1 - γ_c) / (1 - γ_c)) + α_l * (l_f^(1 - γ_l) / (1 - γ_l))
)

@constraint(model, c_m + c_f == w_m * (1 - l_m) + w_f * (1 - l_f))

optimize!(model)

return (
    c_m=value(c_m),
    c_f=value(c_f),
    l_m=value(l_m),
    l_f=value(l_f),
    U=objective_value(model)
)
end

```

図 1.5 と同じ結果が得られました。

```

wf_grid = 0.1:0.01:0.9
lm = [solve_jump(w_f=w).l_m for w in wf_grid]
lf = [solve_jump(w_f=w).l_f for w in wf_grid]
p = plot(xlabel=L"w_f", legend=false, xlims=(0.1, 1.0))
plot!(p, wf_grid, lm, lw=2, color=mypalette[6])
plot!(p, wf_grid, lf, lw=2, color=mypalette[2])
annotate!(p, 0.915, lm[end] - 0.02, text(L"l_m", 9, :black, :left))
annotate!(p, 0.915, lf[end] + 0.02, text(L"l_f", 9, :black, :left))
p

```




図 1.8: **Solution of bargaining problem by JuMP.** $w_m = 1.0, \alpha_l = 1.2, \gamma_c = \gamma_l = 1.5$.

とても便利に思えますが, いくつか注意点があります.

1. 計算の正しさが保証されない. アルゴリズムの中身がブラックボックスであり, 研究者自身が解の正しさを保証できない. 端点解を見逃す可能性や収束しない可能性がある.
2. 計算が遅い. 一階条件を直接解く場合と比べると, 問題の複雑さが増すため, 計算が遅くなる. より大規模なモデルを解きたい場合には, 致命的な問題となる可能性がある.

検算目的で使うぐらいに留めておくのが良いでしょう.

第 2 章

関数近似

Function Approximation

経済モデルの数値計算では、価値関数や政策関数のように、一般形が分からない関数を扱います。これらは有限個のグリッド点の上でしか値を持たなかったり、ブラックボックスとしてしか評価できなかったりします。本章では、そうした関数を扱う 4 つの基本操作を学びます。グリッド上の値から関数全体を復元する**補間** (interpolation)、その導関数を数値的に求める**数値微分** (numerical differentiation)、期待値などの積分を有限個の評価点で近似する**数値積分** (numerical integration)、そして連続な確率過程を有限状態で近似する**離散化** (discretization) です。いずれも、後の第 3 章をはじめ数値計算のあらゆる場面で使われます。

2.1 補間


未知なる関数 $f(x)$ の一般形は分からないが、具体的な x に関しては $f(x)$ の値が計算できる、という状況を考えます。例えば第 3 章の動的計画法では、来期の資本 k' が一般にグリッド点に一致しないため、グリッド上で求めた価値関数や政策関数をグリッド外で評価する必要があります。ちょっと極端な例を考えてみましょう。次の効用最大化問題を考えます。

$$\max_n \log c - v(n) \quad \text{s.t.} \quad c = wn.$$

ここで、労働供給の不効用 $v(n) = \phi \log(n!)$ とします。この時の最適な n^* を求めてみましょう。

2.1.1 グリッドサーチ


最も単純な方法は、 $n = 1, \dots, 10$ ぐらいまで試してみて、最も効用 $u(c, n)$ が大きくなる n を選ぶ方法です。これをグリッドサーチと呼びます。後の第 3 章で扱う Value Function Iteration も、本質的にはこのグリッドサーチを価値関数の最大化に用いています。

図 2.1: Grid Search for Optimal n . $\phi = 0.1$.

6

2.1.2 区分線形補間と3次スプライン補間

これを実数の世界に拡張してみましょう。もし、 n が実数の時の $v(n)$ の値が計算できれば、通常の一変数関数の最大化問題として解くことができます。そのために、 $v(n)$ を補間 (interpolation) してみましょう。Julia では `Interpolations.jl` パッケージを uses。

図 2.2: Linear and Spline Interpolation of Cost Function $v(n)$.

ここでは線形補間 (linear interpolation) と3次スプライン補間 (cubic spline interpolation) の両方を定義しました。線形補間は2点間を直線で結ぶだけですが、スプライン補間はより滑らかな曲線で補間します。スプライン補間がこの「滑らかさ」の意味で最良の補間となる理由は [A.2 節](#) で証明します。

このように実数上に定義された関数を用いれば、通常の最適化問題のように解くことができます。⁴

Linear Interpolation: $n = 5.5811$

Cubic Spline: $n = 5.5516$

今回の例では、階乗はガンマ関数を用いて実数に拡張できるので、より厳密な解を求めることもできます。

Exact Solution: $n = 5.5512$

2.2 数値微分

補間がグリッド上の値から関数そのものを復元するのに対し、ここではその導関数を数値的に求めます。第 1 章では、ニュートン法がヤコビアンを、準ニュートン法が勾配やヘッセ行列を用いました。解析的に導関数が求まればそれを渡すのが最も高速で正確ですが、関数が複雑で微分が面倒な場合や、ブラックボックスとして与えられる場合には、導関数を数値的に求める必要があります。ここでは有限差分から始め、その弱点を複素ステップ微分と自動微分がどう克服するかを見ていきます。

2.2.1 有限差分

微分の定義 $f'(x) = \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h}$ の極限を、有限の $h > 0$ で打ち切ったものが有限差分 (finite difference) です。

i 有限差分

十分小さい $h > 0$ に対して、導関数を次のように近似する。

$$\text{Forward: } f'(x) \approx \frac{f(x+h) - f(x)}{h},$$

$$\text{Central: } f'(x) \approx \frac{f(x+h) - f(x-h)}{2h}.$$

近似の精度はテイラー展開から分かります。

$$f(x \pm h) = f(x) \pm hf'(x) + \frac{h^2}{2}f''(x) \pm \frac{h^3}{6}f'''(x) + \dots$$

を代入すると、

$$\begin{aligned} \frac{f(x+h) - f(x)}{h} &= f'(x) + \frac{h}{2}f''(x) + O(h^2), \\ \frac{f(x+h) - f(x-h)}{2h} &= f'(x) + \frac{h^2}{6}f'''(x) + O(h^4) \end{aligned}$$

⁴線形補間では一階微分までしかとれませんが、スプライン補間を用いれば二階微分が取れるので、derivative-based な最適化手法も使えます。ここでは 1 変数関数なので、bracketing method のような微分のいらぬ手法を用いています。

となり、前進差分の打ち切り誤差は $O(h)$ 、中心差分では2次の項が打ち消し合って $O(h^2)$ です。したがって中心差分の方が高精度です。

刻み幅のトレードオフ. それならば h を限りなく小さくすればよいかというと、そうではありません。 h を小さくすると打ち切り誤差は減りますが、分子が非常に近い2数の差になるため**桁落ち** (subtractive cancellation) が起き、丸め誤差が増大します。この丸め誤差と打ち切り誤差のトレードオフにより、誤差は h の大きさによって下に凸な形を描き、最適な h の大きさが存在します。

実際に $f(x) = e^x$ の $x = 0.5$ での微分 ($f'(0.5) = e^{0.5}$) を、刻み幅 h を変えて計算してみましょう。




図 2.3: **Accuracy of numerical derivatives.** Absolute error of $f'(0.5)$ for $f(x) = e^x$ as a function of the step size h .

図 2.3 の前進差分と中心差分はいずれも V 字（対数軸では下に凸）を描きます。右側では打ち切り誤差が、左側では桁落ちによる丸め誤差が支配的です。中心差分の谷の方が前進差分より低く、かつ左寄りにあり、精度が高いことが分かります。

2.2.2 複素ステップ微分

有限差分の弱点は、分子の引き算で生じる桁落ちでした。これを回避するのが**複素ステップ微分** (complex-step differentiation) です。実軸ではなく虚軸方向に微小変位を与えます。

f が複素解析的なとき、 $f(x + ih)$ をテイラー展開すると

$$f(x + ih) = f(x) + ihf'(x) - \frac{h^2}{2}f''(x) - i\frac{h^3}{6}f'''(x) + \dots$$

なので、虚部をとって h で割ると導関数が得られます。

$$f'(x) \approx \frac{\text{Im}(f(x + ih))}{h}, \quad \text{error } O(h^2).$$

この式には**近い2数の引き算が現れない**ため桁落ちが起きず、 h を 10^{-200} のように極端に小さくしても丸め誤差が増えません。図 2.3 の複素ステップの線が、 h を小さくしても機械精度 ($\approx 10^{-16}$) のまま平坦であることがそれを示しています。

```
0.0
```

ただし複素ステップ微分が使えるのは、 f が複素数に対しても解析的に評価できる場合に限られます。絶対値や複素数向けに特別な分岐を持つ関数などには適用できません。

2.2.3 自動微分

有限差分も複素ステップも、あくまで微分の近似でした。**自動微分** (automatic differentiation, AD) は、プログラムが行う演算の連鎖に微分の連鎖律を適用し、導関数を**機械精度で厳密に**求めます。刻み幅 h を選ぶ必要もありません。

前進モードの AD は**双対数** (dual number) $x + \varepsilon$ ($\varepsilon^2 = 0$) を用います。関数に双対数を通すと、テイラー展開の1次で打ち切られて

$$f(x + \varepsilon) = f(x) + f'(x) \varepsilon$$

となり、 ε の係数として導関数がそのまま取り出せます。Julia では `ForwardDiff.jl` がこれを実装しています。

```
(1.6487212707001282, 1.6487212707001282)
```

有限差分の最良ケースでも誤差は 10^{-8} 程度でしたが、自動微分は厳密解と一致します。多変数関数に対しては、勾配やヘッセ行列も同様に求められます。

```
2-element Vector{Float64}:
 16.596707051512663
  6.972909262383508
```

```
2×2 Matrix{Float64}:
 31.3748  21.3349
 21.3349   6.47976
```

第1章で用いた `Roots.jl`, `Optim.jl`, `NonlinearSolve.jl` は、内部でこの `ForwardDiff.jl` による自動微分を利用しています。解析的な勾配を渡さなくても、これらのソルバーが機械精度の導関数を自動で計算してくれるため、多くの場合はそのまま高速・高精度に解くことができます。

2.3 数値積分

以下の定積分を n 個の区間に分割して近似的に計算することを考えます。

$$\int_a^b f(x) dx \simeq \sum_{i=1}^n w_i f(x_i)$$

ここで, w_i は各区間の重み, x_i は各区間の評価点です. この形の積分計算はいくつか方法がありますが, 最も基本的な台形則から紹介します.

2.3.1 台形則 (Trapezoidal Rule)

💡 台形則 (Trapezoidal Rule)

1. 区間 $[a, b]$ を n 個の等間隔の区間に分割する. つまり, $x_i = a + i \cdot \frac{b-a}{n}$ とする.
2. 各区間を台形で近似する. よって近似式は以下ようになる.

$$\int_a^b f(x) dx \simeq \sum_{i=1}^n (x_i - x_{i-1}) \frac{f(x_{i-1}) + f(x_i)}{2}$$




図 2.4: Visualization of Trapezoidal Rule

ここでは, $f(x) = \sqrt{1-x^2}$ の $[0, 1]$ での積分を計算してみましょう. 単位円の $1/4$ の面積であるため, 解析解は $\pi/4$ です.

(0.7853981633974483, 0.7850997945286542, 0.7853888527655861)

100 個の評価点で少数第三位まで, 1000 個の評価点で少数第四位までの精度が得られていることがわかります.

ここで, 式 (1.1) によって意思決定する人々の時間給 w が次のような分布に従っているとします.

$$\log w \sim \mathcal{N}(\mu, \sigma).$$

この時, 平均労働時間を積分によって求めてみましょう.

$$\bar{h} = \int_0^\infty h^*(w) dF(w; \mu, \sigma).$$

ここで, $h^*(w)$ は時給 w の下での最適労働時間, $F(w; \mu, \sigma)$ は w の累積分布関数です. 以下では, この積分をモンテカルロ法とガウス求積の 2 つの方法で計算します.

2.3.2 モンテカルロ法

i モンテカルロ法 (Monte Carlo Method)

確率変数 $X \sim F$ に対する期待値

$$\mathbb{E}[f(X)] = \int f(x) dF(x)$$

を, F から独立に抽出した n 個のサンプル $x_1, \dots, x_n$ を用いて

$$\mathbb{E}[f(X)] \simeq \frac{1}{n} \sum_{i=1}^n f(x_i), \quad x_i \stackrel{\text{i.i.d.}}{\sim} F$$

と近似する. 大数の法則により, $n \rightarrow \infty$ で真の値に収束する. 収束レートは $O(n^{-1/2})$ である.

期待値を求める積分の場合, モンテカルロ法による近似も有効です. 速度は遅いですが, 実装が簡単であり, ガウス求積などの方法による積分の検算などにも利用できます.

0.46987292630609967

2.3.2.1 準モンテカルロ法

i 準モンテカルロ法 (Quasi-Monte Carlo Method)

モンテカルロ法では擬似乱数を用いるのに対し, 準モンテカルロ法では**低食い違い量列** (low-discrepancy sequence) と呼ばれる決定的な点列を用いる. 代表的な低食い違い量列として, Halton 列, Sobol 列, Niederreiter 列などがある.

一様分布 $U[0, 1]$ 上の積分

$$\int_0^1 f(x) dx \simeq \frac{1}{n} \sum_{i=1}^n f(x_i)$$

において, $x_1, \dots, x_n$ を低食い違い量列とすると, 収束レートは $O(n^{-1}(\log n)^d)$ (d は次元) となり, 通常のモンテカルロ法の $O(n^{-1/2})$ より高速に収束する.

低食い違い量列は空間をより均等に埋めるため, 同じサンプル数でもモンテカルロ法より精度の高い近似が得られます. 特に低次元の積分で効果的です. 図 2.5 は, 単位正方形上の 256 点を擬似乱数と Sobol 列で比較したものです.




図 2.5: Pseudo-random draws vs. a Sobol sequence: 256 points on the unit square.

擬似乱数は各点を独立に引くため、偶然の塊と空白ができます。これが分散、ひいては $O(n^{-1/2})$ という遅い収束の源です。一方 Sobol 列は既存の点が埋めていない場所に次の点を置くように設計された決定的な列で、同じ 256 点でも空間をほぼ均等に覆っていることが分かります。

ここでは、逆関数法を用いて、 $[0, 1]$ 上の一様分布の低食い違い量列から対数正規分布のサンプルを生成します。すなわち、 u_i を低食い違い量列の点とすると、 $w_i = F^{-1}(u_i; \mu, \sigma)$ として対数正規分布に従うサンプルを得ます。

ここでは `QuasiMonteCarlo.jl` パッケージを利用して Sobol 列を生成します。

```
0.46986726169921905
```

モンテカルロ法では 10^6 個のサンプルを用いているのに対し、準モンテカルロ法では 10^4 個のサンプルで同等以上の精度が得られていることがわかります。

2.3.3 ガウス求積 (Gaussian Quadrature)

i ガウス求積 (Gaussian Quadrature)

n 次のルジャンドル多項式 $P_n(x)$ の零点を $x_1, \dots, x_n$ とし、 $L_i(x) = \prod_{j \neq i} (x - x_j)$ 、 $w_i = \int_{-1}^1 \frac{L_i(x)}{L_i(x_i)} dx$ とすると、

$$\int_{-1}^1 f(x) dx = \sum_{i=1}^n w_i f(x_i)$$

が任意の $2n - 1$ 次の多項式 $f(x)$ において成り立つ。

この方法は近似値ではなく、 $2n - 1$ 次の多項式に対して**厳密な値**を計算することができるという点で強力です。また、 $f(x)$ が $2n - 1$ 次の多項式で十分近似できる場合、精度の高い計算が可能です。

💡 定義域の変換 (ガウス求積)

`FastGaussQuadrature.jl` 等のパッケージを利用する際には、定義域を $[-1, 1]$ に変換する必要がある。 $x = \frac{b-a}{2}z + \frac{a+b}{2}$ と変換すると

$$\int_a^b f(x) dx = \frac{b-a}{2} \int_{-1}^1 f\left(\frac{b-a}{2}z + \frac{a+b}{2}\right) dz$$

を得られる。

(0.7853981633974483, 0.7855247925013235, 0.7853983068468604)

10 個程度の評価点で少数第三位まで、100 個程度の評価点で少数第六位までの精度が得られていることがわかります。

2.3.3.1 ガウスエルミート求積

ガウス求積は上に挙げたガウス・ルジャンドル求積の他にも、ガウス・エルミート求積などの類似系があります。

i ガウス・エルミート求積 (Gaussian-Hermite Quadrature)

n 次のエルミート多項式 $H_n(x)$ の零点を $x_1, \dots, x_n$ とし、 $w_i = \frac{2^{n-1}n!\sqrt{\pi}}{(nH_{n-1}(x_i))^2}$ とすると、

$$\int_{-\infty}^{\infty} f(x)e^{-x^2} dx \simeq \sum_{i=1}^n w_i f(x_i)$$

被積分関数が e^{-x^2} という部分を持つ場合により高精度に計算することができます。具体的には、正規分布に基づく積分の計算などに利用可能です。 $F(w; \mu, \sigma)$ が対数正規分布であることを利用して、ガウス・エルミート求積を用いて平均労働時間を計算します。

$$\begin{aligned} \bar{h} &= \int_{-\infty}^{\infty} h^*(\exp(y)) d\Phi(y; \mu, \sigma) \\ &= \int_{-\infty}^{\infty} h^*(\exp(y)) \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y-\mu)^2}{2\sigma^2}\right) dy \\ &= \int_{-\infty}^{\infty} h^*(\exp(\sqrt{2}\sigma z + \mu)) \frac{1}{\sqrt{\pi}} \exp(-z^2) dz \\ &\simeq \sum_{i=1}^n w_i h^*(\exp(\sqrt{2}\sigma x_i + \mu)) \frac{1}{\sqrt{\pi}}. \end{aligned} \tag{2.1}$$

ここでは $w = \exp(y)$, $y = \sqrt{2}\sigma z + \mu$ としました。

0.4698575689662558

2.4 AR(1) 過程の離散化

補間と数値微分は「グリッド上の値しか持たない関数」を扱う道具でした。動的計画法 (第3章) ではもう1つ, 「連続な値をとる確率過程」を有限個の状態に近似する操作が必要になります。生産性や所得のショックは AR(1) のような連続状態の過程でモデル化されますが, ベルマン方程式の期待値を計算するには, これを有限状態のマルコフ連鎖に置き換えるのが最も手軽だからです。過程の分布としての性質 (平均・分散・持続性) をできるだけ保ったまま離散化する, これも関数近似の一種です。

以下では次の AR(1) 過程を考えます。

$$x_{t+1} = \mu + \rho x_t + \varepsilon_{t+1}, \quad \varepsilon_{t+1} \sim \mathcal{N}(0, \sigma^2).$$

μ は切片であって定常平均そのものではないことに注意してください。定常平均は $\mathbb{E}[x_t] = \mu/(1 - \rho)$, 定常分散は $\sigma_x^2 = \sigma^2/(1 - \rho^2)$ です。

これを n 個のグリッドポイント $\{x_1, \dots, x_n\}$ におけるマルコフ過程として離散化することを考えます。すなわち, 以下のような遷移確率行列 Π を考えます。

$$\begin{pmatrix} x_{1,t+1} \\ \vdots \\ x_{n,t+1} \end{pmatrix} = \begin{pmatrix} \pi_{1,1} & \cdots & \pi_{1,n} \\ \vdots & \ddots & \vdots \\ \pi_{n,1} & \cdots & \pi_{n,n} \end{pmatrix} \begin{pmatrix} x_{1,t} \\ \vdots \\ x_{n,t} \end{pmatrix}$$

ここで, $\pi_{i,j} = \Pr(x_{t+1} = x_j \mid x_t = x_i)$ であり, $\sum_{j=1}^n \pi_{i,j} = 1$ が成り立ちます。

2.4.1 Tauchen 法


i Tauchen Method

1. x の定義域 $[x_{\min}, x_{\max}]$ を n 個のグリッドポイントに分割する。通常は定常平均 $\mu/(1 - \rho)$ を中心に, 定常標準偏差 σ_x の3倍程度の範囲を考える。
2. グリッドポイント x_i から x_j に遷移する確率を以下のように定義する。

$$\pi_{i,1} = \Phi\left(\frac{x_1 + \frac{d}{2} - \mu - \rho x_i}{\sigma}\right)$$

$$\pi_{i,j} = \Phi\left(\frac{x_j + \frac{d}{2} - \mu - \rho x_i}{\sigma}\right) - \Phi\left(\frac{x_j - \frac{d}{2} - \mu - \rho x_i}{\sigma}\right) \quad (2 \leq j \leq n-1)$$

$$\pi_{i,n} = 1 - \Phi\left(\frac{x_n - \frac{d}{2} - \mu - \rho x_i}{\sigma}\right)$$

図 2.6: Visualization of Tauchen Method. $\mu = 0$.

```
x = -5.8824720161168536:3.4412360080584268:7.8824720161168536
```

```
5x5 Matrix{Float64}:
```

```
0.849051    0.150945    3.84556e-6  1.22125e-15  0.0
0.0194737   0.896192    0.0843336  7.26002e-7   1.11022e-16
1.22258e-7  0.04266     0.91468    0.04266     1.22258e-7
7.34696e-17 7.26002e-7  0.0843336  0.896192    0.0194737
3.45903e-30 1.23783e-15  3.84556e-6  0.150945    0.849051
```

実用上は QuantEcon.jl の tauchen 関数を利用するのがいいでしょう。

```
mc.state_values = -5.8824720161168536:3.4412360080584268:7.8824720161168536
```

```
5x5 Matrix{Float64}:
```

```
0.849051    0.150945    3.84556e-6  1.22125e-15  0.0
0.0194737   0.896192    0.0843336  7.26002e-7   1.11022e-16
1.22258e-7  0.04266     0.91468    0.04266     1.22258e-7
7.34696e-17 7.26002e-7  0.0843336  0.896192    0.0194737
3.45903e-30 1.23783e-15  3.84556e-6  0.150945    0.849051
```

定常平均は $\mathbb{E}[x_t] = \frac{\mu}{1-\rho}$ で、上の例では $\mu = 0.1$, $\rho = 0.9$ としているため $\mathbb{E}[x_t] = 1.0$ となります。

```
1.0
```

2.4.2 Rouwenhorst 法

Tauchen 法は直感的で実装も簡単ですが、2つの近似誤差を持ちます。第一に、グリッドを $\pm n_{std}\sigma_x$ で打ち切るため、裾の確率質量が端の点に押し付けられます。第二に、離散化された連鎖の定常分散と自己相関は、元の AR(1) のそれらと一致しません。このずれは持続性 ρ が高いほど、状態数 n が少な

いほど大きくなります. 代替となるのが Rouwenhorst 法です (Rouwenhorst (1995 年); 持続的な過程に対する優位性の分析は Kopecky と Suen (2010 年)).

i Rouwenhorst 法

AR(1) 過程 $x_{t+1} = \rho x_t + \varepsilon_{t+1}$, $\varepsilon \sim \mathcal{N}(0, \sigma^2)$ を n 状態で離散化する.

1. グリッドは $[-\psi, \psi]$ の等間隔 n 点とする. ただし $\psi = \sigma \sqrt{\frac{n-1}{1-\rho^2}}$.
2. $p = \frac{1+\rho}{2}$ とし, 遷移行列を次の再帰で構成する. $n = 2$ のとき

$$\Pi_2 = \begin{pmatrix} p & 1-p \\ 1-p & p \end{pmatrix}.$$

$k = 3, \dots, n$ について, Π_{k-1} を左上・右上・左下・右下に埋め込んだ 4 つの $k \times k$ 行列の加重和

$$\Pi_k = p \begin{pmatrix} \Pi_{k-1} & \mathbf{0} \\ \mathbf{0}' & \mathbf{0} \end{pmatrix} + (1-p) \begin{pmatrix} \mathbf{0} & \Pi_{k-1} \\ \mathbf{0} & \mathbf{0}' \end{pmatrix} + (1-p) \begin{pmatrix} \mathbf{0}' & \mathbf{0} \\ \Pi_{k-1} & \mathbf{0} \end{pmatrix} + p \begin{pmatrix} \mathbf{0} & \mathbf{0}' \\ \mathbf{0} & \Pi_{k-1} \end{pmatrix}$$

を作り, 中間の行 ($2, \dots, k-1$ 行目) を 2 で割る.

この構成の見返りは, 打ち切りに頼らないことと, 連鎖の性質が厳密に分かることです.

命題 2.1 (Rouwenhorst 法の厳密性). *Rouwenhorst* 法で離散化された連鎖の定常分布は, 二項分布 $B(n-1, 1/2)$ をグリッドに載せたものである. 定常平均・分散・1次自己相関は元の $AR(1)$ の $0, \sigma_x^2 = \sigma^2/(1-\rho^2)$, ρ に厳密に一致し, さらに条件付き期待値も $\mathbb{E}[x' | x] = \rho x$ と厳密に一致する. これらは状態数 n と持続性 ρ の値によらない (証明は Kopecky と Suen (2010 年) を参照).

```
x = [-4.588314677411236, -2.294157338705618, 0.0, 2.294157338705618, 4.588314677411236]
```

```
5x5 Matrix{Float64}:
```

```
0.814506    0.171475    0.0135375    0.000475    6.25e-6
0.0428688    0.821275    0.128963    0.006775    0.00011875
0.00225625    0.085975    0.823538    0.085975    0.00225625
0.00011875    0.006775    0.128963    0.821275    0.0428688
6.25e-6       0.000475    0.0135375    0.171475    0.814506
```

こちらでも実用上は QuantEcon.jl の `rouwenhorst(N, ρ, σ)` が使えます (上の実装と一致します). 2つの方法を, 離散化された連鎖の定常分布の標準偏差と 1 次自己相関で比べてみましょう. 真の値は $\sigma_x = \sigma/\sqrt{1-\rho^2}$ と ρ です.

表 2.1: 離散化された連鎖の定常標準偏差と 1 次自己相関 ($\sigma = 1$)

ρ	n	σ_x (true)	$\hat{\sigma}_x$ (Tauchen)	$\hat{\rho}$ (Tauchen)	$\hat{\sigma}_x \hat{\rho}$ (Rouwenhorst) (Rouwenhorst)
0.9	5	2.29	2.91	0.932	2.29
0.9	7	2.29	2.69	0.902	2.29
0.99	5	7.09	9.65	1.0	7.09
0.99	7	7.09	9.35	1.0	7.09

Tauchen 法は $\rho = 0.9$ ですでに定常標準偏差を 2~3 割過大にし, $\rho = 0.99$ では自己相関がほぼ 1 に張り付いてしまいます. Rouwenhorst 法はどのケースでも厳密です.

Tauchen 法の退化. 図 2.7 は, 状態 x_4 を条件とした x' の分布 $\mathcal{N}(\rho x_4, \sigma^2)$ に, グリッド点と昇目の境界を重ねたものです. Tauchen 法は, この条件付き分布の確率質量を昇目ごとに拾って遷移確率にするのでした. 定常標準偏差 σ_x を固定したまま持続性を上げると, 条件付き分布の幅 $\sigma = \sigma_x \sqrt{1 - \rho^2}$ はどんどん狭くなる一方, 昇目の幅 d はグリッドの設定 (n と n_{std}) だけで決まって動きません. $\rho = 0.99$ では分布がまるごと自分の昇目に収まって $\pi_{44} \approx 1$ となり, どの状態でも同じことが起きるため連鎖はほとんど動けなくなります. これが自己相関の張り付きの正体です. 逆に ρ が中程度でも, 昇目が粗ければ「最寄りのグリッドに丸める」ことで余分な分散が每期加わり, 定常分散が過大になります (表 2.1 の $\hat{\sigma}_x$ の列). この退化の正確な主張と証明は Kopecky と Suen (2010 年) を参照してください.




図 2.7: Why Tauchen breaks down: the conditional density vs. the grid cells.

持続性の高い過程を扱うとき, そして**データから推定した (ρ, σ) をそのまま離散化に渡すとき** (このとき離散化のずれは推定と数値解法の不整合として推定結果を歪めます) は, Rouwenhorst 法を使うのが安全です.

第3章

動的計画法

Dynamic Programming

3.1 ベルマン方程式の数値解法

以下の無限期間代表的個人のモデルを考えます.

$$\max_{\{c_t, k_{t+1}\}_{t=0}^{\infty}} \sum_{t=0}^{\infty} \beta^t u(c_t) \quad \text{s.t.} \quad c_t + k_{t+1} = f(k_t) + (1 - \delta)k_t.$$

これをベルマン方程式 $V(k)$ に書き換えた時の数値解法を考えます.

$$V(k) = \max_{k'} \{u(f(k) + (1 - \delta)k - k') + \beta V(k')\}$$

大きく分けて, 2つの方法があります.

1. Value Function Iteration

- ベルマン方程式の不動点を直接求める方法
- 収束性が保証されているが, 収束速度は比較的遅い

2. Policy Function Iteration

- 政策関数の不動点を求める方法
- 収束性は保証されていないが, 収束速度は比較的速い

数値計算に用いるために, 以下の関数形とパラメータを仮定します.

- $u(c) = \log c$
- $f(k) = k^\alpha$
- $\beta = 0.96$
- $\delta = 0.1$
- $\alpha = 0.36$

3.1.1 Value Function Iteration

i Value Function Iteration

1. k の定義域 $[k_{\min}, k_{\max}]$ を n 個のグリッドポイントに分割する.
2. $V(k)$ の初期値 V^0 を適当に設定する. つまり, $V^0 = (V_0^0, V_1^0, \dots, V_n^0)$ に適当な値を設定する.
3. V^0 をベルマン方程式の右辺に代入し, 各 k_i に対して V_i^1 を計算する.
4. 2-3 を繰り返す. 収束条件は以下のように設定する.
 - $|V^N - V^{N-1}| < \varepsilon$
 - $|V^N - V^{N-1}|$ はベクトルのノルム
 - ε は十分小さな値を設定する. 例えば, $\varepsilon = 10^{-6}$ とする

なおこのような収束の閾値 ε を tolerance と呼ぶことがあります.

Converged in 306 iterations.




図 3.1: Value Function Iteration.

なお, 各イタレーションでは, k に対する最適な k' や c を求めています. それらを記録しておくことで, 政策関数 $c = h(k)$ や $k' = g(k)$ を求めることができます.

収束の可視化

スライダー (Iteration N) を動かすと, 各反復での価値関数 $V^N(k)$ (実線) が不動点 (灰色の破線) へ収束していく様子を確認できます.

```
//| label: ojs-load
//| echo: false
vfi_path = FileAttachment("static/data/vfi_iterations.csv").csv({typed: true})
vfi_dist = FileAttachment("static/data/vfi_distance.csv").csv({typed: true})
n_iter = d3.max(vfi_path, d => d.iter)
```

```

y_domain = d3.extent(vfi_path, d => d.V)
pow10 = (d) => {
  const e = Math.round(Math.log10(d));
  const digits = Math.abs(e).toString().split("")
    .map(c => "0123456789"[+c]).join("");
  return "10" + (e < 0 ? "-" : "") + digits;
}

```

```

//| label: ojs-slider
//| echo: false
viewof iter = {
  const input = Inputs.range([0, n_iter],
    {step: 1, value: 0, label: "Iteration N", width: 420});
  input.style.fontSize = "17px";
  return input;
}

```

```

//| label: ojs-fig-value
//| echo: false
Plot.plot({
  width: 620,
  height: 400,
  marginLeft: 62,
  marginBottom: 52,
  style: {fontSize: "16px"},
  x: {label: "Capital k"},
  y: {label: "Value V(k)", domain: y_domain},
  marks: [
    Plot.line(vfi_path.filter(d => d.iter === n_iter),
      {x: "k", y: "V", stroke: "#cccccc",
        strokeDasharray: "4 3", strokeWidth: 2}),
    Plot.line(vfi_path.filter(d => d.iter === iter),
      {x: "k", y: "V", stroke: "#0f6a81", strokeWidth: 3}),
    Plot.text(['N = ${iter}'],
      {frameAnchor: "bottom-right", dx: -10, dy: -10,
        fontSize: 20, fontWeight: 600})
  ]
})

```

```

///| label: ojs-fig-distance
///| echo: false
Plot.plot({
  width: 620,
  height: 280,
  marginLeft: 62,
  marginBottom: 52,
  style: {fontSize: "16px"},
  x: {label: "Iteration N"},
  y: {
    label: " $\|V^N - V^{N-1}\|_\infty$ ",
    type: "log",
    ticks: [1, 1e-2, 1e-4, 1e-6],
    tickFormat: pow10
  },
  marks: [
    Plot.line(vfi_dist,
      {x: "iter", y: "dist", stroke: "#c2676d", strokeWidth: 2}),
    Plot.ruleY([1e-6], {stroke: "gray", strokeDasharray: "2 2"}),
    Plot.dot(vfi_dist.filter(d => d.iter === iter),
      {x: "iter", y: "dist", fill: "#0f6a81", r: 6})
  ]
})

```

3.1.2 Policy Function Iteration

上記のベルマン方程式から、以下のオイラー方程式が導出されます。

$$u'(c) = \beta u'(c')(f'(k') + (1 - \delta)). \quad (3.1)$$

ここで消費 c を選ぶと、来期の資本は予算制約 $k' = f(k) + (1 - \delta)k - c$ で決まり、来期の消費は政策関数を通じて $c' = h(k')$ で与えられます。

この政策関数 h を反復的に更新します。反復 N での推定政策 $h^N = (h_1^N, \dots, h_n^N)$ はグリッド点 $\{k_i\}$ 上でしか値を持たないので、これを補間して連続な関数 $\tilde{h}^N(k)$ に拡張します。補間は線形でもスプラインでもよく、グリッド点では $\tilde{h}^N(k_i) = h_i^N$ を満たします。この $\tilde{h}^N$ を来期の政策としてオイラー方程式の右辺に代入すると、各グリッド点 k_i に対して、今期の消費 c を未知数とする次の方程式が得られます。

$$\begin{aligned} u'(c) &= \beta u'(\tilde{h}^N(k'))(f'(k') + 1 - \delta), \\ k' &= f(k_i) + (1 - \delta)k_i - c. \end{aligned} \quad (3.2)$$

右辺の $\tilde{h}^N$ は前の反復から既知なので、これは c に関する 1 本の非線形方程式です。これを解いた解が更新後の政策 h_i^{N+1} であり、政策が変化しなくなるまで反復すれば政策関数の不動点が得られます。

i Policy Function Iteration

1. k の定義域 $[k_{\min}, k_{\max}]$ を n 個のグリッドポイントに分割する。
2. 政策関数の初期値 $h^0 = (h_1^0, \dots, h_n^0)$ を適当に設定する。
3. 現在の政策 h^N を補間して、連続な関数 $\tilde{h}^N$ を作る。各グリッド点 k_i について 式 (3.2) を今期の消費 c について解き、その解を h_i^{N+1} とする。
4. 3 を繰り返す。収束条件は以下のように設定する。
 - $|h^{N+1} - h^N| < \varepsilon$
 - $|h^{N+1} - h^N|$ はベクトルのノルム
 - ε は十分小さな値を設定する。例えば、 $\varepsilon = 10^{-6}$ とする

実装では、補間 $\tilde{h}^N$ を `h_itp` として表します。これは 1 回の反復の中では変化しないので、反復の冒頭で一度だけ構築し、その反復内のすべての `find_zero` の評価で使い回します (`euler_eq` には政策のベクトルではなく、この構築済みの `h_itp` を渡します)。ここでは補間に `linear_interpolation` を使っていますが、スプライン補間などに差し替えても構いません。

Converged in 76 iterations.




図 3.2: Policy Function Iteration.

収束の可視化

スライダー (Iteration N) を動かすと、各反復での政策関数 $h^N(k)$ (実線) が不動点 (灰色の破線) へ収束していく様子を確認できます。

```
//| label: pfi-load
//| echo: false
```

```
pfi_path = FileAttachment("static/data/pfi_iterations.csv").csv({typed: true})
pfi_dist = FileAttachment("static/data/pfi_distance.csv").csv({typed: true})
n_iter_pfi = d3.max(pfi_path, d => d.iter)
y_domain_pfi = d3.extent(pfi_path, d => d.h)
```

```
///| label: pfi-slider
///| echo: false
viewof iter_pfi = {
  const input = Inputs.range([0, n_iter_pfi],
    {step: 1, value: 0, label: "Iteration N", width: 420});
  input.style.fontSize = "17px";
  return input;
}
```

```
///| label: pfi-fig-value
///| echo: false
Plot.plot({
  width: 620,
  height: 400,
  marginLeft: 62,
  marginBottom: 52,
  style: {fontSize: "16px"},
  x: {label: "Capital k"},
  y: {label: "Policy h(k)", domain: y_domain_pfi},
  marks: [
    Plot.line(pfi_path.filter(d => d.iter === n_iter_pfi),
      {x: "k", y: "h", stroke: "#cccccc",
        strokeDasharray: "4 3", strokeWidth: 2}),
    Plot.line(pfi_path.filter(d => d.iter === iter_pfi),
      {x: "k", y: "h", stroke: "#0f6a81", strokeWidth: 3}),
    Plot.text(['N = ${iter_pfi}'],
      {frameAnchor: "top-left", dx: 12, dy: 12, fontSize: 20, fontWeight: 600})
  ]
})
```

```
///| label: pfi-fig-distance
///| echo: false
Plot.plot({
  width: 620,
```

```

height: 280,
marginLeft: 62,
marginBottom: 52,
style: {fontSize: "16px"},
x: {label: "Iteration N"},
y: {
  label: " $\|h^N - h^{N-1}\|_\infty$ ",
  type: "log",
  ticks: [1, 1e-2, 1e-4, 1e-6],
  tickFormat: pow10
},
marks: [
  Plot.line(pfi_dist.filter(d => d.dist > 0),
    {x: "iter", y: "dist", stroke: "#c2676d", strokeWidth: 2}),
  Plot.ruleY([1e-6], {stroke: "gray", strokeDasharray: "2 2"}),
  Plot.dot(pfi_dist.filter(d => d.iter === iter_pfi && d.dist > 0),
    {x: "iter", y: "dist", fill: "#0f6a81", r: 6})
]
})

```

価値関数の復元

ここから $k' := g(k) = f(k) + (1 - \delta)k - h(k)$ が求められます. さらに, $h(k), g(k)$ から価値関数 $V(k)$ を求める方法は主に2つあります.

1. $V(k) \leftarrow u(h(k)) + \beta V(g(k))$ を用いて $V(k)$ の不動点を求める方法 (VFI)
2. 線形方程式

i 価値関数の復元 (線型方程式)

1. 離散化された k から k' への遷移行列 P を求める. グリッド k_i が k_j と k_{j+1} の間に遷移する場合, 以下のように定義する.

- $P_{i,j} = \frac{k_{j+1} - g(k_i)}{k_{j+1} - k_j}$
- $P_{i,j+1} = \frac{g(k_i) - k_j}{k_{j+1} - k_j}$
- $P_{i,k} = 0, \quad k \neq j, j+1$

2. u, V を $u(h(k)), V(k)$ からなる離散化されたベクトルとすると

$$V = u + \beta PV.$$

3. $V = (I - \beta P)^{-1}u$ により V を求める.

ここでは, より高速な線型方程式を用いる方法を実装します. より速度を求める場合, 遷移行列はほとんどの要素がゼロであるため, 疎行列 (Sparse Matrix) を用いることで高速化する可能性があります. Julia の場合, `SparseArrays.jl` で実装されています.




図 3.3: Value Function from PFI and Linear Equation.

また, VFI よりも PFI の方が収束速度が速いことも確認できますが, 実行速度も速いことも確認できます.

BenchmarkTools.Trial: 67 samples with 1 evaluation per sample.


Range (min ... max):	74.414 ms ... 75.507 ms	GC (min ... max):	0.00% ... 0.00%
Time (median):	74.854 ms	GC (median):	0.00%
Time (mean ± σ):	74.873 ms ± 209.810 μs	GC (mean ± σ):	0.00% ± 0.00%



Memory estimate: 278.22 KiB, allocs estimate: 614.

BenchmarkTools.Trial: 129 samples with 1 evaluation per sample.

Range (min ... max):	38.665 ms ... 40.279 ms	GC (min ... max):	0.00% ... 0.00%
Time (median):	38.955 ms	GC (median):	0.00%
Time (mean ± σ):	38.971 ms ± 208.909 μs	GC (mean ± σ):	0.03% ± 0.20%



Memory estimate: 461.69 KiB, allocs estimate: 324.

3.1.3 Endogenous Grid Method

PFI では各グリッド点でオイラー方程式という非線形の方程式の求根していました. Endogenous Grid Method (EGM) (Carroll 2006 年) は, この求根を避ける高速な政策関数反復です. アイデアは, 今期の資本 k をグリッドに固定するのではなく, 来期の資本 k' をグリッドに固定し, オイラー方程式と予算制約を後ろ向きに解くことです.

来期消費の政策 $c' = h(k')$ を所与とすると, オイラー方程式 ((3.1)) から今期の消費 c は閉形式で求められます.

$$c = (u')^{-1}(\beta u'(h(k'))(f'(k') + 1 - \delta)).$$

次に予算制約から今期の資本 k を求めます. 資源関数 $m(k) := f(k) + (1 - \delta)k$ とすると, 予算制約は $c + k' = m(k)$ となるので, これを k について解くと

$$k = m^{-1}(c + k').$$

なお, $m(k)$ は明らかに単調なので, 逆関数 m^{-1} は一意に定まります. また, m^{-1} は反復の前に決定されているので, 一度だけ計算しておけば良いです. これを用いることで, (c, k) の組を求めることができ, グリッド上の点に保管することで, 新しい政策関数 $g(\cdot)$ を構築できます.

i Endogenous Grid Method

1. 来期資本 k' のグリッドを固定し, 資源関数の逆関数 $m^{-1}(\cdot)$ を一度だけ構築する.
2. 政策関数の初期値 $h^0 = (h_1^0, \dots, h_n^0)$ を適当に設定する.
3. 政策 $\tilde{h}^N(k')$ を所与に, 各グリッド点 k'_j について
 - オイラー方程式から今期消費 $c_j = (u')^{-1}(\beta u'(h(k'_j))(f'(k'_j) + 1 - \delta))$ を求める.
 - 予算制約から今期資本 $k_j = m^{-1}(c_j + k'_j)$ を求める.
4. 内生グリッド (k_j, c_j) を補間して, 固定グリッド上の新しい政策 $h^{N+1}(k)$ を得る.
5. 政策が収束するまで 3-4 を繰り返す.

Converged in 76 iterations.





図 3.4: Endogenous Grid Method.

VFI, PFI と同じ政策関数が得られます. EGM は反復の中で求根を行わないため, さらに高速です.

BenchmarkTools.Trial: 8705 samples with 1 evaluation per sample.

Range (min ... max):	532.583 μ s ... 2.195 ms	GC (min ... max):	0.00% ... 72.93%
Time (median):	565.583 μ s	GC (median):	0.00%
Time (mean $\pm$ σ):	574.084 μ s $\pm$ 75.463 μ s	GC (mean $\pm$ σ):	1.63% $\pm$ 6.20%



Memory estimate: 465.31 KiB, allocs estimate: 332.

3.2 確率的なモデル

前節では決定論的な動学モデルを扱いました. ここでは確率的な不確実性を導入します. 生産関数 $f(k, z) = zk^\alpha$ とし, 生産性 z が確率的に変化するモデルを考えます. 生産性 z は以下のような AR(1) 過程に従うとします.

$$\log z' = (1 - \rho)\mu + \rho \log z + \sigma \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, 1).$$

この時, ベルマン方程式は以下のように書き換えられます.

$$V(k, z) = \max_{k'} \{u(f(k, z) + (1 - \delta)k - k') + \beta \mathbb{E}[V(k', z') | z]\}.$$

この $V(k, z)$ を数値計算するためには, z の状態空間を離散化する必要があります. 離散化には 2.4 節 で学んだ Rouwenhorst 法を使います. これは持続性の高い AR(1) 過程でも定常分散と自己相関を

厳密に一致させられるため, Tauchen 法より望ましい選択です. `QuantEcon.jl` の `rouwenhorst` が返す遷移行列を Π と書きます.

```
mc.state_values = -3.588314677411236:2.294157338705618:5.588314677411236
```

```
5×5 Matrix{Float64}:
 0.814506  0.171475  0.0135375  0.000475  6.25e-6
 0.0428688 0.821275  0.128963  0.006775  0.00011875
 0.00225625 0.085975  0.823537  0.085975  0.00225625
 0.00011875 0.006775  0.128963  0.821275  0.0428688
 6.25e-6    0.000475  0.0135375  0.171475  0.814506
```

`rouwenhorst` の引数の AR(1) の定義 (切片 μ の扱い) と, 過程の平均を任意の値に設定する方法は 2.4 節 を参照してください.

3.2.1 Value Function Iteration

AR(1) process を Π で離散化した後のベルマン方程式は以下のようになります.

$$V(k, z) = \max_{k'} \left\{ u(f(k, z) + (1 - \delta)k - k') + \beta \sum_{z'} \pi(z' | z) V(k', z') \right\}.$$

VFI を用いる場合, 実装は価値関数 V の次元を z のために 1 つ増やし, ベルマン方程式の通り実装するだけです. 資本のグリッドは決定論的なモデルと揃えて $[1, 10]$ とします.⁵

```
Converged in 306 iterations.
```

⁵生産性 z ごとの定常状態は $k^*(z) = \left(\frac{z\alpha}{1/\beta - 1 + \delta} \right)^{\frac{1}{1-\alpha}}$ です. ここでの設定では $z \in [0.76, 1.32]$ に対して $k^*(z) \in [3.6, 8.9]$ となり, グリッド $[1, 10]$ に収まります. とくに後述の PFI はオイラー方程式を解くため, グリッドが定常状態を含んでいることが重要です.




図 3.5: Value Function of Stochastic Model.

3.2.2 Policy Function Iteration

PFI も同じように拡張できます. 不確実性の下でのオイラー方程式は, 来期の生産性 z' についての期待値を取る形になります.

$$\begin{aligned}
 u'(c) &= \beta \mathbb{E}[u'(c')(f_k(k', z') + 1 - \delta) \mid z] \\
 &= \beta \sum_{z'} \pi(z' \mid z) u'(\tilde{h}(k', z'))(f_k(k', z') + 1 - \delta).
 \end{aligned} \tag{3.3}$$

決定論的な場合 (式 (3.2)) との違いは 2 点だけです. 第一に, 政策関数が $h(k, z)$ と 2 変数になるため, 補間は生産性の状態ごとに 1 本ずつ, 計 n_z 本の $\tilde{h}(\cdot, z')$ を作ります. z はグリッド上の有限個の状態しか取らないので, 補間が必要なのは k の方向だけです. 第二に, 右辺が $\pi(z' \mid z)$ による期待値になります. なお予算制約 $k' = f(k, z) + (1 - \delta)k - c$ に入るのは今期の z である点に注意してください.

Converged in 77 iterations.




図 3.6: Policy Function Iteration (Stochastic).

価値関数の復元

PFI が返すのは政策関数 $h(k, z)$ です. 決定論的な場合と同じ線形方程式で価値関数 $V(k, z)$ を復元できます. 政策から来期資本 $g(k, z) = f(k, z) + (1 - \delta)k - h(k, z)$ を求め, (k, z) 上の遷移行列 P を作ります. 資本方向は $g(k, z)$ を挟む 2 つのグリッド点に補間で振り分け, 生産性方向は $\pi(z' | z)$ で遷移させます. すると $V = (I - \beta P)^{-1}u$ で価値関数が求まります.




図 3.7: Value function recovered from the PFI policy (stochastic model).

3.2.3 Endogenous Grid Method

EGM も確率的なモデルに自然に拡張できます. 来期の資本 k' をグリッド上に固定し, 各生産性 z についてオイラー方程式 (式 (3.3)) の右辺を評価すると, 今期の消費 c が求根なしに求まります.

$$c = (u')^{-1} \left(\beta \sum_{z'} \pi(z' | z) u'(\tilde{h}(k', z')) (f_k(k', z') + 1 - \delta) \right).$$

この c から資源制約 $c + k' = zk^\alpha + (1 - \delta)k$ を k について解けば内生グリッドが得られます. 決定論的な場合との違いは2点だけです. 第一に, 右辺が $\pi(z' | z)$ による期待値になります. 第二に, 資源制約の左辺 $M(k, z) = zk^\alpha + (1 - \delta)k$ が今期の z に依存するので, その逆関数 $M^{-1}(\cdot, z)$ を生産性の状態ごとに1本ずつ用意します.

Converged in 77 iterations.




図 3.8: Endogenous Grid Method (Stochastic).

決定論的な場合と同様に, EGM は求根も期待値の内側での最適化も要らず, PFI と同じ政策関数により少ない計算コストで到達します.

3.3 Aiyagari モデル

数値計算を行う最大のモチベーションは, 異質な個人を扱うということです. コアマクロで扱った, Ramsey 型の代表的個人モデルを自然に拡張したものが Aiyagari モデルです (Aiyagari 1994 年).

3.3.1 モデル

質量 1 の連続体の家計が存在します. 各家計は無限期間生存し, 割引因子 $\beta \in (0, 1)$ で期待効用を最大化します.

$$\mathbb{E}_0 \sum_{t=0}^{\infty} \beta^t u(c_t), \quad u(c) = \frac{c^{1-\gamma}}{1-\gamma}.$$

ここで $\gamma > 0$ は相対的リスク回避度です。各家計は労働生産性 z_t という個別ショック (idiosyncratic shock) に直面します。これは家計ごとに独立であり、大数の法則によって経済全体では平均化されるため、マクロの集計的な不確実性 (Aggregate shock) はありません。 z_t は AR(1) 過程に従います。

$$\log z_{t+1} = \rho \log z_t + \sigma \varepsilon_{t+1}, \quad \varepsilon_{t+1} \sim \mathcal{N}(0, 1).$$

ここで $\rho \in (-1, 1)$ なので z_t は定常なマルコフ過程です。その定常分布関数を $\Phi(z)$ 、遷移分布関数を $\Pi(z' | z) = \Pr(z_{t+1} \leq z' | z_t = z)$ と書きます。将来の期待値 $\mathbb{E}[\cdot | z]$ はこの Π に関する積分です。

家計が保有できる資産は単一の安全資産 a_t のみです。実質賃金 w と実質利子率 r を所与として、予算制約は

$$c_t + a_{t+1} = wz_t + (1+r)a_t$$

で与えられます。市場が不完備なのは、家計が z_t の変動を保険できる資産がこの 1 種類しかないためです。さらに、家計は無制限には借入できず、借入制約 (borrowing constraint)

$$a_{t+1} \geq -\underline{a}, \quad \underline{a} \geq 0$$

に直面します。 $\underline{a} = 0$ ならば借入は一切できず、資産は非負に限られます。以下ではこの場合を考えます。

3.3.2 家計の動的計画問題

状態変数は手持ちの資産 a と生産性 z の組 (a, z) です。予算制約から消費を $c = wz + (1+r)a - a'$ と書けるので、価値関数 $V(a, z)$ は価格 (r, w) を所与として、次のベルマン方程式を満たします。

$$V(a, z) = \max_{a' \geq -\underline{a}} \{u(wz + (1+r)a - a') + \beta \mathbb{E}[V(a', z') | z]\}. \quad (3.4)$$

この解を貯蓄の政策関数 $a' = g(a, z)$ と消費の政策関数 $c(a, z)$ とします。

この問題は、借入制約を除けば、これまでの代表的個人の問題と同じ構造であり、VFI・PFI・EGM のいずれでも解けます。以下では、オイラー方程式を求根なしに解ける EGM を用います。

借入制約が内点解となる ($a' > -\underline{a}$ の) 領域では、一階条件としてオイラー方程式が成立します。制約が拘束する可能性まで含めると、次の相補性条件 (Kuhn-Tucker 条件) になります。

$$u'(c(a, z)) \geq \beta(1+r) \mathbb{E}[u'(c(a', z')) | z]. \quad (3.5)$$

等式は $a' > -\underline{a}$ のとき成立します。

i 予備的貯蓄 (precautionary saving)

CRRA 効用は $u'''(c) > 0$ を満たす。このとき、イェンセンの不等式から将来消費の不確実性は限界効用の期待値 $\mathbb{E}[u'(c')]$ を引き上げる。式 (3.5) の右辺が大きくなるため、家計は現在の消費を抑えて余分に貯蓄する誘因を持つ。これを予備的貯蓄と呼ぶ。これは保険が完備な経済には存在しない、市場の不完備性に固有の貯蓄動機である。

3.3.3 企業と価格

生産側は、コブ・ダグラス型生産関数 $Y = K^\alpha L^{1-\alpha}$ を持つ代表的企業で記述されます。 δ を資本減耗率とすると、競争市場での利潤最大化条件 (要素価格 = 限界生産性) から、価格は資本労働比 K/L の関数として決まります。

$$r = \alpha \left(\frac{K}{L} \right)^{\alpha-1} - \delta, \quad w = (1-\alpha) \left(\frac{K}{L} \right)^\alpha \quad (3.6)$$

逆に解くと、利子率 r から企業の資本需要が定まります。

$$K^d(r) = L \left(\frac{\alpha}{r+\delta} \right)^{\frac{1}{1-\alpha}}, \quad w(r) = (1-\alpha) \left(\frac{\alpha}{r+\delta} \right)^{\frac{\alpha}{1-\alpha}}. \quad (3.7)$$

労働は非弾力的に供給され、総労働は生産性の定常分布での平均 $L = \int z d\Phi(z)$ に等しくなります。以下では生産性を基準化して $L = 1$ とします。

3.3.4 定常均衡

家計が政策関数 $g(a, z)$ に従って動くと、状態 (a, z) の分布が経済全体に生まれます。その分布が時間を通じて不変になったものが定常分布です。

i 定常一般均衡 (Stationary Recursive Competitive Equilibrium)

価格 (r, w) 、価値関数 V 、政策関数 g 、そして (a, z) の同時分布関数 $\Lambda(a, z) = \Pr(a_t \leq a, z_t \leq z)$ の組が、次を満たすとき定常均衡という。

1. **家計最適化:** (V, g) は所与の (r, w) のもとで 式 (3.4) を解く。
2. **企業最適化:** (r, w) は 式 (3.6) を満たす。
3. **分布の定常性:** Λ は政策 g とショックの遷移 Π のもとで不変である。すなわち、任意の $(a', z') \in [-\underline{a}, \infty) \times \mathbb{R}_{++}$ に対して、

$$\Lambda(a', z') = \int \mathbf{1}\{g(a, z) \leq a'\} \Pi(z' | z) d\Lambda(a, z).$$

右辺は、今期 Λ に従う家計のうち、貯蓄が a' 以下で、かつ生産性が z' 以下に遷移する家計の割合である。借入制約に張り付く家計の質量は $a = -\underline{a}$ での Λ のジャンプとして現れる。

4. **資産市場の清算:** 家計の総資産供給が企業の資本需要に等しい。

$$\underbrace{\int a d\Lambda(a, z)}_{\text{asset supply } A(r)} = \underbrace{K^d(r)}_{\text{capital demand}}. \quad (3.8)$$

代表的個人モデル (完備市場) では、定常状態で必ず $1+r = 1/\beta$ 、すなわち $r = 1/\beta - 1$ が成立しました。Aiyagari モデルの核心は、不完備市場では均衡利子率がこれより低くなることです。

$$r^* < \frac{1}{\beta} - 1.$$

i 市場が完備な場合

完備市場とは、個別状態 z のあらゆる実現に対して支払いが条件づけられた証券 (Arrow 証券) を家計が自由に売買できる状況を指す。本モデルには集計的な不確実性がない (個別ショックは多数の法則で平均化される) ため、個別リスクは完全に分散可能である。したがって均衡では完全なリスク分散 (perfect risk sharing) が達成され、各家計の消費は個別状態 z に依存しなくなる。

これを家計の問題で見る。完備市場では予算制約が生涯の一本の異時点間制約に統合され、状態ごとの借入制約 $a' \geq -\underline{a}$ は均衡で拘束しない。このとき 式 (3.5) は等号で成立し、さらにリスク分散により c_{t+1} が確実 (個別状態によらず一定) になるので、右辺の期待値が外れて

$$u'(c_t) = \beta(1+r) u'(c_{t+1})$$

となる。集計的な不確実性も成長もない定常状態では消費は一定 $c_t = c_{t+1}$ なので $u'(c_t) = u'(c_{t+1})$ となり、

$$1 = \beta(1+r) \Leftrightarrow r = \frac{1}{\beta} - 1.$$

すなわち均衡利子率は時間選好率にちょうど一致する。これは、集計量が代表的個人の新古典派成長モデルと同じ修正黄金律に従うことの帰結でもある。完備市場では予備的貯蓄の動機が消えるため、資産供給曲線 $A(r)$ は 図 3.11 の不完備市場の曲線よりも左に位置し、 $r = 1/\beta - 1$ で初めて発散する。不完備市場の均衡 r^* がその手前に来るのは、この予備的貯蓄の分だけ供給が右に膨らむためである。

直観は予備的貯蓄にあります。家計は保険できない所得リスクに備えて自衛的に貯蓄するため、 r が $1/\beta - 1$ より低くても正の純資産を持とうとします。その結果、資産供給 $A(r)$ は右上がりです。一方、資本需要 $K^d(r)$ は 式 (3.7) より右下がりです。両者の交点である均衡 r^* は、必ず $1/\beta - 1$ の手前に来ます。

3.3.5 数値解法

均衡の探索は、利子率 r に関する一次元の求根問題に帰着します。与えられた r に対して家計の問題を解いて資産供給 $A(r)$ を集計し、式 (3.8) の超過需要 $A(r) - K^d(r)$ がゼロになる r を探します。

💡 Aiyagari モデルの解法

外側ループ (一般均衡): 超過需要 $A(r) - K^d(r) = 0$ を r について解く. $A(r)$ は次の手順で評価する.

1. r を所与として, 式 (3.7) から賃金 $w(r)$ を計算する.
2. 内側ループ (家計): EGM でオイラー方程式 (式 (3.5)) を解き, 貯蓄の政策 $g(a, z)$ を得る.
3. 政策 g のもとで分布の更新式を反復し, 定常分布 Λ を求める.
4. 総資産 $A(r) = \int a d\Lambda$ を集計する.

$A(r)$ は r について増加, $K^d(r)$ は減少するので, 超過需要は単調増加である. したがって二分法 (1.1 節) が安定に使える.

生産性ショックの離散化

モデルは連続な生産性 z で書きましたが, 数値計算では状態空間を有限にする必要があります. 生産性の AR(1) 過程 $\log z' = \rho \log z + \sigma \varepsilon$ は, 2.4 節の Rouwenhorst 法で n_z 状態のマルコフ連鎖 $\{z_1, \dots, z_{n_z}\}$ と遷移確率 $\pi(z' | z)$ に離散化します. これにより Π に関する積分は有限和に置き換わり, 条件付き期待値は

$$\mathbb{E}[V(a', z') | z] = \int V(a', z') d\Pi(z' | z) \approx \sum_{z'} \pi(z' | z) V(a', z')$$

と評価できます. 生産性の定常分布 Φ は遷移行列の不変分布に, 家計の定常分布 Λ は資産グリッドと生産性グリッド上の確率質量 (コードの λ) に対応し, 定常性の条件はその質量の更新式になります. ここでは QuantEcon.jl の rouwenhorst と, 遷移行列の不変分布を求める stationary_distributions をそのまま使います.

パラメータの設定

モデルのパラメータと, 状態空間 (資産グリッドと生産性グリッド) を AiyagariModel にまとめます. 借入制約 $a \geq 0$ の近くで政策関数が大きく曲がるため, 資産グリッドは原点付近を密にとります.⁶ 生産性は不変分布での平均が 1 になるよう基準化し, 総労働を $L = 1$ とします.

家計の問題 (内側ループ)

オイラー方程式 (式 (3.5)) を EGM で解きます. 手順は 3.2 節と同じで, 新しいのは借入制約の扱いだけです. 内生グリッドの下端 $a_{\text{endog}}[1]$ は $a' = 0$ を選ぶ家計に対応するので, 手持ち資産がこれより小さい家計では制約が拘束します. その領域では $a' = 0$ に張り付き, 消費は予算制約から $c = wz + (1+r)a$ となります.

定常分布の計算 (滑らかな分布のための工夫)

EGM が返す貯蓄政策 $g(a, z)$ は補間で構成された滑らかな連続関数ですが, その返り値 a' は資産グリッドの点とは限りません. これを最近傍のグリッド点に丸めて分布を更新すると, 到達可能な少数の点だけに質量が集中し, 分布がギザギザになります. そこで抽選 (lottery) を使います. 政策が返す a'

⁶(range(0, 1, length=na)).^2 のように $[0, 1]$ の等間隔点を二乗することで, 原点付近に点を集めたグリッドを作っています.

が隣り合うグリッド点 $a_j \leq a' < a_{j+1}$ の間に落ちるとき, その家計の質量を重み ω で 2 点に按分します (lottery). 重みは, 抽選の期待値がもとの a' に一致するように決めます.

$$\omega a_j + (1 - \omega) a_{j+1} = a' \Leftrightarrow \omega = \frac{a_{j+1} - a'}{a_{j+1} - a_j}.$$

a' が a_{j+1} に近いほど a_{j+1} に多くの質量が割り当てられます. これは非確率的シミュレーション (Young 2010 年) として知られ, 離散グリッド上で連続的な分布を精度よく近似します.

一般均衡 (外側ループ)

与えられた r に対する超過需要 $A(r) - K^d(r)$ を関数にまとめ, Bracketing method でゼロ点を求めます. 上限は完備市場の利子率 $1/\beta - 1$ のすぐ手前に置きます.

```
r_star = 0.025369305928548195
complete_market = 0.04166666666666674
K_star = 6.819175158799509
```

均衡利子率 $r^* \approx 0.025$ は, 完備市場の値 $1/\beta - 1 \approx 0.042$ を明確に下回っています. これが Aiyagari モデルの中心的な結果であり, 予備的貯蓄による過剰な資本蓄積を反映しています.

3.3.6 結果

貯蓄の政策関数

均衡 r^* における貯蓄の政策関数 $a' = g(a, z)$ を生産性ごとに描きます. 低生産性の家計は手持ち資産を取り崩し ($a' < a$), 高生産性の家計は資産を積み増します. 借入制約 $a' = 0$ が拘束するのは $z_{\min}$ の家計の $a \lesssim 0.03$ の範囲だけで, 資産の全域 ($a \leq 50$) に比べると非常に狭いため, 右のパネルで原点付近を拡大しています. 労働所得の下限 $wz_{\min} \approx 0.37$ が正である限り, 無資産の家計でも消費を賄えるので, 制約が効く領域はこの程度に留まります.




図 3.9: Savings policy function $a' = g(a, z)$. 破線は 45 度線 $a' = a$. 右は原点付近の拡大.

資産の定常分布

定常分布を資産について周辺化すると, 富の分布が得られます. ヒストグラムにするときは集計の仕方に注意が必要です. 資産グリッドは原点付近を密にとっているので, 各グリッド点の質量を素朴に等

間隔ビンへ足し込むと、ビンに入るグリッド点の数が場所によって2個や3個と変わり、分布の性質ではない凹凸が出ます。そこで各グリッド点の質量を、その点が代表する区間（隣接点との中点で区切った幅）とビンの重なりに応じて按分します。借入制約上の質量は幅を持たない点質量なので、最初のビンにそのまま入れます。




図 3.10: **Stationary distribution of assets.** 幅 0.5 のビンに集計した資産の周辺分布. $a = 0$ のビンの質量が借入制約に張り付く家計にあたる。

資本の需要と供給

最後に, Aiyagari モデルを象徴する図を描きます。利子率 r の各値に対して資産供給 $A(r)$ と資本需要 $K^d(r)$ を計算し、縦軸に r 、横軸に資本をとります。供給曲線は右上がりて $r \rightarrow 1/\beta - 1$ の水平線に漸近し、需要曲線は右下がりです。両者の交点が均衡で、完備市場の利子率より低い位置にあります。




図 3.11: **Capital supply and demand.** 灰破線は完備市場の利子率 $1/\beta - 1$, 点は均衡 (K^*, r^*) .

図 3.11 が示すように、不完備市場では均衡利子率が完備市場の水準を下回り、それに伴って資本ストックが過剰に蓄積されます。これは、個別リスクを保険できないことの帰結として生じる、効率性の損失と内生的な富の不平等を同時に表しています。

第4章

GMM

Generalized Method of Moments

構造推定 (structural estimation) では、経済モデルのパラメータ θ を、モデルがデータをよく再現するように定めます。その代表的な方法が、モデルの最適化条件 (一階条件) から導かれるモーメント条件を使う一般化モーメント法 (GMM) です。この章では、前半でモーメント条件を個票の上で直接評価できる場合の GMM と、モーメントがパラメータを定めるかという識別の問題、そして推定量の標準誤差を扱います。後半では、モデル側の対応物が数値的にしか計算できない場合を扱います。これは最小距離推定 (minimum distance estimation)、モデル側をシミュレーションで評価するなら SMM と呼ばれますが、モーメント条件の書き方が違うだけで、やはり GMM の一種です。家族経済学では、家計内の配分や交渉力といった直接観察できない対象を推定するためにこれらの手法が広く使われます。

4.1 一階条件による GMM

データ $\{x_i\}_{i=1}^N$ と、真のパラメータ θ_0 のもとで期待値がゼロになるモーメント条件 $\mathbb{E}[g(x_i, \theta_0)] = \mathbf{0}$ が与えられたとします。典型的には g は最適化の一階条件で、複数の条件を束ねてベクトルにできます。その標本版 $\bar{g}_N(\theta) = \frac{1}{N} \sum_i g(x_i, \theta)$ を可能な限りゼロに近づける θ を選ぶのが GMM です。

i GMM 推定量

GMM 推定量 $\hat{\theta}^{\text{GMM}}$ は、正定値の重み行列 W に対して、次のように定義される：

$$\hat{\theta}^{\text{GMM}} := \arg \min_{\theta} \bar{g}_N(\theta)^{\top} W \bar{g}_N(\theta).$$

パラメータ数と同じだけモーメント条件があれば (丁度識別, just-identified), W に依らず $\bar{g}_N(\hat{\theta}) = \mathbf{0}$ となる。モーメント条件の方が多い場合 (過剰識別, over-identified) は W が推定効率に影響し、最適な W はモーメントの分散共分散行列の逆行列である。

4.1.1 推定量の性質

まず漸近分布です。GMM 推定量は、観測が定常かつエルゴード的であれば一致性と漸近正規性を持ちます (Hansen 1982 年)。その漸近分散は、ヤコビアン G とモーメントの分散共分散行列 V から計算できます。

命題 4.1 (GMM 推定量の漸近分布). モーメント条件 $\mathbb{E}[g(x_i, \theta_0)] = \mathbf{0}$ が正しく、 θ_0 が識別され、標準的な正則条件が成り立つとする。 $G = \partial \mathbb{E}[g]/\partial \theta^{\top}$ ($p \times k$), $V = \lim_{N \rightarrow \infty} \text{Var}(\sqrt{N} \bar{g}_N(\theta_0))$ とおくと、

$$\sqrt{N}(\hat{\theta} - \theta_0) \xrightarrow{d} \mathcal{N}\left(\mathbf{0}, (G^\top W G)^{-1} G^\top W V W G (G^\top W G)^{-1}\right). \quad (4.1)$$

特に $W = V^{-1}$ のとき、分散は $(G^\top V^{-1} G)^{-1}$ に簡約され、これが W の選び方の中で最小になる (効率的 GMM)。

証明は Newey と McFadden (1994 年) などを参考にしてください。式 (4.1) は、重み行列 W の選び方が推定量の効率を左右することを言っています。最適なのは $W = V^{-1}$ ですが、ここに循環があります。 $V = \lim_N \text{Var}(\sqrt{N} \bar{g}_N(\theta_0))$ は真値のまわりで定義される量なので、 V を推定するには θ の推定値が必要です。一方、効率的に θ を推定するには V が必要です。この鶏と卵の順番を決めるのが 2 段階 GMM です。

i 2 段階 GMM

1. 第 1 段階. 適当な正定値行列 (基本は $W = I$) を使って最小化し、 $\hat{\theta}_1$ を得る。効率的ではないが一致推定量である。
2. 重み行列の推定. モーメント条件が独立同時分布なら、 $\hat{S} = \frac{1}{N} \sum_i g(x_i, \hat{\theta}_1) g(x_i, \hat{\theta}_1)^\top$ が V の一致推定量になる。
3. 第 2 段階. $W = \hat{S}^{-1}$ で最小化し直す。これが効率的 GMM 推定量で、その漸近分散は $\frac{1}{N} (G^\top V^{-1} G)^{-1}$ である。

実務上の注意が 2 つあります。第一に、第 1 段階の $W = I$ はモーメントの単位に依存する恣意的な選択です。スケールの大きく違うモーメントを混ぜるときは、各モーメントを標本標準偏差で割った対角行列を第 1 段階に使うほうが安定します。第二に、 $\hat{S}$ は $p \times p$ の行列を N 個の観測から推定したものです。モーメントの本数が多く標本が小さいと $\hat{S}^{-1}$ の推定誤差が大きくなり、漸近的には効率的なはずの第 2 段階が、有限標本ではかえって悪い推定量になることが知られています。共分散構造の推定でこの小標本バイアスを詳しく調べたのが Altonji と Segal (1996 年) です。その場合は非対角成分を捨てて対角の重みで済ませる、という保守的な選択がよく採られます。この章の後半 (4.2 節) で使うのがまさにそれです。

最後に、効率的な重み行列にはおまけがついてきます。最小化された目的関数そのものが検定統計量になるのです。モーメントがパラメータより多いとき、すべてのモーメントを同時にゼロにはできません。その「残り」がモデルと整合的な大きさに収まっているかを見るのが過剰識別の検定です。

i 過剰識別の検定 (Hansen の J)

$W = \hat{V}^{-1}$ のとき、最小化された目的関数に N を掛けたものは、 p 本のモーメント条件がすべて正しいという帰無仮説の下で自由度 $p - k$ の χ^2 分布に従う。

$$J = N \bar{g}_N(\hat{\theta})^\top \hat{V}^{-1} \bar{g}_N(\hat{\theta}) \xrightarrow{d} \chi^2(p - k)$$

J が棄却したときに分かるのは、「 p 本のモーメント条件を 1 つの θ で同時に満たせない」ということだけで、どれが誤っているのかは教えてくれません。原因の候補は、モデルの定式化の誤り、モーメント条件そのもの (たとえば操作変数の外生性) の誤り、標本の偶然、そして標本の大きさの 4 つです。最

後は見落とされがちですが重要で、現実のモデルはどれも近似なので、 N が大きくなるほど J はごく小さな定式化の誤りにも反応し、たいていのモデルは棄却されます。

そこで実務では、推定値における各モーメントのずれ $\bar{g}_j(\hat{\theta})$ を標準誤差で割って並べ、どの条件が外れているのかを見ます。外れたモーメントが特定できれば、次に疑うのはその式を支えている経済的な仮定です。そのうえで、モデルを一般化するか、問題のモーメントを推定から落とすか、棄却を報告したうえで結果を示すかを選ぶことになります。2 番目は手軽に見えますが、落とすと識別が壊れることがあるので、どのモーメントがどのパラメータを支えているかを知らないままでは選べません。逆に、検定を通ったからモデルが正しいということにもなりません。識別が弱ければ検出力もないからです。Andrews ほか (2017 年) が推定値の感応度を報告することを勧めるのも、検定の可否だけでモデルを評価する慣行への処方箋でした。検定は診断の入口であって結論ではない、というくらいの距離感が実務的です。

4.1.2 モデル

GMM の真価は、閉じた形の回帰式に落ちない複数の非線形な最適化条件をまとめてモーメント条件にできる点にあります。Lise と Yamada (2019 年) は、夫と妻の個人別消費・時間配分のパネルデータを使い、家計内の資源配分を特徴づける一階条件の体系を非線形 GMM で推定しています。ここでは、そのモデルの最小限のトイモデルを作ります。

家計は妻 W と夫 H からなります。メンバー $j \in \{W, H\}$ は、自分の私的消費 c_j と自分の余暇 ℓ_j から効用を得ます。効用関数は、 c_j と ℓ_j の CES 集計を CRRA で包んだ形とします。

$$u_j(c_j, \ell_j) = \frac{1}{1 - \sigma_j} \left[\alpha_j c_j^{\phi_j} + (1 - \alpha_j) \ell_j^{\phi_j} \right]^{\frac{1 - \sigma_j}{\phi_j}}. \quad (4.2)$$

α_j は消費と余暇の相対的な選好、 ϕ_j は両者の代替の弾力性 ($= 1/(1 - \phi_j)$) を決めます。ここでは、妻と夫の選好に異質性があることが許容されています ($\alpha_W \neq \alpha_H$, $\phi_W \neq \phi_H$)。

家計は効率的に資源を配分する (collective model) とし、妻への Pareto ウェイトを $\mu \in (0, 1)$ とします。資産 a を状態変数として、家計の動的な問題は次の価値関数で書けます。

$$V(a) = \max_{c_W, \ell_W, c_H, \ell_H, a'} \mu_W u_W(c_W, \ell_W) + \mu_H u_H(c_H, \ell_H) + \delta \mathbb{E}V(a'), \quad (4.3)$$

subject to

$$c_W + c_H + w_W \ell_W + w_H \ell_H + a' = w_W + w_H + (1 + r)a =: y.$$

各メンバーの時間の賦存量を 1 に基準化し、余暇を自分の賃金 w_j で評価しています。右辺の y は full income です。また、 $\mu_W, \mu_H \in (0, 1)$ は、家計内の交渉力を表す Pareto ウェイトで、 $\mu_W + \mu_H = 1$ です。

4.1.2.1 モーメント条件

予算制約のラグランジュ乗数を λ とすると、内点解での一階条件は次のようになります。

$$\mu \frac{\partial u_j}{\partial c_j} = \lambda, \quad \mu \frac{\partial u_j}{\partial \ell_j} = \lambda w_j, \quad j \in \{W, H\}, \quad (4.4)$$

$$\lambda = \delta \mathbb{E}V'(a') \quad (\text{Euler equation}).$$

ここで λ は 富の限界価値 (marginal value of wealth) で, 家計の効率的な配分を特徴づける共通の尺度です. すべての一階条件は λ を含むので, 式 (4.4) の比を取ると λ が消え, 家計内の配分の条件が残ります.

(1) 各メンバーの期内 MRS 条件. $j \in \{W, H\}$ について, 消費と余暇の比を取ると λ も μ も消えます.

$$\frac{\alpha_j}{1 - \alpha_j} \left(\frac{c_j}{\ell_j} \right)^{\phi_j - 1} = \frac{1}{w_j}. \quad (4.5)$$

(2) 家計内の消費配分条件. 妻と夫の消費の一階条件の比を取ると, λ が消えて μ が残ります.

$$\mu_W \frac{\partial u_W}{\partial c_W} = \mu_H \frac{\partial u_H}{\partial c_H}. \quad (4.6)$$

余暇についての同様の条件は 式 (4.5) と 式 (4.6) から導かれるので, 独立な条件はこの3本です.

i なぜオイラー方程式を使わないのか

式 (4.3) は動的な問題なので, オイラー方程式 $\lambda = \delta \mathbb{E}V'(a')$ も一階条件の一部です. しかし Lise と Yamada (2019 年) は, これを推定にあえて使いません. 理由は2つあります.

第一に, **頑健性**です. 流動性制約に直面する家計ではオイラー方程式は成立しませんが, 期内条件 式 (4.5)・式 (4.6) は制約の有無に関わらず成立します. 効率的な配分でありさえすればよいからです.

第二に, **識別**です. 異時点間の代替の弾力性 (すなわち σ_j) を信頼できる形で識別するには, 家計が直面する金利の変動を使う必要があります. しかし家計パネルには通常そうした情報がありません. そこで Lise と Yamada (2019 年) は先行研究にならい $\sigma_W = \sigma_H = 1.5$ に固定します. 以下でも同じく $\sigma_j = 1.5$ を既知として扱い, 残りのパラメータ ($\phi_W, \phi_H, \alpha_W, \alpha_H, \mu$) を推定します.

式 (4.5) と 式 (4.6) の対数を取り, $A_j := \alpha_j c_j^{\phi_j} + (1 - \alpha_j) \ell_j^{\phi_j}$ とおくと,

$$\begin{aligned} e_{ji} &= \log \frac{\alpha_j}{1 - \alpha_j} + (\phi_j - 1) \log \frac{c_{ji}}{\ell_{ji}} + \log w_{ji} & j \in \{W, H\}, \\ e_{3i} &= \log \frac{\mu}{1 - \mu} + \log \frac{\alpha_W}{\alpha_H} + \frac{1 - \sigma_W - \phi_W}{\phi_W} \log A_{W_i} - \frac{1 - \sigma_H - \phi_H}{\phi_H} \log A_{H_i} \\ &\quad + (\phi_W - 1) \log c_{W_i} - (\phi_H - 1) \log c_{H_i}. \end{aligned}$$

モデルが正しければ, これらの残差は平均ゼロになります. つまり, $\mathbf{e}_i := (e_{Wi}, e_{Hi}, e_{3i})^\top$ に対して, $\mathbb{E}[\mathbf{e}_i] = \mathbf{0}$ です. ただし, これだけではパラメータ5個に対して3本のモーメントしかなく, 識別できません. そこで, 残差と賃金の直交条件を加えます. 賃金は外生なので, モデルが正しければ残差と相関しないはずで.

ただし, どの賃金でもよいわけではありません. 賃金にも測定誤差が乗るからです. 観測される賃金を $w_{ji} = w_{ji}^* e_{ji}^w$ とすると, 式 (4.5) の残差には $\log w_{ji}$ がそのまま入っているので, e_{ji} は測定誤差 ϵ_{ji}^w を含みます. 自分の賃金を掛けた条件 $\mathbb{E}[e_{ji} \log w_{ji}]$ は, 残差と操作変数の両方に同じ誤差が入るぶん

だけゼロから外れます。一方、配偶者の賃金なら測定誤差は独立なので直交条件は成り立ちます。残差 e_{3i} には賃金が入らないので、こちらは両方の賃金を使えます。使えるモーメントは 7 本です。

$$\begin{aligned}\mathbb{E}[e_{Wi}(1, \log w_{Hi})^\top] &= \mathbf{0}, \\ \mathbb{E}[e_{Hi}(1, \log w_{Wi})^\top] &= \mathbf{0}, \\ \mathbb{E}[e_{3i}(1, \log w_{Wi}, \log w_{Hi})^\top] &= \mathbf{0}.\end{aligned}\tag{4.7}$$

自分の賃金を捨てるぶん、曲率 ϕ_j の情報は減ります。パネルデータがあれば、測定誤差が時点間で独立であることを使って 1 年前の賃金を操作変数にでき、情報を取り戻せます。Lise と Yamada (2019 年) が実際に採っているのがこの戦略です。

4.1.2.2 データ

真値を Lise と Yamada (2019 年) の推定値に近い水準に取り、 $N = 4000$ 世帯の人工的なクロスセクションデータを作ります。

$$(\phi_W, \phi_H, \alpha_W, \alpha_H, \mu) = (0.2, 0.6, 0.45, 0.55, 0.45).$$

データ生成過程 (DGP) は次の通りです。まず、各家計 i の賃金を対数正規分布から独立に引き、フルインカムを定めます。

$$\begin{aligned}\log w_{Wi} &\sim \mathcal{N}(-0.15, 0.15^2), \\ \log w_{Hi} &\sim \mathcal{N}(0, 0.15^2), \\ y_i &= 1.05(w_{Wi} + w_{Hi}).\end{aligned}$$

次に、真の賃金とフルインカムを所与として、真の配分 (c_{ji}^*, ℓ_{ji}^*) を一階条件 式 (4.5)・式 (4.6) と予算制約から閉じた形で解きます。最後に、消費・余暇・賃金に乗法的な測定誤差を乗せたものを「観測値」とします。

$$c_{ji} = c_{ji}^* e^{\varepsilon_{ji}^c}, \quad \ell_{ji} = \ell_{ji}^* e^{\varepsilon_{ji}^\ell}, \quad w_{ji} = w_{ji}^* e^{\varepsilon_{ji}^w}, \quad \varepsilon_{ji}^c, \varepsilon_{ji}^\ell \stackrel{\text{iid}}{\sim} \mathcal{N}(0, 0.03^2), \quad \varepsilon_{ji}^w \stackrel{\text{iid}}{\sim} \mathcal{N}(0, 0.01^2).$$

賃金の測定誤差は消費や余暇より小さく取っていますが、大きさは問題ではありません。どれだけ小さくても、自分の賃金は操作変数として無効になります。

5x7 DataFrame

Row	id	wW	wH	cW	cH	lW	lH
	Int64	Float64	Float64	Float64	Float64	Float64	Float64
1	1	0.915595	1.08042	0.425136	0.783264	0.596384	0.362711
2	2	0.99009	0.975259	0.43097	0.694002	0.542136	0.438244
3	3	0.701922	0.905238	0.332111	0.532203	0.617971	0.421421
4	4	1.10593	1.22219	0.492344	0.91595	0.587731	0.334796
5	5	0.87725	1.17662	0.413801	0.769628	0.630747	0.309514




図 4.1: **Preference heterogeneity.** The intra-temporal MRS condition (式 (4.5)) in logs. The slope identifies ϕ_j and is free of the Pareto weight.

図 4.1 から識別の直観が得られます。 $\log(c_j/l_j)$ を $\log w_j$ に対して描くと直線に乗り、その傾き $1/(1 - \phi_j)$ が夫と妻で異なることが、選好の異質性を直接示しています。

4.1.3 推定

式 (4.7) の 7 本のモーメントでパラメータ 5 個を推定します。過剰識別 ($p = 7 > k = 5$) なので、4.1.1 節 の手順どおり 2 段階で最小化します。最適化は `Optimization.jl` の共通インターフェース (第 1 章) で行い、微分を使わない Nelder–Mead (NLopt の `LN_NELDERMEAD`) を呼びます。パラメータの制約 $\phi_j < 1$, $\alpha_j, \mu \in (0, 1)$ は、変数変換ではなく箱制約 `lb / ub` としてソルバーに渡します。

点推定が出たら、次はその精度です。2 段階目の重み行列に $W = \hat{S}^{-1}$ を使ったので、これは 命題 4.1 の効率的なケースに当たり、分散は $(G^\top V^{-1} G)^{-1} / N$ に簡約されます。材料は 2 つです。ヤコビアン $\hat{G}$ は数値微分 (2.2 節) で計算し、 $\hat{S}$ はモーメントの標本第 2 モーメント $\frac{1}{N} \sum_i g(x_i, \hat{\theta}) g(x_i, \hat{\theta})^\top$ を推定値 $\hat{\theta}$ で評価し直したものを uses。

表 4.1: 2 段階 GMM の推定値と標準誤差

パラメータ	推定値	標準誤差	真値
ϕ_W	0.195	0.0071	0.2
ϕ_H	0.5983	0.0052	0.6
α_W	0.4494	0.00078	0.45
α_H	0.5502	0.00065	0.55
μ	0.45	0.00018	0.45




図 4.2: **GMM estimates.** Dot: point estimate. Horizontal bar: 95% confidence interval. Dashed line: true value. Each panel has its own scale.

5つのパラメータはどれも真値のごく近くに帰っています。選好の曲率 (ϕ_W, ϕ_H) と選好の水準 (α_W, α_H) は夫婦で異なる値が、そして家計内の交渉力 μ も、それぞれ正しく推定されています。複数の非線形な期条件をまとめてモーメント条件にすることで、選好と交渉力が同時に識別されるわけです。これが Lise と Yamada (2019 年) が実際の家計パネルで行っている構造推定の核となる仕組みです。⁷

図 4.2 で目を引くのは、信頼区間の幅がパラメータによってまるで違うことです (パネルごとに横軸の目盛りが違うことに注意してください)。 ϕ_W の標準誤差だけが飛び抜けて大きく、推定値に対する

⁷Mazzocco (2007 年) は逆に、家計のオイラー方程式を使って家計内のコミットメントを検定します。Lise と Yamada (2019 年) が期条件のみを使うのは、その検定が流動性制約と区別できないという問題を避けるためです。

比で見ると ϕ_H の4倍, α_H の30倍あります. なぜ妻の曲率だけが決まりにくいのか. その答えは次項の識別の分析にあります.

この人工データで攪乱の源になっているのは測定誤差だけなので, 標準誤差の絶対水準は実際の推定より小さく出ます. 現実のデータでは, 選好の異質性や最適化の誤差など, モデルが説明しない変動がもっと大きいからです.

4.1.4 識別

ここまでの推定では, 最小化がうまくいけばパラメータが求まる, ということを暗黙の前提にしてきました. しかしその前提には, そもそもモーメントがパラメータを一意に定めるのかという問いが隠れています. これが識別 (identification) の問題です. どれだけ標本を増やしても区別できないパラメータは, どんな推定法でも推定できません.

推定の入力「パラメータからモーメントへの写像」 $m(\theta) = \mathbb{E}[g(x_i, \theta)]$ でした. 識別はこの写像が反転できるかという問いとして書けます.

i 識別

モーメント写像 $m: \Theta \rightarrow \mathbb{R}^p$ (p 本のモーメント, k 個のパラメータ) に対して,

- **大域識別:** $m(\theta) = m(\theta_0)$ ならば $\theta = \theta_0$.
- **局所識別:** ヤコビアン $G = \frac{\partial m(\theta_0)}{\partial \theta^\top}$ ($p \times k$ 行列) のランクが k (ランク条件) であれば, θ_0 の近傍で識別される.

ランク条件が成り立つには少なくとも $p \geq k$ (次数条件) が必要である.

4.1.4.1 ランク条件は何を言っているのか

ランク条件の中身は, いちばん簡単な線形の例で見るのが早いです. パラメータが2つ $\theta = (\theta_1, \theta_2)^\top$, モーメントが2本で, モーメント写像がちょうど線形 $m(\theta) = G\theta$ だとします. 推定とは, データから得た $\hat{m}$ に対して連立1次方程式 $G\theta = \hat{m}$ を解くことです.

まず, ランクが2の場合.

$$\begin{pmatrix} m_1 \\ m_2 \end{pmatrix} = \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix} \begin{pmatrix} \theta_1 \\ \theta_2 \end{pmatrix} \Rightarrow \theta_1 = \frac{m_1 + m_2}{2}, \quad \theta_2 = \frac{m_1 - m_2}{2}.$$

2本の式は独立な情報を持っているので, 逆に解けます. モーメント m_1 は2つのパラメータの和を, m_2 は差を教えてくれる. 和と差が分かれば, もとの2つは決まります.

次に, ランクが1の場合.

$$\begin{pmatrix} m_1 \\ m_2 \end{pmatrix} = \begin{pmatrix} 1 & 1 \\ 2 & 2 \end{pmatrix} \begin{pmatrix} \theta_1 \\ \theta_2 \end{pmatrix}.$$

2本目の式は1本目をちょうど2倍しただけで, 新しい情報を持っていません. モーメントは2本あるのに ($p = 2 \geq k = 2$ で次数条件は満たされているのに), 決まるのは和 $\theta_1 + \theta_2$ だけです. (θ_1, θ_2) を

$(\theta_1 + t, \theta_2 - t)$ とずらしてもモーメントは 1 ミリも動かないので, $(1, -1)$ 方向についてデータは何も言っていない. これがランク落ちです.⁸

非線形なモデルでも, 真値の近くでは $m(\theta) \approx m(\theta_0) + G(\theta - \theta_0)$ と 1 次近似できるので, 局所識別は結局この連立方程式が解けるかという問題に帰着します. これがランク条件の意味です.

4.1.4.2 識別の強さを特異値で測る

ここまでは「解ける・解けない」という 0/1 の話でした. しかし実際に数値計算の場面で遭遇するのは, その中間である「解けはするが, ほとんど解けていない」という状態です. 上のランク 1 の例で, 2 本目の式の係数を $(2, 2)$ から $(2, 2.001)$ にずらしてみます. 2 本の式はもう平行ではないので, ランクは 2 に戻り, 連立方程式は一意に解けます. それでも実質的に何も推定できていない, というのがこれから見ることです. ランクという離散的な判定ではなく, 「いちばん効かない方向でも, モーメントはどれだけ動くのか」という連続的な量が要ります. それを与えるのが特異値分解です.

i 特異値分解

$p \times k$ 行列 G ($p \geq k$) は, 列が正規直交な U ($p \times k$) と直交行列 V ($k \times k$) を使って

$$G = U \Sigma V^T, \quad \Sigma = \text{diag}(s_1, \dots, s_k), \quad s_1 \geq \dots \geq s_k \geq 0$$

と分解できる. s_j を特異値, V の第 j 列 v_j を右特異ベクトルという. $Gv_j = s_j u_j$ であり, u_j は単位ベクトルだから, s_j は「パラメータを v_j 方向に 1 単位動かしたときにモーメントが動く大きさ」である. 一般に

$$\max_{\|v\|=1} \|Gv\| = s_1, \quad \min_{\|v\|=1} \|Gv\| = s_k$$

で, 最小は最終列 v_k で達成される. したがって

- $s_k > 0 \Leftrightarrow \text{rank } G = k$: どの方向に動かしてもモーメントが動く (局所識別される),
- $s_k = 0 \Leftrightarrow Gv_k = \mathbf{0}$: v_k 方向にはモーメントがまったく動かない (ランク落ち),
- s_k が s_1 に比べて極端に小さい: v_k 方向にはほとんど動かない (弱識別).

さきほどの 2 つの G に, 2 行目を $(2, 2.001)$ にずらしたものを加えた 3 つで計算します.

表 4.2: 3 つの G の特異値と右特異ベクトル (1 行目はどれも $(1, 1)$)

G の 2 行目	ランク	s_1	s_2	s_1/s_2	v_2
$(1.0, -1.0)$	2	1.414	1.41	1.0	$(-0.0, -1.0)$
$(2.0, 2.001)$	2	3.163	0.000316	10000.0	$(-0.707, 0.707)$
$(2.0, 2.0)$	1	3.162	8.23e-17	3.84e16	$(-0.707, 0.707)$

1 行目は素直なケースです. 特異値が 2 つとも $\sqrt{2} \approx 1.41$ で, どの方向に動かしてもモーメントは同じだけ動きます (特異値が等しいので, 「いちばん効かない方向」を 1 つに決める意味はありません).

3 行目のランク落ちのケースを見ると, s_2 はちょうどゼロではなく 10^{-17} 程度の値になっています. 解析的にはゼロですが, 浮動小数点の計算に厳密なゼロはめったに現れません. ランクの判定が「ゼロ

⁸もっと露骨なランク落ちもあります. G のある列がまるごとゼロ, つまりそのパラメータがモーメントにまったく現れない場合です. この後の 図 4.4 で μ の列を見ると, MRS 条件の行がちょうどそうなっています.

とみなす閾値」に依存してしまうのはこのため、これも特異値そのものを見たい理由の1つです。 v_2 は $(1, -1)/\sqrt{2}$, つまり先ほど「ずらしてもモーメントが動かない」と言った方向そのものです。この章でこの後 `svd(G).V[:, end]` を「識別できない方向」として何度も読むのは、これを見えています。

そして中央が本題です。ランクは2で、連立方程式は一意に解けます。しかし $s_2 = 3.2 \times 10^{-4}$ で、 s_1 の1万分の1しかありません。 $v_2 = (1, -1)/\sqrt{2}$ 方向にパラメータを1動かしても、モーメントは0.00032しか動かない。逆に言えば、モーメントのわずかな誤差が、この方向に沿ってパラメータの巨大な誤差に翻訳されます。真値を $\theta_0 = (1, 1)$ として、2本目のモーメントだけを0.001ずらしたデータを与えてみます。

表 4.3: モーメントを0.001ずらしたときの解 (真値は $\theta_0 = (1, 1)$)

G の 2 行目	$\hat{\theta}_1$	$\hat{\theta}_2$
(1.0, -1.0)	1.0005	0.9995
(2.0, 2.001)	0.0	2.0

素直なケースでは0.001のずれは0.0005のずれにしかありません。弱識別のケースでは、同じ0.001が $\hat{\theta} = (0, 2)$ という、真値から $(-1, +1)$ も離れた解を生みます。モーメントの誤差が1000倍に増幅されたわけです ($1/s_2 \approx 3000$ 倍が上限で、その方向にほぼ全部乗っています)。ランク条件は満たされ、ソルバーはエラーも警告も出さず、一意の答えを返します。それでもこの推定値には何の意味もありません。ランク条件が教えてくれるのは識別の必要条件だけで、推定が実質的に可能かどうかを決めているのは最小特異値の大きさです。

目的関数 $\|G(\theta - \theta_0)\|^2$ の等高線を描くと、このことがそのまま図形になります。等高線は $v_1, \dots, v_k$ を軸とする楕円で、軸の長さは $1/s_j$ に比例します。特異値が小さい方向ほど楕円は細長く伸び、 $s_k = 0$ では無限に伸びて平行な溝になります。




図 4.3: **What the rank condition means.** Contours of $\|G(\theta - \theta_0)\|^2$ around the truth, for the three G of 表 4.2. The middle panel has full rank, but is indistinguishable from the rank-deficient one.

左は同心円で、底が1点に定まっています。右は平行な溝で、谷底に沿ってどこまで動いても目的関数の値は変わりません。そして中央は、目で見ると右と区別が付きません。実際には v_2 方向にも $(3.2 \times 10^{-4})^2$ の傾きがあり、谷は $|\theta - \theta_0| \sim 3000$ のはるか遠方で閉じているのですが、この縮尺では平らな溝と同じものです。弱識別が厄介なのは、この「ほとんど平ら」が、数値的にはランク落ちと変わらない振る舞いをするからです。

最適化アルゴリズムは谷底のどこかで問題なく「収束」します。どこに止まるかを決めているのは初期値と丸め誤差です。4.1.3 節 で見た標準誤差の大きさは、この平らさの裏返しです。

大域識別を確かめる一般的な方法はなく、目的関数を複数の初期値から最小化して同じ解に収束するかを見る、といった間接的な確認に頼ることになります。一方、局所識別のランク条件はヤコビアンを数値微分 (2.2 節) で計算すれば機械的に確認できます。しかも識別の分析はデータの実現値をほとんど必要とせず、候補となるパラメータ値でモデルを微分するだけなので、推定の前にモデルとモーメントの設計を点検する道具になります。

4.1.4.3 設計を点検する

標準誤差を計算するときに、7 本のモーメントの 5 つのパラメータに関するヤコビアン $\hat{G}$ を数値微分で求めてありました。同じものを識別の点検に使い回します。目的関数と同じ距離で測るため、行を各モーメントの標準誤差で割り、列をパラメータの値でスケールしたうえで、特異値を見ます。

```
5-element Vector{Float64}:  
 8760.0  
 4070.0  
 2230.0  
 108.0  
 15.6
```

特異値は 5 つともゼロから明確に離れており、ランク条件は満たされています。前節の推定がうまくいったのは幸運ではなかったわけです。

ランク落ちや弱い識別の症状は、推定を回しても見えにくいことに注意してください。目的関数は識別できない方向に沿った**平らな谷**になり、最適化は谷底のどこかで正常に収束します。複数の初期値も同じ谷に落ちるだけのことがあるので、大域識別の間接チェックすら失敗を検出できるとは限りません。識別の分析は推定より先に済ませられるのだから、**推定を回す前に**特異値を確認するのが定石です。

4.1.4.4 どのモーメントがどのパラメータを識別するか

ヤコビアンには、ランク条件の成否以上の情報が詰まっています。「パラメータを 1% 動かしたとき、各モーメントが標準誤差の何倍動くか」を行列として可視化すると、どのモーメントがどのパラメータの情報源かが一目で分かります。

Moment	$e_W \times 1$	-1.5	0.0	32.1	0.0	0.0
	$e_W \times \ln w_H$	0.0	0.0	-0.0	0.0	0.0
	$e_H \times 1$	0.0	9.5	0.0	70.6	0.0
	$e_H \times \ln w_W$	0.0	-6.6	0.0	-49.0	0.0
	$e_3 \times 1$	-0.7	-1.1	14.6	-9.1	23.4
	$e_3 \times \ln w_W$	0.7	0.8	-10.7	6.4	-16.3
	$e_3 \times \ln w_H$	0.0	-0.7	-0.0	2.7	-0.0
		ϕ_W	ϕ_H	α_W	α_H	μ
		Parameter				

図 4.4: Which moment identifies which parameter? Elasticity of each moment with respect to each parameter.

図 4.4 は見事なブロック構造をしています。妻の MRS 条件 (e_W の行) は (ϕ_W, α_W) だけを、夫の行は (ϕ_H, α_H) だけを動かし、 μ の列は e_3 の行にしか値を持ちません。各自の MRS 条件は一階条件の比をとって λ と一緒に μ も消した式 (式 (4.5)) なので、交渉力の情報は夫婦の限界効用を突き合わせる式 (4.6) だけが持っているのです。各自の選好は各自の MRS 条件から、交渉力は夫婦間の条件から、という識別の分業が、行列の形としてそのまま見えています。 $e_W \times \ln w_H$ の行がまるごとゼロなのは、2つの賃金が独立で、しかも夫の対数賃金の平均がゼロだからです。この条件は有効 (残差と直交する) ではありますが、パラメータをまったく動かさないで情報を持っていません。操作変数が有効であることと、有益であることは別だということです。感応度を定量化して見せるこの種の分析は、Andrews ほか (2017 年) が構造推定の透明性のために提案したものと同一発想であり、モーメントの取捨選択の指針になります。

4.1.4.5 過剰識別の検定

4.1.1 節の J 統計量を計算します。効率的な重み行列 $\hat{S}^{-1}$ は前項で作ったものをそのまま使います。モーメントが 7 本、パラメータが 5 個なので、自由度は $7 - 5 = 2$ です。

$J = 1.39$ $\chi^2(2)$ の 5% 臨界値 = 5.99 p 値 = 0.498

J は臨界値を大きく下回り、過剰識別の制約はデータと整合的です。データをモデルから作ったのだから当然ではありますが、実装が意図どおり動いていることの確認にはなります。前項で述べたとおり、検定が通ったからといってモデルが正しいと結論できるわけではありません。

念のため、推定値における 7 本のずれも標準誤差で割って見ておきます。棄却されたときに最初にやる作業を、通ったときにも一度やっておく、というだけのことです。

表 4.4: 推定値におけるモーメントごとのずれ

モーメント	$\bar{g}_j(\hat{\theta})$	標準誤差	t
$e_W \times 1$	6.6e-7	0.00057	0.0
$e_W \times \log w_H$	-7.0e-5	8.5e-5	-0.83
$e_H \times 1$	-4.9e-6	0.00031	-0.02
$e_H \times \log w_W$	4.2e-5	6.9e-5	0.61
$e_3 \times 1$	-2.0e-5	0.00078	-0.03
$e_3 \times \log w_W$	-2.4e-5	0.00017	-0.14
$e_3 \times \log w_H$	-2.8e-5	0.00012	-0.24

どの条件も標準誤差 1 個分に収まっていて、特定の式だけが外れているということはありません。⁹

この節のモーメントは、すべて観測データとパラメータの解析的な式でした。しかしそれが成り立ったのは、一階条件が閉じた形で書け、しかもそこに現れる変数がすべて観測できたからです。モデルの含意が数値的にしか出せない場合や、モデルに観測できない変数が入る場合には、この経路は閉じます。それが次節 (4.2 節) の主題です。

4.2 最小距離推定と SMM

前節の GMM が機能したのは、モーメント関数 $g(x_i, \theta)$ (残差 $\times$ 操作変数) が観測データとパラメータだけで計算できたからです。一階条件を「残差 = 0」の形に書き直し、世帯ごとの数字を代入すれば評価できました。構造推定では、これが書けることの方がむしろ例外です。

書けなくなる理由は 2 つあります。第一に、モデルの含意が数値的にしか出せない場合です。動学モデルの政策関数、均衡モデルの価格、定常状態から計算される結婚率や失業率は、どれもパラメータを与えるたびにモデルを解き直さないと分かりません。データ側の結婚率は調査から数えれば済むのに、それに対応するモデル側の量は閉じた形で書けない、という非対称が生じます。しかも結婚率は誰か 1 人について定義される量ではないので、個人 i ごとの残差という形にそもそもなりません。第二に、世帯 i について観測できない変数がモデルに入る場合です。未観測の異質性や潜在的な状態変数があると、観測できるのはそれらについて平均を取った後の分布だけになります。どちらも、モーメント関数 $g(x_i, \theta)$ が個人ごとに書けないという点で同じであり、モデルが含意する統計量を元に推定する必要があります。

i 最小距離推定

データから計算した統計量 $\hat{m} = \frac{1}{N} \sum_i h(x_i)$ と、モデルが含意するその対応物 $m(\theta)$ の距離を最小化する推定量を最小距離推定量 (minimum distance estimator) という。

$$\hat{\theta} = \arg \min_{\theta} (\hat{m} - m(\theta))^T W (\hat{m} - m(\theta)).$$

これは $g(x_i, \theta) = h(x_i) - m(\theta)$ と置いた GMM である。

⁹個々の t は厳密には標準正規ではありません。7 本のずれは互いに相関しており、しかも 5 個のパラメータを合わせた後の残りだからです。あくまで当たりをつけるための道具として読みます。

モデル側 $m(\theta)$ を, シミュレーションによって計算する場合を, とくに SMM (simulated method of moments) と呼びます. 推定量が変わるわけではなく, $m(\theta)$ の計算方法の名前です. 以下の例ではモデル側の量が2次元の積分になるので, シミュレーション (モンテカルロ法) は使わず求積で計算します.

4.2.1 モデル

静学的な労働供給を考えます. 個人は消費 c と労働時間 h を選びます. 労働時間は週 40 時間を 1 とする単位で測ります.

$$\max_{c, h} U(c, h; \psi_i) = \frac{c^{1-\gamma}}{1-\gamma} - \psi_i \frac{h^{1+1/\eta}}{1+1/\eta} \quad \text{s.t.} \quad c = wh \quad (4.8)$$

ψ_i は働くことの不効用の重み, γ は消費の曲率, η は労働時間の Frisch 弾力性です. 一階条件は

$$w(wh)^{-\gamma} = \psi_i h^{1/\eta} \quad (4.9)$$

で, これは閉じた形で解けます.

$$h^*(w, \psi) = \left(\frac{w^{1-\gamma}}{\psi} \right)^{\frac{\eta}{1+\gamma}}. \quad (4.10)$$

この解を希望労働時間と呼ぶことにします. $\gamma > 1$ なら w の指数が負で, 賃金が上がると希望労働時間は減ります. 所得効果が代替効果に勝つ領域です.

ここで, 個人の異質性を考えます. 賃金 w_i と労働の不効用の重み ψ_i を独立な確率変数とします.

$$\log w_i \sim \mathcal{N}(\mu_w, \sigma_w^2), \quad \log \psi_i \sim \mathcal{N}(\mu_\psi, \sigma_\psi^2) \quad (4.11)$$

式 (4.10) の対数を取れば $h_i^* := \log h^*(w_i, \psi_i)$ は $\log w_i$ と $\log \psi_i$ の線形結合なので, 希望労働時間の分布も対数正規です.

ここに標準労働時間を入れます. 仕事には標準の週労働時間 $\bar{H} = 1$ (40 時間) があり, 何もしなければ人は $\bar{H}$ で働きます. 希望労働時間 h_i^* で働くには, 時間を自由に選べる仕事を探すか, 雇い主と交渉するかが必要で, そのコスト κ_i は人によって異なるとします. 希望時間で働くことの利得を

$$g(w_i, \psi_i) := U(h_i^*; w_i, \psi_i) - U(\bar{H}; w_i, \psi_i) \geq 0, \quad (4.12)$$

と書くと, 人は $g(w_i, \psi_i) > \kappa_i$ のときだけ標準労働時間から外れます. コスト κ_i を平均 $\bar{\kappa}$ の指数分布とすれば, 外れる確率は 式 (4.13) です.

$$\Pr(h_i = h_i^* \mid w_i, \psi_i) = 1 - \exp(-g(w_i, \psi_i)/\bar{\kappa}) \quad (4.13)$$

利得が大きい人ほど, つまり希望時間が 40 時間から遠い人ほど外れやすく, 希望時間が 40 時間に近い人は外れる価値がないのでそのまま 40 時間で働きます. $\mu_w = 0$ に基準化し, 推定するのは $\theta = (\mu_\psi, \sigma_w, \sigma_\psi, \bar{\kappa})$ の 4 つで, 曲率 γ と Frisch 弾力性 η は文献から値を借りてくることにします.

なお、40 時間への集中をモデルに入れる方法はいくつかあり、代表的な研究として Bick ほか (2022 年) や Ma (2024 年) があり、Yanagimoto (2026 年 a) も凸型の所得関数を使って 40 時間の集中を説明しています。

$\eta = 0.5$ は Chetty ほか (2011 年) の値です。彼らは準実験的なマイクロ研究のメタ分析から、intensive margin の Frisch 弾力性を 0.54 と集計し、マクロモデルのカリブレーションには 0.5 を使うよう勧めています。 $\gamma = 1.5$ は前節と同じ値です。




図 4.5: **Desired hours.** Hours from 式 (4.10) as a function of the wage, for two values of the disutility of work. The dotted line is the standard workweek.

賃金が上がると希望労働時間が減ることがわかります。 ψ を上げると、働くことが苦になる分、曲線全体が下に移動します。曲線が点線と交わるあたりの人は希望時間が 40 時間に近く、外れる利得式 (4.12) が小さいので、ほぼ確実に 40 時間で働きます。

この構造が最小距離推定を要求します。前節では一階条件を個人ごとに評価できました。ここでは、40 時間で働いている人について分かるのは「外れる利得がコストを下回った」ことだけで、その人の希望時間も、したがって選好も、点としては復元できません。個人ごとの残差が書けないので、残るのは分布どうしを突き合わせる最小距離推定です。たとえば平均労働時間のモデル側の対応物は 式 (4.14) のような二重積分です。

$$\mathbb{E}[h] = \iint \left[(1 - e^{-g(w, \psi)/\bar{\kappa}}) h^*(w, \psi) + e^{-g(w, \psi)/\bar{\kappa}} \bar{H} \right] dF_w(w) dF_\psi(\psi) \quad (4.14)$$

h^* は閉じた形でも、混合の重み $e^{-g(w, \psi)/\bar{\kappa}}$ が (w, ψ) の非線形な関数なので、積分は数値的にしか計算できません。

4.2.1.1 データ

個票を使います。Blackburn と Neumark (1992 年) が用いた全米縦断調査 (National Longitudinal Survey) の若年男性コホートの 1980 年時点で、就業していた男性 935 人について週平均労働時間と月

収が記録されています。¹⁰

労働時間はモデルに合わせて、40 時間を 1 とする単位で測ります。標本は全員が就業しているので、参加の意思決定を持たない 式 (4.8) のモデルと対象が揃っています。




図 4.6: **Usual weekly hours.** 935 working men, NLS 1980. More than half report exactly 40 hours.

図 4.6 がこの節のモデルを決めた事実です。標本の 53% がちょうど 40 時間で、40 時間未満は 6% しかいません。残りの 41% は 40 時間より長く、45, 50, 55, 60 時間といった切りのよい値に集まっています。

ターゲットとするモーメントは 5 本です。

1. 個人 i の労働時間 h_i の平均, $\mathbb{E}[h_i]$
2. 個人 i の労働時間 h_i の標準偏差, $\sqrt{\text{Var}[h_i]}$
3. 個人 i の対数月収 y_i の標準偏差, $\sqrt{\text{Var}[y_i]}$
4. 労働時間 h_i と対数月収 y_i の相関, $\text{Cov}(h_i, y_i)/(s_h s_y)$
5. 40 時間で働く人のダミー d_i の平均, $\mathbb{E}[d_i]$

このうち標本平均そのものは 1 本目と 5 本目で、残りの 3 本は標本平均の非線形な関数です。標準誤差を出すには、その非線形性をデルタ法で通す必要があります。セクション A.6 の導出を用いれば、どのモーメントの推定誤差も個人ごとの寄与の平均として $\hat{m} - m \simeq \frac{1}{N} \sum_i \xi_i$ と書けます。この ξ_i を影響関数 (influence function) と呼び、5 本のモーメントに対応する成分は次のとおりです。

$$\begin{aligned} \xi_{1i} &= h_i - \mathbb{E}[h], & \xi_{2i} &= \frac{(h_i - \mathbb{E}[h])^2 - m_2^2}{2m_2}, & \xi_{3i} &= \frac{(y_i - \mathbb{E}[y])^2 - m_3^2}{2m_3}, \\ \xi_{4i} &= u_i v_i - m_4 - \frac{m_4}{2}(u_i^2 - 1) - \frac{m_4}{2}(v_i^2 - 1), & \xi_{5i} &= d_i - \mathbb{E}[d] \end{aligned} \quad (4.15)$$

実装では母数を標本の値に置き換えます。 $\mathbb{E}[h]$ を $\bar{h}$ に、 m_2 を s_h に、というようにです。こうして得た $\hat{\xi}_i$ を行に並べた $N \times 5$ 行列の標本分散共分散を N で割れば、それが $\hat{m}$ の分散共分散行列です。

¹⁰R の `wooldridge` パッケージ (GPL-3) の `wage2` として配布されているものです。

$$\hat{V} = \frac{1}{N} \widehat{\text{Var}}(\hat{\xi}_i) \quad (4.16)$$

表 4.5: ターゲットにする 5 本のモーメント (NLS 若年男性コホート 1980 年, 就業者 935 人)

モーメント	データの値	標準誤差
週間就業時間の平均 $\bar{h}$	43.9294	0.24
週間就業時間の標準偏差 s_h	7.2243	0.29
対数月収の標準偏差 s_y	0.4211	0.011
両者の相関 r_{hy}	-0.0472	0.039
ちょうど 40 時間の割合 $\bar{d}$	0.5316	0.016

平均は週 43.9 時間, 標準偏差は週 7.2 時間, 対数所得の標準偏差は 0.42 です. 目を引くのは 4 本目で, 労働時間と対数月収の相関は -0.047, つまりほぼゼロです. 長く働く人ほど稼ぐわけではない, ということです. 散らばりの源が賃金だけならこうはなりません. 賃金が高い人は (このモデルでは) 働く時間が短く, かつ所得は高いので, 相関は明確に負になるはずですが.

表 4.6: 5 本のモーメントの相関

	$\bar{h}$	s_h	s_y	r_{hy}	$\bar{d}$
$\bar{h}$	1.0	0.642	0.108	-0.112	-0.58
s_h	0.642	1.0	0.106	-0.113	-0.302
s_y	0.108	0.106	1.0	0.001	-0.079
r_{hy}	-0.112	-0.113	0.001	1.0	0.03
$\bar{d}$	-0.58	-0.302	-0.079	0.03	1.0

平均労働時間と労働時間の標準偏差の相関が 0.64 と高いのは, どちらも同じ 935 人の労働時間から作られているからです. 40 時間の割合は労働時間の散らばりと負に相関します. 40 時間に人が集まれば散らばりは小さくなるからです. この非対角成分が使えることが, 個票を持っていることの利点です.

4.2.1.2 モーメント条件

式 (4.14) の積分は 2 次元です. 賃金も選好も対数正規なので, どちらも $\exp(\mu + \sqrt{2}sz)$ と変換すればガウス・エルミート求積 (セクション 2.3) がそのまま使えます. 2 つの積分は独立なので, 節点の直積を取るだけです. 各節点では希望時間 h^* と利得 g を計算し, 式 (4.13) の確率で「希望時間で働く」と「40 時間で働く」の 2 つの枝に重みを分けます. 被積分関数は滑らかなので, 各次元 10 点で足ります.¹¹

重み行列には $\hat{V}^{-1}$ を使います. セクション 4.1.1 の意味で効率的な選択であり, 個票があるからこそ選べるものです.

$$\hat{\theta} = \arg \min_{\theta} (m(\theta) - \hat{m})^\top \hat{V}^{-1} (m(\theta) - \hat{m}) \quad (4.17)$$

$\hat{V}$ はすでに $1/N$ を含んでいるので, この目的関数の最小値がそのまま Hansen の J 統計量になります (セクション 4.1.4.5).

¹¹ 8 点から 20 点まで変えても, 以下で報告する J 統計量は小数第 2 位まで動きません.

4.2.2 推定

式 (4.17) を最小化します。大域識別の間接チェックを兼ねて、離れた3つの初期値から解きます。

3つの初期値は同じ点に収束しました。対数不効用の平均 $\hat{\mu}_\psi = -0.37$ (重みの中央値は $e^{\hat{\mu}_\psi} = 0.69$)、対数賃金の標準偏差 $\hat{\sigma}_w = 0.46$ 、対数不効用の標準偏差 $\hat{\sigma}_\psi = 0.52$ 、逸脱コストの平均 $\hat{\kappa} = 0.047$ です。選好の散らばりは無視できる大きさではなく、上下1標準偏差の人の間で不効用の重みが2.8倍違います。式 (4.10) によれば、これは希望労働時間の1.35倍の違いにあたります。 $\hat{\kappa}$ は効用の単位なので、それ自体を読むより、含意される「標準から外れる人の割合」47%の方が分かりやすいでしょう。

当てはまりは、モーメントの標準誤差で測れます。




図 4.7: **Fit.** Targeted moments, model minus data, in standard errors of the moment.

5本とも0.1標準誤差の内側に収まっています。パラメータ4つで5本を狙っているのでは完全には合いませんが、符号が入り混じっているのはモデルがデータをうまくとらえていることの示唆です。

過剰識別の検定をします。 $J = 0.01$ で、自由度 $5 - 4 = 1$ の χ^2 の5%点3.84を下回ります ($p = 0.92$)。5本のモーメントは、この4つのパラメータで整合的に説明できる範囲にあります。 J がほとんどゼロなのは偶然ではありません。セクション 4.2.4.2 で見るとおり、持ち込んだ $\eta = 0.5$ がこのデータの好む値とほぼ一致していることも関係しています。

4.2.3 標準誤差

最小距離推定において標準誤差を考える場合、大きく3つの場合があります。

1. **解析的な方法:** 個票があり、分散共分散行列が手に入る場合
2. **ブートストラップ法:** 個票があるが、分散共分散行列が手に入らない場合
3. **最悪条件:** 個票がなく、分散共分散行列しか手に入らない場合

4.2.3.1 1. 解析的な方法

モーメントを単一の個票で作った場合、データモーメントの分散共分散行列 $\hat{V}$ を用いることで、解析的な標準誤差を計算できます。これは GMM の場合と同じです。

今, $\hat{V}$ が非対角成分まで手元にあるので, 命題 4.1 をそのまま使えます. 必要なのはモデル側のヤコビアン $\hat{G} = \partial m / \partial \theta$ だけで, これは数値微分で取ります.

行列 $\Lambda = (\hat{G}^\top \hat{V}^{-1} \hat{G})^{-1} \hat{G}^\top \hat{V}^{-1}$ は「モーメントが 1 単位動いたとき推定値がどれだけ動くか」を並べたもので, デルタ法の中身そのものです. 標準誤差は $\sqrt{\text{diag}(\Lambda \hat{V} \Lambda^\top)}$ になります.

4.2.3.2 2. ブートストラップ法

式 (4.16) にたどり着くには, ターゲットにした統計量の影響関数を 1 本ずつ手で導く必要がありました. モーメントが分位点や回帰係数のように込み入ってくると, これは面倒になり, 間違えやすくなります. そういうときは, 公式を使わずに標本の引き直しで測れます. 個票があるので手続きは素直です. 935 人を復元抽出で引き直し, 5 本のモーメントを作り直し, 最適化までやり直す. これを繰り返して得られる $\hat{\theta}^{(r)}$ の散らばりが標準誤差です.

最後の一段が肝心で, モーメントの分散だけでなく, そこから推定値への伝わり方も込みで測れます. 重み行列は全標本の $\hat{V}^{-1}$ に固定したままにします. 重みは推定量の定義の一部であって推定対象ではないので, 引き直しのたびに作り直すと, 測りたい散らばりに重みの揺らぎが混ざります.¹²

表 4.7: 解析的な標準誤差とブートストラップ標準誤差 (引き直し 250 回)

パラメータ	推定値	(1) 解析的	(2) ブートストラップ	比
μ_ψ	-0.3678	0.02	0.02	1.02
σ_w	0.4562	0.012	0.012	1.03
σ_ψ	0.5192	0.018	0.018	0.98
$\bar{\kappa}$	0.0468	0.004	0.004	0.99

4 つとも 3% 以内で一致しています. 一致するはずのものが一致した, というだけの結果ですが, 確かめる価値はあります. ヤコビアンの数値微分, 影響関数の導出, デルタ法の適用のどこかを間違えていれば, ここでずれます. とくに相関の影響関数 (式 (4.15) の ξ_{4i}) は項が 3 つあって間違えやすいので, ブートストラップと突き合わせておくと安心です. 素早い解析式と, 遅いが導出の要らない引き直しの, 相互チェックだと思うのがよいでしょう.




図 4.8: **Bootstrap distribution.** 250 resamples, with the point estimate and the analytic 95% interval.

図 4.8 は同じことを絵にしたものです. 破線が解析的な 95% 区間で, ヒストグラムがブートストラップ分布です. 分布はほぼ対称で, 区間の幅も揃っています.

¹² $\hat{V}$ が手に入らない状況なら, 重みも $\hat{V}^{-1}$ 以外の固定した行列 (単位行列や対角行列) を使うことになります. どの重みを使っても推定量は一致性を持ち, ブートストラップはその重みに対応した標準誤差を返します.

4.2.3.3 3. 最悪条件

ここまでの2つは, どちらも個票が手元にあるため計算することができました. しかし, 構造推定ではそうでない場合もよくあります. ターゲットが先行研究や公表統計の点推定で, 手元にあるのは各モーメントの標準誤差 (対角成分) だけ, というのがよくある状況です. もし, 複数の資料からモーメントを集めてくれば, それらの相関はまず手に入りません (Cocci と Plagborg-Møller 2024 年). この例でいえば, 労働時間は労働力調査から, 所得の分散は賃金構造基本統計調査から, というような組み合わせです.

対角成分しか分からないなら, 重み行列も対角にするしかありません. まずその推定量を作ります.

Cocci と Plagborg-Møller (2024 年) は, この状況でも有効な「最悪ケース」の標準誤差を提案しました. 鍵になるのは, 推定量が漸近的にはモーメントの線形結合になるという事実です.

命題 4.2 (最悪ケース標準誤差 (Cocci と Plagborg-Møller 2024 年)). p 本のモーメント $\hat{m}$ をターゲットにした最小距離推定量を考える.

$$\hat{\theta} = \arg \min_{\theta} (m(\theta) - \hat{m})^{\top} W (m(\theta) - \hat{m})$$

ここで, W は $p \times p$ の半正定値な重み行列である.

$G = \partial m(\theta_0) / \partial \theta^{\top}$, V を $\sqrt{N}(\hat{m} - m(\theta_0))$ の漸近分散共分散行列とする. この時, 関心のある量 $r(\theta)$ について, $\lambda = \partial r(\theta_0) / \partial \theta$, $x = WG(G^{\top}WG)^{-1}\lambda$ とおくと, デルタ法よりつぎの漸近分布が得られる.

$$\sqrt{N}(r(\hat{\theta}) - r(\theta_0)) \xrightarrow{d} \mathcal{N}(0, x^{\top}Vx)$$

V の対角成分 ($\sigma_1^2, \dots, \sigma_p^2$) だけが既知のとき,

$$\max_{V \succeq 0, V_{jj} = \sigma_j^2} x^{\top}Vx = \left(\sum_{j=1}^p \sigma_j |x_j| \right)^2$$

であり, 最大はすべてのモーメントが完全相関する時に達成される.

上限の直感は素朴です. V が半正定値なら相関係数は 1 を超えられない, すなわち $|V_{ij}| \leq \sigma_i \sigma_j$ なので, $x^{\top}Vx = \sum_{i,j} x_i x_j V_{ij}$ は各項を $|x_i| |x_j| \sigma_i \sigma_j$ で置き換えたものより大きくなれません. すべてのモーメントが完全相関するとき, その上限がちょうど達成されます.

実装では σ_j をモーメント j の標準誤差に置き換えれば, $\sum_j \sigma_j |x_j|$ がそのまま $r(\hat{\theta})$ の標準誤差になります. 必要なのは各モーメントの標準誤差とヤコビアンだけなので, 先行研究の公表値をターゲットにしたカリブレーションにもそのまま使えます. この最悪ケース標準誤差に基づく信頼区間は, どんな相関構造のもとでも漸近的に名目以上の被覆率を持ちます (完全相関のケースで等号). その代償として, 真の相関構造によっては保守的 (広すぎる区間) になります.

表 4.8: 最悪ケース標準誤差

パラメータ	推定値	分散共分散	無相関仮定	最悪ケース	最悪 / 無相関
μ_{ψ}	-0.3688	0.022	0.028	0.043	1.54
σ_w	0.4563	0.012	0.012	0.018	1.48
σ_{ψ}	0.5187	0.019	0.022	0.041	1.87
$\bar{\kappa}$	0.0468	0.004	0.005	0.0087	1.75

3つの列は同じ推定量 $\hat{\theta}$ の標準誤差を、 V について知っていることの量を変えて計算したものです。左の列は $\hat{V}$ を非対角成分まで使った通常の値で、個票があるからこそ計算できます。中の列は非対角成分をゼロとみなした値、右の列は非対角成分が最悪だったとき (命題 4.2 の完全相関) の値です。最悪ケースは無相関仮定の 1.5 倍から 1.9 倍になっています。これが相関を知らないことの代償です。信頼区間をこれだけ広げておけば、真の相関がどうであっても被覆率は名目以上になります。そしてこの代償には天井があります。Cocci と Plagborg-Møller (2024 年) が示すとおり、Hölder の不等式から最悪ケースは無相関仮定の高々 $\sqrt{p}$ 倍で、モーメント 5 本なら $\sqrt{5} \approx 2.24$ 倍です。相関について何も知らなくても、区間の幅が無相関で計算したものの 2.24 倍を超えることはない。「頑健性の値段は法外ではない」とはこの意味です。

ここで注意したいのは無相関仮定の列です。この例では左の解析的な列と比べて 0.98 倍から 1.24 倍で、大きくは外れていません。しかし相関を無視した標準誤差が正しい値を上回るのか下回るのかは、一般には決まりません。Cocci と Plagborg-Møller (2024 年) のメニューコストモデルを使ったモンテカルロ実験では逆に、無相関を仮定した信頼区間の被覆率が名目 95% を下回り (パラメータによっては 89% 程度)、検定が過剰に棄却します (Cocci と Plagborg-Møller 2024 年, sec. 5.1)。相関の符号と感応度 Λ の符号の組み合わせ次第で、どちらにも転びうるということです。相関が本当に手に入らないなら、「独立とみなす」のではなく最悪ケースを併記するのが安全です。

4.2.4 識別

4.2.4.1 設計を点検する

前節と同じ道具で設計を点検します。標準誤差を計算するときに求めたヤコビアン $\hat{G}$ を、目的関数と同じ距離で測り直します。重みが $\hat{V}^{-1}$ なので、行はモーメントの標準誤差、列はパラメータの値でスケールします。

```
4-element Vector{Float64}:
 38.7
 34.4
 14.8
  8.64
```

4 つとも 0 から離れていて、最大と最小の比は 4.5 倍です。全てのパラメータがよく識別されていることが示唆されています。




図 4.9: **Which moment identifies which parameter?** Change of each moment (in s.e. units) per 1% change of each parameter.

図 4.9 も素直に解釈することができます。平均労働時間の行は μ_ψ に強く反応し、対数所得の散らばりは σ_w によく反応しており、労働時間の散らばりはほぼ σ_ψ だけに反応します。

決定的なのは相関の行です。相関だけが、 σ_w と σ_ψ に符号の違う反応を示します。賃金の散らばりを増やすと相関は下がり、選好の散らばりを増やすと相関は上がる。他の行はどちらも同じ向きに動かすので、散らばりの源が賃金なのか選好なのかを区別できません。相関を 1 本足したことが、 σ_w と σ_ψ を分けているということです。最後の行では、40 時間の割合が $\bar{\kappa}$ と μ_ψ に反応しています。外れるコストが高ければ 40 時間に留まる人が増え、不効用の重みが動けば希望時間の分布全体がずれて、40 時間の近くにいる人の数が変わるからです。

4.2.4.2 感応度と頑健性

推定結果を報告するとき、推定値と標準誤差のほかに何を添えるべきか。構造推定の実務で定着している答えが 2 つあります。モーメントに対する感応度と、外生的に定めた値に対する頑健性です。

第一の感応度は、標準誤差の計算で使った $\Lambda = (\hat{G}^\top W \hat{G})^{-1} \hat{G}^\top W$ そのものです。Andrews ほか (2017 年) はこれを感応度 (sensitivity) と名づけ、報告することを勧めています。¹³ 意味は [命題 4.1](#) の線形化そのもので、モーメント j が Δ だけずれたとき推定値 $\hat{\theta}_k$ は $\Lambda_{kj} \Delta$ だけ動く、という一次近似です。モーメントの 1 本が誤って測られている、あるいはモデルの仮定の 1 つが破れてそのモーメントだけがずれる、という状況を読者が想定したとき、それが推定値にどう伝わるかを Λ から読み取れます。単位を揃えるために、列はモーメントの標準誤差、行は推定値の標準誤差でスケールしておきます (Andrews ほか 2017 年, sec. IV.A)。

¹³Andrews ほか (2017 年) はモーメント条件を $g(\theta) = \hat{s} - s(\theta)$ と「データ引くモデル」の向きで書くので、定義は $\Lambda = -(G^\top W G)^{-1} G^\top W$ と符号が付き (Andrews ほか 2017 年, def. 1)。この節では $m(\theta) - \hat{m}$ の向きで書いているので符号が消え、同じ行列になります。

表 4.9: 感応度行列 $\hat{\Lambda}$

	$\bar{h}$	s_h	s_y	r_{hy}	$\bar{d}$
μ_ψ	-1.39	0.35	-0.05	-0.15	-0.47
σ_w	-0.01	0.1	0.91	-0.36	-0.02
σ_ψ	-0.38	1.03	0.18	0.56	-0.05
$\bar{\kappa}$	0.33	0.36	0.14	0.24	1.1

読み方は 図 4.9 の逆向きです。ヤコビアンは「パラメータを動かすとモーメントがどう動くか」、 Λ は「モーメントが動くと推定値がどう動くか」を並べています。たとえば $\hat{\sigma}_\psi$ は週間就業時間の標準偏差に、 $\hat{\kappa}$ はちょうど 40 時間の割合にもっとも強く依存しています。 Λ の計算に追加の費用はかからないので、推定値の表と一緒に載せておく価値があります。

第二の頑健性は、外生的に定めた値についてです。ここでは消費の曲率 $\gamma = 1.5$ と Frisch 弾力性 $\eta = 0.5$ の 2 つで、どちらも先行研究の値です。外から定めた値を動かして結果がどう変わるかを示すのは、構造推定の論文では付録の定番で、Bick ほか (2022 年) は所得関数の傾きを区間で動かして主結果が変わらないことを確かめ (Bick ほか 2022 年, sec. III.C), Ma (2024 年) は曲率 γ の代替値で弾力性を再計算しています (Ma 2024 年, sec. 5.2.2)。同じことをします。

表 4.10: 外生パラメータの頑健性

持ち込んだ値	μ_ψ	σ_w	σ_ψ	$\bar{\kappa}$	J
基準	-0.368	0.456	0.519	0.0468	0.01
$\gamma = 1.2$	-0.32	0.439	0.453	0.0381	31.53
$\gamma = 1.8$	-0.404	0.459	0.572	0.0574	19.21
$\eta = 0.25$	-0.587	0.448	0.795	0.0647	10.38
$\eta = 1$	-0.262	0.459	0.375	0.0385	11.48

どちらも当てはまりまで動かします。 γ をどちらに動かしても J は悪化し、 η は 0.5 から離れるほど悪化します。 $\eta = 0.25$ で 10.4、 $\eta = 1$ で 11.5 と、どちらも 5% 点 3.84 を超えて棄却されます。持ち込んだ Frisch 弾力性について、データははっきり意見を持っているということです。

それなら η も推定してしまえばよい、と思うのは自然です。パラメータが 5 つ、モーメントが 5 本で丁度識別になるので、過剰識別の検定は使えなくなりますが、推定自体はできます。

推定された Frisch 弾力性は $\hat{\eta} = 0.51$ (標準誤差 0.1) です。Chetty ほか (2011 年) のメタ分析の 0.54 と、持ち込んだ 0.5 は、どちらも 95% 信頼区間 $[0.31, 0.71]$ の中にあります。準実験からの推定値と、横断面の分布の形からの推定値が一致するのは、それ自体が 1 つの結果です。ただし標準誤差は他のパラメータより大きく、丁度識別なので当てはまりの良し悪しでモデルを疑う手段を失います。外から信頼できる値が持ち込めるなら、それを使って過剰識別の余地を残す方が、教科書的には筋が通っています。

最後に大きさを見比べておきます。 $\hat{\sigma}_\psi$ の標準誤差は 0.018 で、推定値の 3.5% でした。一方 表 4.10 では、外生的に定めた値を動かすと $\hat{\sigma}_\psi$ が 0.37 から 0.79 まで動きます。標本誤差より一桁大きい幅です。だからこの表は、標準誤差と切り離さずに、推定結果の一部として並べて報告します。

第Ⅱ部

結婚の経済学

結婚の経済学的な意義

結婚は主体的な選択である以上、経済学分析ではインセンティブの構造を理解することが必要です。様々な要因が結婚の意思決定に影響を与えますが、主に議論されるのは次の4つです。

1. **規模の経済**: 実質的な所得効果
2. **公共財の供給**: 家事労働, 子どもなど
3. **リスクシェアリング**: 所得リスクなど
4. **愛**: 上記3つで説明されない (確率的) 要素

規模の経済

二人以上で住む場合は、家賃や光熱費などの固定費を分担できたり、食事をまとめて作ることによってコストが下げられるなど、消費の効率が上がることがあります。これを経済学では規模の経済 (economies of scale) と呼びます。正確にモデル化すると複雑化してしまうので、ほとんどの研究では OECD の統計による簡便な尺度を用います。

i OECD Equivalence Scale

OECD equivalence scale は、二人目以降の世帯員が消費する財の量を 0.7、子どもは 0.5 として、世帯の消費を調整する尺度である。典型的な夫婦と子ども n 人の世帯の消費は $C(n) = 1 + 0.7 + 0.5n$ と表される。世帯所得を Y とすると、世帯の消費水準は $Y/C(n)$ で表される。

なお、近年は再計算が行われて、大人は 0.5、子どもは 0.3 に調整されており、これを OECD-modified equivalence scale と呼ぶ。

他の簡便な尺度として、世帯員の人数の根号をとる $C(n) = \sqrt{n}$ とする方法もあります。

公共財の供給

結婚している場合、独身の場合と比べて、家事労働の分担や子どもの養育などの便益を得ることができます。これらは、夫婦間で共有され、かつ消費の際に競合しないため、公共財 (public goods) と呼ばれます。

公共財をモデル化する場合は、様々な流儀があり、子どもの人数 n に応じて効用を $u(n)$ とする方法や、家事労働の分担を考慮して効用を $u(h_1, h_2)$ とする方法などがあります。

リスクシェアリング

夫婦が共に働いている場合、片方の所得が減少しても、もう片方の所得で生活を維持することができます。このように結婚は所得リスクを分散する効果があり、経済学ではリスクシェアリング (risk sharing) と呼ばれます。ただし、リスクシェアリングは数ある経済学的な結婚の意義の中でも、それほど大きな効果はないと考えられています。

愛

結婚に最も重要な要素は愛であると考えられる人は多いでしょう。それらは否定されることはありませんが、観察されることでもありません。そのため、経済学のモデルでは、愛は確率的な要素として扱わ

れることが多いです。夢のない話のように思えるかもしれませんが、上記のような経済学的な要因を差し引いても、結婚が成立するのは、愛があるからだとも考えることもできます。

⚠ 結婚の定義

近年では多様な形のパートナーシップも広がっているが、本講義では、注釈のない限り異性間の法律婚を対象とします。しかし、特に西欧諸国では事実婚と法律婚の違いが小さくなっているため、事実婚や同居 (cohabitation) を含めた研究も多いです。

結婚モデルの 2 つの流派

結婚をモデル化するときには、次の二つの流派があります。

1. サーチモデル (Search and Matching Model)

- Shimer と Smith (2000 年) を起源とした每期ランダムに相手を探す動学的モデル
- 結婚のタイミング (晩婚化) や再婚などを扱いやすい
- 講義では Greenwood と Guner (2009 年), Greenwood ほか (2016 年) を紹介

2. 摩擦のない結婚市場モデル (Frictionless Marriage Market)

- Choo と Siow (2006 年) に始まる、初期時点で全ての人が結婚相手を見つけるモデル
- より詳細な家庭の意思決定 (家庭内配分など) をモデル化しやすい
- 講義では一般枠組みとして Galichon ほか (2019 年) を扱い、その特殊ケースとして Choo と Siow (2006 年) を導く
- 応用として Ciscato (2025 年), Reynoso (2024 年) を紹介

この講義では順番にそれぞれのモデルを紹介していきます。

第 5 章

Search & Matching

現実の労働市場や結婚市場では、相手を見つけるには時間がかかり、出会った相手は選び直せるとは限りません。サーチ理論は、この「出会いに時間がかかる」摩擦を最適停止問題として定式化します。原型は McCall の職探しモデル (McCall 1970 年) であり、この章の後半で扱う Greenwood と Guner (2009 年), Greenwood ほか (2016 年), Goussé ほか (2017 年) の結婚サーチモデルは、その直接の応用です。

5.1 McCall モデル

サーチ理論の出発点は、McCall (1970 年) が定式化した職探しモデルです。失業者が、次々に届く賃金オファーを受諾するか、より良いオファーを待って探し続けるか、という最適停止問題として組み立てます。

i McCall の職探しモデル

失業者は每期、賃金オファー w を分布 F から i.i.d. で 1 つ受け取る。この時、 F の台 (support) は有界とする。オファーを受諾すれば以後每期 w を受け取り続け、拒否すれば当期は失業給付 b を受け取って翌期また新しいオファーを引く。

割引率 β のオファー w を手にした失業者の価値関数は

$$V(w) = \max \left\{ \frac{w}{1-\beta}, b + \beta \int V(w') dF(w') \right\}. \quad (5.1)$$

式 (5.1) の構造を見ます。第 1 項はオファーを受ける時の価値 (以後 w が続くので割引現在価値は $w/(1-\beta)$)、第 2 項はオファーを拒否して待つ時の価値です。重要なのは、オファーが i.i.d. なので継続価値がいまのオファー w に依存しない定数 (C とおく) になることです。

$$C = b + \beta \int V(w') dF(w').$$

受諾の価値は w について増加、継続の価値は一定なので、最適な戦略は閾値ルールになります。

命題 5.1 (留保賃金, reservation wage). 式 (5.1) の解 V は一意に存在し、最適政策は留保賃金 w^* を用いた閾値ルール「 $w \geq w^*$ なら受諾」である。 w^* は次の留保賃金方程式を満たす唯一の値である。

$$w^* = b + \frac{\beta}{1-\beta} \int_{w^*}^{\infty} (w - w^*) dF(w). \quad (5.2)$$

証明. Step1 (存在と一意性): 式 (5.1) の右辺は付録 (A.3 節) で見たベルマン作用素の形をしており, オファーの台が有界なら Blackwell の条件を満たす縮小写像である. よって有界な解 V が一意に存在する.

Step2 (閾値ルール): 受諾の価値 $w/(1-\beta)$ は w に対して狭義単調増加であり, 継続価値は定数なので,

$$w^* = (1-\beta)C,$$

に対して, 閾値ルール「 $w \geq w^*$ なら受諾」が最適である.

Step3 (留保賃金と一意性): V の表現を C の定義に代入する.

$$\begin{aligned} \frac{w^*}{1-\beta} &= C \\ &= b + \frac{\beta}{1-\beta} \int V(w') dF(w') \\ &= b + \frac{\beta}{1-\beta} \left(w^* + \int_{w^*}^{\infty} (w - w^*) dF(w) \right) \\ w^* &= b + \frac{\beta}{1-\beta} \int_{w^*}^{\infty} (w - w^*) dF(w). \end{aligned}$$

これは, 左辺が w^* に関して単調増加, 右辺が単調減少する方程式であり, 交点は一意的に存在する.

式 (5.2) の第二項は, 「もう1期待てば, いまの基準 w^* を上回るオファーを引けるかもしれない」という待つことのオプション価値です. 留保賃金は失業給付 b にこのオプション価値を上乗せした水準になります. オファーの上限が w^* より大きい限り, 失業者は b を上回るオファーでも拒否します.

命題 5.2 (留保賃金の比較静学).

1. 失業給付 b の増加は留保賃金 w^* を上げる.
2. オファー分布の平均保存的な広がり, w^* を上昇させる.

証明.

(1) 式 (5.2) の右辺をすべて左辺に集めた式を定義する.

$$\Phi(w^*, b) := w^* - b - \frac{\beta}{1-\beta} \int_{w^*}^{\infty} (w - w^*) dF(w) = 0.$$

オプション価値項の微分は 補題 A.1 より,

$$\frac{\partial}{\partial w^*} \int_{w^*}^{\infty} (w - w^*) dF(w) = -(1 - F(w^*)).$$

よって,

$$\frac{\partial \Phi}{\partial w^*} = 1 + \frac{\beta}{1-\beta} (1 - F(w^*)) > 0, \quad \frac{\partial \Phi}{\partial b} = -1$$

であり, 陰関数定理から

$$\frac{dw^*}{db} = -\frac{\partial \Phi / \partial b}{\partial \Phi / \partial w^*} = \frac{1}{1 + \frac{\beta}{1-\beta}(1 - F(w^*))} > 0.$$

- (2) 右辺の積分は $\int \max\{w - w^*, 0\} dF(w)$ と書け, $\max\{w - w^*, 0\}$ は w の凸関数である. Rothschild と Stiglitz (1970 年) の定理 (A.3) より, 平均保存的な広がり凸関数の期待値を下げない. したがって右辺は上方 (少なくとも同水準) にシフトし, 式 (5.2) の解 w^* は上がる.

5.2 Greenwood と Guner (2009 年)

最初の応用は, 結婚と離婚の長期トレンドをサーチモデルで説明した Greenwood と Guner (2009 年) です. アメリカでは戦後, 結婚率が一貫して低下し, 離婚率は 1980 年ごろまで急上昇しました (図 5.1). 同じ時期に, 既婚女性の労働参加率は 20% 台から 70% 近くまで上昇しています (図 5.2). この論文は, これらのトレンドを個人の嗜好の変化ではなく, **家事の機械化** (家電の普及による家事財の価格 p の下落) と **賃金 w の上昇** という 2 つの技術的な力で説明できるか, を定量的に問うたものです.




Fig. 2. Rates of marriage and divorce, 1950-2000

図 5.1: US marriage and divorce rates, 1950-2000 (Fig. 2)




Fig. 3. Household hours worked and female labor force participation, 1950–90

図 5.2: Hours worked and female participation (Fig. 3)

5.2.1 モデル

1期を1年とする無限期間モデルで、各期に確率 δ で退出し、同数の独身者が新しく生まれます。エージェントは性別を持たない「中性」の個人で、独身か有配偶かのどちらかです。独身者は每期ランダムに他の独身者と出会い、マッチの質 b を観察して結婚するかを決めます。有配偶者のマッチの質は每期変動し、その値に応じて離婚するかを決めます。つまり本章前半で見たとおり、結婚と離婚が同じ最適停止問題の表と裏として定式化されています (図 5.3)。




図 5.3: Flows between singlehood and marriage

選好. 1期あたりの効用は、市場消費 c と家庭内生産 n から得られます。

$$U^S(c, n) = \alpha \log(c - \bar{c}) + (1 - \alpha)n^\zeta / \zeta$$

$$U^M(c, n) + b = \alpha \log((c - \bar{c})/2^\phi) + (1 - \alpha)(n/2^\phi)^\zeta / \zeta + b$$

注目してほしい点が2つあります. 1つ目に最低消費 $\bar{c} > 0$ を導入することで効用を非ホモセティックであるということです. 所得が低いほど $\bar{c}$ の負担が相対的に大きい, という性質です. 第2に, 有配偶者の消費は 2^ϕ で割られています. $\phi < 1$ なら「2人で暮らすと1人あたりの生活費は2倍未満で済む」という規模の経済 (economies of scale) を表します.

家庭内生産. 家庭内生産 n は, 市場で買う家事財 d (価格 wp) と家事時間 h の CES 関数です.

$$n = (\theta d^\kappa + (1 - \theta)h^\kappa)^{1/\kappa}$$

$0 < \kappa < 1$ なら家事財と家事時間は代替的で, 家事財が安くなる (p の下落) と時間 h が財 d に置き換えられます. 洗濯機が洗濯時間を置き換える, という機械化の仮説がここに入っています.

マッチの質. 独身者が出会いで引くマッチの質は $b \sim \mathcal{N}(\mu_s, \sigma_s^2)$ の i.i.d., 有配偶者のマッチの質は AR(1) 過程

$$b' = (1 - \rho)\mu_m + \rho b + \sigma_m \sqrt{1 - \rho^2} \xi, \quad \xi \sim \mathcal{N}(0, 1)$$

に従います. 分布 $F(b)$ と $G(b' | b)$ のパラメータ $(\mu_s, \sigma_s, \mu_m, \sigma_m, \rho)$ は自由にカリブレーションできるので, 出会いの「当たり外れ」と結婚生活の「安定性」をデータから推定することになります.

価値関数. 独身者の価値 W と有配偶者の価値 $V(b)$ は次のベルマン方程式を満たします.

$$W = \max_{c, d, h} U^S(c, n) + \beta \int_{-\infty}^{\infty} \max\{W, V(b)\} dF(b)$$

subject to $c = w(1 - h) - wpd$.

$$V(b) = \max_{c, d, h} U^M(c, n) + b + \beta \int_{-\infty}^{\infty} \max\{W, V(b')\} dG(b' | b)$$

subject to $c = w(2 - h) - wpd$.

$V(b)$ は b について増加するので, 「 $V(b) \geq W$ なら結婚 (継続)」は McCall モデルと同じ留保値ルールです. マッチの質 b は夫婦に共通なので, 両者の閾値は一致し, 合意の問題は生じません.

定常均衡. 個人の停止ルールを所与とすると, 独身者の測度 s と有配偶者の累積分布 $M(b)$ は流入出のバランスで決まります.

$$s = \delta + (1 - \delta)s \int_{-\infty}^{\infty} \mathbb{1}\{V(b') \leq W\} dF(b') + (1 - \delta) \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \mathbb{1}\{V(b') \leq W\} dG(b' | b_{-1}) dM(b_{-1})$$

$$M(b) = (1 - \delta)s \int_{-\infty}^b \mathbb{1}\{V(b') > W\} dF(b') + (1 - \delta) \int_{-\infty}^{\infty} \int_{-\infty}^b \mathbb{1}\{V(b') > W\} dG(b' | b_{-1}) dM(b_{-1})$$

第1式は「独身者 = 参入者 + 結婚しなかった独身者 + 離婚した有配偶者」, 第2式は「質 b 以下の有配偶者 = 新規結婚 + 離婚しなかった継続結婚」という計算です. 定義から $s = 1 - \int dM(b)$ が成り立ちます.

物品市場は単純化されており, 生産関数は $Y = wL$ (ゼロ利潤条件から w が価格), 資源制約は $C + wpD = Y$ です. 賃金 w の上昇と家事財価格 p の下落は, データに合わせて外生的に与えられます.

5.2.2 定性的な含意

結婚と離婚の意思決定を除いた家計の意思決定は貯蓄がないため、静的な問題として考えることができます。

命題 5.3 (家庭内労働時間の比較静学). 家庭内労働時間 h は

- p の下落に対して, 減少する ($0 < \kappa < 1$ かつ $\zeta < \kappa$)
- w の上昇に対して, 増加する ($0 < \bar{c}$)

直感はこうです. p の下落には2つの経路があります. 第1に, 家庭内生産関数が代替的 ($0 < \kappa < 1$) なので, 家庭内生産1単位あたりの家事時間が家事財に置き換わります. 第2に, 家庭内生産が安くなると需要そのものが増えるので, こちらは家事時間を増やす向きに働きます. $\zeta < \kappa$ は前者が後者を上回るための条件で, 特に $\zeta < 0$ なら市場消費と家庭内生産の代替の弾力性 $1/(1 - \zeta)$ が1未満になり, 家庭内生産への総支出そのものが減るので, 2つの経路が同じ向きに働きます (推定値もこの範囲にあります). w の上昇は, 最低消費 $\bar{c}$ を賄うのに必要な市場労働を相対的に減らし, その分が家庭内労働に回ります. 実際, $\bar{c} = 0$ なら w は一階条件

$$\frac{\alpha p}{z - h - pd - \frac{\bar{c}}{w}} = (1 - \alpha)z^{-\phi\zeta}[\theta d^\kappa + (1 - \theta)h^\kappa]^{\zeta/\kappa - 1}\theta d^{\kappa - 1}$$

$$\frac{\alpha}{z - h - pd - \frac{\bar{c}}{w}} = (1 - \alpha)z^{-\phi\zeta}[\theta d^\kappa + (1 - \theta)h^\kappa]^{\zeta/\kappa - 1}(1 - \theta)h^{\kappa - 1}$$

から消え, 家庭内労働時間は w に対して不変になります.

命題 5.4 (結婚のメリット). 有配偶者と独身者の効用の差 $u^m - u^s$ は,

- p の下落に対して, 減少する ($\zeta < 0$)
- w の上昇に対して, 減少する ($0 < \bar{c}$)

こちらが結婚の衰退の核心です. このモデルで結婚のメリットは規模の経済だけなので, 有配偶者は実質的に「所得の高い家計」です. 最低消費 $\bar{c}$ の負担は低所得者 (独身者) に大きくかかるため, w が上昇すると独身者の方が大きく楽になり, 効用差が縮みます. また家庭内生産の効用は消費よりも凹 ($\zeta < 0$) なので, p の下落も水準の低い独身者に大きく効きます. つまり, 賃金上昇と家事の機械化はどちらも「独身でやっていく」ことを相対的に容易にし, 結婚のメリットを減らす, というのがこの論文の主張です.

5.2.3 推定

一部のパラメータはモデルの外から与えます.

- $1/\delta = 47$: 平均寿命 (18 歳から 65 歳までの期間)
- $\beta = 0.96 \times (1 - \delta)$: 1 年あたりの割引率 0.96 と生存確率 $1 - \delta$ の積
- $\phi = 0.766$: OECD 世帯等価尺度 $1 + 0.7 = 2^\phi$
- $\theta = 0.206, \kappa = 0.189$: McGrattan ほか (1997 年)
- $w_{1950} = 1.00$ (基準化), $w_t = w_{1950} \exp(0.022(t - 1950))$: 1950-2000 年の平均賃金上昇率

残る 10 個のパラメータ

$$\lambda := (\bar{c}, p_{1950}, \gamma, \alpha, \zeta, \mu_s, \sigma_s, \mu_m, \sigma_m, \rho)$$

は, 1950 年から 2000 年までの 16 個の統計量 (婚姻世帯と独身世帯の労働時間の各年代値, 婚姻率・結婚確率・離婚確率の始点と終点) をターゲットとした SMM でカリブレーションします (図 5.4).

Table 2
Parameter Values

Category	Parameter Values	Criteria
Tastes	$\beta = 0.960 \times (1 - \delta), \phi = 0.766$ $\alpha = 0.278, \zeta = -1.901$	A priori information Estimated—vital statistics
Technology	$c = 0.131$ $\theta = 0.206, \kappa = 0.189$	Estimated—hours data A priori information
Life span	$1/\delta = 47$	A priori information
Shocks	$\mu_s = -4.252, \sigma_s^2 = 8.063$ $\mu_m = 0.521, \sigma_m^2 = 0.680, \rho = 0.896$	Estimated—vital statistics
Prices	$p_{1950} = 9.959, \gamma = 0.059$ $p_t = p_{1950} \times e^{-\gamma \times (t-1950)}$ for $t = 1951, \dots, 2000$	Estimated—hours data
Wages	$w_{1950} = 1.00$ $w_t = w_{1950} \times e^{0.022 \times (t-1950)}$ for $t = 1951, \dots, 2000$	Normalization A priori information

図 5.4: SMM estimates (Table 2)

推定されたマッチの質の分布は, それ自体が読み物として面白い結果です. まず $\mu_s = -4.252$ と, 出会いの平均的な質は大きく負です. それでも結婚が起きるのは分布の右裾を引いたときだけで, 「良い相手を待つ」(waiting for the right person) という McCall 型のオプション価値の構造がデータから浮かび上がります. また $\sigma_s^2 = 8.063 \gg \sigma_m^2 = 0.680$ で, 出会いの当たり外れは結婚生活の変動よりはるかに大きく, $\mu_m = 0.521 > 0, \rho = 0.896$ と, いったん成立した結婚のマッチの質は平均的に正で持続的です. 「入口の選別が厳しく, 入ったあとは安定している」市場というのがこのモデルの描く結婚市場です.

5.2.4 結果




Fig. 6. Decline in marriage, 1950-2000: U.S. data and model

図 5.5: Decline in marriage: data and model (Fig. 6)




Fig. 7. Rates of marriage and divorce, 1950-96: U.S. data and model

図 5.6: Marriage and divorce rates: data and model (Fig. 7)

技術進歩の経路だけを入れたモデルが、既婚人口比率の低下 (図 5.5) と、結婚率の低下・離婚率の上昇 (図 5.6) をかなりの程度再現します。駆動力は命題 5.4 のとおり、有配偶と独身の効用差 $u^m - u^s$ の縮小です (図 5.5 右パネル)。賃金の上昇は最低消費の重荷の差を縮め、家事の機械化は独身生活のコストを下げる。どちらも「結婚しないと生活が成り立たない」という経済的な結婚の動機を弱めた、というのがこの論文の答えです。

このモデルの限界もはっきりしています。エージェントは中性で同質なので、「誰と誰が結婚するか」は問えません。Greenwood ほか (2016 年) は、ジェンダー・教育・能力の異質性を導入して、まさにその問いに挑みます。

5.3 Greenwood ほか (2016 年)

5.3.1 事実: 同類婚と格差

Greenwood ほか (2016 年) が説明したい事実は 3 つあります。

第 1 に、結婚・離婚のトレンドは学歴によって大きく異なります (図 5.7)。離婚率は大卒者の方が一貫して低く、有配偶率は 1960 年時点では大卒者の方が低かったのに、非大卒者の結婚が大きく減った結果、2005 年には似たような水準になっています。




FIGURE 1. MARRIAGE AND DIVORCE BY EDUCATION

図 5.7: Marriage and divorce by education (Fig. 1)

第 2 に、同類婚 (assortative mating) の傾向が強まっています (図 5.8)。経済学で同類婚とは、教育などの属性が似た者同士の結婚を指します (assortative matching, educational homogamy とも)。夫婦の学歴のクロス表に χ^2 検定をかけるとランダムマッチングは棄却され、相関係数や対角要素のランダムマッチ比といった指標で見ると、同類婚の程度は 1960 年から 2005 年にかけて上昇しています。¹⁴

¹⁴同類婚の計測方法にはそれ自体に論点があります。詳しくは Chiappori ほか (2025 年) を参照のこと。

TABLE 1—ASSORTATIVE MATING, AGES 25–54

1960			2005		
Husband	Wife		Husband	Wife	
	< College	College		< College	College
< College	0.855 (0.821)	0.023 (0.056)	< College	0.545 (0.427)	0.108 (0.226)
College	0.082 (0.115)	0.041 (0.008)	College	0.109 (0.227)	0.237 (0.120)

Statistics Measuring Assortative Mating					
$\chi^2 = 33,451$	obs. = 195,034	$\chi^2 = 77,739$	obs. = 288,423		
$\rho = 0.41$	$\delta = 1.08$	$\rho = 0.52$	$\delta = 1.43$		

図 5.8: Assortative mating by education (Table 1)

第3に、女性の大学進学率と既婚女性の労働参加が急上昇し (図 5.9), その背後で大卒プレミアムの上昇とジェンダー賃金格差の縮小が進みました (図 5.10). そして世帯所得のジニ係数は 0.31 (1960) から 0.43 (2005) へと大きく上昇しています (図 5.11). 同類婚は「高所得同士・低所得同士の世帯」を作るので、世帯間格差の拡大と直結する現象です。




FIGURE 3. THE INCREASE IN MARRIED FEMALE LABOR-FORCE PARTICIPATION

図 5.9: Married female participation (Fig. 3)




FIGURE 4. THE RISE IN FEMALE EDUCATIONAL ATTAINMENT, THE COLLEGE PREMIUM, AND THE NARROWING OF THE GENDER WAGE GAP

図 5.10: College premium and gender gap (Fig. 4)




FIGURE 5. THE INCREASE IN HOUSEHOLD INCOME INEQUALITY

図 5.11: Household income inequality (Fig. 5)

5.3.2 モデル

骨格は Greenwood と Guner (2009 年) と同じ「出会い + マッチの質 + 停止ルール」ですが, エージェントに**ジェンダー** $g \in \{m, f\}$ と**タイプ** (能力 $a \sim A$, 教育 $e \in \{0, 1\}$) が入ります. 1 期 1 年の無限期間モデルで毎期の退出確率は δ , 各期の意思決定のタイミングは 図 5.12 のとおりです. 独身者は每期ランダムに異性の独身者と出会い, 相手の能力 a^* ・教育 e^* ・マッチの質 b ・女性の労働参加コスト q を見て結婚を決めます. 時間は単位 1 で, 労働は $h \in \{0, \bar{h}\}$ のフルタイムか非労働かの二択です. 結婚後は男性は必ずフルタイムで働き, 女性はフルタイム労働と家事専念を選べます.




FIGURE 6. TIMING OF DECISIONS

図 5.12: Timing of decisions (Fig. 6)

教育と時給. 時給は能力・教育・ジェンダーで決まります. 教育レベル e の男性の時給は $w_e a$ ($w_1 > w_0$), 女性の時給は $\phi w_e a$ で, $\phi \in [0, 1]$ がジェンダー賃金格差を表します. 教育には一度きりのコスト κ がかかり,

$$\kappa \sim \mathcal{N}\left(\frac{\eta_g}{a}, \sigma_\kappa^2\right)$$

と, 能力の高い人ほど平均的にコストが低くなっています. 大卒プレミアム w_1/w_0 が上がれば進学が増える, という教育の内生的な選択がここに入ります.

選好と家庭内生産. 効用は Greenwood と Guner (2009 年) と同じ発想で, 最低消費と規模の経済を持ちます.

$$T_s(c, n) = \frac{1}{1-\zeta}(c - \bar{c})^{1-\zeta} + \frac{\alpha}{1-\xi}n^{1-\xi} \quad (\text{single})$$

$$T_m(c, n) = \frac{1}{1-\zeta}\left(\frac{c - \bar{c}}{1+\chi}\right)^{1-\zeta} + \frac{\alpha}{1-\xi}\left(\frac{n}{1+\chi}\right)^{1-\xi} \quad (\text{married})$$

家庭内生産は家事財 d と家事時間の CES で,

$$n = \left(\theta d^\lambda + (1-\theta)(z - h_T)^\lambda\right)^{1/\lambda}$$

$z \in \{1, 2\}$ は世帯の総時間, h_T は世帯の総労働時間, $\lambda \in (0, 1)$ なら家事財と家事時間は代替的です.

期内の意思決定. 独身者の期内効用は

$$U_S^g(a, e) := \max_{c, d} T_S(c, n), \quad \text{s.t.} \quad c = \begin{cases} w_e \phi a \bar{h} - pd & (g = f) \\ w_e a \bar{h} - pd & (g = m) \end{cases}$$

で, $n = \left(\theta d^\lambda + (1 - \theta)(1 - \bar{h})^\lambda \right)^{1/\lambda}$ です. 有配偶者は妻の労働 $h^f \in \{0, 1\}$ も選びます.

$$U_M^g(a, e, a^*, e^*, b, q) := \max_{c, d, h^f} T_M(c, n) - h^f q,$$

subject to

$$c = \begin{cases} w_{e^*} a^* \bar{h} + w_e \phi a \bar{h} h^f - pd & (g = f) \\ w_e a \bar{h} + w_{e^*} \phi a^* \bar{h} h^f - pd & (g = m) \end{cases}$$

and $n = \left(\theta d^\lambda + (1 - \theta)(2 - \bar{h} - \bar{h} h^f)^\lambda \right)^{1/\lambda}$. q は妻がフルタイムで働くことへの効用コストで, 夫婦共通に効きます.

マッチの質と労働参加コスト. 独身者は毎期, 異性の独身者と出会い, $b \sim \mathcal{N}(\bar{b}_s, \sigma_{b,s}^2)$ と $q \in \mathcal{Q}^e = \{q_l^e, q_h^e\}$ を引きます. q の分布は**男性の教育** e に依存し, $q_l^e < q_h^e$ が各 $\frac{1}{2}$ の確率で実現します. 有配偶者のマッチの質は AR(1)

$$b' = (1 - \rho_{b,m})\bar{b}_m + \rho_{b,m}b + \sigma_{b,m}\sqrt{1 - \rho_{b,m}^2}\varepsilon, \quad \varepsilon \sim \mathcal{N}(0, 1)$$

で変動します.

結婚の合意. Greenwood と Guner (2009 年) と違い, 結婚の便益はタイプの組み合わせに依存するので, 男女の利害は一致しません. 結婚は双方が独身に留まるより良いと判断したときにのみ成立します.

$$V_m^g(a, e, a^*, e^*, b, q) \geq V_s^g(a, e) \text{ and } V_m^{g^*}(a^*, e^*, a, e, b, q) \geq V_s^{g^*}(a^*, e^*).$$

この条件が満たされる, つまり結婚するという場合のインディケータを $\mathbb{1}^g(a, e, a^*, e^*, b, q)$ と書くことにします.

価値関数. 独身者は, 出会う相手のタイプ分布 $\hat{S}^{g^*}$ を所与として期待を取ります.

$$\begin{aligned} V_s^g(a, e) &= U_S^g(a, e) + \beta \int_{\mathcal{B}} \int_{\mathcal{T}} \int_{\mathcal{Q}} \mathbb{1}^g(a, e, a^*, e^*, b, q) V_m^g(a, e, a^*, e^*, b, q) \\ &\quad + (1 - \mathbb{1}^g(a, e, a^*, e^*, b, q)) V_s^g(a, e) dQ(q) d\hat{S}^{g^*}(a^*, e^*) dF(b) \end{aligned}$$

$$\begin{aligned} V_m^g(a, e, a^*, e^*, b, q) &= U_M^g(a, e, a^*, e^*, b, q) + b + M(e, e^*) \\ &\quad + \beta \int_{\mathcal{B}} \mathbb{1}^g(a, e, a^*, e^*, b', q) V_m^g(a, e, a^*, e^*, b', q) \\ &\quad + (1 - \mathbb{1}^g(a, e, a^*, e^*, b', q)) V_s^g(a, e) dG(b'|b) \end{aligned}$$

有配偶者の価値には, 教育の組み合わせに直接依存する項 $M(e, e^*)$ が入っています. 「似た学歴の相手ということ自体の効用」で, 同類婚の選好的な源泉を捉える項です.

教育の選択. 結婚市場に参入する前に, 各人はコスト κ を見て教育を選びます.

$$\max_{e \in \{0,1\}} V_s^g(a, e) - e\kappa \Rightarrow E_a^g(\kappa) = \begin{cases} 1 & \kappa \leq V_s^g(a, 1) - V_s^g(a, 0) \\ 0 & \text{otherwise} \end{cases}$$

教育リターン $V_s^g(a, 1) - V_s^g(a, 0)$ には, 賃金の上昇だけでなく結婚市場でのマッチング相手の変化も含まれる点が重要です. 大卒女性が増えれば大卒男性にとって大卒の相手と出会うやすくなり, それもまた教育のリターンを変える, というフィードバックが働きます.

定常均衡. 独身者の分布 $S^g(a, e)$ と有配偶者の分布 $M^g(a, e, a^*, e^*, b_{-1}, q)$ は, Greenwood と Guner (2009 年) と同じ発想の流出入バランスを満たす定常分布として定義されます (式は長くなるだけなので論文に譲ります). 出会いの相手は, 独身者の数で標準化された分布

$$\hat{S}^g(a^*, e^*) := \frac{S^g(a^*, e^*)}{\int_{\mathcal{T}} dS^g(a^*, e^*)}$$

からランダムに引かれます. 状態変数の次元は増えていますが, 構造は「停止ルール + 定常分布」のままです.

5.3.3 推定

モデルの外から与えるパラメータは, $1/\delta = 30$ (25-54 歳の 30 年), $\bar{h} = 0.36$ (週 40 時間 / 可処分 16 × 7 時間) などです (図 5.13).

TABLE 2—PARAMETERS: A PRIORI INFORMATION

Category	Parameter values	Criteria
Preferences	$\chi = 0.70$	OECD scale
	$\tilde{\beta} = 0.96$	Prescott (1986)
Household technology	$\theta = 0.21, \lambda = 0.19$	McGrattan et al. (1997)
Death probability	$\delta = 1/30$	A 30-year lifespan
Hours	$\bar{h} = 0.36$	Data

図 5.13: A priori parameters (Table 2)

残る 22 個のパラメータは, **1960 年**のデータによる 24 個のターゲット (学歴別の結婚・離婚・妻の労働参加, 賃金分布など) を用いた最小距離推定で決めます (図 5.14).

TABLE 4—DATA AND BENCHMARK MODEL, 1960

	<i>Data</i>		<i>Model</i>	
<i>Education</i>	Fem.	Males	Fem.	Males
	0.072	0.125	0.074	0.129
<i>Marriage</i>				
Fraction	Sing.	Marr.	Sing.	Marr.
	0.130	0.870	0.151	0.849
<i>Rates</i>	< Coll.	Coll.	< Coll.	Coll.
Marriage	0.925	0.849	0.888	0.882
Divorce	0.053	0.033	0.044	0.040
<i>Sorting</i>	Wife		Wife	
Husband	< Coll.	Coll.	< Coll.	Coll.
< College	0.855	0.023	0.843	0.028
College	0.082	0.041	0.085	0.045
Corr., educ.	0.414		0.403	
<i>Work, Married Fem.</i>				
Husband	Wife		Wife	
	< Coll.	Coll.	< Coll.	Coll.
< College	0.328	0.528	0.318	0.586
College	0.213	0.347	0.207	0.294
Participation, all	0.324		0.315	
Income, fraction	0.110		0.122	
<i>Inequality</i>				
Gini	0.306		0.307	
Ratio 90/10	4.829		4.536	
Ratio 90/50	1.817		2.043	
Income, Sf/Married	0.473		0.393	
<i>Income, Marriage</i>				
Husband	Wife		Wife	
	< Coll.	Coll.	< Coll.	Coll.
< College	0.932	1.335	0.943	0.700
College	1.369	1.501	1.400	1.501
Skill premium	1.548		1.565	
Gender gap	0.446		0.419	

図 5.14: Targets, 1960 (Table 4)

TABLE 3—PARAMETERS: ESTIMATED (*Minimum distance*)

Category	Parameter values	Standard error	95 percent conf. interval
Preferences	$\alpha = 1.198$	0.029	[1.141, 1.255]
	$\xi = 3.114$	0.021	[3.073, 3.155]
	$\zeta = 1.782$	0.010	[1.762, 1.803]
	$c = 0.068$	0.0004	[0.067, 0.069]
	$\mu_0 = 0.400$	0.170	[0.067, 0.733]
	$\mu_1 = 1.308$	0.094	[1.124, 1.492]
Ability shocks	$\sigma_a^2 = 0.310$	0.003	[0.304, 0.315]
Marital bliss shocks	$\bar{b}_s = -1.497$	0.111	[-1.715, -1.279]
	$\sigma_{b,s}^2 = 0.599$	0.075	[0.451, 0.746]
	$\bar{b}_m = -0.403$	0.029	[-0.459, -0.347]
	$\sigma_{b,m}^2 = 0.338$	0.028	[0.284, 0.393]
	$\rho_{b,m} = 0.959$	0.004	[0.951, 0.967]
	$q_l^0 = 0.175$	0.066	[0.046, 0.305]
Home shocks	$q_h^0 = 0.303$	0.127	[0.053, 0.552]
	$q_l^1 = -0.226$	0.066	[-0.354, -0.097]
	$q_h^1 = -0.126$	0.123	[-0.367, 0.115]
	$p_{1960} = 54.703$	8.219	[38.594, 70.812]
Price and wages	$w_{0,1960} = 1$ (normalization)	—	—
	$w_{1,1960} = 1.040$	0.015	[1.011, 1.068]
	$\phi_{1960} = 0.400$	0.002	[0.396, 0.404]
	$\eta_m = 69.861$	5.525	[59.031, 80.690]
Cost of education	$\eta_f = 134.970$	8.770	[117.781, 152.159]
	$\sigma_\kappa = 54.134$	4.871	[44.587, 63.681]

図 5.15: Estimated parameters (Table 3)

推定値 (図 5.15) の読み方は Greenwood と Guner (2009 年) とよく似ています. $\bar{b}_s = -1.497 < 0$: 出会いの平均的な質は負で, 良い相手を待つ構造. $\bar{b}_s < \bar{b}_m$ かつ $\sigma_{b,s} > \sigma_{b,m}$: 選別を通過した結婚のマッチの質は, ランダムな出会いより良く, 安定している. $\rho_{b,m} = 0.959$: 結婚生活のマッチの質はきわめて持続的です. 興味深いのは女性の労働参加コスト q です. 夫が非大卒だと共働きに正のコスト ($q_l^0, q_h^0 > 0$), 夫が大卒だと共働きはむしろプラス ($q_l^1, q_h^1 < 0$) と推定されます. 論文は解釈を明示していませんが, 性別役割分担の価値観や職種による働きやすさの違いなど, 複合的な要因を吸収した係数と考えられます.

2005 年への移動. 1960 年に合わせたモデルを, 技術と教育のパラメータだけ動かして 2005 年に「移動」させます. 非大卒男性の賃金 $w_{0,2005} = 1.17$ (17% 上昇) はデータから直接, 家事財の価格は Gordon (1990) や NIPA を根拠に毎年 5% の下落 ($p_{2005} = p_{1960}e^{-0.05(2005-1960)}$) とし, 残りは 2005 年のターゲットに対する最小距離推定で求めます.¹⁵

表 5.1: 2005 年の再推定パラメータと対応するターゲット

	2005	(1960)	Target	2005	(1960)
w_1	1.81	1.04	Skill premium of college	2.020	1.550
ϕ	0.59	0.40	Female relative earnings	0.640	0.450
η_f	66.45	134.97	Share of college, females	0.332	0.072
η_m	55.75	69.86	Share of college, males	0.318	0.125

¹⁵ この部分のターゲットは論文の記述からは正確には特定できませんが, おおよそ次の表のような対応と読めます.

さらに、同類婚の当てはまりを改善するために教育マッチ効果 $M(e, e^*)$ のパラメータも $\mu_{0,2005} = 0.214$, $\mu_{1,2005} = 0.375$ と動かしています。1960 年と比べて「階級意識」(class consciousness) が弱まった、という解釈です。

5.3.4 反実仮想

カリブレーションされたモデルで、技術の各要素を 1960 年の水準に固定する実験をします。




図 5.16: Share of singles




図 5.17: Married women's participation

結婚の減少には p の下落と w の上昇の両方が効いています (図 5.16)。家事財の技術が進歩しなければ家庭内の協業が魅力を保ち、賃金が上がらなければ独身の生活が成り立ちにくいままだからです。一方、既婚女性の労働参加を押し上げたのは主に家事財の技術進歩です (図 5.17)。女性の賃金が男性より低いという構造が変わらない限り、家事負担は女性に寄ったままなので、家事時間を解放する技術が参加の条件になります。




図 5.18: Correlation of spousal education




図 5.19: Gini of household income

同類婚の増加と世帯所得格差の拡大を駆動するのは賃金、とりわけ大卒プレミアムの上昇です (図 5.18, 図 5.19)。大卒の価値が上がると、教育への投資が増えると同時に「大卒の相手」の結婚市場での価値も上がり、同類婚傾向が強まり、それが世帯所得の格差を広げます。

5.3.5 まとめ

Greenwood と Guner (2009 年) に対する拡張のポイントは 2 つです。第 1 に、ジェンダーと教育・能力の異質性を入れたことで、学歴別の結婚行動や同類婚という「誰と誰が」の問いを扱えるようになりました。モデルの本質は変わらず、定常分布 S や M の次元が増えただけです。第 2 に、教育選択を内生化したことで、賃金構造の変化が教育・結婚市場・世帯格差へ波及する経路を一つのモデルで定量化

できます。ただし、家計内の資源配分は「共通の効用へのスケーリング + 妻の労働の二択」という簡便な形に留まっています。家計の中の交渉と時間配分を本格的に開くのが、Goussé ほか (2017 年) です。

5.4 Goussé ほか (2017 年)

5.4.1 Motivation

1990 年代以降の先進国では、それまでのマクロなトレンドが落ち着き、別の変化が進みます。既婚女性の労働供給の伸びは頭打ちになる一方で、男女間・既婚未婚間の時間配分の差は根強く残り、結婚の賃金プレミアムは (特に男性で) 上昇し、ジェンダー賃金格差はゆっくり縮小し、社会の意識は伝統的家族観から離れていきました。Greenwood ほか (2016 年) のような集計技術の変化だけでは、この時期の変化は説明しにくくなっています。そこでこの論文は、賃金・学歴に加えて家族観 (family values) という第 3 の異質性を明示的に入れ、次の問いを立てます。

- 男女の労働供給・家事時間の差は、どこまでが賃金の差で、どこまでが学歴で、どこまでが家族観 (保守的な価値観) によるのか
- 家計内の資源配分 (sharing rule) は、結婚市場の競争からどう内生的に決まるのか

1 つ目の問いに答えるための材料が、家族観を測る Family Values Index (FVI) です。BHPS の、子ども・結婚・同棲・離婚についての意識を問う質問への回答を主成分分析して作った指標で、値が高いほど社会的に保守的であることを意味します。図 5.20 は、男女別・配偶関係別の FVI の平均の推移です。男性は女性より、有配偶者は独身者より保守的で、4 つのグループすべてが 1991 年から 2008 年にかけて緩やかにリベラル化しています (18 年で 0.5 未満)。有配偶者と独身者の差は、家族観が結婚市場の選別に効いていることを示唆します。




図 5.20: Family Values Index (Table I, Bottom Panel)

2 つ目の問いが、この講義の文脈では特に重要です. Collective モデル (4.1 節で GMM 推定した Pareto ウェイト μ) では、交渉力は外生か、分配要因の誘導形の関数として与えられていました. サーチ・マッチングの均衡でこれを内生化すると、「結婚市場で誰に出会えるか」という outside options が交渉力の源泉として定式化できます.

5.4.2 モデル

このモデルは、ここまでの2本と違って連続時間で表現されています. Greenwood と Guner (2009 年) と Greenwood ほか (2016 年) が 1 期 1 年の離散時間だったのに対し、ここでは出会い・マッチの質の変動といったイベントがポアソン過程として到着します. 割引率は r で表され、価値関数は Hamilton-Jacobi-Bellman (HJB) 方程式の形で価値関数が書かれます. 連続時間モデルに関しては、付録 B にまとめてあります.

なお、連続時間モデルにおいて資産のような連続的に動く状態変数がある場合、数値計算としては有限差分法 (finite difference method) を使う必要があります. この手法によるマクロモデルの解法とその有用性は Achdou ほか (2022 年) が示しました. しかし、Goussé ほか (2017 年) のモデルは状態変数をポアソン到着する離散的なイベントに限定しているので、連続時間の HJB 方程式を解く必要がありません. 逆にいうと Greenwood と Guner (2009 年) のように match quality が前の期に依存するような確率過程 (Ornstein-Uhlenbeck など) を入れていないのはそのためと考えられます. Yanagimoto (2026 年 b) は、Greenwood と Guner (2009 年) のモデルを連続時間化して数値計算する方法を示しました.

5.4.2.1 タイプと出会い

男性のタイプ i , 女性のタイプ j は, それぞれ (賃金 w , 学歴, 家族観指数) の組です. タイプ i の独身男性の分布を $n_m(i)$, タイプ j の独身女性の分布を $n_f(j)$, タイプの組 (i, j) の夫婦の分布を $m(i, j)$ と書き, 独身の総数を $N_m = \int n_m(i)di$, $N_f = \int n_f(j)dj$ とします. これらはいずれも内生変数です.

サーチをするのは独身者だけです. 出会いは CRS のマッチング関数で生まれ, 1 人あたりの出会い率は $\lambda = \xi(N_m N_f)^{-1/2}$ です. 出会った男女はマッチの質 $z \sim \log \mathcal{N}(0, \sigma)$ (CDF を $G(z)$ とおく) を引き, 双方が合意すれば結婚します. 合意するかどうかはタイプの組と z の実現で決まるので, 観察される i, j から結婚に至る確率は 式 (5.3) で表されます.

$$\alpha_{ij} = \int \mathbb{1}_{ij}(z) dG(z). \quad (5.3)$$

ここで, $\mathbb{1}_{ij}(z)$ は, タイプの組 (i, j) がマッチの質 z で結婚するかどうかを示すインディケーターです.

結婚後は, 率 δ でマッチの質が引き直されます. 新しい z' は同じ G から独立に引かれるので, 引き直しを 1 回生き延びる確率はふたたび α_{ij} です. したがって離婚ハザードは $\delta(1 - \alpha_{ij})$ になります. 結婚と離婚を同じ α_{ij} が決めているという構造が重要です. α_{ij} が高い組は, 「結婚しやすく壊れにくい」と言う構造を作ります. 逆に, 一目惚れのような高い z の実現で結婚した組は, 引き直しに弱く壊れやすい, という予測が出ます.

図 5.21 にここまでの構造をまとめました. 独身の男女がそれぞれのプールで相手を探し, 率 λ で出会って z を引き, 合意すれば夫婦のプールへ移ります. 結婚後は率 δ で z が引き直され, 合意が続けばそのまま, 途切れれば両者が独身のプールに戻ります. 図の下に書いた流出入のバランスが, 後で定常状態を定める条件になります.




図 5.21: Search and matching with types, bargaining, and renegotiation

5.4.2.2 選好と家庭内生産

各個人は, 私的消費 c , 私的余暇 e , そして家計の公共財 q (食事, 住環境, 子育てなど) から効用 $U_i(c, e, q)$ を得ます. 各人の使える時間の総量は 1 に基準化し, それを市場労働 h , 私的余暇 e , 家事時間 d の 3 つに配分します ($h = 1 - e - d$). 公共財を作る唯一の投入がこの家事時間 d で, その公共財が, 結婚を独身より魅力的にしうる唯一のチャネルです.

公共財の生産関数は独身と夫婦でそれぞれ Stone-Geary 型で書かれます.

$$q = F_g^0(d) = (d - D_g^0)^{K_g^0} \quad (\text{Single})$$

$$q = F_{ij}(d_m, d_f) = Z_{ij}(d_m - D_m^1)^{K_m^1} (d_f - D_f^1)^{K_f^1} \quad (\text{Married})$$

ここで, D は最低投入量, Z_{ij} はマッチの質です. 夫婦の生産関数は二つの要素からなります.

1. **マッチの質** Z_{ij} : 学歴の補完性が高いほど Z_{ij} が大きくなり, 家事時間の投入量が増えます
2. **家族観** D_g : 家族観が保守的なほど, D_g が大きくなり, 家事時間の投入量が増えます

予算制約は独身が

$$c + w_i e = w_i(1 - d) =: R,$$

夫婦が以下になります.

$$c_m + w_i e_m = w_i(1 - d_m) - t_m =: R_m,$$

$$c_f + w_j e_f = w_j(1 - d_f) - t_f =: R_f$$

(t_m, t_f) は配偶者間の移転で, 世帯の生活費 C_{ij} を賄う制約 $t_m + t_f = C_{ij}$ を満たします. C_{ij} は家庭内生産の技術を動かすための固定費用, あるいは共同で消費する分の費用と解釈され, タイプの組に依存する一方で賃金には依存しません. 独身にはこの費用がかかりません.

効用関数は, 直接効用 U_i ではなく, 私的支出 R と公共財 q を所与として c, e を最適に選んだあとの (条件付き) 間接効用

$$\psi_i(R, q) = \max_{c, e} U_i(c, e, q) \quad \text{s.t.} \quad c + w_i e \leq R$$

の形で特定化されます.

$$\psi_i(R, q) = \frac{q(R - A_i)}{B_i}, \quad A_i = a_{0i} + a_{1i}w_i + \frac{1}{2}a_2w_i^2, \quad \ln B_i = b_i \ln w_i \quad (5.4)$$

A_i は「効用が正になるのに最低限必要な私的支出」, B_i は本人の賃金 (余暇の価格) に応じた個人別の価格指数で, 分子 $q(R - A_i)$ は名目の効用水準と読めます. 公共財 q と私的支出が掛け算で入るのがポイントで, これが後で移転可能効用を生みます. パラメータ a_{0i}, a_{1i}, b_i は本人の特性 (学歴・家族観) の線形関数, a_2 は性別ごとの定数です.

余暇の価格は賃金 w_i なので, 余暇の需要は Roy の恒等式

$$e = -\frac{\partial \psi_i / \partial w_i}{\partial \psi_i / \partial R}$$

から求められます. 式 (5.4) を微分すると $\partial \psi_i / \partial R = q/B_i$, $\partial \psi_i / \partial w_i = -q[A'_i B_i + (R - A_i)B'_i]/B_i^2$ なので,

$$e = A'_i + \frac{B'_i}{B_i}(R - A_i)$$

です。 $A'_i = a_{1i} + a_2 w_i$, $B'_i/B_i = b_i/w_i$ を代入して w_i を掛ければ、余暇支出と消費は

$$w_i e = a_{1i} w_i + a_2 w_i^2 + b_i (R - A_i), \quad c = R - w_i e$$

となります。 q は分子と分母で打ち消し合うので、余暇の需要は公共財の水準に依存しません。推定では、この余暇支出が家事時間とともにデータに当てられます。なお、 ψ_i が d に依存しないのは、 $e \leq 1 - d$ の制約が効かない（内点解の）範囲を仮定しているからです（Goussé ほか 2017 年, eqs. 5.1, 6.1-6.3）。

ここで、規模の経済がどこにあるかを整理します。夫婦の q は 2 人の家事時間から一度だけ作られ、それを 2 人が同時に享受します。公共財が世帯内で非競合であること自体が規模の経済で、さらに Z_{ij} が組み合わせ次第でその生産性を押し上げます。一方、私的消費 c と私的余暇 e の側には「2 人なら 1 人あたり割安」という等価尺度は一切入っていません。結局、結婚の得失は公共財から得られるこの利益と、生活費 C_{ij} とのトレードオフで決まります。

5.4.2.3 HJB 方程式

独身の男性（タイプ i ）の価値 $V_m^0(i)$ は次を満たします。

$$rV_m^0(i) = u_m^0(i) + \lambda \iint [V_m^1(i, j, z) - V_m^0(i)]^+ n_f(j) dG(z) dj \quad (5.5)$$

$u_m^0(i)$ は独身のフロー効用（自分の家事時間を最適に選んだときの間接効用 $\max_d \psi_i(w_i(1 - d), F_i^0(d))$ ）、 $V_m^1(i, j, z)$ はタイプ i の男性がタイプ j の相手とマッチの質 z で結婚したときの価値です。率 λ で相手に出会い、相手のタイプは独身女性の分布 n_f から、 z は G から引かれます。正の部分 $[\cdot]^+$ が「合意しなければ独身のまま」で、出会っても価値が上がらなければ結婚しません。右辺第 2 項がそのまま外部機会の価値で、良い相手に出会いやすいタイプほど大きくなります。

結婚している男性の価値は、自分のタイプ i だけでなく相手のタイプ j とマッチの質 z にも依存します。結婚契約の価値を $W_m(i, j, z)$ と書くと、契約で決まったフロー効用 $u_m(i, j, z)$ と、次に z が引き直されたときの選択の価値からなります。

$$rW_m(i, j, z) = u_m(i, j, z) + \delta \int [\max\{V_m^0(i), V_m^1(i, j, z')\} - W_m(i, j, z)] dG(z') \quad (5.6)$$

第 2 項が離婚のオプション価値です。率 δ で新しい z' が引かれ、継続の価値 $V_m^1(i, j, z')$ が独身の価値 $V_m^0(i)$ を上回れば結婚は続き、下回れば離婚します。引き直されるのは z だけで、タイプの組 (i, j) は結婚している限り変わらないことに注意してください。離婚してはじめて i は独身プールに戻り、相手を選び直します。

以下では、混乱の恐れがないところではタイプの引数を省いて V_m^0 , $V_m^1(z)$, W_m のように書きます。

5.4.2.4 Nash Bargaining

夫婦は、家事時間 (d_m, d_f) と私的支出への移転 (t_m, t_f) を、独身の価値（outside options）を交渉決裂点とする、Nash bargaining で決めます。

$$\max [W_m(i, j, z) - V_m^0(i)]^\beta [W_f(i, j, z) - V_f^0(j)]^{1-\beta}$$

ここではコミットメントができず、どちらもいつでも交渉から降りられる (離婚できる) と仮定します。そのため、 z が引き直されるたびに配分は再交渉されます。

この時、交渉力の源泉は次の 2 つからなります。

1. **Behavioral** β : Nash ウェイトで、交互提案交渉の相対的な忍耐強さに対応します。どちらがより待てるか、交渉が上手かといったものをまとめて吸収した誘導形のパラメータです。
2. **Economic** V_m^0, V_f^0 : 交渉決裂点で、離婚して結婚市場に参入した場合の価値によって決定されます。家計の外の均衡が家計内の力関係に持ち込まれます。

推定では β は全カップル共通の定数として 1 つだけ推定されます。したがって、カップルによって分配が違う理由はすべて outside options の差とマッチの質 z の側にある、という構造になっています。

コミットメントがないということは、契約が約束する継続価値が、各時点で本人にとって最適な選択と整合的でなければならない、ということです。つまり 式 (5.6) の契約の価値 W_m は継続価値 $V_m^1(z)$ そのものでなければならず、これを代入して整理すると (セクション A.7.1), 次の式を得ます。

$$(r + \delta)[V_m^1(z) - V_m^0] = u_m - rV_m^0 + \delta \int [V_m^1(z') - V_m^0]^+ dG(z') \quad (5.7)$$

左辺が結婚をしていることの純価値 (net surplus) のフロー換算で、右辺が結婚した場合に受け取るフローの効用になります。 $u_m - rV_m^0$ が「今期、結婚しているおかげで独身より多く得ている分」、 $\delta \int [V_m^1(z') - V_m^0]^+ dG(z')$ が「次に z' が引き直されたときのオプション価値」 になります。

5.4.2.5 余剰とマッチング集合

TU のもとでは、男女の取り分を足し合わせて 1 つの余剰にまとめられます。余剰を $S_{ij}(z) := B_i[V_m^1(z) - V_m^0] + B_j[V_f^1(z) - V_f^0]$ と定義すると、セクション A.7.2 より、次の式が成り立ちます。

$$(r + \delta)S_{ij}(z) = zF_{ij}X_{ij} - B_i rV_m^0 - B_j rV_f^0 + \delta \int S_{ij}(z')^+ dG(z') \quad (5.8)$$

ここで、家計の純私的支出 $X_{ij} := w_i(1 - d_m) + w_j(1 - d_f) - C_{ij} - A_i - A_j$ です。

この時、合意条件 $1_{ij}(z) = \mathbb{1}\{S_{ij}(z) \geq 0\}$ を閉じた形でかけます。式 (5.8) の右辺は $zF_{ij}X_{ij}$ のみが z に依存し、自明に増加関数であるので、余剰 $S_{ij}(z)$ も z について増加関数になります。したがって、ある閾値 z_{ij} が存在して、「 z が z_{ij} 以上なら結婚、それ未満なら独身」という留保値ルールが成り立ちます。すなわち、式 (5.3) のインディケータは次の形で書くことができます。

$$\alpha_{ij} = \int \mathbb{1}\{S_{ij}(z) \geq 0\} dG(z) = 1 - G(z_{ij}) \quad (5.9)$$

独身の価値は、出会える相手の分布に対する期待余剰で決まります (導出は セクション A.7.4)。

$$B_i rV_m^0 = B_i u_m^0 + \lambda \beta \int \bar{S}_{ij} n_f(j) dj \quad (5.10)$$

この方程式が outside option を定めます。良い相手に会いやすいタイプほど期待余剰が大きくなり家計内の交渉力が強くなります。

5.4.2.6 Sharing rule

Nash 交渉の解として、夫が受け取る純私的支出のシェアは

$$\beta_{ij}(z) = \beta + \frac{(1 - \beta)B_i r V_m^0 - \beta B_j r V_f^0}{z F_{ij} X_{ij}}$$

となります (導出は付録の A.7.5 節). collective モデルで外生だった Pareto ウェイトが, 「Nash ウェイト β + 外部機会の差」という 2 つの構造的な源泉に分解されているのが分かります. 分母にマッチの質 z が入るので, 同じタイプの夫婦でも z の実現によってシェアが異なります. この「観察できない配分のばらつき」が, 後で識別に使われます.

5.4.2.7 定常状態

タイプの組 (i, j) ごとに, 結婚による流入と離婚による流出がバランスします.

$$\delta(1 - \alpha_{ij}) m(i, j) = \lambda n_m(i) n_f(j) \alpha_{ij} \quad (5.11)$$

ここで, m は夫婦の分布, n_m, n_f は独身者の分布です. 実証上は, 経済は 3 年ごとの定常状態を渡り歩くと仮定し, 賃金・学歴・家族観の分布だけを期間ごとに動かして, 構造パラメータは全期間で共通とします.

5.4.3 推定

データはイギリスの家計パネル BHPS の 1991-2008 年 (22-50 歳) です. 賃金, 市場労働時間, 家事時間 (BHPS の設問の制約で育児は含みません) を使います. 家族観指数 (Family Values Index) は, 「未就学児がいるのに母親が働くと子どもが苦しむ」「夫が稼ぎ妻は家庭を守るべき」といった 13 の意識項目の第 1 主成分です. この指数は賃金・学歴とほぼ直交しており (R^2 は数 %), 賃金や教育とは独立の異質性として機能します.

推定は 3 段階に分かれます. 推定の前にデータから, 各 i, j (賃金・学歴・家族観の組) の次のものを計算しておきます.

- 賃金 w_i, w_j
- 独身の分布 $n_m(i), n_f(j)$ と総数 N_m, N_f
- 夫婦の分布 $m(i, j)$
- 結婚・離婚のフロー $MF(i, j), DF(i, j)$

1. 結婚・離婚フロー: タイプの組ごとの結婚・離婚フローは次のようになります.

$$\begin{aligned} MF(i, j) &= \lambda n_m(i) n_f(j) \alpha_{ij}, \\ DF(i, j) &= \delta(1 - \alpha_{ij}) m(i, j). \end{aligned}$$

ここで, 結婚率 $MR(i, j) := \frac{MF(i, j)}{n_m(i) n_f(j)}$, 離婚率 $DR(i, j) := \frac{DF(i, j)}{m(i, j)}$ と書くと, α_{ij} を消去して, 次のように書けます.

$$\frac{MR(i, j)}{\lambda} + \frac{DR(i, j)}{\delta} = 1.$$

出会い関数 $\lambda = \xi(N_m N_f)^{-\frac{1}{2}}$ を代入すると、次の式を得ます。

$$\frac{1}{\xi}(N_m N_f)^{\frac{1}{2}}MR(i, j) + \frac{1}{\delta}DR(i, j) = 1. \quad (5.12)$$

フローはサンプルが小さいので、 $MR(i, j), DR(i, j)$ は学歴（男女それぞれ 3 カテゴリ）のセルごとに集計し、4 つの期間（94-96, 97-99, 00-02, 03-05）をプールして推定します¹⁶。推定は 1 を被説明変数、 $(N_m N_f)^{1/2}MR(i, j)$ と $DR(i, j)$ を説明変数とする切片なしの回帰です¹⁷。これにより $\hat{\xi} = 0.151$, $\hat{\delta} = 0.0378$ を得ます。これは、出会いの間隔は中央値で 4 年半ほど、引き直し率は 18 年に 1 回ほどという意味です。また、 α_{ij} は 式 (5.11) を変形して、

$$\alpha_{ij} = \frac{\delta m(i, j)}{\lambda n_m(i)n_f(j) + \delta m(i, j)},$$

から復元されます。

ここで注意すべきなのは、この復元がセルごとに流入と流出が一致する $MF(i, j) = DF(i, j)$ を課していることです。この仮定はグラフで確認できます。タイプの組・期間ごとの結婚フロー $MF(i, j)$ を横軸、離婚フロー $DF(i, j)$ を縦軸にとったのが 図 5.22 で、定常状態が成り立っていれば点は 45 度線に乗るはず¹⁸。回帰直線の傾きは 0.86 ($R^2 = 64\%$) と 45 度線からやや外れますが、系統的なズレは見られません。

¹⁶両端の期間（91-93, 06-08）は、1991 年の離婚フローと 2008 年の結婚フローが計算できないため除かれています。

¹⁷丁度識別のモーメント条件なので、GMM と OLS は一致します。論文はこれを OLS と呼んでいます。

¹⁸この図のセルは学歴（3）× 家族観（2）を男女それぞれにとり、4 年幅の 4 期間（92-95, 96-99, 00-03, 04-07）と組み合わせた $3 \times 3 \times 2 \times 2 \times 4 = 144$ 点です。




図 5.22: Marriage and divorce flows by type and period (Fig. 6)

2. 家事時間と余暇支出の回帰: 家事時間と余暇支出を, 賃金・学歴・家族観に回帰する形で選好・家庭内生産のパラメータと (β, σ) を推定します. パラメータを更新するたびに均衡 (マッチング確率, 单身者の分布, sharing rule) を解き直します. β は夫婦の余暇の水準から, σ はその分散から識別されます (付録 A.7.6.3 節)

3. 公共財の質 均衡における家庭内生産は次の式で表されます.

$$F_{ij} = Z_{ij} \left(\frac{K_m^1}{w_i} \right) K^{K_m^1} \left(\frac{K_f^1}{w_j} \right) X_{ij}^{K_m^1 + K_f^1}.$$

ここから, Z_{ij} が復元できます.

主要な推定値は, 出会い率 $\xi = 0.151$ (出会いの間隔は中央値で4年半ほど), 引き直し率 $\delta = 0.038$ (18年に1回ほど), Nash ウェイト $\hat{\beta} = 0.45$, マッチの質のばらつき $\hat{\sigma} = 0.268$ です. 選好と家庭内生産のパラメータは 図 5.23 にまとめられています. 家族観が効くのは家庭内生産の最低投入時間で, 夫婦の $D_j^1[FVI]$ は女性で $+0.0159$, 男性で -0.0073 と符号が逆です. 保守的な妻は家事時間を増やし, 保守的な夫は減らす, という比較優位がここで作られています. 一方, 学歴は選好側 (消費のウェイト a_{0j}, a_{1j}) と生活費 C に効きます.

Preferences			Home production, singles		
$a_{0f}[Ed = L]$	-21.46	(7.80)	$D_f^0[Ed = L]$	0.0524	(0.0177)
$a_{0m}[Ed = L]$	-26.63	(8.09)	$D_m^0[Ed = L]$	0.0467	(0.0188)
$a_{0f}[Ed = H]$	-12.74	(5.01)	$D_m^0[Ed = H]$	0.0481	(0.0142)
$a_{0m}[Ed = H]$	-13.58	(5.50)	$D_f^0[Ed = H]$	0.0363	(0.0142)
$a_{0f}[FVT]$	0.7455	(0.7355)	$D_f^0[FVT]$	0.0096	(0.0041)
$a_{0m}[FVT]$	0.6168	(0.6101)	$D_m^0[FVT]$	0.0031	(0.0039)
$a_{1f}[Ed = L]$	0.4403	(0.0175)	K_f^0	0.0177	(0.0070)
$a_{1m}[Ed = L]$	0.3939	(0.0197)	K_m^0	0.0002	(0.0034)
$a_{1f}[Ed = H]$	0.4350	(0.0215)	Home production, couples		
$a_{1m}[Ed = H]$	0.3812	(0.0258)	$D_f^1[Ed = L]$	0.0701	(0.0105)
$a_{1f}[FVT]$	0.0184	(0.0046)	$D_m^1[Ed = L]$	0.0660	(0.0095)
$a_{1m}[FVT]$	-0.0001	(0.0050)	$D_f^1[Ed = H]$	0.0564	(0.0094)
a_{2f}	-0.0031	(0.0007)	$D_m^1[Ed = H]$	0.0708	(0.0085)
a_{2m}	-0.0008	(0.0005)	$D_f^1[FVT]$	0.0159	(0.0029)
$b_f[Ed = L]$	0.0303	(0.0119)	$D_m^1[FVT]$	-0.0073	(0.0025)
$b_m[Ed = L]$	0.0345	(0.0122)	$C[constant]$	37.14	(10.05)
$b_f[Ed = H]$	0.0721	(0.0248)	$C[FVT_f]$	-1.251	(0.787)
$b_m[Ed = H]$	0.0940	(0.0340)	$C[FVT_m]$	-3.896	(1.180)
$b_f[FVT]$	-0.0023	(0.0020)	$C[Ed_f = L]$	-4.023	(2.328)
$b_m[FVT]$	-0.0000	(0.0021)	$C[Ed_m = L]$	-9.105	(3.742)
			K_f^1	0.0183	(0.0038)
			K_m^1	0.0056	(0.0026)

図 5.23: Estimated preference and home production parameters (Table III)

5.4.4 結果

5.4.4.1 同類婚の 3 つの側面

図 5.24 は、第 1 段階で推定したマッチング確率 α_{ij} を、学歴・家族観・賃金の 3 つの次元それぞれで集計したものです。同類婚のパターンは次元ごとにまったく違う顔を持ちます。

- **学歴:** 対称な homophily. 対角線上の確率が高く、行と列を入れ替えてもほぼ同じ形になる
- **家族観:** 非対称な homophily. 保守的な人は保守的な相手を強く選ぶが、リベラルな人は相手の家族観にほぼ無差別
- **賃金:** homophily は**ほぼない**. 女性の賃金はマッチングにほとんど影響せず、観察されるのは「低賃金の男性が結婚しにくい」という一方向の選別だけ

		Female								
		1991–1993			2000–2002			2006–2008		
		<HS	HS	>HS	<HS	HS	>HS	<HS	HS	>HS
Male	<HS	0.49	0.31	0.21	0.49	0.42	0.23	0.47	0.46	0.26
	HS	0.34	0.35	0.23	0.41	0.42	0.26	0.44	0.47	0.32
	>HS	0.21	0.17	0.39	0.24	0.32	0.42	0.18	0.33	0.43

(a) By education

		Female											
		1991–1993				2000–2002				2006–2008			
		Q4	Q3	Q2	Q1	Q4	Q3	Q2	Q1	Q4	Q3	Q2	Q1
Male	Q4	0.51	0.49	0.41	0.30	0.59	0.47	0.42	0.31	0.58	0.49	0.46	0.36
	Q3	0.50	0.48	0.42	0.32	0.49	0.44	0.41	0.34	0.49	0.46	0.44	0.36
	Q2	0.45	0.44	0.41	0.35	0.45	0.42	0.40	0.35	0.45	0.44	0.43	0.36
	Q1	0.37	0.37	0.38	0.37	0.38	0.38	0.38	0.36	0.39	0.39	0.39	0.35

(b) By FVI

		Female											
		1991–1993				2000–2002				2006–2008			
		Q4	Q3	Q2	Q1	Q4	Q3	Q2	Q1	Q4	Q3	Q2	Q1
Male	Q4	0.50	0.49	0.48	0.42	0.52	0.50	0.48	0.44	0.59	0.55	0.52	0.44
	Q3	0.43	0.44	0.43	0.39	0.50	0.49	0.48	0.45	0.51	0.49	0.47	0.40
	Q2	0.41	0.42	0.41	0.37	0.40	0.42	0.42	0.41	0.41	0.42	0.41	0.35
	Q1	0.29	0.31	0.31	0.30	0.25	0.28	0.30	0.31	0.27	0.30	0.30	0.27

(c) By wage quartile

図 5.24: Matching probabilities by type (Table II)

家族観の非対称性は 図 5.24 (b) にはっきり出ています. FVI の四分位で, Q4 が最も保守的, Q1 が最もリベラルです. リベラルな男性 (Q1 の行) のマッチング確率は相手の家族観によらずほぼ一定 (1991-93 年で 0.37-0.38) なのに対し, 保守的な男性 (Q4 の行) は相手が保守的なら 0.51, リベラルなら 0.30 と大きく下がります. 列で見ても同じで, 保守的な人だけが相手を選んでいきます.

3つ目の結果は, 「妻が夫より稼ぐ夫婦が極端に少ない」という有名な事実 (Bertrand ほか 2015 年) に別の解釈を与えます. これは夫婦の賃金比の分布の形についての事実ですが, これはどの組み合わせが結婚に至るかに大きく影響を受けます. そこでマッチング確率を妻の賃金シェア $\frac{w_f}{w_f + w_m}$ の関数として描いたのが 図 5.25 です. シェアが $1/2$ 以下の範囲ではほぼ平らで, $1/2$ を超えると急に落ちます. 見た目は「妻に追い抜かれる結婚は避けられる」という規範の話と整合的です.

ただし, 妻の賃金シェアが高いということは, 裏返せば夫の賃金が低いということでもあります. どちらが効いているのかを分解しているのが 図 5.24 (c) です. 高賃金の男性 (Q4) は低賃金の男性 (Q1) のおよそ 2 倍の頻度で結婚する一方, 女性の賃金はマッチングにほとんど効いていません. つまり 図 5.25 の下落は, 妻の賃金シェアが $1/2$ を超えたことに反応しているのではなく, そこに低賃金の夫が集まっていることの反映だ, というのがこのモデルの解釈です.




図 5.25: Matching probability by the wife's wage share (Fig. 7)

i Bertrand ほか (2015 年) のジェンダー規範

Bertrand ほか (2015 年) は妻の家計に占める所得の割合が 50% を境に大きく下落することを示しました。




図 5.26: Distribution of Relative Income, Figure 1 of Bertrand ほか (2015 年)

彼女らはこの現象を「妻が夫より稼ぐことへの社会的規範」だと解釈しました (Breadwinner norm). しかし, 結婚市場の結果である可能性が Goussé ほか (2017 年) で示唆されただけでなく, Binder と Lam (2022 年) が社会規範なしのモデルで同様の分布を再現しています。

5.4.4.2 同類婚はどこから来るのか

ここまでは観察されたパターンの記述です. 構造モデルを使うと, そのパターンがモデルのどの部分から生まれているのかを切り分けられます. 手がかりは, 公共財の質 Z_{ij} をどこまで単純化するとマッチング確率の当てはまりが崩れるか, という実験です (図 5.27).

まず, 時点不変の構造パラメータでマッチング確率を予測すると, どの期間でも R^2 は 0.8 前後です. $\ln Z_{ij}$ を二次関数で近似しても 0.75 までしか落ちないので, 高次の項は捨ててかまいません. ところが交差項 (男性のタイプ $\times$ 女性のタイプ) をすべて落とすと 0.54 まで崩れます. 補完性が同類婚を作っている, ということです.

面白いのは, そこへ交差項を 1 つずつ戻したときです. 学歴の交差項 $Ed_m \times Ed_f$ だけが 0.71 まで回復させ, 残り 8 通りはどれも 0.54-0.62 にとどまります. 家族観の交差項 $FVI_m \times FVI_f$ に至っては 0.54 のままで, 何も足していません.

	1991	1994	1997	2000	2003	2006	Mean
Nonparametric estimation of Z_{ij}	0.72	0.83	0.86	0.87	0.82	0.78	0.81
Quadratic projection of $\ln Z_{ij}$	0.68	0.77	0.80	0.80	0.75	0.72	0.75
Quadratic projection of $\ln Z_{ij}$ without interactions	0.38	0.51	0.60	0.62	0.57	0.53	0.54
Quadratic projection of $\ln Z_{ij}$ with no interactions but...							
$w_m * w_f$	0.43	0.54	0.63	0.65	0.59	0.56	0.57
$FVI_m * FVI_f$	0.37	0.51	0.61	0.63	0.57	0.54	0.54
$Ed_m * Ed_f$	0.66	0.72	0.76	0.75	0.69	0.67	0.71
$w_m * Ed_f$	0.43	0.55	0.64	0.66	0.61	0.57	0.58
$w_f * Ed_m$	0.53	0.61	0.68	0.67	0.63	0.58	0.62
$w_m * FVI_f$	0.38	0.51	0.60	0.62	0.57	0.54	0.54
$w_f * FVI_m$	0.38	0.51	0.60	0.62	0.57	0.54	0.54
$FVI_f * Ed_m$	0.38	0.51	0.60	0.62	0.57	0.54	0.54
$FVI_m * Ed_f$	0.37	0.52	0.60	0.63	0.59	0.55	0.54

図 5.27: Fit of matching probabilities (Table IV)

つまり、公共財の質に入る補完性（「似た相手ということ自体が良い」という選好的なチャネル）で説明できるのは学歴の同類婚だけです。家族観の非対称な homophily は、ここではなく家庭内生産の側から来ています。保守的な妻は家事時間を増やし、保守的な夫は減らす（ $D_j^1[FVI]$ の符号が男女で逆、図 5.23）ので、保守的な相手は分業の相手として価値を持ちます。学歴は選好を通じて、家族観は家庭内生産の比較優位を通じて同類婚を生む、というのがこの論文の整理です。

5.4.4.3 モデルのフィット

構造パラメータは全期間で共通なので、期間ごとに動かしているのは賃金・学歴・家族観の分布だけです。それでも、男女別・配偶関係別の賃金・家族観・学歴構成・市場労働時間・家事時間のトレンドは概ね再現されます（図 5.28）。女性の市場労働時間の変化をやや過大に予測する点を除けば、水準も傾きも合っています。




図 5.28: Model fit: trends by gender and marital status (Fig. 8)

より厳しいテストが、夫婦の中での賃金シェアと稼得シェアの分布です (図 5.29)。全夫婦に加えて、夫婦とも保守的な組とリベラルな組に分けて描いても、分布の形の違い (保守的な夫婦では妻の稼得シェアが低い側に大きく偏り、リベラルな夫婦ではより対称に近い) がモデルで再現されます。家族観が家庭内生産の比較優位を通じて分業を決める、という構造が効いている証拠です。




図 5.29: Model fit: wage and earnings shares within couples (Fig. 9)

5.4.4.4 Sharing rule: 夫はなぜ 55% を取るのか

推定されたモデルで家計内の配分を計算すると、夫は家計の純私的支出の平均 **55%** を受け取ります。内訳は、Nash ウェイト $\beta = 0.45$ (この部分だけなら妻の方がわずかに強い) に、男性の**外部機会**の良さが約 10% ポイント上乗せされる、というものです。結婚市場の均衡が男性に有利に働いている分が、交渉力の差として家計内に持ち込まれています。このシェアは 1991-2008 年を通じてほぼ一定 (0.54-0.56) です。

タイプ別に見ると (図 5.30)、学歴には補償的な移転が働いています。夫の学歴が低いほど夫の取り分は大きく、妻の学歴が高いほど夫の取り分は大きくなります。妻の取り分が夫を上回る唯一のケースは、非大卒の妻が大卒の夫と結婚した場合です。家族観による差はほとんどありません (分業には強く

効くのに、私的支出の分配には効かない)。目を引くのは最下段の賃金比によるパネルで、賃金の高い側ほど取り分が大きく、しかもその差が時間とともに開いています。伝統的な家族像から離れていく文化的変化の副産物として、夫婦間の再分配がむしろ細っている、という読み方ができます。




図 5.30: Mean sharing rule by type (Fig. 10)

5.4.4.5 反実仮想: 女性の労働供給は何で決まっているか

推定されたモデルの労働供給の賃金弾力性は、既婚女性で約 0.4 と男性の 2 倍以上あり、ミクロ実証の相場と整合的です。そのうえで、男女差の源泉を分解する 4 つの反実仮想が行われます (図 5.31)。

1. **ジェンダー賃金格差をなくす** (学歴・家族観を条件とした男女の賃金差を消す): 既婚女性の市場労働は +10% 程度. 結婚市場への影響はごく小さい (賃金は女性のマッチングにほぼ無関係のため)
2. **女性に男性の選好を与える**: 市場労働 +8% 程度だが, 独身者が大きく減るなど結婚市場への影響が最大
3. **女性の家庭内生産の比較優位をなくす** (家庭内生産パラメータを男性と同じに): 既婚女性の市場労働 +34%, 家事時間 -61% と, 最大の効果
4. **全員をリベラルな家族観にする**: 既婚女性の市場労働 +30%, 家事時間 -26%, 夫の家事時間 +18%

3 と 4 の効果がほぼ同じ大きさであることが, この論文の結論を要約しています。「全員をリベラルにする」ことは「女性の家庭内生産の比較優位を取り除く」とことと定量的にほぼ同値であり, 家族観は比較優位を通じて分業を規定している, ということです. 残る男女の市場労働の差 (2 時間程度) は, ジェンダー賃金格差でほぼ説明できます.

	Actual 2000-02	Baseline sim.	(1) No wage gap		(2) Same preferences		(3) Same domestic production		(4) $FVT = 1$ for all	
<i>Labor supply</i>										
Married Men	42.99	42.49	42.37	−0.3%	41.77	−1.7%	42.55	0.2%	43.24	1.8%
Single Men	37.48	36.83	36.71	−0.3%	36.87	0.1%	36.78	−0.1%	36.49	−0.9%
Married Women	25.86	26.63	29.27	9.9%	28.66	7.6%	35.77	34.3%	34.53	29.6%
Single Women	30.07	29.56	32.29	9.3%	30.00	1.5%	34.46	16.6%	30.64	3.7%
<i>Home production time</i>										
Married Men	5.13	5.33	5.37	0.8%	5.56	4.3%	5.35	0.5%	6.26	17.5%
Single Men	5.00	5.04	5.04	−0.1%	5.06	0.3%	5.04	0.1%	4.54	−9.8%
Married Women	14.99	15.52	14.35	−7.5%	16.45	6.0%	6.10	−60.7%	11.45	−26.2%
Single Women	10.00	10.01	9.30	−7.1%	10.63	6.2%	4.90	−51.0%	9.23	−7.8%
<i>Population</i>										
# single men	1416	1468	1475	0.5%	1258	−14.3%	1418	−3.4%	1586	8.0%
# single women	1452	1509	1498	−0.7%	1305	−13.5%	1457	−3.4%	1633	8.2%
# couples	3802	3745	3747	0.1%	3943	5.3%	3786	1.1%	3627	−3.2%

図 5.31: Counterfactual simulations (Table VI)

第 6 章

Marriage and Fertility

所得と出生率の関係は、家族の経済学で最も古いパズルのひとつです。子どもが正常財なら、所得が上がれば子どもの数は増えるはずです。しかし人口転換 (demographic transition) 以降、国の間でも、時系列でも、家計の間でも、所得と子どもの数には負の相関が観察されてきました。この章の前半では、出生の経済学のサーベイである Doepke ほか (2023 年) に沿って、このパズルに答えた 2 つの古典的なアイデアを学び、さらに 21 世紀の高所得国では、それらが説明してきた関係そのものが弱まり、逆転したことを見ます。後半では、古典的な出生理論を時間配分・家庭内生産・結婚市場と組み合わせて、過去 140 年のアメリカの構造変化として定量化した Greenwood ほか (2023 年) を読みます。

6.1 Doepke ほか (2023 年)

出生行動を経済学的に説明しようという試みは Becker (1960 年) に始まり、その後の数十年で大きく発展しました。まずはその成果を Doepke ほか (2023 年) の整理を通して見てみましょう。

6.1.1 Old Facts




図 6.1: Total Fertility Rates since 1850. Figure 1 of Doepke ほか (2023 年)

図 6.1 の国々の合計特殊出生率は、19 世紀のほとんどの期間を通じて女性 1 人あたり 4 人から 5 人の間にありました。20 世紀に入る頃から急速に低下し、第一次世界大戦の前にはほとんどの国で 4 人を大きく下回ります。戦後のベビーブームで一時的に回復したのち再び低下し、20 世紀後半からは 1.4 から 2.1 の間で落ち着いています。

出生率の指標には 2 つの定義があるので、ここで整理しておきます。

i 2つの出生率

Total Fertility Rate (TFR, 合計特殊出生率):

$$TFR = \sum_{x=15}^{49} \frac{\text{\#of births to women aged } x}{\text{\#of women aged } x}.$$

年齢別の出生行動が変わらないと仮定したとき、女性が一生に産む子どもの数を表す。晩産化のような年齢別の出生行動の変化が起きると、一時的に大きく動くことに注意。

Complete Cohort Fertility (CCF, 完結コーホート出生率):

$$CCF = \frac{\text{\#of children to women born at year } b}{\text{\#of women born at year } b}.$$

ある年に生まれた女性が実際に一生に産んだ子どもの数を表す。通常は 50 歳になるまで確定しない (Human Fertility Database は「少なくとも 44 歳」の定義を採用)。




図 6.2: 日本の合計特殊出生率 (TFR) と完結コーホート出生率 (CCF) の推移。

図 6.2 では、日本の TFR と CCF の推移を示しています。1966 年の TFR の急落は丙午によるもので、出産を回避する行動が実際に観察されました (今年、2026 年は丙午年です)。CCF は TFR より滑らかに動いており、2つの指標の違いがよく現れています。




図 6.3: Fertility and Income Across Countries. Figure 3 of Doepke ほか (2023 年)

人口転換の結果、所得と出生率の関係は、国の中の時系列でも、発展段階の異なる国の間でもはっきりと負になりました。1970 年の国別データ (図 6.3) では、発展段階の全域にわたって強い負の相関が見られます。1 人あたり GDP が 1,000 ドル (2010 年価格) 未満の最貧国のほとんどは女性 1 人あたり 5 人を超える出生率を持ち、20,000 ドルを超える国の多くは 3 人を下回っていました。同じ負の関係は 1 つの国の家計の間にもあり、豊かで教育水準の高い家計ほど子どもが少ない傾向がありました。

注意したいのは、この負の相関が「所得そのものの増加が出生を減らす」ことを意味しない点です。因果効果を推定する実証研究では、妻の賃金や子育ての費用などを一定にして男性の所得だけが外生的に増えると、出生はむしろ増える傾向が見られます。純粋な所得効果が正であることと、無条件の相関が負であることは矛盾しません。この 2 つを両立させるのが、以下の 2 つのアイデアです。

6.1.2 Quantity-Quality Tradeoff

「豊かになると子どもが減る」という事実は、一見すると経済学的な説明と矛盾するように思えます。豊かになれば、人は普通あらゆるものを多く消費するからです。出生の低下は、経済学の外にある文化や規範の変化で子どもへの「好み」が薄れたことを反映しているだけかもしれません。これに対する Gary Becker の答えが、出生の経済学の第 1 の big idea である quantity-quality トレードオフです。

出発点は、親は子どもの**数** (quantity) だけでなく、一人あたりにかける資源、すなわち**質** (quality) も選ぶ、という観察です。ここでの「質」は価値判断ではなく、教育・健康など子ども一人あたりへの投資を指します。Becker と Lewis (1973 年) が定式化したように、質への支出が所得とともに増えるなら、豊かな親にとって子どもは高くつきます。したがって質の需要が所得に対して十分に弾力的なら、子どもの数は所得とともに減りえます。




図 6.4: Average years of schooling since 1870. Figure 4 of Doepke ほか (2023 年)

質のなかで最も注目されてきたのは教育です。子どもへの支出の大きな部分を占めるうえ、学費が無料でも、学校に通う子どもは働けないという大きな機会費用があるからです。大衆教育が広がる以前は、子どもの労働が多くの家計の所得の相当部分を担っていました。図 6.4 のように、1 人あたり所得が急成長した 19 世紀後半から 20 世紀にかけて教育水準も急上昇しており、出生率の低下と同時に進んだこの動きは quantity-quality トレードオフと整合的です。

子の質を高める親のインセンティブのモデル化には、2 つの伝統があります。

- **Warm glow:** 子どもの数や人的資本そのものから親が直接効用を得る. 以下のモデルはこの型で, de la Croix と Doepke (2003 年) の定式化に従う
- **利他主義 (altruism):** 子どもの生涯効用そのものが親の効用関数に入る. Becker と Barro (1988 年) に始まる定式化. 子の人的資本が子の生活を良くする限り親の効用はその増加関数になるので, 人的資本の水準だけでなく, 子の人生におけるそのリターンも質への関心を左右する. 以下のモデルの γ は, このリターンの誘導形と読める

6.1.2.1 A Toy Model

まず, 閉形式で解ける warm glow 型のシンプルなモデルでトレードオフの仕組みを見ます. 親は消費 c , 子どもの数 n , 子ども 1 人あたりの人的資本 h から効用を得ます.

$$\max_{c, n, e} \log c + \delta \log(n h(\theta, e)) \quad \text{s.t.} \quad c + p n e \leq (1 - \phi n) w.$$

- e : 子ども 1 人あたりの教育時間. 価格 p は教師の賃金
- ϕ : 子ども 1 人あたりの子育て時間. 親自身の時間を使うため, 機会費用は ϕw
- θ : 子どもの生来の人的資本
- 人的資本の生産関数は $h = (\theta + e)^\gamma$, $0 < \gamma < 1$

命題 6.1 (閉形式解と賃金の効果). 内点解 ($\gamma \phi w > p \theta$) において, 最適な子どもの数と教育時間は

$$n = \frac{\delta}{1 + \delta} \cdot \frac{1 - \gamma}{\phi - \frac{p}{w} \theta}, \quad e = \frac{\gamma \phi w - p \theta}{p(1 - \gamma)}.$$

したがって賃金 w の上昇は, 子どもの数 n を減らし, 1 人あたりの教育時間 e を増やす.

証明は付録にあります

直感はこうです. 子どもの「数」の費用の中心は親の子育て時間 ϕ であり, その機会費用 ϕw は親の賃金に比例して上がります. 一方, 「質」の費用 p は市場で決まる外生的な価格です. 賃金が上がると, 数は高くなり質は相対的に安くなるので, 親は数から質へ投資を振り替えます. 先進国の少子化と教育水準の上昇という組み合わせが, 賃金の上昇ひとつから出てくるわけです.

このモデルでも子どもは正常財です. 賃金ではなく資産が外生的に増えれば (純粋な所得効果), 出生は増えます. しかし家計の間の所得の違いの多くは, 資産ではなく稼得能力 w の違いです. w の変化には正の所得効果と負の代替効果が伴い, 代替効果には 2 つの成分があります. 第 1 に, 子どもは時間を使うので, w が上がると子どもは消費に比べて高くなります. 第 2 に, w が上がると質 h が数 n に比べて安くなります. この 2 つを合わせると代替効果が所得効果を上回り, 出生は w とともに減ります.

ただし, この結果を国の間の比較や 1 つの国の時系列に当てはめるときは注意が必要です. 教育の価格 p は主に教師の賃金なので, 経済全体の賃金水準が上がれば p も w に比例して上がるはずで, $p = \bar{p} w$ と置くと

$$n = \frac{\delta}{1 + \delta} \cdot \frac{1 - \gamma}{\phi - \bar{p} \theta}, \quad e = \frac{\gamma \phi - \bar{p} \theta}{\bar{p}(1 - \gamma)}$$

となり, 賃金水準は出生にも教育にも影響しません. 集計レベルで負の相関を生むのは, 教育のリターン γ です. n は γ の減少関数, e は増加関数なので, 経済成長が人的資本のリターンの上昇によっ

て駆動されているなら, 1 人あたり所得の上昇と出生の低下が同時に起こります. 人的資本のリターンの上昇が成長を生む, という性質は成長理論の多くのベンチマークモデルが持っています.

6.1.3 女性の機会費用




図 6.5: Female labor market opportunities, United States. Figure 5 of Doepke ほか (2023 年)

Quantity-quality の文献は家計全体の意思決定を考え, 父親と母親を区別しません. しかし実際には, 子育てで両親が担う役割は異なります. 工業化以前は家族が農場や工房で一緒に働いており, 両親とも子育てにある程度関わっていました. 工業化は職場と家庭を分け, 父親は工場や事務所で働き, 母親は家で家事と子育てを担うようになります. その結果, 子育ての時間費用は主に母親の時間費用になりました. 女性の労働参加が上昇し始めると, 子育てと仕事は女性の時間をめぐって競合するようになります.

図 6.5 はアメリカの例です. 既婚女性の労働参加率は 20 世紀初めには低く, 1930 年代から 1940 年代に緩やかに, 第二次世界大戦後には急速に上昇しました (右). 女性のフルタイム労働者の賃金は, 1950 年代から 1970 年代の一時的な落ち込みを除いて 1 世紀にわたって上昇し, 男性の賃金の 50% 未満から約 80% になりました (左). 女性の賃金と労働参加の上昇は出生率の大きな低下と同時に起きており, 時系列で女性の労働参加と出生の間にはっきりとした負の関係が現れます. 1 つの国のクロスセクションでも, フルタイムで働く女性は専業主婦より子どもが少なく, パートタイムの女性はその中間です. 国の間でも, 1980 年代までは女性の労働参加率が低い国ほど出生率が高い傾向がありました.

この事実が, 出生の経済学の第 2 の big idea を生みました. 子育ての多くを女性が担うなら, 子どもの時間費用を決めるのは平均的な賃金ではなく**女性の賃金**です. モデルを夫婦に拡張して確かめます. 夫婦の賃金を w_m, w_f とし, 子育て時間はすべて妻が担うとします. 子育てが夫婦間で完全に代替可能で $w_m > w_f$ なら, 子育て時間の合計が妻の時間を超えない限り, これが最適な分業です.

$$\max_{c, n, e} \log c + \delta \log(n h(\theta, e)) \quad \text{s.t.} \quad c + pen = w_m + (1 - \phi n)w_f.$$

命題 6.1 とまったく同じ計算で,

$$n = \frac{\delta}{1 + \delta} \cdot \frac{(w_m + w_f)(1 - \gamma)}{\phi w_f - p\theta}, \quad e = \frac{\gamma \phi w_f - p\theta}{p(1 - \gamma)}$$

が得られます. 対数を取って女性の賃金 w_f で微分すると,

$$\frac{\partial \log n}{\partial w_f} = \frac{1}{w_m + w_f} - \frac{\phi}{\phi w_f - p\theta} = \frac{-p\theta - \phi w_m}{(w_m + w_f)(\phi w_f - p\theta)} < 0.$$

第1項は所得効果(家計のフルインカムが増える), 第2項は価格効果(子育ての機会費用が上がる)です。子育て時間の費用が女性の賃金だけに比例するため, 価格効果が必ず所得効果に勝ち, 女性の賃金上昇は出生を減らします。一方で教育時間 e は w_f とともに増えるので, ここでも数から質への振り替えが起きています。男性の賃金 w_m の上昇は, 対照的に所得効果しか持たないので出生を増やします。「誰の賃金が増えるか」が出生の予測を分ける, というのがこのモデルの核心です。

Doepke ほか (2023 年) は男女の賃金格差の役割に焦点を当てるため, 教育のリターンをゼロ ($\gamma = 0$) と置いています。このとき教育投資はゼロ ($e = 0$) になり,

$$n = \frac{\delta}{1 + \delta} \cdot \frac{1}{\phi} \left(1 + \frac{w_m}{w_f} \right)$$

が得られます。出生率を決めるのは男女の賃金比 w_m/w_f であり, 男女の賃金格差が縮まると出生は下がります。男性の賃金の上昇が純粋な所得効果なのに対し, 女性の賃金の上昇には所得効果と代替効果の両方が伴います。家計所得の大部分が男性の稼ぎである限り所得効果は小さく, 代替効果が勝ちます。このモデルは国内のクロスセクションにも含意を持ちます。賃金の主な決定要因は教育なので, 夫婦の学歴が完全には相関しない限り, 女性の学歴と出生はクロスセクションで負に相関するはずですが。

同じ考え方を一般均衡に持ち込んだのが Galor と Weil (1996 年) です。物理資本は肉体労働を代替し, 女性の労働と補完的なので, 資本蓄積は男女の賃金格差を縮め, 女性の労働参加を増やします。女性の労働参加の上昇は出生を下げ, 出生の低下は1人あたり資本の蓄積を速めます。この相互作用が人口転換と成長の加速を同時に生みます。

ここまでをまとめると, 古い事実と古いモデルは次のように対応しています。

- **古い事実:** 20 世紀を通じて高所得国の出生率は低下し, 国の間でも家計の間でも所得と出生は負に相関した。同じ時期に教育水準と女性の賃金・労働参加率が上昇した
- **Quantity-quality トレードオフ:** 賃金や教育のリターンが高いと, 親は子どもの質に投資し, 数を減らす
- **女性の時間の機会費用:** 女性の賃金が高いと子育ての機会費用が高く, 子どもの数が減る

6.1.4 関係の逆転と原因

Doepke ほか (2023 年) の基本的な主張は, 出生の経済学が新しい時代に入ったということです。そのきっかけは理論の進歩ではなく, 出生行動そのものの変化です。人口転換から 20 世紀後半まで出生を特徴づけていた基本的な関係は, 高所得国の最近のデータでは成り立たなくなっています。




図 6.6: Fertility and GDP per capita across OECD economies. Figure 8 of Doepke ほか (2023 年)

所得と出生. 世界の最も豊かな国と最も貧しい国を比べれば、所得と出生の負の関係は今も残っています。サハラ以南のアフリカなど所得の最も低い国々は人口転換の途中にあり、出生率は高いままです。しかし高所得国の中では、この関係はほぼ消えました。高所得国の出生率の低下は1980年代半ばまでにほぼ終わり、その後は1人あたり所得が伸び続けても、出生率は横ばいかわずかに上昇しています。OECD 諸国のクロスセクション (図 6.6) を見ると、1980年にはまだはっきりと負の関係があり、所得の最も低いポルトガルやスペインで出生率が最も高くなっていました。2000年にはこの関係が逆転し、豊かな国の方がわずかに出生率が高くなっています。国の間の相関係数は1970年代から1980年代前半まで負で、1987年に正に転じ、その後も正のままです。所得と出生の関係がU字型で、高所得国の多くがその右側の上昇部分に入った、と読むこともできます。いずれにせよ、これを説明するには所得と出生が単調に負の関係にならないモデルが必要です。




図 6.7: Fertility and female labor force participation across OECD economies. Figure 12 of Doepke ほか (2023 年)

女性の労働参加と出生. 女性の労働参加率が高い国ほど出生率が低い、という関係も高所得国では逆転しました。1980年の負の関係は、2000年には正の関係になっています (図 6.7)。女性の労働参加率と出生率の国の間の相関係数は、1980年の -0.5 から10年ほどで約 0.75 まで上昇し、1990年以降はやや下がったものの正のまま推移しています (Ahn と Mira 2002 年)。

女性の学歴と出生. アメリカの女性の学歴別の出生率を見ると、1980年代には学歴の全域で負だった関係が、1990年には上端で平らになり (大学院卒と大卒の出生率がほぼ同じ)、直近の2時点では最上位の学歴で出生が上昇しています。この上端での上昇は白人女性ではっきりしている一方、黒人女性では今も学歴とともに単調に下がります。ヨーロッパでもフランスやドイツでは最上位の学歴で出

生が上昇しており、イタリアやスペインでは上昇は見られないものの、高卒以上では関係がほぼ平らです。

Doepke ほか (2023 年) の見方では, quantity-quality トレードオフや女性の時間の機会費用という考え方自体は今も有効ですが, 高所得国の経済環境の変化がそれらの力を弱めました. 論文は4つの要因を挙げています. 公教育と児童労働法, 子育ての市場化, キャリアと出産のタイミング, 避妊と不妊治療です. ここでは最初の2つを見ます.

6.1.4.1 公教育と児童労働法

人口転換の時期には, 教育の拡大が親に強い金銭的なトレードオフを課していました. 学校が有料なら教育の1年ごとに支出がかかり, さらに重要なことに, 学費が無料でも学校に通う子どもは働けません. 児童労働の所得を失うことが教育の大きな機会費用になり, 強い quantity-quality トレードオフを生んでいました. 狭い意味での児童労働 (14 歳までの労働) が消えた後も, 15 歳や 16 歳で学校を離れて働き, 家計に所得の一部を入れる子どもは高所得国でも少し前まで珍しくありませんでした.

高所得国では, このトレードオフの多くが力を失っています. 公教育は子ども時代のほぼ全体をカバーするようになり, 多くの子どもが少なくとも 12 年間学校にとどまって 18 歳以上で卒業します. 大学や大学院に進むかといった教育の意思決定は子どもが成人した後に来るので, その費用 (放棄所得や学生ローン) を負うのは親よりも子ども自身です. 親が大学の費用を支えることは今もありますが, 程度の問題として, 教育と出生の意思決定の相互作用は弱まり, quantity-quality トレードオフの力も弱まりました.

実証研究もこの解釈と整合的です. 双子の出生を出生数の外生的な増加として使う研究は, インドや中国では子どもの教育の低下を見出す一方, 質の高い公教育があるノルウェーやイスラエルでは, 出生順位を制御すると教育への影響はほとんど見られません. Liu (2015 年) のサーベイも, quantity-quality トレードオフが今では主に低所得国で見られることを示しています.

6.1.4.2 子育ての市場化

第2の big idea は, 子どもを増やすには女性が市場労働を減らさなければならない, という前提に立っていました. しかし子育てのサービスを市場で買えるなら, このトレードオフは弱まります. 子育てを外部的化すると, 子どもの時間費用が金銭的な費用に変わるので, 女性の時間の機会費用の重要性が下がるからです. 2つ目の big idea のモデルを拡張して確かめます.

i 子育ての市場化を含む出生モデル

夫婦は消費 c と子どもの数 n を選ぶ (子どもの質は捨象する). 子ども 1 人あたり, 時間費用 ϕ に加えて, 食費や衣服などの金銭的な費用 ψ がかかる. 子育て時間のうち割合 $s \in [0, \bar{s}]$ を市場から価格 p_s で買うことができ, 残りの $(1-s)$ は妻が担う. $\bar{s}$ は外部化できる子育ての上限である.

$$\max_{c, n, s} \log c + \delta \log n \quad \text{s.t.} \quad c + \psi n + sp_s n \phi = w_m + w_f(1 - (1-s)n\phi).$$

予算制約を整理すると $c + \pi(s)n = w_m + w_f$ となります. ここで

$$\pi(s) = \psi + (sp_s + (1-s)w_f)\phi$$

は子ども 1 人の完全価格 (full price) で、金銭的費用と、子育て時間を市場で買う分と妻が担う分の費用を合わせたものです。\$s\$ を所与とすると、対数効用なので支出の割合は一定 (\$c = (w_m + w_f)/(1 + \delta)\$) で、

$$n = \frac{\delta}{1 + \delta} \cdot \frac{w_m + w_f}{\psi + (sp_s + (1 - s)w_f)\phi} \quad (6.1)$$

となります。これを目的関数に代入すると、効用は \$\pi(s)\$ の減少関数です。\$\pi(s)\$ は \$s\$ について傾き \$\phi(p_s - w_f)\$ の線形関数なので、最適な \$s\$ は端点になります。妻の賃金の子育ての市場価格より低い (\$w_f < p_s\$) 夫婦は自分たちで子育てをし (\$s = 0\$), 高い (\$w_f > p_s\$) 夫婦は買えるだけ買います (\$s = \bar{s}\$)。高賃金の女性は働き続け、低賃金の女性は子育てに時間を使って労働供給を減らします。

命題 6.2 (女性の賃金と出生). \$s\$ を所与とすると、

$$\frac{\partial n}{\partial w_f} = \frac{\delta}{1 + \delta} \cdot \frac{\psi + (sp_s - (1 - s)w_m)\phi}{\pi(s)^2}.$$

子どもの金銭的費用が時間費用に比べて小さい (\$\psi < w_m\phi\$) とき、これは \$s < s^*\$ なら負、\$s = s^*\$ ならゼロ、\$s > s^*\$ なら正である。ただし

$$s^* = \frac{w_m\phi - \psi}{(p_s + w_m)\phi} \in (0, 1).$$

証明は付録に示す。

子育てを外部化する割合が大きいほど、妻の賃金の上昇は子どもの限界費用をあまり押し上げず、所得効果だけが残ります。最適な \$s\$ と組み合わせると、市場化の上限 \$\bar{s}\$ が女性の賃金と出生の関係をどう変えるかが分かります。

- 市場化ができない (\$\bar{s} = 0\$) なら、すべての女性が \$s = 0\$ を選び、出生は女性の賃金の減少関数になる (古いモデル)
- \$w_f < p_s\$ の女性は \$s = 0\$ を選ぶので、\$\bar{s}\$ に関係なく出生は \$w_f\$ の減少関数である
- \$\bar{s}\$ が上がると、\$w_f \geq p_s\$ の女性での出生と賃金の関係は平らになっていき、\$\bar{s} = s^*\$ でちょうど平らになる
- \$\bar{s} = 1\$ (完全な市場化) なら、出生は女性の賃金について U 字型になる。賃金分布の下側では賃金の上昇が子育ての機会費用を上げて出生を下げ、上側では子どもの限界費用は変わらず、所得効果だけが出生を上げる

\$w_f = p_s\$ では \$\pi(s)\$ が \$s\$ に依存しないので、出生は \$w_f\$ について連続で、\$w_f = p_s\$ で屈折します。図 6.8 はその数値例です (パラメータは図の注)。この数値例では、妻の子育て時間 \$(1 - s)n\phi\$ はどの \$w_f\$ でも妻の時間 (1) を下回ります。




図 6.8: 子育ての市場化と女性の賃金・出生の関係 (モデルの数値例).

現実には市場化には限界があり、高賃金の親も子育てに相当の時間を使っています。それでも市場化は、女性の労働供給と出生の歴史的な関係を弱めた一因と考えられます。子育ての費用を機会費用から金銭的な費用に変えることで、市場化は所得と出生の関係も弱めます。豊かな夫婦ほど子育てを「買う」資源を持つからです。子育ての市場化の役割は Ahn と Mira (2002 年) などが強調しており、因果的な証拠もあります。アメリカでは低技能の移民の流入が家事や子育てのサービスの価格を下げました。低技能の移民の流入が大きい都市では、子育てを外部化しやすい高学歴の女性で仕事と子どものトレードオフが弱まり、出生率が上がっています。

子育ての市場化は、家庭内労働時間の減少と家庭内生産の市場化という、より一般的な流れの一部です。20 世紀の家電の普及は料理・掃除・洗濯にかかる時間を減らし、女性の労働参加と余暇の増加を後押ししました。サービス経済の拡大も、食事・ケア・掃除を市場で買えるようにしました。この家庭内の技術進歩を、出生・女性の就業・教育・結婚の長期的な変化と 1 つのモデルで結びつけたのが、後半で読む Greenwood ほか (2023 年) です。

6.2 Greenwood ほか (2023 年)

Greenwood ほか (2023 年) は Kuznets (1957 年) に着想を得て、過去 140 年ほどの間にアメリカの家族に起こった大きな変化を、家族経済学者にとっての「Kuznets facts」として次の 6 つにまとめています。

1. (家事) 労働時間の減少
2. 出生率の減少
3. 結婚の減少
4. 世帯サイズの縮小
5. 高学歴者の増加
6. ブルーカラーからホワイトカラーへの転換

この論文の目的は、これら 6 つの変化を 1 つのモデルと少数の駆動力で説明することです。近年の少子化を念頭においた理論というよりは、古典的な出生理論（この章の前半で学んだ quantity-quality トレードオフ）を洗練させ、長期の構造変化に正面から当てはめたものと位置づけられます。

6.2.1 6 つの Kuznets facts

論文はアメリカを念頭に置っていますが、日本を含む多くの先進国で同様の傾向が観察されます。モデルに入る前に、6 つの事実を駆け足で見てください。

6.2.1.1 ① (家事) 労働時間の減少




図 6.9: Housework in the United States. Figure 2.2 of Greenwood ほか (2023 年)

図 6.9 のように、20 世紀は家事労働時間が減少し続けた時代でした。洗濯機・冷蔵庫・電子レンジといった家電の普及がその背景にあります。




図 6.10: Average weekly hours and labor-force participation in the United States. Figure 2.1 of Greenwood ほか (2023 年)

市場労働の時間も第二次世界大戦までは減少傾向にありました (図 6.10)。一方で女性の労働参加率は大きく上昇しており、家事負担の減少がその一因と考えられます。

6.2.1.2 ② 出生率の減少




図 6.11: Fertility in the United States. Figure 2.6 of Greenwood ほか (2023 年)

ベビーブームという例外を挟みつつ、出生率は長期的に減少傾向にあります (図 6.11). TFR と CCF の定義と日本の推移は、セクション 6.1.1 で見ました。




図 6.12: The cross-country decline in fertility. Figure 2.7 of Greenwood ほか (2023 年)

国ごとのパネルデータ (図 6.12) を見ると、GDP per capita と TFR の間には負の相関があります。Doepke ほか (2023 年) でみたように、これこそ第 1 世代の出生モデルが説明しようとした古い事実です。

6.2.1.3 ③ 結婚の減少




図 6.13: Marriage in the United States. Figure 2.8 of Greenwood ほか (2023 年)

1960 年以降、未婚化と晩婚化が進行しています (図 6.13). 法律婚によらない関係 (同居, cohabitation) を考慮しても、減少傾向は変わりません。




図 6.14: The cross-country relationship between per-capita GDP and marriage. Figure 2.10 of Greenwood ほか (2023 年)

未婚化・晩婚化は所得と正の相関を持ちます (図 6.14). 家事労働の減少や女性の労働参加によって「独身でいることの価値」が上昇した、というのが以下のモデルの見方です。




図 6.15: 日本の 45-54 歳の未婚率と初婚年齢の推移。

図 6.15 のように、未婚化・晩婚化は日本でも進行しています。ただし日本は婚外子の割合が欧米諸国と比べて極めて低い (2020 年で 2.4%) ため、結婚の減少が出生の減少に直結しやすいという特徴があります。

6.2.1.4 ④ 世帯サイズの縮小




図 6.16: Household size in the United States and across countries. Figure 2.11 of Greenwood ほか (2023 年)

世帯サイズは縮小傾向にあり、所得と負の相関を持ちます (図 6.16). 少子化の影響に加えて、3 世代同居の減少も所得と負の相関を持っています。

6.2.1.5 ⑤ 高学歴者の増加




図 6.17: Educational attainment in the United States. Figure 2.12 of Greenwood ほか (2023 年)




図 6.18: The cross-country relationship between per-capita GDP and educational attainment. Figure 2.13 of Greenwood ほか (2023 年)

高学歴化は進行しており (図 6.17), 所得と正の相関を持ちます (図 6.18). 供給側の要因は親の教育投資の増加であり, この章の前半で学んだ子どもの数と質のトレードオフ (quantity-quality trade-off) がその理論です. 需要側の要因は高学歴者への賃金プレミアムの上昇で, 次の事実⑥と表裏一体です.

6.2.1.6 ⑥ ブルーカラーからホワイトカラーへの転換




図 6.19: Occupations in the United States for men and women. Figure 2.14 of Greenwood ほか (2023 年)




図 6.20: The cross-country relationship between per-capita GDP and white-collar jobs. Figure 2.15 of Greenwood ほか (2023 年)

ホワイトカラーの割合は上昇しており (図 6.19), 所得とも正の相関を持ちます (図 6.20). 背景にあるのはスキル偏向的な技術進歩 (skill-biased technological change) です (Acemoglu と Autor 2011 年). 以下では, これら 6 つの事実を 1 つのモデルで説明する Greenwood ほか (2023 年) の定量分析を読みます.

6.2.2 Model

モデルは静学で, 各エージェントは人生を 1 回の意思決定として選びます. 家計は性別のない独身者と有配偶者からなります. 独身者は 1 単位の時間を持ち, 家事労働 h (household labor), 余暇 l (leisure), 市場労働 t (toiling in the market) に配分します ($h + l + t = 1$). 有配偶者は 2 人分の 2 単位の時間を持ち, これに加えて k 人の子どもに対する基礎的な子育て b (basic childcare) と教育 e (education) の時間を使います ($h + l + t + bk + ek = 2$).

賃金. スキルには合計が 1 になる *brain* と *brawn* の 2 種類があり, 賃金はそのポートフォリオで決まります.

$$w = sv + (1 - s)u.$$

$s \in [0, 1]$ は brain スキルの割合, v と u はそれぞれ brain と brawn のリターンで, $v > u$ を仮定します. 比率 $q = v/u$ が大卒プレミアムに対応します.

家庭内生産. 家事の成果 n は, 家庭内生産用の耐久財 d (価格 p) と家事労働 h の CES 集計で作られます.

$$n = (\theta d^\sigma + (1 - \theta)h^\sigma)^{1/\sigma}.$$

ここで家事労働の投入 h には子どもも寄与します. 独身者では $h = h$ ですが, 有配偶者では子ども 1 人あたり生産性 χ で家事を手伝い, $h = h + \chi k$ となります. かつての子どもは農場や家庭内で立派な労働力でした. 児童労働の消滅は, この χ の低下として表現されます.

子どもの教育. 親は子どもの brain スキル割合 s を選べますが, そのためには子ども 1 人あたり $e = \gamma s$ の教育時間がかかります. 子どもを「高スキルに育てる」ことが親の時間を食う, という形で quantity-quality トレードオフが入っています.

効用関数. 独身者は消費 c , 家事の成果 n , 余暇 l から効用を得ます.

$$u^S(c, n, l) = \alpha \frac{c^{1-\rho} - 1}{1-\rho} + \beta \frac{n^{1-\nu} - 1}{1-\nu} + (1 - \alpha - \beta) \frac{l^{1-\lambda} - 1}{1-\lambda}.$$

有配偶者はこれに加えて, 子どもの数 k と子どものスキル水準 $sv + (1 - s)u$ から効用を得ます.

$$\begin{aligned} u^M(c, n, l, k, s) = & \alpha \frac{(\varepsilon c)^{1-\rho} - 1}{1-\rho} + \beta \frac{(\varepsilon n)^{1-\nu} - 1}{1-\nu} + \delta \frac{l^{1-\lambda} - 1}{1-\lambda} \\ & + \psi \frac{k^{1-\kappa} - 1}{1-\kappa} + \xi \frac{(sv + (1 - s)u)^{1-\zeta} - 1}{1-\zeta}. \end{aligned}$$

$\varepsilon \in [0.5, 1.0]$ は世帯の等価尺度 (equivalence scale) で, 2 人で暮らすことの規模の経済を表します. 子どものスキルからの効用は, この章の前半の言葉で言えば warm glow 型 (子の効用ではなく属性から直接効用を得る) の質への選好です.

家計の問題. 独身者と有配偶者の価値はそれぞれ

$$\begin{aligned} S &= \max_{d, h, l} u^S(c, n(d, h), l) \quad \text{s.t. } c + pd = w(1 - h - l), \\ M &= \max_{d, h, l, k, s} u^M(c, n(d, h), l, k, s) \quad \text{s.t. } c + pd = w(2 - h - l - bk - ek) \end{aligned}$$

で与えられます.

結婚の決定. 独身者は人生の初めに他の独身者とマッチし, 結婚生活の joy shock j を引きます. 結婚するのは $M + j \geq S$ のときです. j は位置 a , スケール d のガンベル分布

$$G(j) = \exp\left(-\exp\left(-\frac{j-a}{d}\right)\right)$$

に従うとします (frictionless marriage の章で学んだ第一種極値分布です). 婚姻率を m とすると, 独身者の割合は

$$1 - m = \Pr(M + j < S) = G(S - M)$$

と閉じた形で書けます。

6.2.3 Calibration

6.2.3.1 データに基づくパラメータ

カリブレーションの第一歩は、モデルの外から測れるものを測ってしまうことです。

- **価格:** $w_{1880} = 1$ に基準化. 賃金は年率 1.7% で上昇したと推定され $w_{2020} = 11.3$ (1880–1988 年は Williamson (1995 年), 1989 年以降は FRED の実質報酬を総労働時間で割って推定). 耐久財価格は $p_{1880} = 100$ に基準化し, 年率約 5% の下落 (Greenwood ほか 2016 年) から $p_{2020} = 0.108$. 大卒プレミアム $q_{2020} = 1.81$ は Current Population Survey (2018 年) より
- **家庭内生産:** $\theta = 0.206$, $\sigma = 0.282$ は McGrattan ほか (1997 年) より. $0 < \sigma < 1$ なので耐久財と家事労働は代替的で, 「安くなった耐久財が家事時間を置き換える」経路が開いている
- **相対的リスク回避度:** $\rho = 1.25$ (文献の標準的な値)
- **等価尺度:** OECD modified scale ($1 + 0.5$) より $\varepsilon = 1/1.5 \simeq 0.667$
- **子育て時間:** American Time Use Survey (ATUS) と Gershuny と Harms (2016 年) から, 基礎的な子育て時間の平均 (1920, 1965, 2019) として $b = 0.030$
- **教育時間:** $\gamma = e/s$ の関係を使い, ホワイトカラーの割合 s_t と家庭での教育時間 e_t から推定 (ATUS, American Heritage Time Use Study, Gershuny と Harms (2016 年)). 平均して $\gamma = 0.026$
- **子どもの家事労働 χ :** 児童の労働時間と生産性の積として推定. 生産性は Lebergott (1964 年) に基づき, 1880 年の児童の労働時間は途上国のデータ (Webbink ほか 2012 年), 2020 年は Hofferth と Sandberg (2001 年) を用いる

6.2.3.2 SMM: 2 つのループ

残りのパラメータは SMM で推定しますが, その実装に工夫があります. 推定を外側と内側の 2 つのループに分けるのです。

- **外側のループ:** (α, q_{1880}) だけを数値的に探索する
- **内側のループ:** 残りの選好パラメータ $\Lambda(\alpha, q_{1880}) = (\beta, \nu, \delta, \lambda, \psi, \kappa, \xi, \zeta)$ は, (α, q_{1880}) を所与とする一階条件から解析的に決まる
- ガンベル分布のパラメータ (a, d) は, 他のすべてが決まった後に婚姻率から決まる

数値的に探索するパラメータが実質 2 個まで減るので, 推定は非常に軽くなります. 内側のループの仕掛けは, どの一階条件も「曲率パラメータはデータの 2 時点比から, ウェイトパラメータは水準から」という形で逐次的に解けることです. 順番に見ていきます。

Step 1-2 (λ, δ) : 余暇. 余暇 l の一階条件は

$$\delta l^{-\lambda} = \alpha \varepsilon^{1-\rho} (w(2 - bk - \gamma sk - h - l) - pd)^{-\rho} w. \quad (6.2)$$

2020 年と 1880 年でこの式の比を取ると δ が消え,

$$\left(\frac{l_{2020}}{l_{1880}} \right)^{-\lambda} = \left(\frac{w_{2020}(2 - bk_{2020} - \gamma s_{2020} k_{2020} - h_{2020} - l_{2020}) - p_{2020} d_{2020}}{w_{1880}(2 - bk_{1880} - \gamma s_{1880} k_{1880} - h_{1880} - l_{1880}) - p_{1880} d_{1880}} \right)^{-\rho} \frac{w_{2020}}{w_{1880}}$$

から λ が求まります. λ が分かれば, 式 (6.2) を 2020 年の水準で評価して δ が求まります.

Step 3-4 (κ, ψ): 子どもの数. 子どもの数 k の一階条件は

$$\psi k^{-\kappa} = \delta l^{-\lambda} (b + \gamma s - \chi). \quad (6.3)$$

右辺の括弧は子ども 1 人の純時間費用 (子育て + 教育 - 家事の手伝い) です. やはり 2 時点の比

$$\left(\frac{k_{2020}}{k_{1880}} \right)^{-\kappa} = \left(\frac{l_{2020}}{l_{1880}} \right)^{-\lambda} \frac{b + \gamma s_{2020} - \chi_{2020}}{b + \gamma s_{1880} - \chi_{1880}}$$

から κ が, 水準から ψ が求まります.

Step 5-6 (ζ, ξ): 子どもの質. 子どものスキル s の一階条件は

$$\xi (sv + (1-s)u)^{-\zeta} (v-u) = \delta l^{-\lambda} \gamma k. \quad (6.4)$$

左辺は brain スキルを増やす限界便益, 右辺はその時間費用 (子ども全員分の教育時間) です. 2 時点の比

$$\left(\frac{s_{2020}v_{2020} + (1-s_{2020})u_{2020}}{s_{1880}v_{1880} + (1-s_{1880})u_{1880}} \right)^{-\zeta} \frac{v_{2020} - u_{2020}}{v_{1880} - u_{1880}} = \left(\frac{l_{2020}}{l_{1880}} \right)^{-\lambda} \frac{k_{2020}}{k_{1880}}$$

から ζ が, 水準から ξ が求まります.

Step 7-8 (ν, β): 家事. 家事労働 h の一階条件は

$$\beta \varepsilon^{1-\nu} (1-\theta) (\theta d^\sigma + (1-\theta)(h + \chi k)^\sigma)^{\frac{1-\nu-\sigma}{\sigma}} (h + \chi k)^{\sigma-1} = \delta l^{-\lambda}. \quad (6.5)$$

2 時点の比

$$\left(\frac{\theta d_{2020}^\sigma + (1-\theta)(h_{2020} + \chi_{2020}k_{2020})^\sigma}{\theta d_{1880}^\sigma + (1-\theta)(h_{1880} + \chi_{1880}k_{1880})^\sigma} \right)^{\frac{1-\nu-\sigma}{\sigma}} \left(\frac{h_{2020} + \chi_{2020}k_{2020}}{h_{1880} + \chi_{1880}k_{1880}} \right)^{\sigma-1} = \left(\frac{l_{2020}}{l_{1880}} \right)^{-\lambda}$$

から ν が, 1880 年の水準から β が求まります.

外側のループ. 残った (α, q_{1880}) は, 独身者の市場労働時間と家事労働時間 (1880, 2020) をターゲットに

$$\min_{\alpha, q_{1880}} \sum_i \left(\frac{D_i - \mathcal{M}_i(\alpha, q_{1880})}{D_i} \right)$$

を最小化して決めます. 有配偶者側のモーメント (出生率, 教育, 時間配分) は内側のループの構成上, データと完全に一致します (表 6.1).

表 6.1: Results, data and model. Table 5.3 of Greenwood ほか (2023 年)

Table 5.3 Results, data and model.

Variable	Description	Data 1880, 2020	Model 1880, 2020
Fertility			
k	Fertility rate	4.240, 1.640	4.240, 1.640
Schooling			
s	Schooling	0.168, 0.765	0.168, 0.765
Time			
h	Housework (<i>married</i>)	0.518, 0.156	0.518, 0.156
	Housework (<i>single</i>)	0.185, 0.057	0.251, 0.072
t	Market work (<i>married</i>)	0.614, 0.597	0.614, 0.597
	Market work (<i>single</i>)	0.360, 0.302	0.226, 0.218
l	Leisure (<i>married</i>), <i>implied</i>	0.722, 1.165	0.722, 1.165
	Leisure (<i>single</i>), <i>implied</i>	0.455, 0.641	0.523, 0.710
bk	Childcare	0.128, 0.049	0.128, 0.049
ek	Educational care	0.019, 0.033	0.019, 0.033
Marriage			
m	Fraction married	0.612, 0.238	0.612, 0.238
$1 - m$	Fraction single (unmarried)	0.388, 0.762	0.388, 0.762

結婚のパラメータ. すべての選好パラメータが決まると S と M が計算できます. 独身者の割合 $s = 1 - m$ はガンベル分布から

$$\log(-\log s) = -(S - M - a)/d \quad (6.6)$$

を満たすので, 2 時点の比

$$\frac{\log(-\log s_{2020})}{\log(-\log s_{1880})} = \frac{S_{2020} - M_{2020} - a}{S_{1880} - M_{1880} - a}$$

から a が, 式 (6.6) の水準から d が求まります. 推定されたパラメータは 表 6.2 のとおりです.

表 6.2: Parameter values. Table 5.2 of Greenwood ほか (2023 年)

Table 5.2 Parameter values.

Parameter	Description	Value	Identification
Market consumption			
α, ρ	Weight, exponent	0.154, 1.250	Eq. (5.7), literature
Home goods consumption			
β, ν	Weight, exponent	0.059, 1.708	Eq. (5.6)
Leisure			
δ	Weight, married	0.283	Eq. (5.3)
$1 - \alpha - \beta$	Weight, single	0.787	Implied
λ	Exponent	0.407	Eq. (5.3)
Fertility			
ψ, κ	Weight, exponent	0.014, 0.541	Eq. (5.4)
Schooling			
ξ, ζ	Weight, exponent	0.099, 1.607	Eq. (5.5)
Home production technology			
θ, σ	Durables weight, exponent	0.206, 0.282	Literature, Sec 6.4
χ_{1880}, χ_{2020}	Child labor-productivity: 1880, 2020	0.015, 0.011	Data
Cost of Children			
b, γ	basic, education	0.030, 0.026	Data
Marriage, Gumbel			
a, d	location, shape	-0.593, 0.028	Eqs. (5.8) and (5.9)
Prices (continuous growth rates are presented)			
$p_{1880}, p_{2020}, \% \Delta p$	Durables: 1880 and 2020 levels, growth	100.000, 0.108, -4.879%	Normalization, literature
$w_{1880}, w_{2020}, \% \Delta w$	Wages: 1880 and 2020 levels, growth	1.000, 11.300, 1.732%	Normalization, data for % Δ
$q_{1880}, q_{2020}, \% \Delta q$	Skill premium: 1880 and 2020 levels, growth	1.384, 1.810, 0.192%	Eq. (5.7), 2020 Data
Equivalence scale			
ε	Equivalence scale	0.667	OECD

6.2.4 Great Transition

1880 年から 2020 年への変化を駆動する力として、論文は 3 つに注目します。

1. 全体的な技術革新 (neutral technological progress, $\mathbf{z}$)
2. スキル偏向的な技術革新 (skill-biased technological progress, $\mathbf{x}$)
3. 家庭内生産用耐久財の価格低下 (p)

技術革新をモデル化するため、brawn 労働 $\mathbf{u}$ と brain 労働 $\mathbf{v}$ を CES で束ねる代表的企業を導入します。

$$\max_{\mathbf{u}, \mathbf{v}} \mathbf{z}((1 - \omega)\mathbf{u}^\iota + \omega\mathbf{x}\mathbf{v}^\iota)^{\frac{1}{\iota}} - \mathbf{u}\mathbf{u} - \mathbf{v}\mathbf{v}.$$

一階条件から、大卒プレミアム q は

$$q = \frac{v}{u} = \frac{\omega\mathbf{x}}{1 - \omega} \left(\frac{\mathbf{v}}{\mathbf{u}} \right)^{\iota-1} = \frac{\omega\mathbf{x}}{1 - \omega} \left(\frac{s}{1 - s} \right)^{\iota-1} \quad (6.7)$$

と書けます (最後の等式は、総労働時間を $\mathbf{t}$ として $\mathbf{u} = (1 - s)\mathbf{t}$, $\mathbf{v} = s\mathbf{t}$ を代入したものです). CES のパラメータ (ω, ι) は Acemoglu と Autor (2011 年) の値を使い、式 (6.7) から各時点の $\mathbf{x}$ が、brawn 労働の一階条件から $\mathbf{z}$ が逆算できます (表 6.3).

表 6.3: Technology parameter values. Table 6.1 of Greenwood ほか (2023 年)

Table 6.1 Technology parameter values.

Parameter	Description	Value	Identification
Market Production Function			
ω, t	Weight on skilled labor, exponent	0.439, 0.552	Literature
Technology Factors (continuous growth rates are presented)			
$x_{1880}, x_{2020}, \% \Delta x$	Skill biased: 1880 and 2020 levels, growth	0.864, 3.920, 1.081%	Eq. (6.2)
$z_{1880}, z_{2020}, \% \Delta z$	Neutral: 1880 and 2020 levels, growth	2.192, 4.157, 0.457%	Eq. (6.1)
$p_{1880}, p_{2020}, \% \Delta p$	Process Innovation: 1880 and 2020 levels, growth	100.000, 0.108, -4.879%	Literature

3つの駆動力を $z_t = z_{1880} e^{\Delta z(t-1880)}$, $x_t = x_{1880} e^{\Delta x(t-1880)}$, $p_t = p_{1880} e^{\Delta p(t-1880)}$ と指数的に動かし、モデルに 1880 年から 2020 年までの移行経路を生成させます。




図 6.21: Transitional dynamics: fertility, schooling, and marriage. Figure 6.1 of Greenwood ほか (2023 年)

図 6.21 のように、2 時点 (1880, 2020) しかターゲットにしていなくても途中的経路もよく再現できています。特に注目すべきは、婚姻率が 20 世紀半ばに向けて上昇してから低下するという $\cap$ 字型を再現している点です。

では、どの駆動力がどの事実を担っているのでしょうか。反実仮想で 1 つずつ止めてみます。

スキル偏向的な技術革新 x を止めると。




図 6.22: Comparative dynamics: fertility and schooling. Figure 6.2 of Greenwood ほか (2023 年)

大卒プレミアムが上昇しない世界 (図 6.22) では、出生率は高止まりし、大卒者の割合も増えません。教育のリターンが低いままなので、親は子どもの「質」ではなく「数」に投資し続けるからです。出生率の低下と教育の拡大が、quantity-quality トレードオフを通じて同じ 1 つの力 (x) から出ていることが分かります。

耐久財価格 p の低下を止めると。




図 6.23: Comparative dynamics: housework, market work, and leisure. Figure 6.3 of Greenwood ほか (2023 年)

洗濯機や冷蔵庫が安くない世界 (図 6.23) では, 家事労働時間は減らず, 代わりに市場労働時間が減ります. そしてもうひとつ, 意外な変化が起きます. 婚姻率が上昇し続けるのです (図 6.24).




図 6.24: Comparative dynamics: marriage. Figure 6.4 of Greenwood ほか (2023 年)

婚姻率の $\cap$ 字型は, 2つの力の綱引きで生まれていました. 前半は大卒プレミアムの上昇が子ども (とその教育) の価値を高め, 結婚を魅力的にします. 後半は耐久財の価格低下が家事の規模の経済という結婚の古典的なメリットを侵食し, 独身の生活コストを下げます. 1960 年頃を境に後者が優勢になった, というのがこのモデルの読み方です.

6.2.4.1 まとめ

6つの Kuznets facts は, 実質的に2つの駆動力に整理されます.

スキル偏向的な技術革新 (x : 大卒プレミアムの上昇)

- 高学歴者の増加 (⑤) とホワイトカラーへの転換 (⑥) を直接駆動する
- quantity-quality トレードオフを通じて, 出生率の低下 (②) と世帯サイズの縮小 (④) を駆動する

家庭内生産用耐久財の価格低下 (p)

- 家事の機械化により家事労働時間の減少 (①) を駆動する
- 家事の規模の経済という結婚のメリットを縮小させ, 結婚の減少 (③) を駆動する

この章の前半で学んだ quantity-quality の静学的なメカニズムが, 時間配分・家庭内生産・結婚市場と組み合わせられて 140 年の構造変化を説明する, という構成になっています. 一方で, 前半で見たよう

に, この枠組みはあくまで「古い事実」のための理論です. 21 世紀の高所得国で起きた, 所得や女性の労働参加と出生率の関係の逆転を説明するには, 子育ての市場化やキャリアと家族の両立のしやすさといった新しい要素が必要になります (Doepke ほか 2023 年).

付録 A

証明

A.1 黄金分割法における黄金比

1.2.2 節の黄金分割法では、区間の内分点を黄金比 $\varphi = \frac{\sqrt{5}-1}{2} \approx 0.618$ で取りました。ここでは、なぜ黄金比が現れるのかを示します。

各反復で関数値が必要になりますが、関数評価はコストが高いため、できるだけ評価回数を減らしたいです。そこで、次の2つの条件を満たすように内分点を配置することを考えます。

1. **縮小率を一定にする。** 各反復で区間が同じ割合 $r \in (0, 1)$ だけ縮小する。
2. **計算済みの点を再利用する。** 前の反復で評価した2つの内分点のうち一方が、新しい区間の内分点としてそのまま使える。これにより、1反復あたりの新規の関数評価を1回に抑えられる。

命題 A.1 (黄金分割法の内分比)。 区間 $[a, b]$ の幅を $L = b - a$ とし、比率 $\varphi \in (\frac{1}{2}, 1)$ で左右対称に2つの内分点 $x_1 = a + (1 - \varphi)L$, $x_2 = a + \varphi L$ を取る配置のうち、上の2条件 (一定の縮小率と点の再利用) を満たすものは

$$\varphi = \frac{\sqrt{5}-1}{2} \approx 0.618$$

(黄金比の逆数) に限る。

証明. 区間 $[a, b]$ の幅を $L = b - a$ とし、内分点を左右対称に取る。

$f(x_1) > f(x_2)$ の場合、極小値は x_1 より右にあるので、区間を $[x_1, b]$ に更新する。新しい区間の幅は $L' = b - x_1 = \varphi L$ となるため、縮小率は $r = \varphi$ で一定である (条件 1)。対称な場合 $f(x_1) \leq f(x_2)$ でも、区間は $[a, x_2]$ となり幅は φL で同じである。

次に点の再利用を考える。区間を $[x_1, b]$ に更新したとき、古い点 x_2 は新しい区間の内部に残っている。これを新しい区間の (左側の) 内分点として再利用するには、 x_2 が新しい区間 $[x_1, b]$ の左端から幅の $1 - \varphi$ の位置になければならない (条件 2)。

$$x_2 = x_1 + (1 - \varphi)L' = x_1 + (1 - \varphi)\varphi L.$$

ここで $x_1 = a + (1 - \varphi)L$, $x_2 = a + \varphi L$ を代入すると、

$$a + \varphi L = a + (1 - \varphi)L + (1 - \varphi)\varphi L$$

$$\varphi = (1 - \varphi)(1 + \varphi)$$

$$\varphi = 1 - \varphi^2.$$

整理すると $\varphi^2 + \varphi - 1 = 0$ であり, $\varphi \in (\frac{1}{2}, 1)$ の解は $\varphi = \frac{\sqrt{5}-1}{2}$ に限る.

得られた φ は黄金比 $\phi = \frac{1+\sqrt{5}}{2} \approx 1.618$ の逆数 $\varphi = 1/\phi$ に等しく, $\varphi^2 = 1 - \varphi$ という自己相似的な関係を満たすことが, 区間の縮小と点の再利用を両立させる鍵になっています.

A.2 3 次スプライン補間の最小曲率性

2.1 節では, 補間の手法として線形補間と 3 次スプライン補間を比較しました. ここでは, 3 次スプライン補間が「滑らかさ」という明確な意味で最良の補間になっていることを示します.

補間関数と滑らかさ. データ点 $(x_1, y_1), \dots, (x_n, y_n)$ ($x_1 < \dots < x_n$) が与えられたとき, これらを通る関数 f (すなわち $f(x_i) = y_i$ を満たす関数) を補間関数と呼びます. 補間関数は無数に存在するため, 何らかの意味で「良い」ものを選ぶ必要があります. スプラインの語源は製図で用いる薄い弾性板 (しなう定規) で, その弾性エネルギーは曲率の 2 乗の積分に比例します. 勾配が小さいとき曲率は f'' で近似できるので, 「なめらかさ」を測る指標として次の**曲げエネルギー** (bending energy) を考えます.

$$J(f) = \int_{x_1}^{x_n} (f''(x))^2 dx.$$

$J(f)$ が小さいほど関数の曲がりが少なく, 不要な振動のない滑らかな補間だといえます.

定義 A.1 (自然な 3 次スプライン). 関数 g が次をすべて満たすとき, データ点を補間する**自然な 3 次スプライン** (natural cubic spline) と呼ぶ.

1. 各小区間 $[x_i, x_{i+1}]$ 上で g は 3 次以下の多項式である.
2. g は区間全体 $[x_1, x_n]$ で 2 階連続微分可能である ($g \in C^2$).
3. データ点を補間する: $g(x_i) = y_i$.
4. 両端で 2 階微分がゼロ (自然境界条件): $g''(x_1) = g''(x_n) = 0$.

定理 A.1 (自然な 3 次スプラインの最小曲率性). データ点を補間する任意の C^2 級関数 f の中で, 自然な 3 次スプライン g は曲げエネルギー J を最小にする.

$$J(g) \leq J(f), \quad \text{with equality iff } f = g.$$

つまり, 与えられた点を通る滑らかな関数のうち, 自然な 3 次スプラインが最も曲がりの少ない補間を与えます.

証明. $h := f - g$ とおく. f, g はともにデータ点を補間するので, 各ノードで $h(x_i) = f(x_i) - g(x_i) = 0$ である. $f = g + h$ より, 曲げエネルギーを展開すると

$$J(f) = \int_{x_1}^{x_n} (g'' + h'')^2 dx = J(g) + 2 \int_{x_1}^{x_n} g'' h'' dx + \int_{x_1}^{x_n} h''^2 dx.$$

交差項が消えることを示す. 部分積分すると

$$\int_{x_1}^{x_n} g'' h'' dx = [g''(x)h'(x)]_{x_1}^{x_n} - \int_{x_1}^{x_n} g'''(x)h'(x) dx.$$

第1項は自然境界条件 $g''(x_1) = g''(x_n) = 0$ よりゼロである。第2項は、 g が各小区間 $[x_i, x_{i+1}]$ で3次多項式なので g''' がその区間で定数 c_i となることを使う。

$$\int_{x_1}^{x_n} g'''(x)h'(x) dx = \sum_{i=1}^{n-1} c_i \int_{x_i}^{x_{i+1}} h'(x) dx = \sum_{i=1}^{n-1} c_i (h(x_{i+1}) - h(x_i)) = 0.$$

最後の等号は、すべてのノードで $h(x_i) = 0$ であることによる。したがって交差項はゼロとなり、

$$J(f) = J(g) + \int_{x_1}^{x_n} (h''(x))^2 dx \geq J(g).$$

等号が成立するのは $\int (h'')^2 dx = 0$ 、すなわち $h'' \equiv 0$ のときに限る。このとき h は1次関数だが、 h は2つ以上のノードでゼロになるため $h \equiv 0$ 、つまり $f = g$ でなければならない。

以上より、自然な3次スプラインは「与えられた点を通る最も滑らかな関数」という変分問題の解になっています。これが、高次の多項式補間で生じる不要な振動 (Runge 現象) を避けつつ、線形補間と違って2階微分まで連続な補間が得られる理由です。

A.3 縮小写像と動的計画法

数値計算パートの動的計画法 (第3章) では、価値関数反復 (VFI) がひとつの関数に収束していく様子を可視化で確認しました。ここでは、その背後にある理論を証明付きで整理します。ベルマン方程式の解 (価値関数) は存在するのか、一意なのか、そして VFI はなぜ、どれくらいの速さで収束するのか。答えはすべて、縮小写像 (contraction mapping) という一つ概念から得られます。標準的な教科書としては Stokey, Lucas and Prescott (1989) があります。

A.3.1 縮小写像

関数の列の収束を扱うので、議論の舞台は「関数同士の距離」が定義された空間です。

定義 A.2 (距離空間と完備性). 集合 S と関数 $d: S \times S \rightarrow \mathbb{R}_{\geq 0}$ の組 (S, d) が距離空間であるとは、任意の $f, g, h \in S$ に対して次が成り立つことをいう。

- $d(f, g) = 0 \Leftrightarrow f = g$
- 対称性: $d(f, g) = d(g, f)$
- 三角不等式: $d(f, h) \leq d(f, g) + d(g, h)$

距離空間が完備 (complete) であるとは、任意のコーシー列 (項同士の距離がいくらでも小さくなる列) が S の中に極限を持つことをいう。

ここで使うのは、状態空間 X 上の有界関数の空間 $B(X)$ と sup ノルムの距離

$$d(f, g) = \|f - g\| = \sup_{x \in X} |f(x) - g(x)|$$

です。この空間が完備であることは知られています (有界関数の一様収束極限は有界)。

定義 A.3 (縮小写像). 距離空間 (S, d) 上の写像 $T: S \rightarrow S$ が係数 $\beta \in (0, 1)$ の縮小写像 (contraction mapping) であるとは、任意の $f, g \in S$ に対して

$$d(Tf, Tg) \leq \beta d(f, g)$$

が成り立つことをいう。

縮小写像は「どの 2 点も、写すたびに距離が β 倍以下に縮む」写像です。直感的には、空間全体が 1 点に向かって縮んでいくので、その 1 点が不動点になるはずです。これを正確に述べたのが次の定理です。

定理 A.2 (Banach の不動点定理). (S, d) を完備距離空間、 T を係数 β の縮小写像とする。このとき、

1. T はただ 1 つの不動点 $v^* \in S$ ($Tv^* = v^*$) を持つ。
2. 任意の初期点 $v_0 \in S$ から反復列 $v_n = Tv_{n-1}$ を作ると、 $v_n \rightarrow v^*$ であり、収束は幾何級数的である。

$$d(v_n, v^*) \leq \beta^n d(v_0, v^*).$$

証明. Step1 (反復列はコーシー列): $d(v_{n+1}, v_n) = d(Tv_n, Tv_{n-1}) \leq \beta d(v_n, v_{n-1})$ を繰り返すと $d(v_{n+1}, v_n) \leq \beta^n d(v_1, v_0)$ である。 $m > n$ に対して三角不等式を使うと

$$d(v_m, v_n) \leq \sum_{k=n}^{m-1} d(v_{k+1}, v_k) \leq \sum_{k=n}^{\infty} \beta^k d(v_1, v_0) = \frac{\beta^n}{1-\beta} d(v_1, v_0)$$

となり、 $n \rightarrow \infty$ でゼロに収束する。よって $\{v_n\}$ はコーシー列であり、完備性からある $v^* \in S$ に収束する。

Step2 (v^* は不動点): 任意の n に対して

$$d(Tv^*, v^*) \leq d(Tv^*, v_{n+1}) + d(v_{n+1}, v^*) \leq \beta d(v^*, v_n) + d(v_{n+1}, v^*)$$

であり、右辺は $n \rightarrow \infty$ でゼロに収束するので $d(Tv^*, v^*) = 0$ 、すなわち $Tv^* = v^*$ 。

Step3 (一意性): v, w がともに不動点なら $d(v, w) = d(Tv, Tw) \leq \beta d(v, w)$ であり、 $\beta < 1$ より $d(v, w) = 0$ 、すなわち $v = w$ 。

Step4 (収束の速さ): $d(v_n, v^*) = d(T^n v_0, T^n v^*) \leq \beta^n d(v_0, v^*)$ 。

ある写像が縮小写像かどうかを定義から直接確かめるのは面倒ですが、経済学に現れる作用素には次の便利な十分条件があります。

命題 A.2 (Blackwell の十分条件). $T: B(X) \rightarrow B(X)$ が次の 2 条件を満たすなら、 T は $\sup$ ノルムに関して係数 β の縮小写像である。

1. **単調性:** $f \leq g$ (すべての x で $f(x) \leq g(x)$) ならば $Tf \leq Tg$ 。
2. **割引:** ある $\beta \in (0, 1)$ が存在して、任意の定数 $a \geq 0$ に対して $T(f + a) \leq Tf + \beta a$ 。

証明. 任意の f, g に対して、すべての x で $f(x) \leq g(x) + \|f - g\|_{\infty}$ が成り立つ。単調性と割引を順に使うと

$$Tf \leq T\left(g + \|f - g\|_{\infty}\right) \leq Tg + \beta \|f - g\|_{\infty}.$$

f と g を入れ替えれば逆向きの不等式も得られるので, すべての x で $|(Tf)(x) - (Tg)(x)| \leq \beta \|f - g\|_{\infty}$ となり, $\sup$ をとって $\|Tf - Tg\|_{\infty} \leq \beta \|f - g\|_{\infty}$.

A.3.2 ベルマン方程式への適用

動的計画法の章で扱った問題を一般形で書きます. 状態 $x \in X$, 実行可能な選択の集合 $\Gamma(x)$, 当期リターン $u(x, a)$, 状態の遷移 $x' \sim Q(\cdot | x, a)$, 割引因子 $\beta \in (0, 1)$ とし, u は有界とします. ベルマン方程式は

$$V(x) = \max_{a \in \Gamma(x)} \{u(x, a) + \beta \mathbb{E}[V(x') | x, a]\} \quad (\text{A.1})$$

であり, 右辺を関数 V への操作とみなしたものがベルマン作用素 T です.

$$(TV)(x) = \max_{a \in \Gamma(x)} \{u(x, a) + \beta \mathbb{E}[V(x') | x, a]\}.$$

式 (A.1) を解くことは, T の不動点を見つけることにほかなりません.

命題 A.3 (ベルマン作用素は縮小写像). u が有界なら, ベルマン作用素 T は $B(X)$ 上の係数 β の縮小写像である. したがって式 (A.1) の有界な解 V^* はただ1つ存在し, 任意の初期関数 V_0 からの価値関数反復 $V_N = TV_{N-1}$ は

$$\|V_N - V^*\|_{\infty} \leq \beta^N \|V_0 - V^*\|_{\infty}$$

を満たして V^* に収束する.

証明. u が有界 ($|u| \leq \bar{u}$) なら, $|V| \leq M$ に対して $|TV| \leq \bar{u} + \beta M$ なので T は $B(X)$ を $B(X)$ に写す. Blackwell の条件を確かめる.

単調性: $f \leq g$ なら, どの (x, a) でも $u(x, a) + \beta \mathbb{E}[f] \leq u(x, a) + \beta \mathbb{E}[g]$ であり, 各選択枝の値が大きくなるので $\max$ も大きくなる. よって $Tf \leq Tg$.

割引: 定数 $a \geq 0$ に対して

$$T(V + a)(x) = \max_{a' \in \Gamma(x)} \{u(x, a') + \beta \mathbb{E}[V(x')]\} + \beta a = (TV)(x) + \beta a.$$

よって命題 A.2 より T は係数 β の縮小写像であり, $B(X)$ は完備なので定理 A.2 のすべての結論が従う.

この命題が, 数値計算パートで見た事実の理論的な裏付けです. 価値関数は存在して一意であり, VFI はどんな初期関数から始めても収束し, 収束の速さは β で決まります. β が1に近い (将来を重視する) 問題ほど収束が遅い, という数値計算上の経験則も, 誤差が β^N で減ることの直接の帰結です.¹⁹

A.3.2.1 停止基準と誤差の保証

実際の計算では真の V^* を知らないまま反復を止める必要があります. 隣り合う反復の差から, 真の誤差を評価できます.

¹⁹なお, 式 (A.1) の解が逐次問題 (無限和の最大化) の価値関数と一致することは, 有界性のもとで別途確認できます (verification argument). 直感的には, ベルマン方程式を N 回展開すると逐次問題の N 期打ち切りと残差 $\beta^N V$ に分解でき, 残差は消えていくためです.

命題 A.4 (事後誤差評価).

$$\|V_N - V^*\|_\infty \leq \frac{\beta}{1-\beta} \|V_N - V_{N-1}\|_\infty.$$

証明. 三角不等式と縮小性より

$$\|V_N - V^*\|_\infty \leq \sum_{k=N}^{\infty} \|V_{k+1} - V_k\|_\infty \leq \sum_{j=1}^{\infty} \beta^j \|V_N - V_{N-1}\|_\infty = \frac{\beta}{1-\beta} \|V_N - V_{N-1}\|_\infty.$$

数値計算パートの VFI で使った「更新幅 $\|V_N - V_{N-1}\|_\infty$ が許容誤差 ε を下回ったら停止」という基準は, この命題によって真の誤差が $\beta\varepsilon/(1-\beta)$ 以下であることを保証します. 係数 $\beta/(1-\beta)$ は $\beta = 0.96$ なら 24 です. 更新幅と真の誤差は 1~2 桁ずれうるので, 許容誤差はその分だけ小さめに設定する必要があります.

A.3.2.2 価値関数が引き継ぐ性質

縮小写像の議論には, もうひとつ便利な使い方があります. $B(X)$ の閉部分集合 S' (たとえば非減少関数の集合や凹関数の集合) に対して $T(S') \subset S'$ が示せれば, 不動点 V^* も S' に属します. 反復列がずっと S' の中にいて, S' が閉じているので極限も S' に残るからです.

命題 A.5 (単調性と凹性の継承). リターン $u(x, a)$ が x について非減少で, 実行可能集合が拡大的 ($x \leq \tilde{x}$ ならば $\Gamma(x) \subset \Gamma(\tilde{x})$), 遷移が単調なら, V^* は x について非減少である. さらに u が凹, Γ のグラフが凸, 遷移が線形 (決定論的な線形遷移や凹性を保つ確率遷移) なら, V^* は凹である.

証明. 非減少な V に対して TV も非減少になることを見る. $x \leq \tilde{x}$ とすると, どの $a \in \Gamma(x)$ に対しても $u(\tilde{x}, a) + \beta \mathbb{E}[V | \tilde{x}, a] \geq u(x, a) + \beta \mathbb{E}[V | x, a]$ であり (u の単調性と遷移の単調性), さらに $\tilde{x}$ では選択肢が増えるので $\max$ は下がらない. よって $(TV)(\tilde{x}) \geq (TV)(x)$. 非減少関数の集合は $\sup$ ノルムで閉じているので, 非減少な V_0 から始めた反復列の極限 V^* も非減少である. 凹性も同様に, T が凹関数を凹関数に写すこと (凸結合の状態で凸結合の政策が実行可能であり, リターンが凹であること) を確かめればよい.

数値計算パートで補間 (関数近似の章) が素直に機能したのは, 近似対象の V^* がこうした形状の規則性を持つからです. 逆に, 離散選択が入って価値関数にキンクが生じる場合には, 結婚の部の frictionless marriage の章で見た対数和による平滑化が効いてきます.

縮小写像の枠組みは, サーチ理論の章での留保値の存在の議論にもそのまま使われています.

A.4 留保賃金方程式のオプション価値項

サーチ理論の章の [命題 5.2](#) (留保賃金の比較静学) では, 留保賃金方程式のオプション価値項

$$H(x) := \int_x^\infty (w - x) dF(w)$$

を閾値 x で微分して $H'(x) = -(1 - F(x))$ を使いました. ここではこれを証明します. x は積分の下端と被積分関数の両方に現れるので, ライプニッツ則 (積分記号下の微分) の出番です. 積分区間が無

限に伸びていることが唯一の注意点で、上端からの寄与を心配する必要はない代わりに、微分と積分の交換を正当化する条件が要ります。

補題 A.1 (オプション価値項の微分). F を分布関数とし、 $\mathbb{E}[w] = \int w dF(w) < \infty$ とする。このとき $H(x) = \int_x^\infty (w - x) dF(w)$ はすべての x で有限であり、 F が x に質点を持たない (すなわち F が x で連続な) 各点で微分可能で

$$H'(x) = -(1 - F(x))$$

が成り立つ。とくに F の台が有界ならば、前提はつねに満たされる。

証明. Step1 (有限性): $0 \leq (w - x)\mathbb{1}\{w > x\} \leq |w| + |x|$ であり、右辺は $\mathbb{E}[w] < \infty$ より可積分である。よって $H(x)$ は有限である。

Step2 (ライプニッツ則): F が密度 f を持つ場合を考える。端点が動く積分に対するライプニッツ則は

$$\frac{d}{dx} \int_{a(x)}^{b(x)} g(w, x) dw = g(b(x), x)b'(x) - g(a(x), x)a'(x) + \int_{a(x)}^{b(x)} \frac{\partial g}{\partial x}(w, x) dw$$

である。境界の2項は「端が動いた分だけ積分区間に入出入りする短冊の面積」であり、その大きさは端における被積分関数の値に端の動く速さを掛けたものになる。

いまの場合 $g(w, x) = (w - x)f(w)$, $a(x) = x$, $b(x) = \infty$ である。上端は x に依存しない定数なので、動かない端からは短冊が出入りせず、上端の境界項はそもそも現れない。²⁰ 下端については $a'(x) = 1$ であるが、被積分関数が $w = x$ でちょうどゼロになるため

$$-g(x, x)a'(x) = -(x - x)f(x) = 0$$

と消える。残る積分項は $\partial g / \partial x = -f(w)$ より

$$\int_x^\infty \frac{\partial g}{\partial x}(w, x) dw = - \int_x^\infty f(w) dw = -(1 - F(x))$$

である。

Step3 (交換の正当化): 有限区間であれば微分と積分の交換は被積分関数の連続性から従うが、積分区間が無限のときは広義積分の極限と微分の極限を入れ替えることになるため、優関数が必要である。ここでは x を含む任意の近傍上で

$$\left| \frac{\partial}{\partial x}(w - x) \right| = 1, \quad \int 1 dF(w) = 1 < \infty$$

であり、定数関数 1 が優関数として使える。よって優収束定理から交換が許され、Step2 の計算が正当化される。

Step4 (密度を仮定しない場合): F が密度を持たなくても結論は変わらない。 $H(x) = \mathbb{E}[\max\{w - x, 0\}]$ と書き、 $h > 0$ に対して差分を場合分けすると

²⁰ $g(\infty, x) \cdot \frac{d\infty}{dx}$ のような項を書いてゼロとみなすのは誤りである。上端が x に依存する場合にのみ、その項が立つ。

$$H(x+h) - H(x) = -h(1 - F(x+h)) - \int_{(x, x+h]} (w-x) dF(w)$$

が厳密に成り立つ。右辺第2項は0以上 $h(F(x+h) - F(x))$ 以下なので、差分商は

$$-(1 - F(x)) \leq \frac{H(x+h) - H(x)}{h} \leq -(1 - F(x+h))$$

に挟まれる。 F は右連続だから $h \downarrow 0$ で両端が $-(1 - F(x))$ に収束し、右微分係数が定まる。左からの差分商についても同様に計算すると極限は $-(1 - F(x^-))$ となるので、両側微分が一致するのは $F(x^-) = F(x)$, すなわち F が x に質点を持たないときである。

H が x について非増加であることは $H'(x) \leq 0$ から、凸であることは $H'(x) = -(1 - F(x))$ が x について非減少であることから分かります。なお 命題 5.2 の (2) で使うのは、同じ被積分関数 $\max\{w - x, 0\}$ が w について凸であるという別の性質で、そちらは平均保存的な広がりのもとでの期待値の単調性から従います。

A.5 平均保存的な広がりと凸順序

命題 5.2 の (2) は、「オファー分布の平均が同じでも分散が大きければ留保賃金は上がる」という主張でした。証明では、待つことのオプション価値 $\mathbb{E}[\max\{w - w^*, 0\}]$ が被積分関数の凸性ゆえに広がりとともに増える、という事実を使っていました。

定理 A.3 (平均保存的な広がりと凸順序, Rothschild と Stiglitz (1970 年)). 平均の等しい2つの分布 F と G について、次の3条件は同値である。

1. $X \sim F$ と $\mathbb{E}[\varepsilon | X] = 0$ を満たすノイズ ε を用いて $X + \varepsilon \sim G$ と書ける。このとき G は F の平均保存的な広がり (mean-preserving spread) であるという。
2. 期待値の存在する任意の凸関数 φ について $\mathbb{E}_G[\varphi(w)] \geq \mathbb{E}_F[\varphi(w)]$ が成り立つ。
3. すべての x について $\int_{-\infty}^x (F(t) - G(t))dt \leq 0$ が成り立つ。

証明. ここでは 命題 5.2 で使う $1 \Rightarrow 2$ の向きだけを示す。 $X \sim F$, $\mathbb{E}[\varepsilon | X] = 0$, $X + \varepsilon \sim G$ とする。 φ が凸なら、 X で条件付けた上でイェンセンの不等式を適用して

$$\mathbb{E}[\varphi(X + \varepsilon) | X] \geq \varphi(\mathbb{E}[X + \varepsilon | X]) = \varphi(X)$$

が得られる。両辺の期待値を取れば $\mathbb{E}_G[\varphi] = \mathbb{E}[\varphi(X + \varepsilon)] \geq \mathbb{E}[\varphi(X)] = \mathbb{E}_F[\varphi]$ である。

残りの向きは非自明である。 $2 \Rightarrow 1$ は、与えられた凸順序を実現する結合の存在を主張するもので、Strassen の定理による (Strassen 1965 年)。 $2 \Leftrightarrow 3$ は部分積分による書き換えで、Rothschild と Stiglitz (1970 年) にある。

A.6 標本統計量の影響関数

4.2 節のターゲットは、労働時間の平均 $\bar{h}$ と標準偏差 s_h , 対数月収の標準偏差 s_y , 両者の相関 r_{hy} , 40 時間ちょうどの割合 $\bar{d}$ の5本でした。標本平均そのものは1本目と5本目で、残りの3本は標本平均

の非線形な関数です。その分散共分散行列をデルタ法で導きます。出発点は、個人 i から作れる 6 つの量です。

$$a_i = (h_i, h_i^2, y_i, y_i^2, h_i y_i, d_i)^\top, \quad \bar{a} = \frac{1}{N} \sum_{i=1}^N a_i \quad (\text{A.2})$$

5 本のモーメントは、どれもこの標本平均の関数として書けます。

$$\hat{m} = \phi(\bar{a}), \quad \phi(a) = \left(a_1, \sqrt{a_2 - a_1^2}, \sqrt{a_4 - a_3^2}, \frac{a_5 - a_1 a_3}{\sqrt{(a_2 - a_1^2)(a_4 - a_3^2)}}, a_6 \right)^\top \quad (\text{A.3})$$

$\bar{a}$ は標本平均なので中心極限定理がそのまま使えます。 $\mu_a = \mathbb{E}[a_i]$, $\Sigma_a = \text{Var}(a_i)$ として $\sqrt{N}(\bar{a} - \mu_a) \xrightarrow{d} \mathcal{N}(0, \Sigma_a)$ です。あとは ϕ を通すだけで、 $D = \partial\phi/\partial a^\top$ を μ_a で評価した 5×6 行列とすると

$$\sqrt{N}(\hat{m} - m) \xrightarrow{d} \mathcal{N}(0, D \Sigma_a D^\top) \quad (\text{A.4})$$

となります。これがデルタ法です。ここで $\xi_i = D(a_i - \mu_a)$ と置くと、式 (A.4) の分散は $\text{Var}(\xi_i)$ そのもので、 $\hat{m} - m \simeq \frac{1}{N} \sum_i \xi_i$ と、推定誤差が個人ごとの寄与の平均として書けます。この ξ_i を影響関数 (influence function) と呼びます。行列 D と Σ_a を別々に持つ代わりに ξ_i を 1 本の列として持てば、実装は標本分散共分散を 1 回取るだけになります。

D を計算します。第 1 行は $\phi_1 = a_1$ なので $\partial\phi_1/\partial a = (1, 0, 0, 0, 0, 0)$, すなわち

$$\xi_{1i} = h_i - \mathbb{E}[h]$$

です。第 5 行の指標も同じで、 $\xi_{5i} = d_i - \mathbb{E}[d]$ です。第 2 行は $\phi_2 = (a_2 - a_1^2)^{1/2}$ の微分です。分母に現れる $\sqrt{a_2 - a_1^2}$ を μ_a で評価したものは h の母標準偏差、つまりターゲットの 2 本目 $m_2 = \phi_2(\mu_a)$ そのものなので、それで書くと

$$\frac{\partial\phi_2}{\partial a_1} = \frac{-a_1}{\sqrt{a_2 - a_1^2}} = -\frac{\mathbb{E}[h]}{m_2}, \quad \frac{\partial\phi_2}{\partial a_2} = \frac{1}{2\sqrt{a_2 - a_1^2}} = \frac{1}{2m_2}$$

なので、2 つの成分を合わせて

$$\xi_{2i} = -\frac{\mathbb{E}[h]}{m_2}(h_i - \mathbb{E}[h]) + \frac{1}{2m_2}(h_i^2 - \mathbb{E}[h^2]) \quad (\text{A.5})$$

となります。第 2 項を平均のまわりで書き直すと $h_i^2 - \mathbb{E}[h^2] = (h_i - \mathbb{E}[h])^2 - m_2^2 + 2\mathbb{E}[h](h_i - \mathbb{E}[h])$ なので、これを式 (A.5) に代入すると第 1 項がちょうど打ち消えて

$$\xi_{2i} = \frac{(h_i - \mathbb{E}[h])^2 - m_2^2}{2m_2} \quad (\text{A.6})$$

が残ります。平均を推定したことによる誤差が、標準偏差の影響関数には残らないということです。第 3 行も h を y に、 m_2 を m_3 に置き換えれば同じ形になります。

第 4 行の相関も同じ手続きですが、 ϕ_4 が 5 つの成分に依存するので項が増えます。標準化した値 $u_i = (h_i - \mathbb{E}[h])/m_2$, $v_i = (y_i - \mathbb{E}[y])/m_3$ を使うと、整理した結果は次の形にまとまります。

$$\xi_{4i} = u_i v_i - m_4 - \frac{m_4}{2}(u_i^2 - 1) - \frac{m_4}{2}(v_i^2 - 1) \quad (\text{A.7})$$

第1項は共分散の影響関数で、残りの2項は分母の2つの標準偏差を推定したことの効果です。相関は標準偏差で割った量なので、分母の推定誤差も相関の推定誤差に効いてくる、ということです。

実装では母数を標本の値に置き換えて $\hat{\xi}_i$ を作り、その標本分散共分散を N で割ります (式 (4.16)).

A.7 Goussé, Jacquemet, Robin (2017) の式の導出

5章の Goussé ほか (2017 年) のモデルについて、本文で結果だけを示した式を導きます。記号は本文のとおりで、男性のタイプを i 、女性のタイプを j 、マッチの質を z とし、混乱の恐れがないところではタイプの引数を省きます。

A.7.1 コミットメントのない結婚の価値

まず、コミットメントのない結婚の純価値を与える 式 (5.7) を、既婚者の価値の HJB 方程式 式 (5.6) から導きます。コミットメントがないので、契約の価値 $W_m(i, j, z)$ は継続価値 $V_m^1(i, j, z)$ に等しくなければなりません。以下ではタイプの引数 (i, j) を省き、 $u_m = u_m(i, j, z)$ と書きます。式 (5.6) に $W_m = V_m^1(z)$ を代入した

$$rV_m^1(z) = u_m + \delta \int [\max\{V_m^0, V_m^1(z')\} - V_m^1(z)] dG(z')$$

から出発します。

まず、自明に次の表現を得ます。

$$\max\{V_m^0, V_m^1(z')\} = V_m^0 + [V_m^1(z') - V_m^0]^+.$$

これを 式 (5.7) に代入すると、次の式が得られます。

$$\begin{aligned} rV_m^1(z) &= u_m + \delta \int [V_m^0 + [V_m^1(z') - V_m^0]^+ - V_m^1(z)] dG(z') \\ &= u_m + \delta V_m^0 + \delta \int [V_m^1(z') - V_m^0]^+ dG(z') - \delta V_m^1(z) \end{aligned}$$

$\delta V_m^1(z)$ を左辺に移して、 $(r + \delta)V_m^0$ を引くと、次の式を得ます。

$$(r + \delta)[V_m^1(z) - V_m^0] = u_m + \delta \int [V_m^1(z') - V_m^0]^+ dG(z') - rV_m^0.$$

A.7.2 余剰の方程式

本文の間接効用の特定化 $\psi_i(R, q) = q(R - A_i)/B_i$ のもとで、夫婦のフロー効用は $u_m = zF_{ij}(R_m - A_i)/B_i$ 、 $u_f = zF_{ij}(R_f - A_j)/B_j$ です。価格指数で重みつけて足すと

$$B_i u_m + B_j u_f = zF_{ij}(R_m + R_f - A_i - A_j) =: zF_{ij} X_{ij}$$

となり、移転 (t_m, t_f) が消えます。 $X_{ij} = w_i(1 - d_m) + w_j(1 - d_f) - C_{ij} - A_i - A_j$ は、世帯の私的支出から最低私的支出を差し引いた純私的支出で、分配には依存しません。

余剰を $S_{ij}(z) := B_i[V_m^1(z) - V_m^0] + B_j[V_f^1(z) - V_f^0]$ と定義します。TU のもとで Nash 交渉の解は余剰を交渉力の比で分けるので、次の式を得ます。

$$B_i[V_m^1(z) - V_m^0] = \beta S_{ij}(z), \quad B_j[V_f^1(z) - V_f^0] = (1 - \beta)S_{ij}(z) \quad (\text{A.8})$$

したがって夫婦がともに結婚を続けることに合意するのは $S_{ij}(z) \geq 0$ のときで、正の部分についても $B_i[V_m^1(z') - V_m^0]^+ = \beta S_{ij}(z')^+$ 、女性側は $(1 - \beta)S_{ij}(z')^+$ です。

男性の式 (5.7) を B_i 倍、女性側の同じ式を B_j 倍して足します。左辺は $(r + \delta)S_{ij}(z)$ 、右辺のフロー効用の和は上の $zF_{ij}X_{ij}$ 、積分の中は $\beta S^+ + (1 - \beta)S^+ = S_{ij}(z')^+$ にまとまるので、次の式を得ます。

$$(r + \delta)S_{ij}(z) = zF_{ij}X_{ij} - B_i rV_m^0 - B_j rV_f^0 + \delta \int S_{ij}(z')^+ dG(z')$$

A.7.3 家事時間の効率性条件

夫婦は Nash 交渉で家事時間 (d_m, d_f) と移転 (t_m, t_f) を選びます。TU のもとでは Nash 交渉の解は「まず余剰 $S_{ij}(z)$ を最大化し、次にそれを式 (A.8) の比で分ける」と2段階に分かれます。余剰の方程式で (d_m, d_f) に依存するのは今期のフロー $zF_{ij}(d_m, d_f)X_{ij}(d_m, d_f)$ だけです。独身の価値 V_m^0, V_f^0 は結婚市場の状態で決まる所与の量であり、継続価値の項は引き直された z' のもとで改めて選ばれる配分の価値なので、今期の家事時間には依存しません。移転は X_{ij} に入らないので、家事時間の問題は

$$\max_{d_m, d_f} F_{ij}(d_m, d_f) X_{ij}(d_m, d_f), \quad X_{ij} = w_i(1 - d_m) + w_j(1 - d_f) - C_{ij} - A_i - A_j$$

という静学的な問題に落ちます。 z は掛け算の定数なので解に影響せず、これが本文で再帰性と呼んだ性質です。一階条件は、 $\partial X_{ij} / \partial d_m = -w_i$ を使って

$$\frac{\partial F_{ij}}{\partial d_m} X_{ij} - w_i F_{ij} = 0 \Leftrightarrow \frac{1}{w_i} \frac{\partial \ln F_{ij}}{\partial d_m} = \frac{1}{X_{ij}},$$

女性側も同様に $\frac{1}{w_j} \frac{\partial \ln F_{ij}}{\partial d_f} = \frac{1}{X_{ij}}$ です。2本を並べれば本文の効率性条件

$$\frac{1}{w_i} \frac{\partial \ln F_{ij}}{\partial d_m} = \frac{1}{w_j} \frac{\partial \ln F_{ij}}{\partial d_f}$$

になります。左右はそれぞれ「家事時間を1単位増やしたときの公共財の増加率を、その時間の機会費用（賃金）で割ったもの」で、家事1円あたりの限界生産性が夫婦で等しい、という標準的な効率性条件です。

Stone-Geary 型 $F_{ij} = Z_{ij}(d_m - D_m)^{K_m}(d_f - D_f)^{K_f}$ では $\partial \ln F_{ij} / \partial d_m = K_m / (d_m - D_m)$ なので、一階条件は $d_m - D_m = K_m X_{ij} / w_i$ 、 $d_f - D_f = K_f X_{ij} / w_j$ と解けます。これを X_{ij} の定義に戻すと $X_{ij} = w_i(1 - D_m) + w_j(1 - D_f) - C_{ij} - A_i - A_j - (K_m + K_f)X_{ij}$ なので、

$$X_{ij} = \frac{w_i(1 - D_m) + w_j(1 - D_f) - C_{ij} - A_i - A_j}{1 + K_m + K_f} \quad (\text{A.9})$$

と純私的支出が閉じた形で決まり、家事時間もそれに K/w を掛けたものとして決まります。ここから本文の比較静学が読めます。夫の賃金 w_i が上がると X_{ij}/w_i は下がり（分子の w_i を含まない部分が正なら）、夫の家事時間は減ります。妻の最低投入時間 D_f が大きい（家族観が保守的）と X_{ij} が $w_j/(1+K_m+K_f)$ だけ下がるので、夫の家事時間 $D_m+K_m X_{ij}/w_i$ は減り、妻の家事時間 $D_f+K_f X_{ij}/w_j$ は D_f の直接の増加が X_{ij} を通じた減少（ $K_f/(1+K_m+K_f) < 1$ ）を上回るので増えます。

独身者の家事時間も同じ形で決まります。本文の $u_m^0(i) = \max_d \psi_i(w_i(1-d), F_i^0(d))$ の一階条件は $\frac{1}{w_i} \frac{\partial \ln F_i^0}{\partial d} = \frac{1}{w_i(1-d)-A_i}$ で、分配の相手がいない分だけ右辺の純私的支出が本人のものだけになります。 $F_i^0(d) = (d-D_m^0)^{K_m^0}$ を代入すると $K_m^0(w_i(1-d)-A_i) = w_i(d-D_m^0)$ なので、

$$d_m^0 = D_m^0 + \frac{K_m^0}{1+K_m^0} \left(1 - D_m^0 - \frac{A_i}{w_i}\right)$$

と閉じた形で決まります（女性も同様）。

A.7.4 独身の価値

独身男性の HJB 方程式 式 (5.5) の両辺を B_i 倍し、正の部分に 式 (A.8) を使うと

$$B_i rV_m^0 = B_i u_m^0 + \lambda \iint \beta S_{ij}(z)^+ n_f(j) dG(z) dj = B_i u_m^0 + \lambda \beta \int \bar{S}_{ij} n_f(j) dj$$

となります。ここで $\bar{S}_{ij} := \int S_{ij}(z)^+ dG(z)$ は正の部分の期待余剰です。女性側は β を $1-\beta$ に、 n_f を n_m に替えれば同じ形です。余剰の方程式と合わせると、 (S_{ij}, V_m^0, V_f^0) はタイプの組ごとに連立する線形の積分方程式系になります。

A.7.5 Sharing rule

夫が受け取る純私的支出のシェアを $\beta_{ij}(z) := B_i u_m = (R_m - A_i)/X_{ij}$ と定義します。フロー効用の式から $B_i u_m = z F_{ij}(R_m - A_i)$ なので、 $\beta_{ij}(z) = B_i u_m / (z F_{ij} X_{ij})$ です。 $B_i u_m$ は2通りに書けます。男性の 式 (5.7) に 式 (A.8) を入れると

$$(r+\delta)\beta S_{ij}(z) = B_i u_m + \delta\beta \int S_{ij}(z')^+ dG(z') - B_i rV_m^0,$$

一方、式 (5.8) を β 倍すると

$$(r+\delta)\beta S_{ij}(z) = \beta z F_{ij} X_{ij} - \beta B_i rV_m^0 - \beta B_j rV_f^0 + \delta\beta \int S_{ij}(z')^+ dG(z').$$

2式の右辺を等しいとおくと積分の項が消え、

$$B_i u_m = \beta z F_{ij} X_{ij} + (1-\beta)B_i rV_m^0 - \beta B_j rV_f^0$$

を得ます。両辺を $z F_{ij} X_{ij}$ で割れば本文の sharing rule

$$\beta_{ij}(z) = \beta + \frac{(1-\beta)B_i rV_m^0 - \beta B_j rV_f^0}{z F_{ij} X_{ij}}$$

です。第 1 項が Nash ウェイト、第 2 項が外部機会の差で、分母に z が入るので同じタイプの夫婦でも z が高いほどシェアは β に近づきます。外部機会の差はフローの水準として一定なのに、分けるべきパイ $zF_{ij}X_{ij}$ が大きくなるからです。

A.7.6 推定の手順

本文で 3 段階にまとめた推定手順を、式のレベルで説明します。論文の本文 6.3 節、付録 B (識別)、付録 C (推定)、付録 D (数値計算) に基づきます (Goussé ほか 2017 年)。以下では夫婦の家庭内生産のパラメータを本文どおり (D_m, D_f, K_m, K_f) 、独身のものを $(D_m^0, D_f^0, K_m^0, K_f^0)$ と書きます。 F_{ij} はマッチの質 z を掛ける前の夫婦の生産 (均衡での値) を表します。割引率 r は推定の対象ではなく、所与として扱います。

データと離散化。 標本は BHPS の 1991-2008 年で、22 歳未満と 50 歳超を除きます。これを 91-93, 94-96, 97-99, 00-02, 03-05, 06-08 の 3 年ごとの 6 期間に分け、各期間を「タイプの分布だけが異なる別々の定常状態」からの標本とみなします。構造パラメータは全期間で共通です。タイプ i, j は (学歴, 賃金, 家族観指数) の組で、学歴 3 区分 (O-level, A-level, 高等教育) $\times$ 賃金の Chebyshev 節点 16 $\times$ 家族観指数の Chebyshev 節点 8 の格子に離散化します。観察するのは、独身者の家事時間 d^0 と労働時間 h^0 、夫婦それぞれの d_m, d_f, h_m, h_f で、余暇は $e = 1 - d - h$ として作ります。

A.7.6.1 第 1 段階: 出会い率・引き直し率・マッチング確率

ストックとフロー。 各期間について、3 年分の横断面をプールし、独身男性・独身女性・夫婦のストックの分布 $n_m(i), n_f(j), m(i, j)$ を上の格子上でカーネル密度推定します。フローは連続する 2 年の状態の遷移を数えて作ります。たとえば「1994 年に独身で 1995 年に既婚」の人数が 1994 年の結婚フロー、「1993 年に既婚で 1994 年に独身」の人数が 1994 年の離婚フローです。これを 3 年分足して期間のフローとします。フローの標本は小さいので、フローだけは学歴のみで集計します。

フローとマッチング確率の関係。 独身の男女は率 λ で出会い、確率 α_{ij} で結婚します。結婚している夫婦は率 δ で z を引き直し、確率 $1 - \alpha_{ij}$ で離婚します。よって単位時間あたりのフローは

$$MF(i, j) = \lambda n_m(i) n_f(j) \alpha_{ij}, \quad DF(i, j) = \delta m(i, j) (1 - \alpha_{ij}) \quad (\text{A.10})$$

です (Goussé ほか 2017 年, eqs. B.1-B.2)。結婚率 $MR(i, j) := MF(i, j) / [n_m(i) n_f(j)]$ と離婚率 $DR(i, j) := DF(i, j) / m(i, j)$ を定義すると、式 (A.10) は $MR/\lambda = \alpha_{ij}$, $DR/\delta = 1 - \alpha_{ij}$ と書けます。2 本を足すと α_{ij} が消え、

$$\frac{MR(i, j)}{\lambda} + \frac{DR(i, j)}{\delta} = 1 \quad (\text{A.11})$$

を得ます (Goussé ほか 2017 年, eq. B.3)。同じ z の引き直しが結婚と離婚の両方を決めているから、この制約が出てきます。

(ξ, δ) の OLS。 出会い率は Cobb-Douglas のマッチング関数 $\lambda = \xi(N_m N_f)^{-1/2}$ なので、式 (A.11) は

$$1 = \frac{1}{\xi} \left[(N_m N_f)^{1/2} MR(i, j) \right] + \frac{1}{\delta} DR(i, j)$$

という、被説明変数が定数 1 で定数項のない線形回帰になります。係数 $1/\xi$ と $1/\delta$ を OLS で推定します。 α_{ij} がタイプの組によって異なる限り 2 つの説明変数は共線にならないので、この回帰で識別できます。推定には中間の 4 期間 (94-96 から 03-05) をプールし、両端の 2 期間は使いません。1991 年は前年の状態がないので離婚フローが、2008 年は翌年の状態がないので結婚フローが作れないからです。生存時間モデルを使わないのは、結婚期間にも独身期間にも打ち切りがあるためです。推定値は $\hat{\xi} = 0.151$, $\hat{\delta} = 0.0378$ です。出会いの間隔は中央値で約 4.5 年、 z の引き直しの間隔は中央値で約 18 年に対応します。

マッチング確率. λ と δ が分かれば、式 (A.11) の 2 つの項からフローだけで $\alpha_{ij} = \delta MR / (\delta MR + \lambda DR)$ と書けます (Goussé ほか 2017 年, eq. B.4)。しかし論文は、流入と流出が等しい ($MF = DF$) という定常状態の条件 式 (5.11) を α_{ij} について解いた

$$\alpha_{ij} = \frac{\delta m(i, j)}{\delta m(i, j) + \lambda n_m(i) n_f(j)} \quad (\text{A.12})$$

を使います (Goussé ほか 2017 年, eq. 6.14)。理由は 2 つあります。第 1 に、家計が定常状態の分布を前提に期待を形成するというモデルの仮定と整合的です。第 2 に、フローよりストックの標本の方がはるかに大きいので、精度よく推定できます。論文はこの $\hat{\alpha}_{ij}$ を「制約なしの (unconstrained)」マッチング確率と呼び、本文の 図 5.24 はこれを集計したものです。式 (A.12) はモデルの経済的なメカニズム (価値関数) を一切使っていない点に注意してください。

A.7.6.2 準備: α_{ij} から外部機会と家庭内生産の水準を求める

第 2 段階と第 3 段階の両方で、独身の価値 $B_i r V_m^0$, $B_j r V_f^0$ と夫婦の家庭内生産の水準 $F_{ij} X_{ij}$ が必要になります。これらは、パラメータ $(\beta, \sigma, D, K, C, A, B)$ と第 1 段階の α_{ij} , n_m , n_f が与えられれば、 Z_{ij} を知らなくても計算できます。その手順をまとめます。

マッチの質の分布. G は $\ln z \sim \mathcal{N}(0, \sigma^2)$ の対数正規分布です。平均を 0 とするのは、0 でない平均は Z_{ij} に吸収されるからです。以下で $\bar{G}(s) := \int (z - s)^+ dG(z)$ を使います。対数正規分布では、標準正規分布の CDF を Φ として

$$G(s) = \Phi\left(\frac{\ln s}{\sigma}\right), \quad \bar{G}(s) = e^{\sigma^2/2} \Phi\left(-\frac{\ln s}{\sigma} + \sigma\right) - s \Phi\left(-\frac{\ln s}{\sigma}\right)$$

です (Goussé ほか 2017 年, sec. 6.1)。 $\bar{G}$ は減少関数で、 $\bar{G}'(s) = -(1 - G(s))$ を満たします。

Step 1: 留保値. 式 (5.9) より、留保値は

$$z_{ij} = G^{-1}(1 - \alpha_{ij}) = \exp(\sigma \Phi^{-1}(1 - \alpha_{ij}))$$

です。 σ を与えれば、第 1 段階の α_{ij} からそのまま計算できます。

Step 2: 期待余剰と外部機会の比. $\bar{S}_{ij} := \int S_{ij}(z')^+ dG(z')$ はスカラーなので、式 (5.8) は

$$(r + \delta) S_{ij}(z) = z F_{ij} X_{ij} - (B_i r V_m^0 + B_j r V_f^0) + \delta \bar{S}_{ij}$$

という z の 1 次式です。 $S_{ij}(z_{ij}) = 0$ で留保値を定めると

$$z_{ij} = \frac{B_i r V_m^0 + B_j r V_f^0 - \delta \bar{S}_{ij}}{F_{ij} X_{ij}}, \quad \alpha_{ij} = 1 - G \left(\frac{B_i r V_m^0 + B_j r V_f^0 - \delta \bar{S}_{ij}}{F_{ij} X_{ij}} \right) \quad (\text{A.13})$$

が得られ (Goussé ほか 2017 年, eq. 5.6), 余剰は $S_{ij}(z) = F_{ij} X_{ij} (z - z_{ij}) / (r + \delta)$ と書けます. これを正の部分で積分すると

$$\bar{S}_{ij} = \frac{F_{ij} X_{ij}}{r + \delta} \bar{G}(z_{ij}) \quad (\text{A.14})$$

です (Goussé ほか 2017 年, eq. 5.5). 式 (A.13) の左の式を $B_i r V_m^0 + B_j r V_f^0 = F_{ij} X_{ij} z_{ij} + \delta \bar{S}_{ij}$ と書き直し, 式 (A.14) で $F_{ij} X_{ij} = (r + \delta) \bar{S}_{ij} / \bar{G}(z_{ij})$ を代入すると

$$B_i r V_m^0 + B_j r V_f^0 = \delta \bar{S}_{ij} \left[\frac{r + \delta}{\delta} \frac{z_{ij}}{\bar{G}(z_{ij})} + 1 \right]$$

なので, 未知の $F_{ij} X_{ij}$ を含まない関係

$$\delta \bar{S}_{ij} = \theta_{ij} (B_i r V_m^0 + B_j r V_f^0), \quad \theta_{ij} := \frac{\bar{G}(z_{ij})}{\frac{r + \delta}{\delta} z_{ij} + \bar{G}(z_{ij})} \quad (\text{A.15})$$

を得ます (Goussé ほか 2017 年, eq. B.15). $\theta_{ij} \in [0, 1]$ は α_{ij} と (σ, r, δ) だけで決まる既知の数です.

Step 3: 独身の価値を線形方程式として解く. 式 (A.15) を 式 (5.10) (と女性側の対応する式) の $\bar{S}_{ij}$ に代入すると

$$\begin{aligned} B_i r V_m^0 &= B_i u_m^0 + \frac{\lambda \beta}{\delta} \int (B_i r V_m^0 + B_j r V_f^0) \theta_{ij} n_f(j) dj, \\ B_j r V_f^0 &= B_j u_f^0 + \frac{\lambda(1 - \beta)}{\delta} \int (B_i r V_m^0 + B_j r V_f^0) \theta_{ij} n_m(i) di \end{aligned} \quad (\text{A.16})$$

となります (Goussé ほか 2017 年, eqs. C.2-C.3). ここで独身のフロー効用は, 式 (5.4) で $R - A_i = X_i^0$, $q = F_i^0(d_m^0)$ とおいたものです. 独身の家事時間の閉じた形 (A.7.3 節の末尾) を使うと

$$X_i^0 := \frac{w_i(1 - D_m^0) - A_i}{1 + K_m^0}, \quad d_m^0 = D_m^0 + \frac{K_m^0 X_i^0}{w_i}, \quad B_i u_m^0 = \left(\frac{K_m^0 X_i^0}{w_i} \right)^{K_m^0} X_i^0 \quad (\text{A.17})$$

です ($R - A_i = w_i(1 - d_m^0) - A_i = X_i^0$ は d_m^0 を代入すれば確かめられます) (Goussé ほか 2017 年, eqs. 6.6, 6.9). $B_i u_m^0$, θ_{ij} , n_m , n_f がすべて既知なので, 式 (A.16) は未知関数 $B_i r V_m^0$, $B_j r V_f^0$ についての線形の積分方程式 (第 2 種 Fredholm 方程式) です. 右辺の積分作用素が縮小写像なら解は一意的で, その十分条件は $\lambda \beta \int \theta_{ij} n_f(j) dj < \delta$ と $\lambda(1 - \beta) \int \theta_{ij} n_m(i) di < \delta$ です (Goussé ほか 2017 年, Appendix B). この方程式に Z_{ij} は現れません.

離散化した解法. タイプを格子点 i, j に離散化し, 積分を Clenshaw-Curtis 求積の重み ω_i, ω_j による和で置き換えます. 行列

$$\Theta_m = -\frac{\lambda \beta}{\delta} [\theta_{ij} n_f(j) \omega_j]_{i,j}, \quad \Theta_f = -\frac{\lambda(1 - \beta)}{\delta} [\theta_{ij} n_m(i) \omega_i]_{j,i},$$

$$\Lambda_m = I - \frac{\lambda\beta}{\delta} \text{diag} \left(\sum_j \theta_{ij} n_f(j) \omega_j \right), \quad \Lambda_f = I - \frac{\lambda(1-\beta)}{\delta} \text{diag} \left(\sum_i \theta_{ij} n_m(i) \omega_i \right)$$

を作ると, Λ が自分の価値の係数, Θ が相手の価値の係数になり,

$$\begin{bmatrix} B_i r V_m^0 \\ B_j r V_f^0 \end{bmatrix} = \begin{bmatrix} \Lambda_m & \Theta_m \\ \Theta_f & \Lambda_f \end{bmatrix}^{-1} \begin{bmatrix} B_i u_m^0 \\ B_j u_f^0 \end{bmatrix}$$

と連立 1 次方程式 1 本で解けます (Goussé ほか 2017 年, Appendix D.3). 価値関数反復は不要です.

Step 4: 期待余剰と家庭内生産の水準. Step 3 の解を 式 (A.15) に入れると $\bar{S}_{ij}$ が, さらに 式 (A.14) を逆に解くと

$$F_{ij} X_{ij} = \frac{(r + \delta) \bar{S}_{ij}}{\bar{G}(z_{ij})} \quad (\text{A.18})$$

が求まります (Goussé ほか 2017 年, eqs. 5.7, B.14). 「このタイプの組がこの確率 α_{ij} で結婚するには, 家庭内生産がこの水準でなければならない」という逆算です.

A.7.6.3 第 2 段階: 選好・家庭内生産・交渉力・マッチの質の分散

パラメータ化. 選好は本文の 式 (5.4) で, a_{0i}, a_{1i}, b_i は本人の特性 x_i (学歴と家族観指数) の線形関数, a_2 は性別ごとの定数です. 最低投入時間 D_m, D_f, D_m^0, D_f^0 は特性の関数, 生活費 C_{ij} は x_i と x_j の線形関数 (交差項なし) です. 第 2 段階で推定するのは, これらと (K_m, K_f, K_m^0, K_f^0) , Nash ウェイト β , マッチの質の分散 σ です.

独身者の条件付き期待値. 独身の家事時間は 式 (A.17) の d_m^0 です. 余暇は, 本文の Roy の恒等式から得た $w_i e = a_{1i} w_i + a_2 w_i^2 + b_i (R - A_i)$ に $R - A_i = X_i^0$ を入れたものです. したがって残差は

$$\varepsilon_i^0 = d_i^0 - D_m^0 - \frac{K_m^0 X_i^0}{w_i}, \quad \eta_i^0 = e_i^0 - a_{1i} - a_2 w_i - \frac{b_i X_i^0}{w_i}$$

です (女性も同様) (Goussé ほか 2017 年, Appendix C).

夫婦の条件付き期待値. 家事時間は付録 A.7.3 節のとおり $d_m = D_m + K_m X_{ij}/w_i$, $d_f = D_f + K_f X_{ij}/w_j$ で, X_{ij} は 式 (A.9) です. z に依存しないので, そのまま残差が作れます. 余暇は私的支出の分け方に依存します. sharing rule の定義から $R_m - A_i = \beta_{ij}(z) X_{ij}$, $R_f - A_j = (1 - \beta_{ij}(z)) X_{ij}$ なので

$$w_i e_m = a_{1i} w_i + a_2 w_i^2 + b_i \beta_{ij}(z) X_{ij}, \quad w_j e_f = a_{1j} w_j + a_2 w_j^2 + b_j (1 - \beta_{ij}(z)) X_{ij} \quad (\text{A.19})$$

です (Goussé ほか 2017 年, eqs. B.5-B.6). z は計量経済学者には見えないので, 結婚していることを条件とした期待値を取ります. 既存の夫婦の z は, 独立に引かれた最後の値のうち留保値を上回ったものなので, その分布は G を $z \geq z_{ij}$ で切断したものです. 本文の sharing rule を使うと

$$\bar{\beta}_{ij} := E[\beta_{ij}(z) \mid z \geq z_{ij}] = \beta + E\left[\frac{1}{z} \mid z \geq z_{ij}\right] \frac{(1 - \beta) B_i r V_m^0 - \beta B_j r V_f^0}{F_{ij} X_{ij}} \quad (\text{A.20})$$

です (Goussé ほか 2017 年, eq. C.1). 右辺の $B_i r V_m^0$, $B_j r V_f^0$, $F_{ij} X_{ij}$ は A.7.6.2 節の手順で計算します. 残差は

$$\begin{aligned}\varepsilon_{m,ij} &= d_{m,ij} - D_m - \frac{K_m X_{ij}}{w_i}, & \varepsilon_{f,ij} &= d_{f,ij} - D_f - \frac{K_f X_{ij}}{w_j}, \\ \eta_{m,ij} &= e_{m,ij} - a_{1i} - a_2 w_i - \frac{b_i \bar{\beta}_{ij} X_{ij}}{w_i}, & \eta_{f,ij} &= e_{f,ij} - a_{1j} - a_2 w_j - \frac{b_j (1 - \bar{\beta}_{ij}) X_{ij}}{w_j}\end{aligned}$$

です.

2 次のモーメント. 同じタイプの夫婦でも z が違えば分け方 $\beta_{ij}(z)$ が違うので, 余暇がばらつきま. このばらつきが σ の情報源です. 分け方の条件付き分散は

$$\sigma_{ij}^2 := \text{Var}[\beta_{ij}(z) \mid z \geq z_{ij}] = \text{Var}\left[\frac{1}{z} \mid z \geq z_{ij}\right] \left(\frac{(1 - \beta) B_i r V_m^0 - \beta B_j r V_f^0}{F_{ij} X_{ij}} \right)^2$$

です (Goussé ほか 2017 年, eq. C.4). 式 (A.19) より夫の余暇の偏差は $b_i X_{ij}/w_i$ 倍, 妻の余暇の偏差は $-b_j X_{ij}/w_j$ 倍の $\beta_{ij}(z) - \bar{\beta}_{ij}$ なので, 2 次のモーメントの残差は

$$\nu_{mm,ij} = \eta_{m,ij}^2 - \frac{b_i^2 \sigma_{ij}^2 X_{ij}^2}{w_i^2}, \quad \nu_{ff,ij} = \eta_{f,ij}^2 - \frac{b_j^2 \sigma_{ij}^2 X_{ij}^2}{w_j^2}, \quad \nu_{mf,ij} = \eta_{m,ij} \eta_{f,ij} + \frac{b_i b_j \sigma_{ij}^2 X_{ij}^2}{w_i w_j}$$

となります. 夫婦の余暇の共分散が負 (夫の取り分が増えれば妻の取り分が減る) なので, ν_{mf} は足し算になります.

切断対数正規分布のモーメント. 式 (A.20) と σ_{ij}^2 には $1/z$ の切断モーメントが現れます. 以下は論文には書かれていない標準的な計算です. $x = \ln z \sim \mathcal{N}(0, \sigma^2)$ について $E[e^{-kx} \mathbb{1}\{x \geq \ell\}] = e^{k^2 \sigma^2 / 2} \Phi(-\ell/\sigma - k\sigma)$ が成り立ちます. $\ell = \ln z_{ij}$, $\alpha_{ij} = \Phi(-\ell/\sigma)$ とおくと

$$E\left[\frac{1}{z} \mid z \geq z_{ij}\right] = \frac{e^{\sigma^2/2} \Phi(-\ell/\sigma - \sigma)}{\alpha_{ij}}, \quad E\left[\frac{1}{z^2} \mid z \geq z_{ij}\right] = \frac{e^{2\sigma^2} \Phi(-\ell/\sigma - 2\sigma)}{\alpha_{ij}}$$

で, 分散は 2 番目から 1 番目の 2 乗を引いたものです.

推定量. 残差 ε , η , ν の 2 乗和を, 選好・家庭内生産のパラメータ, β , σ について最小化します (非線形最小二乗). パラメータを動かすたびに, A.7.6.2 節の手順で z_{ij} , θ_{ij} , 独身の価値, $F_{ij} X_{ij}$, $\bar{\beta}_{ij}$, σ_{ij}^2 を計算し直します.

付録 C の残差は第 1 段階の $\hat{\alpha}_{ij}$ と分布 $\hat{n}_m, \hat{n}_f$ を代入すれば計算できる形をしています. ただし論文の本文 (6.3 節) は, 反実仮想ではマッチング確率と分布をモデルから予測しなければならないので, 推定でもパラメータの更新ごとにそれらをモデルで計算し直し, ベンチマーク経済そのものをデータに当てての方が望ましい, と述べています. モデルで α_{ij} を計算するには Z_{ij} が要るので, 論文が手順全体を iterative と呼んでいることと合わせると, 第 2 段階と第 3 段階を交互に繰り返していると読めます (この点は論文に明示されていません).

識別の考え方. 付録 B の議論を要約します. 特性 (x_i, x_j) を固定すると, 残る変動は賃金 (w_i, w_j) と観察されない z だけです.

1. 式 (A.19) の 2 本から $\beta_{ij}(z)$ を消去すると

$$w_i e_m + \frac{b_i}{b_j} w_j e_f = a_{1i} w_i + a_2 w_i^2 + \frac{b_i}{b_j} (a_{1j} w_j + a_2 w_j^2) + b_i X_{ij}$$

となり (Goussé ほか 2017 年, eq. B.8), 賃金を固定すれば右辺は定数です. 夫婦の余暇に残る変動は z による分け方の違いだけなので, $w_i e_m$ を $w_j e_f$ に回帰した傾きから b_i/b_j が分かります.

2. 家事支出 $w_i d_m = w_i D_m + K_m X_{ij}$ と上の合成された余暇支出は, 賃金について非線形に動きます. その変動から a_2, b, K, a_1, D が識別されます. このためには需要体系が賃金について線形でないこと ($a_2 \neq 0$) と, 家事時間が賃金に反応すること ($K_m + K_f \neq 0$) が必要です.
3. 独身者の余暇と家事時間の式から a_0 と (K^0, D^0) が識別され, X_{ij} の式から生活費 C_{ij} が決まります.
4. 最後に, 分け方の水準 $\bar{\beta}_{ij}$ (夫婦の余暇の平均) から β が, そのばらつき σ_{ij}^2 (夫婦の余暇の分散・共分散) から σ が識別されます.

推定値は $\hat{\beta} = 0.45$, $\hat{\sigma} = 0.268$ で, その他のパラメータは本文の 図 5.23 にあります.

A.7.6.4 第 3 段階: 公共財の質 Z_{ij}

第 2 段階までで Z_{ij} 以外のパラメータがすべて決まっています. Z_{ij} は, モデルの予測するマッチング確率が第 1 段階の $\hat{\alpha}_{ij}$ に一致するように逆算します.

Step 5: 格子点ごとの Z_{ij} . A.7.6.2 節の Step 1-4 を推定済みのパラメータで実行し, 各タイプの組の $F_{ij} X_{ij}$ (式 (A.18)) を得ます. 一方, 夫婦の家事時間 $d_m - D_m = K_m X_{ij}/w_i$, $d_f - D_f = K_f X_{ij}/w_j$ を Stone-Geary 型の生産関数に代入すると

$$F_{ij} = Z_{ij} \left(\frac{K_m X_{ij}}{w_i} \right)^{K_m} \left(\frac{K_f X_{ij}}{w_j} \right)^{K_f}$$

です (Goussé ほか 2017 年, eq. 6.10). 式 (A.9) のとおり X_{ij} は Z_{ij} に依存しないので, 両辺に X_{ij} を掛けて Z_{ij} について解くと

$$Z_{ij} = F_{ij} X_{ij} \left[\left(\frac{K_m}{w_i} \right)^{K_m} \left(\frac{K_f}{w_j} \right)^{K_f} X_{ij}^{1+K_m+K_f} \right]^{-1} \quad (\text{A.21})$$

となります (Goussé ほか 2017 年, Appendix C). これでタイプの組ごとに Z_{ij} の値が 1 つずつ得られます.

Step 6: 多項式による平滑化. 格子点ごとの Z_{ij} は $\hat{\alpha}_{ij}$ の推定誤差をそのまま含むので, 両者の特性 (x_i, x_j) のすべての交差項を含む高次多項式で近似します. 論文はこれを, 一致推定量 $\hat{\alpha}_{ij}$ に基づく標準的な最小距離推定と位置づけています (Goussé ほか 2017 年, sec. 6.3). 学歴の補完性 (同類婚の動機) は, この多項式の交差項として Z_{ij} に現れます.

まとめ. 3 段階の役割を整理すると, 第 1 段階はモデルの価値関数を使わずにフローとストックだけから $(\xi, \delta, \alpha_{ij})$ を出し, 第 2 段階は時間配分から選好・生産・交渉のパラメータを出し, 第 3 段階は「観

察されたマッチング確率を再現する公共財の質」として Z_{ij} を出します。3つを結ぶのが、 α_{ij} を与えれば独身の価値が線形方程式 式 (A.16) で解ける、という移転可能効用モデルの性質です。

A.8 出生モデルの証明

A.8.1 閉形式解と賃金の効果

証明. $h = (\theta + e)^\gamma$ を代入すると、目的関数は $\log c + \delta \log n + \delta \gamma \log(\theta + e)$ となる。予算制約より $c = w - n(\phi w + pe)$ 。

n と e の一階条件はそれぞれ

$$\frac{\phi w + pe}{c} = \frac{\delta}{n}, \quad \frac{np}{c} = \frac{\delta \gamma}{\theta + e}.$$

2本の比を取ると $\gamma(\phi w + pe) = p(\theta + e)$ となり、これを解いて e の式を得る。 n の一階条件 $n(\phi w + pe) = \delta c$ を予算制約に代入すると $c = w - \delta c$ 、すなわち $c = w/(1 + \delta)$ 。また e の式より $\phi w + pe = (\phi w - p\theta)/(1 - \gamma)$ なので、

$$n = \frac{\delta c}{\phi w + pe} = \frac{\delta}{1 + \delta} \cdot \frac{w(1 - \gamma)}{\phi w - p\theta} = \frac{\delta}{1 + \delta} \cdot \frac{1 - \gamma}{\phi - \frac{p}{w}\theta}.$$

比較静学は式から直ちに従う。 w が上がると分母の $\phi - p\theta/w$ が大きくなるので n は減少し、 $\gamma\phi w - p\theta$ が大きくなるので e は増加する。

A.8.2 女性の賃金と出生

証明. 式 (6.1) を w_f で微分すると、 $\partial\pi/\partial w_f = (1 - s)\phi$ より

$$\frac{\partial n}{\partial w_f} = \frac{\delta}{1 + \delta} \cdot \frac{\pi(s) - (w_m + w_f)(1 - s)\phi}{\pi(s)^2}.$$

分子は $\psi + sp_s\phi + (1 - s)w_f\phi - (1 - s)w_m\phi - (1 - s)w_f\phi = \psi + (sp_s - (1 - s)w_m)\phi$ である。これは s の増加関数で、 $s(p_s + w_m)\phi = w_m\phi - \psi$ のときゼロになる。 $\psi < w_m\phi$ なら $s^* > 0$ 、また $w_m\phi - \psi < (p_s + w_m)\phi$ なので $s^* < 1$ である。

付録 B

連続時間モデル

本文の章はすべて離散時間でモデルを組んできましたが、現代のマクロ経済学では連続時間の定式化も広く使われています。この章の前半では、連続時間の確率過程（ブラウン運動、伊藤積分、OU 過程）と最大値原理（HJB 方程式）という理論の道具を整えます。後半では、その道具を使って Aiyagari モデルの連続時間版を**有限差分法**（finite difference method）で解きます（Achdou ほか 2022 年）。

B.1 確率過程

連続時間の確率過程は、時間 t に対してランダムな値をとる関数 x_t の族 $(x_t)_{t \geq 0}$ として定義されます。連続時間の確率過程として基礎になるのは、連続的なノイズを表すブラウン運動（Brownian motion）です。

B.1.1 ブラウン運動

i ブラウン運動

$b_0 = 0$ を満たす確率過程 $(b_t)_{t \geq 0}$ は次の性質を満たすとき、ブラウン運動と呼ばれる。

- 独立増分: 任意の $0 \leq t_1 < t_2 < \dots < t_n$ に対して、 $b_{t_2} - b_{t_1}, b_{t_3} - b_{t_2}, \dots, b_{t_n} - b_{t_{n-1}}$ は独立である。
- 正規性: 任意の t に対して、 $b_t \sim \mathcal{N}(\mu t, \sigma^2 t)$
- 連続パス: b_t は t の関数として連続である。

特に、 $\mu = 0, \sigma = 1$ の場合を標準ブラウン運動と呼ぶ。

なお標準ブラウン運動 B_t は明らかに $B_{t+1} - B_t \sim \mathcal{N}(0, 1)$ を満たすので、離散時間のホワイトノイズの連続時間版とみなすことができます。

後で伊藤積分や伊藤の補題で繰り返し使う $(dB_t)^2 = dt$ という計算規則は、ブラウン運動の二次変分（quadratic variation）が時間 t に等しいという性質に由来します。

命題 B.1 (ブラウン運動の二次変分). 標準ブラウン運動 B_t に対して、区間 $[0, t]$ の分割 $0 = s_0 < s_1 < \dots < s_n = t$ を考え、その幅（メッシュ）を $\|P\| := \max_i (s_{i+1} - s_i)$ とする。メッシュを 0 に近づけると、増分の二乗和は t に二乗平均収束する。

$$\sum_{i=0}^{n-1} (B_{s_{i+1}} - B_{s_i})^2 \xrightarrow{L^2} t \quad (\|P\| \rightarrow 0).$$

これを微分の記法で略記したものが $(dB_t)^2 = dt$ である。

証明. 二乗和を $S := \sum_{i=0}^{n-1} \Delta_i^2$ (ただし $\Delta_i := B_{s_{i+1}} - B_{s_i}$, 区間幅 $\delta_i := s_{i+1} - s_i$) と書く. S が t に二乗平均収束 (L^2 収束) するとは, 定義により

$$\mathbb{E}[(S - t)^2] \rightarrow 0 \quad (\|P\| \rightarrow 0)$$

が成り立つことである. これを示す. ブラウン運動の正規性と独立増分性から $\Delta_i \sim \mathcal{N}(0, \delta_i)$ で互いに独立である.

Step1: $\mathbb{E}[\Delta_i^2] = \text{Var}(\Delta_i) = \delta_i$ なので, 区間幅の総和が t であることから

$$\mathbb{E}[S] = \sum_i \delta_i = t.$$

Step2: Δ_i^2 は独立なので分散は和になる. 正規分布 $\mathcal{N}(0, \delta_i)$ は $\mathbb{E}[\Delta_i^4] = 3\delta_i^2$ を満たすから, $\text{Var}(\Delta_i^2) = 3\delta_i^2 - \delta_i^2 = 2\delta_i^2$ であり,

$$\text{Var}(S) = \sum_i 2\delta_i^2 \leq 2 \left(\max_i \delta_i \right) \sum_i \delta_i = 2t \|P\|.$$

Step3: $\mathbb{E}[S] = t$ なので二乗平均誤差は分散に一致し,

$$\mathbb{E}[(S - t)^2] = \text{Var}(S) \leq 2t \|P\| \xrightarrow{\|P\| \rightarrow 0} 0.$$

よって $S \xrightarrow{L^2} t$ が成り立つ.

B.1.2 伊藤積分

ここからブラウン運動を含む確率微分方程式を扱います. このとき, 伊藤積分を用います.

i 伊藤積分

過去の情報のみに依存する関数 f_s と標準ブラウン運動 B_t に対して, 伊藤積分 $\int_0^t f_s dB_s$ を, 区間分割 $0 = s_0 < s_1 < \dots < s_n = t$ に沿った和の二乗平均極限として定義する.

$$\int_0^t f_s dB_s := \lim_{\max_i |s_{i+1} - s_i| \rightarrow 0} \sum_{i=0}^{n-1} f_{s_i} (B_{s_{i+1}} - B_{s_i}).$$

このとき次の2つの性質が成り立つ.

- 平均ゼロ: $\mathbb{E}\left[\int_0^t f_s dB_s\right] = 0$
- 伊藤の等長性 (Itô isometry): $\mathbb{E}\left[\left(\int_0^t f_s dB_s\right)^2\right] = \int_0^t \mathbb{E}[f_s^2] ds$

各増分 $B_{s_{i+1}} - B_{s_i}$ を区間の左端 s_i の値 f_{s_i} で評価する点が重要です. これにより, f_{s_i} は区間 $[s_i, s_{i+1}]$ の将来の増分 $B_{s_{i+1}} - B_{s_i}$ に依存しない (独立である) という性質が使えます. この独立性を踏まえると, 平均ゼロは直感的です.

$$\mathbb{E}[f_{s_i} \Delta_i] = \mathbb{E}[f_{s_i}] \mathbb{E}[\Delta_i] = 0.$$

等長性に関しては, 和の二乗を展開すると, 異なる区間の積 ($i \neq j$) は独立かつ平均ゼロより消え, 対角項だけが残ります. 各対角項は $\mathbb{E}[f_{s_i}^2 \Delta_i^2] = \mathbb{E}[f_{s_i}^2] \mathbb{E}[\Delta_i^2]$ となるので, 命題 B.1 の二次変分を使うと,

$$\sum_i \mathbb{E}[f_{s_i}^2 \Delta_i^2] = \sum_i \mathbb{E}[f_{s_i}^2] (s_{i+1} - s_i) \xrightarrow{n \rightarrow \infty} \int_0^t \mathbb{E}[f_s^2] ds.$$

微分の記法でいえば, $\mathbb{E}[dB_t] = 0$ が平均ゼロを, $(dB_t)^2 = dt$ が等長性を生んでいる, と見ることができます.

命題 B.2 (伊藤積分の正規性). 被積分関数 f_s が決定論的な (B_s に依存しない) とき, 伊藤積分は正規分布に従う.

$$\int_0^t f_s dB_s \sim \mathcal{N}\left(0, \int_0^t f_s^2 ds\right).$$

証明. 伊藤積分は近似和 $\sum_i f_{s_i} \Delta_i$ ($\Delta_i := B_{s_{i+1}} - B_{s_i}$) の L^2 極限である. f_s が決定論的ななら f_{s_i} は定数なので, 各項は $f_{s_i} \Delta_i \sim \mathcal{N}(0, f_{s_i}^2 (s_{i+1} - s_i))$ で正規である. さらにブラウン運動の独立増分性から Δ_i は互いに独立なので, 独立な正規確率変数の和である近似和もまた正規分布に従う.

$$\sum_i f_{s_i} \Delta_i \sim \mathcal{N}\left(0, \sum_i f_{s_i}^2 (s_{i+1} - s_i)\right).$$

この近似和は $\|P\| \rightarrow 0$ で伊藤積分に L^2 収束し, その分散は $\sum_i f_{s_i}^2 (s_{i+1} - s_i) \rightarrow \int_0^t f_s^2 ds$ に収束する. 正規分布の族は分布収束に関して閉じている²¹ ので, 平均ゼロ性と合わせて, 極限である伊藤積分も正規分布 $\mathcal{N}(0, \int_0^t f_s^2 ds)$ に従う.

B.1.3 Orstein-Uhlenbeck 過程

AR(1) 過程の連続時間版として, Orstein-Uhlenbeck (OU) 過程を考えます. OU 過程は以下の確率微分方程式で定義されます.

i OU 過程

OU 過程 x_t は以下の確率微分方程式で定義される.

$$dx_t = -\gamma(x_t - \mu)dt + \sigma dB_t.$$

ここで B_t は標準ブラウン運動.

命題 B.3 (OU 過程の解). OU 過程 x_t は次のように陽に解ける.

$$x_t = \mu + (x_0 - \mu)e^{-\gamma t} + \sigma \int_0^t e^{-\gamma(t-s)} dB_s. \quad (\text{B.1})$$

²¹ L^2 収束は分布収束を含意する. $\mathcal{N}(0, v_n)$ の特性関数 $e^{-v_n u^2/2}$ は $v_n \rightarrow v$ より $\mathcal{N}(0, v)$ の特性関数 $e^{-v u^2/2}$ に各点収束するので, レヴィの連続性定理 (Lévy's continuity theorem) により極限は $\mathcal{N}(0, v)$ に従う.

証明. 確率微分方程式を積分因子 (integrating factor) $e^{\gamma t}$ を用いて解く. 積分因子は決定論的なので, 通常の積の微分法則が使えて

$$d(e^{\gamma t}(x_t - \mu)) = \gamma e^{\gamma t}(x_t - \mu) dt + e^{\gamma t} dx_t.$$

ここに $dx_t = -\gamma(x_t - \mu) dt + \sigma dB_t$ を代入するとドリフト項が打ち消し合い,

$$d(e^{\gamma t}(x_t - \mu)) = e^{\gamma t} \sigma dB_t.$$

両辺を 0 から t まで積分する. 左辺は微分を積分した増分 $[e^{\gamma s}(x_s - \mu)]_0^t$ なので,

$$e^{\gamma t}(x_t - \mu) - (x_0 - \mu) = \sigma \int_0^t e^{\gamma s} dB_s.$$

両辺を $e^{\gamma t}$ で割ると, 解が陽に求まる.

$$x_t = \mu + (x_0 - \mu) e^{-\gamma t} + \sigma \int_0^t e^{-\gamma(t-s)} dB_s.$$

命題 B.4 (OU 過程の平均と分散).

$$\mathbb{E}[x_t] = \mu + (x_0 - \mu) e^{-\gamma t}, \quad \text{Var}(x_t) = \frac{\sigma^2}{2\gamma} (1 - e^{-2\gamma t}).$$

また, $t \rightarrow \infty$ のとき, x_t は平均 μ , 分散 $\frac{\sigma^2}{2\gamma}$ の正規分布に収束する.

証明. Step1: 式 (B.1) の期待値をとる. 右辺第 3 項は伊藤積分なので平均ゼロであり,

$$\mathbb{E}[x_t] = \mu + (x_0 - \mu) e^{-\gamma t}.$$

Step2: 式 (B.1) より $x_t - \mathbb{E}[x_t] = \sigma \int_0^t e^{-\gamma(t-s)} dB_s$ である. 被積分関数 $e^{-\gamma(t-s)}$ は決定論的なので, 伊藤の等長性を用いると

$$\text{Var}(x_t) = \sigma^2 \mathbb{E} \left[\left(\int_0^t e^{-\gamma(t-s)} dB_s \right)^2 \right] = \sigma^2 \int_0^t e^{-2\gamma(t-s)} ds.$$

$\tau = t - s$ と置換すると $\int_0^t e^{-2\gamma(t-s)} ds = \int_0^t e^{-2\gamma\tau} d\tau = \frac{1 - e^{-2\gamma t}}{2\gamma}$ なので,

$$\text{Var}(x_t) = \frac{\sigma^2}{2\gamma} (1 - e^{-2\gamma t}).$$

Step 3: 決定論的な被積分関数に対する伊藤積分は正規分布に従うので, 式 (B.1) より x_t も正規分布である. $t \rightarrow \infty$ で平均は μ , 分散は $\frac{\sigma^2}{2\gamma}$ に収束するから, x_t は定常分布 $\mathcal{N}(\mu, \frac{\sigma^2}{2\gamma})$ に収束する.

B.2 最大値原理

B.2.1 HJB 方程式 (Deterministic)

復習として, ノイズのない決定論的な最適制御問題の Hamilton-Jacobi-Bellman (HJB) 方程式を導きます.

i HJB 方程式 (決定論的)

状態 x_t が制御 u_t のもとで

$$\dot{x}_t = g(x_t, u_t)$$

に従い, 意思決定者は割引率 ρ で

$$V(x_0) = \max_{\{u_t\}} \int_0^\infty e^{-\rho t} f(x_t, u_t) dt$$

を最大化するとする. このとき, 最適価値関数 $V(x)$ は次の HJB 方程式を満たす.

$$\rho V(x) = \max_u \{f(x, u) + V'(x) g(x, u)\}. \quad (\text{B.2})$$

証明. 微小区間 $[t, t + dt]$ に最適性原理 (principle of optimality) を適用する. いま dt だけ制御 u を選び, 以降を最適に続けると

$$V(x) = \max_u \{f(x, u) dt + e^{-\rho dt} V(x_{t+dt})\}.$$

決定論的なので $x_{t+dt} = x + g(x, u) dt + o(dt)$ であり, テイラー展開より

$$V(x_{t+dt}) = V(x) + V'(x) g(x, u) dt + o(dt).$$

これに $e^{-\rho dt} \approx 1 - \rho dt$ を代入し, dt の 1 次まで残すと

$$V(x) = \max_u \{V(x) + (f(x, u) + V'(x) g(x, u) - \rho V(x)) dt\} + o(dt).$$

両辺から $V(x)$ を引いて dt で割り, $dt \rightarrow 0$ とすると 式 (B.2) を得る.

ここに確率的なノイズを加えた場合, HJB 方程式を導くには伊藤の補題が必要になります.

B.2.2 伊藤の補題

i 伊藤の補題 (Itô's lemma)

x_t が確率微分方程式 $dx_t = g_t dt + \sigma_t dB_t$ (g_t はドリフト, σ_t は拡散係数で, ともに時刻 t までの情報に依存してよい) に従うとき, 2 階連続微分可能な関数 ϕ に対して

$$\begin{aligned} d\phi(x_t) &= \phi'(x_t) dx_t + \frac{1}{2} \phi''(x_t) (dx_t)^2 \\ &= \left[\phi'(x_t) g_t + \frac{1}{2} \phi''(x_t) \sigma_t^2 \right] dt + \phi'(x_t) \sigma_t dB_t. \end{aligned}$$

証明. $\phi(x_t)$ の微小時間 $[t, t+dt]$ での変化をテイラー展開し, 2 次の項まで残すと

$$\phi(x_{t+dt}) - \phi(x_t) = \phi'(x_t) dx_t + \frac{1}{2} \phi''(x_t) (dx_t)^2 + o((dx_t)^2).$$

ここに $dx_t = g_t dt + \sigma_t dB_t$ を代入すると

$$(dx_t)^2 = g_t^2 (dt)^2 + 2g_t \sigma_t dt dB_t + \sigma_t^2 (dB_t)^2.$$

命題 B.1 の二次変分 $(dB_t)^2 = dt$ を用い, より高次の $(dt)^2$ と $dt dB_t$ を $o(dt)$ として落とすと $(dx_t)^2 = \sigma_t^2 dt$ となる. これを代入すると

$$\begin{aligned} d\phi(x_t) &= \phi'(x_t) dx_t + \frac{1}{2} \phi''(x_t) \sigma_t^2 dt \\ &= \left[\phi'(x_t) g_t + \frac{1}{2} \phi''(x_t) \sigma_t^2 \right] dt + \phi'(x_t) \sigma_t dB_t. \end{aligned}$$

B.2.3 HJB 方程式 (Stochastic)

状態が確率微分方程式 $dx_t = g(x_t, u_t) dt + \sigma(x_t, u_t) dB_t$ に従い, 割引率 ρ で

$$V(x_0) = \max_{\{u_t\}} \mathbb{E}_0 \int_0^\infty e^{-\rho t} f(x_t, u_t) dt$$

を最大化する確率的な問題を考えます. $V(x)$ を最適価値関数と呼びます. 伊藤の補題を使うと, 決定論的な式 (B.2) が次のように拡張されます.

i HJB 方程式 (確率的)

状態が $dx_t = g(x_t, u_t) dt + \sigma(x_t, u_t) dB_t$ に従うとき, 最適価値関数 V は次の Hamilton-Jacobi-Bellman (HJB) 方程式を満たす.

$$\rho V(x) = \max_u \left\{ f(x, u) + V'(x) g(x, u) + \frac{1}{2} \sigma(x, u)^2 V''(x) \right\}.$$

証明. 微小区間 $[t, t+dt]$ に最適性原理 (principle of optimality) を適用する. いま dt だけ制御 u を選び以降を最適に続けると, 状態が確率的なので将来の価値は期待値で評価される.

$$V(x) = \max_u \{ f(x, u) dt + e^{-\rho dt} \mathbb{E}[V(x_{t+dt}) | x_t = x] \}.$$

伊藤の補題より $dV = [V'(x)g(x, u) + \frac{1}{2}\sigma(x, u)^2 V''(x)]dt + V'(x)\sigma(x, u)dB_t$ であり, 伊藤積分の項は平均ゼロなので,

$$\mathbb{E}[V(x_{t+dt}) | x_t = x] = V(x) + \left[V'(x)g(x, u) + \frac{1}{2}\sigma(x, u)^2 V''(x) \right] dt.$$

これと $e^{-\rho dt} \approx 1 - \rho dt$ を代入し, dt の 1 次まで残すと

$$V(x) = \max_u \left\{ V(x) + \left(f(x, u) + V'(x)g(x, u) + \frac{1}{2}\sigma(x, u)^2 V''(x) - \rho V(x) \right) dt \right\} + o(dt).$$

両辺から $V(x)$ を引いて dt で割り, $dt \rightarrow 0$ とすると命題の HJB 方程式を得る.

B.3 連続時間の Aiyagari モデル

ここからは, 上で整えた道具を使って, 連続時間の異質エージェントモデルを実際に解きます. 題材は Aiyagari モデル (3.3 節) の連続時間版です. 生産性の対数を OU 過程でモデル化するので, HJB 方程式には伊藤の補題が生む 2 階微分の項がそのまま現れます. 数値解法は Achdou ほか (2022 年) の有限差分法です. 離散時間版と比べながら, 連続時間の数値計算がなぜ速く, なぜ頑健なのかを見ていきます.

B.3.1 設定

家計は割引率 ρ で期待生涯効用 $\mathbb{E}_0 \int_0^\infty e^{-\rho t} u(c_t) dt$ を最大化します. 資産 a は資本で, 予算制約と借入制約は

$$\dot{a}_t = wz_t + ra_t - c_t, \quad a_t \geq 0$$

です. 労働生産性 $z_t = e^{x_t}$ の対数は OU 過程

$$dx_t = -\theta x_t dt + \sigma dB_t$$

に従います (命題 B.3 の記法で $\gamma = \theta$, $\mu = 0$ とし, 平均回帰の速さを CRRA 係数と区別して θ と書きます). OU 過程は AR(1) の連続時間版なので, 離散時間の章との対応は明快です. 1 年間隔で観測すると自己相関 $e^{-\theta}$, 定常分散 $\sigma^2/(2\theta)$ の AR(1) になるので (命題 B.4), 動的計画法の章のカリブレーション $(\rho_z, \sigma_\varepsilon) = (0.9, 0.2)$ をそのまま

$$\theta = -\log 0.9, \quad \frac{\sigma^2}{2\theta} = \frac{\sigma_\varepsilon^2}{1 - \rho_z^2}$$

で写し取れます. 割引率も同様に $\rho = -\log \beta = -\log 0.96$ とします. 企業は Cobb-Douglas 生産関数 $K^\alpha L^{1-\alpha}$ を持ち, $k = K/L$ として $r = \alpha k^{\alpha-1} - \delta$, $w = (1 - \alpha)k^\alpha$ が成り立ちます. 労働供給は非弾力的で, $\mathbb{E}[z] = 1$ に基準化すれば $L = 1$ です.

i 定常均衡の方程式系

定常均衡は, 価値関数 $v(a, x)$, 密度 $g(a, x)$, 価格 (r, w) の組であって次を満たすものである.

HJB 方程式:

$$\rho v = \max_c u(c) + \partial_a v(we^x + ra - c) - \theta x \partial_x v + \frac{\sigma^2}{2} \partial_{xx} v. \quad (\text{B.3})$$

Kolmogorov Forward (KF) 方程式 (定常):

$$0 = -\partial_a [s(a, x)g] + \partial_x [\theta x g] + \frac{\sigma^2}{2} \partial_{xx} g, \quad (\text{B.4})$$

ここで $s(a, x) = we^x + ra - c(a, x)$ は貯蓄関数, $c(a, x) = (u')^{-1}(\partial_a v)$.

資本市場の清算:

$$\iint a g(a, x) da dx = K, \quad r = \alpha(K/L)^{\alpha-1} - \delta. \quad (\text{B.5})$$

HJB 方程式が価値関数を「後ろ向き」に決め, その政策関数のもとで KF 方程式が分布を「前向き」に決め, 分布が価格 r を決めて HJB に戻る, というループ構造です.²² アルゴリズムの全体像を先に図で示しておきます (図 B.1). 以下の数値解法の節は, この図の各ブロックを上から順に実装していきます.

²² この「後ろ向きの HJB + 前向きの KF」という連立系は, 平均場ゲーム (Mean Field Game) の定常系そのものです. Achdou ほか (2022 年) の枠組みは, Lasry と Lions の MFG 理論を異質エージェント・マクロに持ち込んだものといえます.




図 B.1: Equilibrium loop of the finite difference method

借入制約の入りが離散時間と決定的に違います。連続時間では制約は内点で決して binding にならないため、一階条件 $u'(c(a, x)) = \partial_a v(a, x)$ が $a > 0$ の**すべての点で等号で**成り立ちます。制約は HJB 方程式そのものではなく、境界条件

$$\partial_a v(0, x) \geq u'(we^x) \quad (\text{B.6})$$

として入ります。これは一階条件を通じて $s(0, x) \geq 0$ を含意するので、制約が破られることはありません。KF 方程式には境界条件すら不要です。最適政策が制約を尊重している限り、分布は自動的に $[0, \infty)$ に収まるからです。 x 方向はグリッドを定常標準偏差の ± 3 倍で打ち切り、端では反射壁 (reflecting barrier) を仮定します。OU 過程のドリフトは端では常に内側を向くので、この打ち切りの影響はわずかです。

B.4 有限差分法

B.4.1 Upwind スキーム

資産グリッド $a_1 = 0 < a_2 < \dots < a_{N_a}$ (等間隔, 幅 Δa) を取り, x を固定して資産方向の微分を前方差分と後方差分で近似します.

$$\partial_a v_{i,F} = \frac{v_{i+1} - v_i}{\Delta a}, \quad \partial_a v_{i,B} = \frac{v_i - v_{i-1}}{\Delta a}.$$

どちらを使うべきでしょうか. 答えは「**状態が動く向きに合わせる**」です. 貯蓄 (ドリフト) が正なら前方差分, 負なら後方差分を使う. これが upwind スキームで, $s_i^+ = \max\{s_i, 0\}$, $s_i^- = \min\{s_i, 0\}$ として HJB 方程式の資産方向を

$$\frac{v_{i+1} - v_i}{\Delta a} s_i^+ + \frac{v_i - v_{i-1}}{\Delta a} s_i^- \quad (\text{B.7})$$

と離散化します (図 B.2).




図 B.2: Upwind scheme: the difference follows the drift

有限差分スキームが真の解 (粘性解) に収束するための Barles-Souganidis の十分条件は単調性・整合性・安定性の3つで, このうち非自明なのが単調性です. upwind は, まさに単調性を保証するための差分の選び方になっています (Achdou ほか 2022 年, sec. 5.3).

実装上は, まず前方差分で仮の貯蓄 $s_{i,F} = we^x + ra_i - (u')^{-1}(\partial_a v_{i,F})$ を, 後方差分で $s_{i,B}$ を計算し,

- $s_{i,F} > 0$ なら前方差分を採用する
- $s_{i,B} < 0$ なら後方差分を採用する
- どちらでもない場合 ($s_{i,F} \leq 0 \leq s_{i,B}$) はその点を**定常点**とみなして $s_i = 0$, $c_i = we^x + ra_i$ とする

という規則にします.²³

境界条件の扱いは驚くほど簡単です. 下端 $a_1 = 0$ では**後方差分**だけに状態制約の境界条件 式 (B.6) を等号で課します: $\partial_a v_{1,B} = u'(we^x)$. 前方差分は普通に計算し, どちらを使うかは upwind に選ばせます. 貯蓄が正なら境界条件は使われず, 負になりそうときだけ発動して $s = 0$ で止める, という仕掛けです. 上端では貯蓄が負になるので前方差分は使われず, 境界条件は実質不要です.

²³なお Achdou ほか (2022 年) の本文はスキームの詳細を数値付録に委ねているため, この規則と後述の陰的スキームは, 公開されている数値付録と実装コードに従っています.

B.4.2 生産性方向の離散化

OU 過程の項 $-\theta x \partial_x v + \frac{\sigma^2}{2} \partial_{xx} v$ も同じ発想で離散化します。ドリフト $-\theta x$ は upwind (符号に応じて片側差分), 拡散項は中心差分です。グリッド $x_1 < \dots < x_{N_x}$ (幅 Δx) 上の点 j について, 隣へ移る「強度」をまとめると

$$\lambda_j^\downarrow = \frac{\sigma^2}{2\Delta x^2} + \frac{\max\{\theta x_j, 0\}}{\Delta x}, \quad \lambda_j^\uparrow = \frac{\sigma^2}{2\Delta x^2} + \frac{\max\{-\theta x_j, 0\}}{\Delta x} \quad (\text{B.8})$$

となります ($x_j > 0$ なら平均回帰のドリフトは下向きに働く, という形です)。端のグリッドでは外向きの強度を落とします。これが反射壁にあたります。できあがる三重対角行列 B_x は各行の和がゼロの**強度行列** (連続時間マルコフ連鎖の生成作用素) です。つまりこの離散化は, AR(1) を有限状態マルコフ連鎖で近似した Tauchen 法・Rouwenhorst 法 (2.4 節) の連続時間版です。²⁴

B.4.3 遷移行列 A

以上を合わせると, 離散化された HJB 方程式は

$$\rho v = u + A(v)v \quad (\text{B.9})$$

という形になります。 A は $N_a N_x \times N_a N_x$ の疎行列で, 資産方向の upwind 部分 (三重対角) と生産性方向の B_x (帯 2 本) の和です。重要な性質が 2 つあります。

- **各行の和はゼロ:** A は全体として連続時間マルコフ連鎖の強度行列である
- 有限差分法は, 富と生産性の連続な動きを「隣のグリッド点へのポアソンジャンプ」で近似していると解釈できる。離散時間で遷移確率行列を作ったことの, 連続時間版にあたる

図 B.3 がこのジャンプの解釈を図解しています。状態 (a_i, x_j) から確率的に移れる先は, **上下左右の隣接グリッドの 4 点** だけです。資産方向は upwind が選んだ片側 (実際に正の強度を持つのは矢印 2 本のうち 1 本), 生産性方向は 式 (B.8) の 2 本です。




図 B.3: Poisson-jump interpretation of the generator

²⁴upwind のドリフト近似は分散をわずかに水増しします。Tauchen 法で見た「升目への丸めが余分な分散を生む」現象と同種のもので, $\Delta x \rightarrow 0$ で消えます。下の実装では離散化された定常分布の標準偏差を理論値と比べて確認します。

この「隣にしか跳べない」構造が、そのまま A の疎パターンになります。図 B.4 は小さいグリッド ($N_a = 12, N_x = 4$) で A の非ゼロ要素の位置を描いたものです。資産方向のジャンプは各ブロック内の**三重対角** (対角とその上下1本ずつ)、生産性方向のジャンプはブロックを跨ぐ $\pm N_a$ の位置の**帯2本** として現れ、 A の各行の非ゼロ要素は高々5個です。




図 B.4: **Sparsity pattern of A** ($N_a = 12, N_x = 4$ for illustration).

行列のサイズは $N_a N_x$ の2乗で増えますが、非ゼロ要素は $5N_a N_x$ 程度にしか増えません。疎行列ソルバはゼロでない要素だけを保存・計算するので、後で出てくる連立一次方程式 (陰的スキームと KF 方程式) は巨大なグリッドでも一瞬で解けます。これが有限差分法の速さの核心です。

B.4.4 陰的スキーム

式 (B.9) は A が v に依存する非線形方程式なので、反復で解きます。擬似的な時間ステップ Δ を入れた**陰的スキーム** (implicit scheme) を使います。

$$\frac{v^{n+1} - v^n}{\Delta} + \rho v^{n+1} = u(c^n) + A(v^n)v^{n+1} \Leftrightarrow \left[\left(\frac{1}{\Delta} + \rho \right) I - A^n \right] v^{n+1} = u^n + \frac{v^n}{\Delta}. \quad (\text{B.10})$$

各反復は疎な連立一次方程式を1回解くだけです。陰的スキームは無条件に安定なので、 Δ をいくらでも大きく取れます ($\Delta = 1000$ など)。その結果、反復は**数十回**で収束します。素朴な価値関数反復が何百回もかかるのとは比べると大きな違いです (離散時間との定量的な比較は実装のあとで行います)。

B.4.5 KF 方程式はタダで解ける

分布はどう求めるのでしょうか。ここが有限差分法の最も美しい部分です。KF 作用素は HJB に現れる生成作用素の**随伴** (adjoint) なので、離散化すると 式 (B.4) は

$$A^\top g = 0 \quad (\text{B.11})$$

になります (Achdou ほか 2022 年, sec. 5.4). HJB を解いた時点で A は手元にあるので, KF 方程式は**転置行列の連立一次方程式を 1 回解くだけ**です. 分布のシミュレーションも, 遷移行列の別途構築も要りません. 式 (B.11) は特異 (解が定数倍で不定) なので, 1 つの成分を固定して解いてから, 密度の積分が 1 になるように正規化します. 借入制約に張り付く家計の質量は, 下端のグリッド点に立つ大きな値として現れます.

B.4.6 均衡

利子率を与えると企業の一階条件から $k(r) = (\alpha/(r + \delta))^{1/(1-\alpha)}$ と $w(r)$ が決まるので, 資本の超過供給関数

$$S(r) = \iint a g da dx - k(r)L$$

の二分法で均衡利子率を求めます. r を与えて $\text{HJB} \rightarrow \text{KF} \rightarrow S(r)$ と計算し, 正なら r を下げ, 負なら上げるだけです.

まとめると, この手法が速く頑健な理由は 4 つです (Achdou ほか 2022 年, sec. 5.1).

1. 借入制約は境界条件に封じ込められ, 内点の一階条件は常に等号で成り立つ (occasionally binding な場合分けが消える)
2. 一階条件が静学的で, $c = (\partial_a v)^{-1/\gamma}$ と手で解ける. 求根も期待値の計算も不要
3. 連続時間の過程はグリッド上を 1 点ずつしか動かないので, 行列が疎になる
4. KF 方程式が HJB の転置としてタダで手に入る

B.5 Julia 実装

カリブレーションは動的計画法の章の Aiyagari モデルを OU 過程に写したものです.

まず生産性方向の生成作用素 B_x を 式 (B.8) のとおり組み立てます. その定常分布を使って $\mathbb{E}[z] = 1$ に基準化し, 離散化が OU 過程の定常標準偏差を再現しているかも確認しておきます.

```
(sd_discretized = 0.4669, sd_theory = 0.4588)
```

HJB 方程式のソルバは, upwind による政策の計算, 遷移行列 A の構築, 陰的更新 式 (B.10) の 3 ステップの反復です.

KF 方程式は転置行列の連立一次方程式です. 特異性は 1 成分を固定して外し, 最後に密度として正規化します.

最後に, 資本の超過供給に対する二分法で均衡利子率を求めます.

```
(r = 0.0243, K = 6.93, hjb_iter = 43)
```

均衡利子率は割引率 $\rho = -\log 0.96 \approx 0.041$ を明確に下回ります. 予備的貯蓄による過剰な資本蓄積という Aiyagari モデルの中心的な結果が, 連続時間でもそのまま現れています. 離散時間の章で得た $r^* \approx 0.021$ とはカリブレーションの写像や離散化の違いから小さなずれがありますが, 定性的な結論

は同じです。そして、グリッドが $N_a N_x = 62,000$ 点あるにもかかわらず、HJB 方程式の反復が数十回、均衡全体も二分法 20 回で数分以内に収まっていることに注目してください。速さの源泉は 図 B.4 で見た疎性です。実際の A は $62,000 \times 62,000$ ですが、非ゼロ要素は全体の 0.01% にも遠く及びません。

```
(nonzeros = 243957, share_percent = 0.0063)
```

B.5.1 政策関数




図 B.5: **Saving policy functions.** Low-productivity households at the constraint have $s = 0$.

生産性の低い家計は資産を取り崩しながら借入制約に向かって滑り落ち、制約点でちょうど $s = 0$ になります。内点で制約が binding にならない、という理論の構造がそのまま見えています。生産性の高い家計は広い範囲で貯蓄を続けますが、十分に資産を持つと ($\rho > r^*$ なので) やはり取り崩しに転じます。

B.5.2 定常分布




図 B.6: **Stationary asset distribution.** The point mass at the constraint is omitted.

```
mass at the borrowing constraint: 0.0322
```

離散時間版と同じく、借入制約の近くに密度が集中し、制約点そのものには質量が立ちます (図では質量を除いた密度部分を描いています). KF 方程式に一切の境界条件を与えていないのに、質量まで含めて正しい分布が「転置を解くだけ」で出てくるのが、この手法の強みです.

B.5.3 離散時間モデルとの比較

連続時間版が本当に離散時間の Aiyagari モデルを再現しているのか、同じカリブレーションの離散時間モデルを解いて確かめます. 実装は動的計画法の章と同じ、単調性を利用したグリッドサーチの VFI に Howard の改善を加えたものです. 所得過程の離散化には Rouwenhorst 法を使います. Tauchen 法は少ない状態数で分散を過大評価するため (2.4 節), 比較がその分だけ歪んでしまうからです. Rouwenhorst 法は AR(1) の 2 次モーメントを厳密に再現するので、離散時間の所得過程は連続時間の OU 過程と (2 次モーメントの意味で) 完全に揃います.

まず、資本の需要曲線と供給曲線を両方のモデルで重ねてみます (図 B.7).




図 B.7: **Capital demand and supply.** Continuous vs. discrete time, same calibration.

供給曲線はほぼ重なり、需要曲線との交点 (均衡利子率) も互いに近い位置にあります。

```
(r_discrete = 0.025, r_continuous = 0.0243)
```

残る小さな差は、意思決定のタイミング (離散時間では1年分まとめて意思決定する) と離散化そのものの違いによるものです。連続時間版は離散時間の Aiyagari モデルの答えを再現しつつ、滑らかな政策関数と分布を返している、と言ってよいでしょう。

次に計算時間です。同じ均衡価格のもとで、家計問題と定常分布の計算をそれぞれ計測します (収束判定はどちらも $\max|\Delta v| < 10^{-6}$)。

表 B.1: 家計問題と定常分布の計算時間

	手法	状態数 $N_a \times N_z$	家計問題	定常分布
離散時間	VFI + Howard	200×7	0.01 秒 / 13 反復	0.01 秒 / 616 反復
離散時間	VFI + Howard	$2,000 \times 31$	0.5 秒 / 17 反復	0.87 秒 / 591 反復
連続時間	有限差分	$2,000 \times 31$	3.91 秒 / 31 反復	0.09 秒 / 1 回の求解

結果は一見すると意外かもしれませんが、**家計問題単体では、チューニングされた離散時間の VFI も十分に速い**のです。これは選択変数が1次元で、政策の単調性と価値関数の凹性を使うとグリッドサーチがほぼ線形時間で済むという、この問題に固有の事情によります。連続時間の優位がはっきり出るのは**定常分布**です。離散時間では遷移行列の反復 (べき乗法) を数百回まわす必要があるのに対し、連続時間では HJB の副産物 A の転置を1回解くだけで済みます。

より本質的な違いは、表の数字の外にあります。

- 離散時間の速さは「1次元の選択を単調なグリッドサーチで解ける」ことに依存する。選択変数が増える (ポートフォリオ選択, 耐久財など) と最大化のコストが急速に増すのに対し、連続時間の一階条件は静学的なまま変わらない

- 連続時間の政策関数はグリッドへの丸めがなく滑らかで、借入制約もちょうど 1 点で処理される。推定 (4.2 節) のように解を何千回も呼ぶ用途では、この滑らかさが目的関数の滑らかさに直結する

B.6 まとめと拡張

この章のアルゴリズムをまとめると次のとおりです。

1. r を所与として企業の一階条件から (k, w) を求め, upwind + 陰的スキームで HJB 方程式 式 (B.9) を解く (反復数十回)
2. 遷移行列の転置から KF 方程式 式 (B.11) を 1 発で解き, 定常分布を得る
3. 資本市場の超過供給を見て r を二分法で更新する

同じ骨格が、ほとんど変更なしに広いクラスのモデルへ拡張できます (Achdou ほか 2022 年, sec. 7).

- **より単純な所得過程:** 所得を 2 状態のポアソン過程に落とすと 2 階微分の項が消えて HJB は常微分方程式になり, Achdou ほか (2022 年) の本文で解析される Huggett モデルになる。借入制約近傍の貯蓄関数や資産分布の質量について、鋭い理論的特徴づけが得られる
- **移行動学:** 時間依存の HJB を終端条件から**後ろ向き**に, KF を初期分布から**前向き**に解き, 価格の経路を収束するまで更新する。MIT ショックの分析がそのまま可能
- **非凸性・停止問題:** 住宅のような不可分性や、デフォルトのような停止問題も、粘性解の枠組みのもとで同じ離散化で扱える

離散時間の動的計画法 (第 3 章) と対をなす計算技術として、この有限差分法は現代の異質エージェント・マクロの標準的な道具になっています。実装のバリエーションは Achdou ほか (2022 年) の公開コードが網羅しており、この章のコードはその最小構成にあたります。

References

- Acemoglu, Daron, と David Autor. 2011 年. 「Skills, Tasks and Technologies: Implications for Employment and Earnings」. *Handbook of Labor Economics*, vol. 4. Elsevier. [https://doi.org/10.1016/S0169-7218\(11\)02410-5](https://doi.org/10.1016/S0169-7218(11)02410-5).
- Achdou, Yves, Jiequn Han, Jean-Michel Lasry, Pierre-Louis Lions, と Benjamin Moll. 2022 年. 「Income and Wealth Distribution in Macroeconomics: A Continuous-Time Approach」. *Review of Economic Studies* 89 (1): 45–86. <https://doi.org/10.1093/restud/rdab002>.
- Ahn, Namkee, と Pedro Mira. 2002 年. 「A Note on the Changing Relationship Between Fertility and Female Employment Rates in Developed Countries」. *Journal of Population Economics* 15 (4): 667–82. <https://doi.org/10.1007/s001480100078>.
- Aiyagari, S. Rao. 1994 年. 「Uninsured Idiosyncratic Risk and Aggregate Saving」. *The Quarterly Journal of Economics* 109 (3): 659–84. <https://doi.org/10.2307/2118417>.
- Altonji, Joseph G., と Lewis M. Segal. 1996 年. 「Small-Sample Bias in GMM Estimation of Covariance Structures」. *Journal of Business & Economic Statistics* 14 (3): 353–66. <https://doi.org/10.1080/07350015.1996.10524661>.
- Andrews, Isaiah, Matthew Gentzkow, と Jesse M. Shapiro. 2017 年. 「Measuring the Sensitivity of Parameter Estimates to Estimation Moments*」. *The Quarterly Journal of Economics* 132 (4): 1553–92. <https://doi.org/10.1093/qje/qjx023>.
- Becker, Gary S. 1960 年. 「An Economic Analysis of Fertility」. *Demographic and Economic Change in Developed Countries*. Columbia University Press.
- Becker, Gary S., と Robert J. Barro. 1988 年. 「A Reformulation of the Economic Theory of Fertility」. *The Quarterly Journal of Economics* 103 (1): 1–26. <https://doi.org/10.2307/1882640>.
- Becker, Gary S., と H. Gregg Lewis. 1973 年. 「On the Interaction Between the Quantity and Quality of Children」. *Journal of Political Economy* 81 (2, Part 2): S279–88. <https://doi.org/10.1086/260166>.
- Bertrand, Marianne, Emir Kamenica, と Jessica Pan. 2015 年. 「Gender Identity and Relative Income Within Households」. *The Quarterly Journal of Economics* 130 (2): 571–614. <https://doi.org/10.1093/qje/qjv001>.
- Bick, Alexander, Adam Blandin, と Richard Rogerson. 2022 年. 「Hours and Wages」. *The Quarterly Journal of Economics* 137 (3): 1901–62. <https://doi.org/10.1093/qje/qjac005>.
- Binder, Ariel J., と David Lam. 2022 年. 「Is There a Male-Breadwinner Norm? The Hazards of Inferring Preferences from Marriage Market Outcomes」. *Journal of Human Resources* 57 (6): 1885–914. <https://doi.org/10.3368/jhr.58.2.0320-10803R1>.
- Blackburn, M., と D. Neumark. 1992 年. 「Unobserved Ability, Efficiency Wages, and Interindustry Wage Differentials」. *The Quarterly Journal of Economics* 107 (4): 1421–36. <https://doi.org/10.2307/2118394>.

- Carroll, Christopher D. 2006 年. 「The Method of Endogenous Gridpoints for Solving Dynamic Stochastic Optimization Problems」. *Economics Letters* 91 (3): 312–20. <https://doi.org/10.1016/j.econlet.2005.09.013>.
- Chetty, Raj, Adam Guren, Day Manoli, と Andrea Weber. 2011 年. 「Are Micro and Macro Labor Supply Elasticities Consistent? A Review of Evidence on the Intensive and Extensive Margins」. *American Economic Review* 101 (3): 471–75. <https://doi.org/10.1257/aer.101.3.471>.
- Chiappori, Pierre-André, Monica Costa Dias, Costas Meghir, と Hanzhe Zhang. 2025 年. 「Changes in Marital Sorting: Theory and Evidence from the United States」. *Journal of Political Economy* 133 (10): 3045–77. <https://doi.org/10.1086/736764>.
- Choo, Eugene, と Aloysius Siow. 2006 年. 「Who Marries Whom and Why」. *Journal of Political Economy* 114 (1): 175–201. <https://doi.org/10.1086/498585>.
- Ciscato, Edoardo. 2025 年. 「Assessing Racial and Educational Segmentation in Large Marriage Markets」. *Review of Economic Studies* 92 (6): 3788–839. <https://doi.org/10.1093/restud/rdae115>.
- Cocci, Matthew D, と Mikkel Plagborg-Møller. 2024 年. 「Standard Errors for Calibrated Parameters」. *Review of Economic Studies*, 10 月, rdae099. <https://doi.org/10.1093/restud/rdae099>.
- de la Croix, David, と Matthias Doepke. 2003 年. 「Inequality and Growth: Why Differential Fertility Matters」. *American Economic Review* 93 (4): 1091–113. <https://doi.org/10.1257/000282803769206214>.
- Doepke, Matthias, Anne Hannusch, Fabian Kindermann, と Michèle Tertilt. 2023 年. 「The Economics of Fertility: A New Era」. *Handbook of the Economics of the Family*, vol. 1. Elsevier. <https://doi.org/10.1016/bs.hefam.2023.01.003>.
- Galichon, Alfred, Scott Duke Kominers, と Simon Weber. 2019 年. 「Costly Concessions: An Empirical Framework for Matching with Imperfectly Transferable Utility」. *Journal of Political Economy* 127 (6): 2875–925. <https://doi.org/10.1086/702020>.
- Galor, Oded, と David N. Weil. 1996 年. 「The Gender Gap, Fertility, and Growth」. *American Economic Review* 86 (3): 374–87. <https://www.jstor.org/stable/2118202>.
- Gershuny, Jonathan, と Teresa Attracta Harms. 2016 年. 「Housework Now Takes Much Less Time: 85 Years of US Rural Women’s Time Use」. *Social Forces* 95 (2): 503–24. <https://doi.org/10.1093/sf/sow073>.
- Goussé, Marion, Nicolas Jacquemet, と Jean-Marc Robin. 2017 年. 「Marriage, Labor Supply, and Home Production」. *Econometrica* 85 (6): 1873–919. <https://doi.org/10.3982/ECTA11221>.
- Greenwood, Jeremy, と Nezih Guner. 2009 年. 「Marriage and Divorce Since World War II: Analyzing the Role of Technological Progress on the Formation of Households」. *NBER Macroeconomics Annual 2008, Volume 23*. University of Chicago Press.
- Greenwood, Jeremy, Nezih Guner, Georgi Kocharkov, と Cezar Santos. 2016 年. 「Technology and the Changing Family: A Unified Model of Marriage, Divorce, Educational Attainment, and Married Female Labor-Force Participation」. *American Economic Journal: Macroeconomics* 8 (1): 1–41. <https://doi.org/10.1257/mac.20130156>.
- Greenwood, Jeremy, Nezih Guner, と Ricardo Marto. 2023 年. 「The Great Transition: Kuznets Facts for Family-Economists」. *Handbook of the Economics of the Family*, 編集者: Shelly Lundberg と

Alessandra Voena, vol. 1. Handbook of the Economics of the Family, Volume 1. North-Holland. <https://doi.org/10.1016/bs.hefam.2023.01.006>.

Hansen, Lars Peter. 1982 年. 「Large Sample Properties of Generalized Method of Moments Estimators」. *Econometrica* 50 (4): 1029–54. <https://doi.org/10.2307/1912775>.

Hofferth, Sandra L., と John F. Sandberg. 2001 年. 「How American Children Spend Their Time」. *Journal Of Marriage And The Family* 63 (2): 295–308. <https://doi.org/10.1111/j.1741-3737.2001.00295.x>.

Kopecky, Karen A., と Richard M. H. Suen. 2010 年. 「Finite State Markov-Chain Approximations to Highly Persistent Processes」. *Review of Economic Dynamics* 13 (3): 701–14. <https://doi.org/10.1016/j.red.2010.02.002>.

Kuznets, Simon. 1957 年. 「Quantitative Aspects of the Economic Growth of Nations: II. Industrial Distribution of National Product and Labor Force」. *Economic Development and Cultural Change* 5 (S4): 1–111. <https://doi.org/10.1086/449740>.

Lebergott, Stanley. 1964 年. *Manpower in Economic Growth; the American Record Since 1800*. New York, McGraw-Hill.

Lise, Jeremy, と Ken Yamada. 2019 年. 「Household Sharing and Commitment: Evidence from Panel Data on Individual Expenditures and Time Use」. *Review of Economic Studies* 86 (5): 2184–219. <https://doi.org/10.1093/restud/rdy066>.

Liu, Haoming. 2015 年. 「The Quantity–Quality Fertility–Education Trade-Off」. *IZA World of Labor*, 1–10. <https://doi.org/10.15185/izawol.143>.

Ma, Eunseong. 2024 年. *The 40-Hour Work Week*. {{SSRN Scholarly Paper}} No. 4697593. Social Science Research Network. <https://doi.org/10.2139/ssrn.4697593>.

Mazzocco, Maurizio. 2007 年. 「Household Intertemporal Behaviour: A Collective Characterization and a Test of Commitment」. *Review of Economic Studies* 74 (3): 857–95. <https://doi.org/10.1111/j.1467-937X.2007.00447.x>.

McCall, J. J. 1970 年. 「Economics of Information and Job Search」. *The Quarterly Journal of Economics* 84 (1): 113–26. <https://doi.org/10.2307/1879403>.

McGrattan, Ellen R., Richard Rogerson, と Randall Wright. 1997 年. 「An Equilibrium Model of the Business Cycle with Household Production and Fiscal Policy」. *International Economic Review* 38 (2): 267–90. <https://doi.org/10.2307/2527375>.

Newey, Whitney K., と Daniel McFadden. 1994 年. 「Chapter 36 Large Sample Estimation and Hypothesis Testing」. *Handbook of Econometrics*, vol. 4. Elsevier. [https://doi.org/10.1016/S1573-4412\(05\)80005-4](https://doi.org/10.1016/S1573-4412(05)80005-4).

Reynoso, Ana. 2024 年. 「The Impact of Divorce Laws on the Equilibrium in the Marriage Market」. *Journal of Political Economy* 132 (12): 4155–204. <https://doi.org/10.1086/732532>.

Rothschild, Michael, と Joseph E Stiglitz. 1970 年. 「Increasing Risk: I. A Definition」. *Journal of Economic Theory* 2 (3): 225–43. [https://doi.org/10.1016/0022-0531\(70\)90038-4](https://doi.org/10.1016/0022-0531(70)90038-4).

Rouwenhorst, K. Geert. 1995 年. 「Asset Pricing Implications of Equilibrium Business Cycle Models」. *Frontiers of Business Cycle Research*, 編集者: Thomas F. Cooley. Princeton University Press. <https://doi.org/10.2307/j.ctv14163jx.16>.

- Shimer, Robert, と Lones Smith. 2000 年. 「Assortative Matching and Search」. *Econometrica* 68 (2): 343–69. <https://doi.org/10.1111/1468-0262.00112>.
- Strassen, V. 1965 年. 「The Existence of Probability Measures with Given Marginals」. *Annals of Mathematical Statistics* 36 (2): 423–39. <https://doi.org/10.1214/aoms/1177700153>.
- Webbink, Ellen, Jeroen Smits, と Eelke De Jong. 2012 年. 「Hidden Child Labor: Determinants of Housework and Family Business Work of Children in 16 Developing Countries」. *World Development* 40 (3): 631–42. <https://doi.org/10.1016/j.worlddev.2011.07.005>.
- Williamson, Jeffrey G. 1995 年. 「The Evolution of Global Labor Markets Since 1830: Background Evidence and Hypotheses」. *Explorations in Economic History* 32 (2): 141–96. <https://doi.org/10.1006/exeh.1995.1006>.
- Yanagimoto, Kazuharu. 2026 年 a. *Barriers to Gender Convergence: The Interactive Effects of Job Inflexibility and Social Norms*. arXiv:2603.20817. arXiv. <https://doi.org/10.48550/arXiv.2603.20817>.
- Yanagimoto, Kazuharu. 2026 年 b. *Marriage and Divorce in Continuous Time*. arXiv:2602.19798. arXiv. <https://doi.org/10.48550/arXiv.2602.19798>.
- Young, Eric R. 2010 年. 「Solving the Incomplete Markets Model with Aggregate Uncertainty Using the Krusell–Smith Algorithm and Non-Stochastic Simulations」. *Journal of Economic Dynamics & Control* 34 (1): 36–41. <https://doi.org/10.1016/j.jedc.2008.11.010>.